分类号_____ 密级_____
UDC _____ 编号_____



云南师範大學
YUNNAN NORMAL UNIVERSITY

专业硕士研究生
学位论文

论文题目：基于双向 Mamba 的课堂语音增强算法及轻量化应用研究

英文题目：**Research on Classroom Speech Enhancement Algorithm Based on Bidirectional Mamba and Lightweight Applications**

学　　院　民族教育信息化实验室

专业学位类别　电子信息

专业学位领域　计算机技术

研究生 姓 名　崔自渊　学 号　2324410003

导 师 姓 名　周菊香　职 称　教授

2026 年 5 月 15 日

独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

学位论文作者签名：

年　月　日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权云南师范大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

学位论文作者签名：　　指导教师签名：

年　月　日　　年　月　日

摘要

课堂实录数据真实记录了教学过程中的师生互动与课堂活动，是数字化教学环境中宝贵的第一手资料，为开展人工智能技术支持下的课堂话语分析等教育教学研究提供重要基础。然而，实录课堂环境中普遍存在混响效应强、背景噪声复杂、信噪比偏低等问题严重影响了音频质量，从而导致后续语音识别、转录文本等任务的准确性降低。尽管基于深度学习的语音增强技术取得了显著进展，能一定程度上提高音频质量，但现有方法在实录课堂场景中仍面临长时依赖建模能力不足、计算复杂度高等挑战，特别是在低资源场景中难以满足实际应用需求。为此，本文开展了基于 Mamba 架构的课堂语音增强算法改进及轻量化应用研究，通过引入具备线性计算复杂度和长序列建模优势的 Mamba 架构，围绕实录课堂语音数据构建、双向上下文建模能力提升以及轻量化网络设计等方面，对现有深度学习语音增强方法进行针对性改进，以进一步提升真实环境下课堂语音的增强性能与系统部署效率。具体研究内容如下：

（1）实录课堂教师语音增强语料库构建。针对现有语音增强研究中缺乏面向中文实录课堂场景专用数据、且通用语音或会议等场景数据难以真实反映课堂声学特性的不足，本研究构建了实录课堂教师语音增强语料库。与其他应用场景相比，课堂语音通常具有远场采集、混响效应显著、背景噪声来源复杂且时变性强等特点，直接影响语音增强模型的训练效果与实际应用性能。基于上述特性，干净语音采集自多位中学教师在语文、数学两门学科中的真实授课录音，噪音语料来源于真实课堂环境中的学生讨论声、课桌椅移动声、空调运转声等典型背景噪声，并通过响度归一化后按不同信噪比范围进行混合，生成带噪语音数据，以模拟真实课堂的复杂声学条件，为后续课堂语音增强模型的针对性训练与性能评估提供数据基础。

（2）基于外部双向 Mamba 的课堂语音增强方法。针对实录课堂场景中语音时序跨度长、混响效应显著且背景噪声复杂多变，现有语音增强方法在长时序上下文建模和全局依赖关系建模能力受限的问题，本文提出一种基于全频带外部双向 Mamba 的时频语音增强方法。该方法通过外部双向 Mamba 模块，对语音序列的双向上下文信息进行建模，在保持线性计算复杂度的同时有效建模课堂语音中的全局时序依赖关系。同时，设计了 Inception 深度卷积模块，通过

将大卷积核分解为多分支并行卷积，在保证增强性能的同时提升计算效率。模型整体采用时频域编解码架构与幅度—相位并行解码策略，并结合感知对比度拉伸技术，以提升复杂课堂环境下的语音感知质量。实验结果表明，该方法在抑制课堂背景噪声和保持语音自然度方面，相比 MP-SENet、Mamba-SEUNet 等当前语音增强的主流模型表现出色。

（3）基于双路径 Mamba+的轻量化课堂语音增强方法。为了进一步解决在计算资源受限情况模型难以部署等实际应用问题，本研究提出一种子频带双路径 Mamba+的时频语音增强方法。该方法在前述工作基础上引入遗忘门机制，通过选择性融合新特征与历史特征，并采用双路径建模策略，在时间维度使用单向 Mamba+保证因果性，在频率维度使用双向 Mamba+充分捕获频谱结构。同时，为进一步改善传统卷积对频谱特征分布特性建模不足的问题，通过引入子频带卷积，充分利用频谱的局部相关性和全局结构特征，在保持轻量级设计的同时提升模型的特征提取能力。实验结果表明，该方法能够在基线模型参数量缩减约 54 倍的情况下依然保持良好的语音增强效果。

（4）实录课堂语音增强与转录系统设计与开发。为了验证所提方法的实际应用效果，本文基于双路径 Mamba+的轻量化方法，设计并开发了用于实录课堂语音数据预处理和分析的应用系统。该系统采用 PyTorch 实现核心算法，基于 Vue+FastAPI+MySQL 架构，主要实现了课堂音视频上传、语音增强、语音识别、文本转录及可视化等核心功能。用户上传课堂教学音视频后，系统可自动完成语音增强处理，并将教师讲授内容转录为文本。该系统为课堂笔记自动生成、课堂教学话语分析、智能教学评价等智能教育领域多应用场景提供技术支持。

关键字：课堂智能分析；语音增强；Mamba；模型轻量化；

Abstract

The classroom record data truly records the teacher-student interaction and classroom activities in the teaching process. It is a valuable first-hand information in the digital teaching environment and provides an important basis for the development of education and teaching research such as classroom discourse analysis supported by artificial intelligence technology. However, there are many problems in the recording classroom environment, such as strong reverberation effect, complex background noise and low signal-to-noise ratio, which seriously affect the audio quality, resulting in reduced accuracy of subsequent speech recognition, transcription text and other tasks. Although the speech enhancement technology based on deep learning has made significant progress and can improve the audio quality to a certain extent, the existing methods still face the challenges of insufficient long-term dependence modeling ability and high computational complexity in the recording classroom scene, especially in the low-resource scene. It is difficult to meet the actual application requirements. Therefore, this paper carries out the research on the improvement of classroom speech enhancement algorithm and lightweight application based on Mamba architecture. By introducing Mamba architecture with linear computational complexity and long sequence modeling advantages, the existing deep learning speech enhancement methods are improved in order to further improve the enhancement performance and system deployment efficiency of classroom speech in real environment around the construction of real classroom speech data, the improvement of bidirectional context modeling ability and the design of lightweight network. The specific research contents are as follows :

(1) Record classroom teacher speech enhancement corpus construction. In view of the lack of specific data for Chinese classroom scenes in the existing speech enhancement research, and the fact that scene data such as general speech or meetings are difficult to truly reflect the acoustic characteristics of the classroom, this study constructs a speech enhancement corpus for recording classroom teachers. Compared with other application scenarios, classroom speech usually has the characteristics of far-field acquisition, significant reverberation effect, complex and time-varying

background noise sources, which directly affects the training effect and practical application performance of speech enhancement models. Based on the above characteristics, the clean speech is collected from the real teaching recordings of many middle school teachers in the two subjects of Chinese and mathematics. The noise corpus is derived from the typical background noise such as student discussion sound, desk and chair moving sound, air conditioning running sound and so on in the real classroom environment. After the loudness is normalized, it is mixed according to different signal-to-noise ratio ranges to generate noisy speech data to simulate the complex acoustic conditions of the real classroom and provide data basis for the targeted training and performance evaluation of the subsequent classroom speech enhancement model.

(2) Classroom speech enhancement method based on external bidirectional Mamba. Aiming at the problem that the existing speech enhancement methods are limited in long-term context modeling and global dependency modeling due to the long time series span, significant reverberation effect and complex background noise in the recording classroom scene, this paper proposes a time-frequency speech enhancement method based on full-band external bidirectional Mamba. This method models the bidirectional context information of the speech sequence through the external bidirectional Mamba module, and effectively models the global temporal dependency in the classroom speech while maintaining the linear computational complexity. At the same time, the Inception deep convolution module is designed. By decomposing the large convolution kernel into multi-branch parallel convolution, the computational efficiency is improved while ensuring enhanced performance. The model adopts the time-frequency domain codec architecture and the amplitude-phase parallel decoding strategy, and combines the perceptual contrast stretching technology to improve the speech perception quality in the complex classroom environment. The experimental results show that this method performs better than the current mainstream models of speech enhancement such as MP-SENet and Mamba-SEUNet in suppressing classroom background noise and maintaining speech naturalness.

(3) A lightweight classroom speech enhancement method based on dual-path

Mamba+. In order to further solve the practical application problems such as the difficulty of model deployment in the case of limited computing resources, this study proposes a sub-band dual-path Mamba+ time-frequency speech enhancement method. This method introduces the forgetting gate mechanism on the basis of the above work, selectively fuses new features and historical features, and adopts a dual-path modeling strategy. One-way Mamba + is used in the time dimension to ensure causality, and two-way Mamba+ is used in the frequency dimension to fully capture the spectrum structure. At the same time, in order to further improve the problem of insufficient modeling of spectral feature distribution characteristics by traditional convolution, the sub-band convolution is introduced to make full use of the local correlation and global structural characteristics of the spectrum, so as to improve the feature extraction ability of the model while maintaining the lightweight design. The experimental results show that this method can still maintain good speech enhancement effect when the number of baseline model parameters is reduced by about 54 times.

(4) The design and development of classroom speech enhancement and transcription system. In order to verify the practical application effect of the proposed method, based on the lightweight method of dual-path Mamba +, this paper designs and develops an application system for the preprocessing and analysis of recorded classroom voice data. The system uses PyTorch to implement the core algorithm. Based on Vue + FastAPI + MySQL architecture, it mainly implements core functions such as classroom audio and video upload, speech enhancement, speech recognition, text transcription and visualization. After users upload classroom teaching audio and video, the system can automatically complete speech enhancement processing and transcribe the teacher 's teaching content into text. The system provides technical support for multiple application scenarios in the field of intelligent education, such as automatic generation of classroom notes, classroom teaching discourse analysis, and intelligent teaching evaluation.

Keywords: Classroom Intelligent Analysis; Speech enhancement; Mamba; Model Lightweighting

目录

摘要 I

ABSTRACT III

目录 VI

第 1 章 绪论 1

1.1 研究背景与意义 1

1.2 国内外研究现状 2

1.2.1 语音增强技术发展现状 2

1.2.2 语音增强轻量化研究现状 5

1.2.3 实录课堂语音增强轻量化的挑战及应用 5

1.3 关键技术问题分析 7

1.4 本文研究内容 7

1.5 论文组织结构安排 9

第 2 章 相关理论和技术基础 11

2.1 语音增强理论基础 11

2.1.1 语音信号概述 11

2.1.2 噪音信号概述 11

2.1.3 语音增强的基本原理与框架 12

2.2 基于深度神经网络的语音增强模型 16

2.2.1 基于卷积神经网络的语音增强算法 16

2.2.2 基于循环神经网络的语音增强算法 17

2.2.3 基于 Transformer 的语音增强算法 20

2.2.4 基于 Mamba 的语音增强算法 22

2.3 语音增强公共数据集 23

2.4 语音增强自建数据集 24
2.4.1 实录课堂教师语音增强语料库构建 25
2.5 评价指标 27
2.6 本章小结 29
第 3 章 基于外部双向 MAMBA 的课堂语音增强方法 30
3.1 引言 30
3.2 模型设计 31
3.2.1 模型概述 31
3.2.2 编码器 31
3.2.3 时频外部双向 Mamba 模块 33
3.2.4 幅度掩码解码器和相位解码器 34
3.2.5 感知度对比拉伸 34
3.2.6 损失函数 35
3.3 实验与分析 36
3.3.1 实验环境与设置 36
3.3.2 评价指标 37
3.3.3 对比实验 37
3.3.4 消融实验 40
3.4 本章小结 42
第 4 章 基于双路径 MAMBA+的轻量化课堂语音增强方法 43
4.1 引言 43
4.2 模型设计 43
4.2.1 模型概述 43
4.2.2 子频带编码器 44
4.2.3 时频双路径 Mamba+模块 45
4.2.4 子频带幅度掩码解码器 50
4.2.5 Fast Griffin-Lim 算法 51

4.2.6 损失函数 52
4.3 实验与分析 54
4.3.1 实验设置 54
4.3.2 对比实验 54
4.3.3 消融实验 58
4.4 本章小结 59
第 5 章 实录课堂语音增强与转录系统开发及应用 61
5.1 需求分析 61
5.2 系统设计 62
5.2.1 技术难点 62
5.2.2 系统功能模块设计 63
5.2.3 系统流程图设计 65
5.3 功能实现及界面展示 66
5.3.1 用户登录模块 66
5.3.2 教师语音增强 67
5.3.3 教师语音转录 69
5.4 本章小结 70
第 6 章 总结与展望 71
6.1 总结 71
6.2 展望 72
参考文献 74
攻读学位期间发表的学术论文和研究成果 82
致谢 83

第 1 章 绪论

1.1 研究背景与意义

人工智能与教育深度融合已成为教育强国建设的核心战略，驱动教育进入智能化、数字化转型的关键阶段。《教育强国建设规划纲要（2024—2035 年）》[1]、《关于加快推进教育数字化的意见》[2]等最新政策明确提出，要构建“人工智能+教育”应用新范式、推动人工智能融入教学全流程，国家智慧教育平台 2.0 智能版全面落地，智慧课堂、混合式教学成为常态化形态[3]。在此背景下，基于课堂教学数据的智能分析成为研究热点，而基于语音识别的课堂言语分析是量化教学行为、实现精准教学与智能评价的核心手段。然而，真实课堂环境中，学生低语、设备噪声、混响等多重干扰导致实录语音信噪比低、识别准确率大幅下降，严重制约课堂语音转录与话语分析的有效性。语音增强技术作为音频信号处理核心，可有效抑制噪声、提升语音清晰度，为课堂语音分析提供高质量数据基础。更重要的是，智慧课堂对实时语音处理提出低延迟、强鲁棒性要求，现有算法难以适配复杂课堂声学场景，因此面向真实课堂的语音增强技术研究，既是突破语音识别瓶颈的关键，也是推动智慧课堂从数据采集向智能分析升级、提升混合式教学体验的重要支撑，具有重要理论与实践价值

课堂属于教育主阵地，留存了丰富的教学活动记录，也积累了宝贵的教育资源。在信息化教学环境支撑下，借助各类视频终端设备所采集的实录课堂数据，可以如实呈现师生互动、课堂讨论以及教学过程的本来面貌，这些材料对教育研究、教学评估、师资培养和学习资源建设都具有重要价值，属于珍贵的一手资料[4]。当前处于教育大数据阶段，实录课堂数据在分析教学规律、优化教学方法、提升教学质量方面扮演着关键数据源的角色已有研究证实，深入分析实录课堂能够发现教学过程中隐藏的内在规律，这些发现可为开展个性化教学、实施智能化评估以及进行精准化干预提供科学支撑[5]。不过，实录课堂环境与专业录音室相比，面临着不少技术层面的难题已有研究提到，课堂环境的声学特征比较复杂，具体表现为背景噪声种类多（例如空调运转声、投影仪风扇声、走廊传来的噪声等）、突发声音难以预料（比如椅子挪动声、文具掉落声、学生私下交谈声等）、多种声源同时存在（教师讲课声、学生发言声、设备操作

声等），以及声学条件经常变化（不同教室的混响特点、座位排列方式、人员密度变化等）[6]。这些因素让实录课堂的音频质量往往出现不稳定，直接影响了后续的语音识别、内容分析、情感计算等智能化应用效果实录课堂的持续时间比较长，内容也比较复杂，这对算法的稳定性、运行效率和适应能力都提出了更高的技术标准。

教学内容要顺利传达，离不开高质量的课堂音频，语音增强技术能让音频质量变好、语音更清晰，这样学习体验有保障，也给教学研讨和师资培训提供了标准化的素材[7]。但现有深度学习语音增强模型参数量大、计算复杂度高，我国一些基层学校和教育机构的硬件配置比较低，很难适配这类模型，开展轻量化语音增强算法研究，在保持增强效果的同时降低模型参数和计算量，有利于该技术在教育领域普及，也能推进教育资源数字化建设。

1.2 国内外研究现状

1.2.1 语音增强技术发展现状

语音增强技术处于语音信号处理与人工智能的交叉地带，属于该领域的关键技术，回顾其发展历程，能看到技术从传统信号处理理论过渡到现代深度学习框架的完整变化。这项技术以噪声抑制和信号恢复为核心任务，在推进数字信号处理、机器学习与声学建模三者融合的过程中，完成了从经典谱减算法到智能神经网络的技术升级，并在深度学习浪潮推动下，实现了从手工设计特征向数据驱动学习模式的根本转换。这一技术演进路径体现了信号处理理论、计算机科学等多学科协同取得的丰硕成果，也体现出社会对高质量音频体验有着强烈需求。自 20 世纪 70 年代初步建立理论体系以来，该技术经历多轮重大更新，从早期频谱减法发展到当今基于深度神经网络的端到端增强模型，在降噪效果、计算效率和环境适应性上都实现了质的提升[8]。深度学习和人工智能技术快速发展，语音增强在通信、教育、娱乐等多种应用场景中性能持续完善，已逐步成为智能音频处理和多媒体应用的核心支撑技术。

经典信号处理理论是传统语音增强方法的基础，这类方法借助数学建模与统计分析完成噪声抑制和语音还原该阶段的研究工作以语音信号和噪声特性的先验认知为前提，借助特定滤波器设计或变换域处理完成增强任务谱减法是最早获得广泛应用的语音增强技术，其提出者为 Boll 于 1979 年提出[9]，这一方法

先估计噪声功率谱再做减法以获得清晰语音，计算量比较小，能够方便地实现实时处理维纳滤波法于 20 世纪 80 年代初进入语音增强领域，按照最小均方误差准则构建最优线性滤波器[10]。之后，自适应滤波法在 80 年代中期开始投入使用，借助实时调整滤波器参数来匹配时变噪声环境，主要涵盖最小均方（Least Mean Square，LMS）算法、归一化最小均方（Normalized Least Mean Square，NLMS）算法以及递推最小二乘（Recursive Least Square，RLS）算法等[11]。进入 90 年代后，子空间方法把含噪语音信号拆分为信号子空间和噪声子空间，利用投影操作抑制噪声，代表性方法有主成分分析（Principal Component Analysis，PCA）与奇异值分解（Singular Value Decomposition，SVD）等[12]。小波变换法在 90 年代中期出现，借助多分辨率分析特性在不同时频尺度下处理语音信号[13]。这些传统方法虽然在特定条件下有一定效果，但遇到复杂多变的噪声环境时，通常需要准确估计语音和噪声的统计特性，在非平稳噪声情况下表现存在不足[14]。

深度学习技术的出现彻底改变了语音增强领域的研究方式。过去的研究主要依赖手工设计的特征，而现在数据驱动的方法能够自动学习从含噪语音到清晰语音的复杂映射，适应各种噪声环境和声学条件。语音增强算法分类框架图如图 1.1 所示。

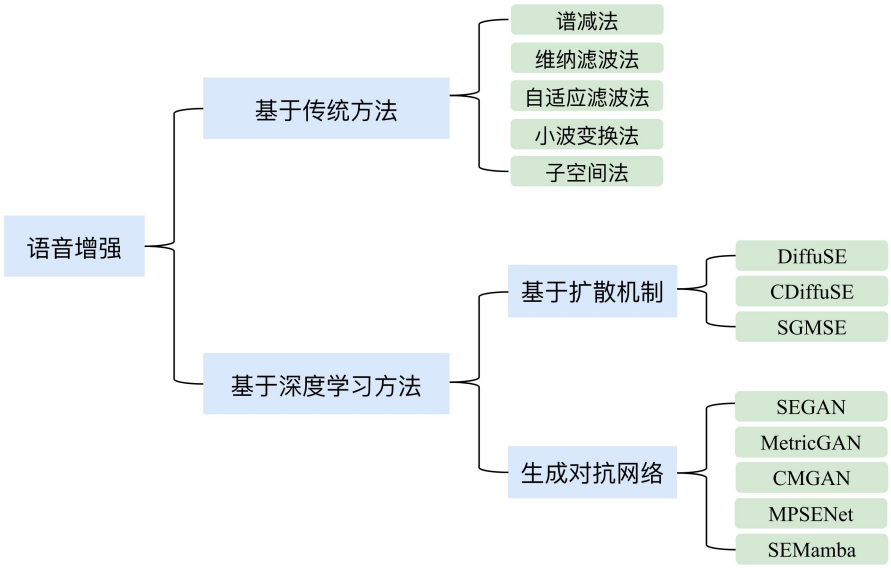


图 1.1 语音增强算法分类框架图

深度神经网络（Deep Neural Network，DNN）[15] 是深度学习在语音增强领域的早期应用，实现了端到端的语音增强处理，这类方法把多层感知器堆叠起

来，学习复杂的非线性映射关系，自动提取语音信号的高级特征，DNN 不用像传统方法那样做繁琐的特征工程, 用大量数据训练后效果比传统方法好, 在 DNN 基础上，卷积神经网络（Convolutional Neural Network，CNN）的引入进一步提升了语音增强的性能[15]。CNN 充分利用了语音信号在频域上的局部关联和平移不变特点，通过卷积和池化操作，CNN 能够有效提取语音频谱的局部模式和纹理特征，这种结构很适合处理语音的二维时频表示，比如短时傅里叶变换频谱图，在频域语音增强上表现很好，为了更好建模语音的时间序列特性，RNN（Recurrent Neural Network, RNN) 及其改进变体被广泛应用于语音增强任务[16]。长短期记忆网络（Long Short-Term Memory，LSTM）和门控循环单元（Gated Recurrent Unit，GRU）通过引入门控机制，有效解决了传统 RNN，在处理长序列时，所面临的梯度消失问题[17]。

循环神经网络在持续演进，注意力机制的加入让语音增强模型具备了自适应挑选特征的能力。模型在学习过程中会识别各个时频区域的重要程度，降低噪声区域的干扰。这让模型在复杂噪声条件下的稳定性和增强质量有了明显提升。在注意力机制进一步发展的基础上，Transformer 架构依靠自注意力机制，在语音增强工作中表现出很好的性能。自注意力机制可以建立序列中任意两点之间的直接联系，捕捉长时间跨度的依赖关系。跟循环神经网络那种按顺序处理的方式比起来，Transformer 可开展并行计算，效率有比较大的提升[18]。

近年来，生成模型技术快速发展，扩散模型（Diffusion Model，DM）作为新兴的生成模型范式，在语音增强领域展现出巨大潜力[19]。通过逐步去噪的生成过程，DM 能够产生高质量的语音信号，训练过程也比较稳定。与此同时，状态空间模型（State Space Model，SSM），为处理长序列语音信号提供了新的解决方案[20]。特别是 Mamba，通过选择性状态空间机制，实现了线性计算复杂度，而且保持了较好的长距离依赖建模能力。这一特点使其在处理长时间语音序列时相比 Transformer 具有更高的计算效率，为语音增强技术的后续发展指出了新的发展方向。

深度学习在语音增强领域确实取得了比较明显的进展，不过这些方法在实际应用中通常需要消耗大量计算资源和训练数据，模型结构往往也比较复杂，部署时经常面临计算效率不够高和资源受限的问题，开展轻量化语音增强技术研究就显得十分必要。

1.2.2 语音增强轻量化研究现状

近期研究聚焦于探索轻量化语音增强方法，旨在降低计算需求的同时实现与先进模型相当的性能。一种直接的解决方案是采用剪枝和量化等技术来压缩性能优良的模型。另一类方法是高效模型设计，例如 TRU-Net 通过一维卷积解耦频率与时间轴计算，并用深度卷积替代标准卷积操作，并行 GRU 与优化跳跃连接同样可用于设计微型增强模型。第三类方案则是将轻量化模型与自适应后处理相结合[21]。以 RNNoise[22]和 PercepNet[23]为例，它们先对低分辨率频谱包络进行粗略增强，再运用音高梳状滤波器精细抑制音高谐波间的噪声。基于 PercepNet 改进的 DeepFilterNet[24]首先采用更强大的 U-Net 类深度神经网络增强频谱包络，继而运用深度滤波进一步强化周期性成分。

除了上述的频域方法外，时域语音分离技术也面临着独特的挑战。时域分离系统通常需要处理由大量时间步组成的输入序列，这给极长序列的建模带来了挑战。传统循环神经网络因优化困难而在建模此类长序列时表现欠佳。另一方面，当一维卷积神经网络的感受野小于序列长度时，无法实现语句级的序列建模。为解决这一问题，DPRNN 通过在深度结构中组织循环神经网络层，实现了对超长序列的有效建模[25]。DPRNN 将长序列输入划分为较小的块，并迭代执行块内和块间操作，使得每次操作的输入长度可与原始序列长度的平方根成正比，从而显著降低了计算复杂度。DPCRN 模型通过用 DPRNN 模块替代 CRN 中的循环神经网络，有效提升了建模能力[26]。其中，块内 RNN 用于建模单帧内的频谱模式，块间 RNN 则用于建模连续帧之间的时序依赖关系。在此基础上，GTCRN 模型通过分组策略有效简化了 DPCRN 的网络结构，并引入子带特征提取模块与时序递归注意力模块进一步提升性能，在实现更优增强效果的同时显著降低了计算资源消耗[27]。

1.2.3 实录课堂语音增强轻量化的挑战及应用

上述轻量化方法虽然在通用场景下取得了良好效果，但实录课堂作为教育信息化建设的重要组成部分，其独特的声学环境和应用需求使得这些方法难以直接满足实际要求。随着慕课、翻转课堂等在线教育模式的发展，课堂录制已成为知识传播的核心环节，录制音频的质量直接影响在线学习效果[28]。

实录课堂的声学环境呈现出显著的复杂性。与单说话人、相对安静的场景不同，课堂中存在多种噪声源的混合，例如，环境噪声（空调、走廊、室外交

通）持续存在，设备噪声（投影仪风扇、扩音设备、录制设备底噪）伴随教学活动，学生活动噪声（讨论、翻书、桌椅移动）间歇出现，瞬态冲击噪声（关门、物品掉落）不定期干扰。这种多源异质噪声的叠加使课堂声学环境呈现出强非平稳性和高度不确定性[29]。此外，课堂空间通常具有较长的混响时间，尤其在大型阶梯教室中，混响效应会显著降低语音清晰度[30]。

现有技术在应对实录课堂场景时面临诸多困难。问题在于语音增强模型在特征建模上还存在局限，当前基于 Mamba 架构的语音增强模型虽然能够高效处理长序列语音信号，但在特征建模方面仍存在明显不足。首先，Mamba 采用单向因果计算方式，只能利用历史信息进行处理，无法同时获取未来时刻的上下文信息，在处理长语音内容时，完整音频片段的双向时序依赖关系无法被充分利用。其次，在多尺度特征提取方面，传统方法通常采用大卷积核来扩大感受野，来捕捉更丰富的时频特征。但这种方式会带来很高的内存开销，在资源有限的设备上容易形成性能瓶颈。同时，单一尺度的卷积核很难有效捕捉语音信号在不同时间与频率尺度上的复杂特征模式，这也限制了模型整体的特征表达能力；另一问题在于轻量化模型在参数效率和长序列建模上表现不够好。虽然语音增强性能已大幅提升，但深度学习模型普遍存在参数量大、计算复杂度高的问题，这严重限制了其在资源受限设备上的部署。实录课堂场景的特殊性让这一挑战更加突出：课堂录制设备通常为边缘端设备，计算能力、存储空间和功耗预算都比较有限；课堂音频持续时间长，要求模型具备稳定的长时处理能力和较低的计算资源消耗。现有轻量化方法主要面临三个方面困境：第一，参数压缩技术（如剪枝、量化），虽能减小模型规模，但往往以牺牲性能为代价；第二，传统卷积网络在训练时，通常需要设计复杂的分支结构来提升特征学习效果，但这些分支在推理阶段会产生额外的计算量与内存消耗；第三，现有紧凑模型在处理长序列时，对历史信息的保留能力不足，传统 Mamba 块的门控机制会让模型更偏向于保留近期信息，容易忽略远期的历史特征。此外，紧凑网络由于参数有限，在训练后期常常陷入性能停滞，难以通过调整超参数获得显著提升。

综上所述，针对实录课堂场景的轻量化语音增强研究，需要在多个维度做好平衡。既要抵御多种复杂噪声与混响影响，又要在资源有限的设备上高效运行；既要保证教师语音清晰保真，还要在长时间连续处理中保持效果稳定。该

领域目前尚未获得足够重视，本文专门面向实录课堂场景研究轻量化语音增强算法，这类工作既有较高理论价值，也有较高实用价值。

1.3 关键技术问题分析

通过上述分析，当前实录课堂语音增强技术应用仍面临以下关键挑战：

（1）实录课堂专用数据资源匮乏

现有公开数据集主要面向英文通用场景，噪声以人工合成为主，无法真实反映中文课堂环境中混响效应强、背景噪声复杂多变、远场采集信噪比低等声学特性，制约了面向课堂场景的语音增强模型的针对性训练与客观评估。

（2）长时双向上下文建模能力受限

实录课堂语音时序跨度长，现有 Transformer 类方法受制于二次计算复杂度；现有 Mamba 类方法虽具备线性复杂度优势，但普遍采用单向因果建模，在离线处理场景中未能充分利用未来帧信息，全局双向依赖关系建模能力不足。

（3）模型参数量大导致低资源场景部署困难

现有高性能语音增强模型参数规模多在百万级以上，计算开销高，难以在硬件资源受限的基层教育机构及便携录制设备上实际落地，阻碍了语音增强技术在教育领域的广泛应用。

1.4 本文研究内容

针对上述存在的问题，本文通过聚焦基于双向 Mamba 的课堂语音增强研究与系统构建，进一步提高了语音增强的性能，并将其应用于真实课堂教学中。具体研究内容包括以下几个方面：

（1）构建实录课堂教师教学语音增强语料库

由于目前针对课堂教学场景的语音增强公开数据集较为稀缺，本研究通过线下实录采集的方式，构建了实录课堂教师教学语音增强语料库，以支持真实课堂环境下的语音增强模型训练与评估。该语料库包含干净语音与噪音两部分：干净语音来源于 80 余位教师的真实授课录音，涵盖语文、数学两门学科，总时长达 100 小时，采样率为 16kHz，采样精度为 16bit，每条音频均为单说话人场景；噪音语料库采集自真实课堂环境，包含学生讨论声、课桌椅移动声、翻书

写字声、走廊脚步声、空调风扇运转声、投影仪设备噪音、窗外环境噪音等多种典型课堂背景噪声。通过将干净语音与噪音按不同信噪比混合，生成模拟真实课堂声学环境的带噪语音数据。语料库按照 7：1：2 的比例划分为训练集、验证集和测试集，为课堂教学场景下的语音增强、降噪等任务的模型训练与微调提供数据支持。

（2）基于外部双向 Mamba 的课堂语音增强方法

针对现有语音增强技术在实录课堂应用中存在的不足，本研究提出了一种基于外部双向 Mamba 的实录课堂教师教学语音增强方法。传统语音增强技术在复杂课堂场景中常因学生讨论声、课桌椅移动声、设备噪音等多种背景噪声干扰，以及单向因果计算仅利用历史信息等因素导致增强效果降低，难以有效保持教师授课语音的自然度和清晰度。为解决这些问题，本研究提出一种基于外部双向 Mamba 的实录课堂语音增强方法。通过设计外部双向 Mamba 模块，同时利用历史和未来语音信息进行双向建模，捕获课堂语音信号中的全局依赖关系，克服了传统 Mamba 架构单向处理的局限性。此外，针对大卷积核在语音增强任务中造成的高内存访问开销问题，本研究设计了 Inception 深度卷积模块，通过将大卷积核分解为多分支并行卷积和恒等映射，在保持模型性能的同时显著提升计算效率和特征提取能力。双向建模能力使模型能够更精确地捕获完整语音信号的上下文信息，减少课堂噪声干扰，提升精度；同时利用时频域编解码架构和幅度-相位并行解码策略，结合课堂语音信号的时频特性，增强模型对复杂课堂环境的适应能力。在公共数据集和自建数据集上的实验结果表明，提出的方法在多个客观评价指标上优于现有语音增强方法，尤其在抑制多种课堂背景噪声和保持语音自然度方面取得显著提升。

（3）基于双路径 Mamba+的轻量化课堂语音增强方法

针对实录课堂语音增强任务中计算资源受限、模型难以高效部署的挑战，本研究提出了一种基于双路径 Mamba+的轻量化实录课堂教师教学语音增强方法。由于传统深度学习语音增强模型往往依赖大量参数和计算资源，在教室录播系统、移动采集设备等资源受限场景下难以实现高效部署，且复杂的网络结构严重限制了处理效率，无法满足课堂录制批量处理和低配置设备应用的实际需求。针对这些局限，本研究设计了一种融合双路径 Mamba+和子频带卷积的轻量化语音增强框架。该方法通过 Mamba+模块的遗忘门机制选择性地融合新特征与历史特征，并在频率维度采用双向 Mamba+模块以线性计算复杂度实现课堂语

音信号完整上下文依赖关系的捕获。同时，针对传统卷积对频谱特征分布特性建模不足的问题，引入子频带卷积机制将频谱特征重塑并划分为多个子频带分别进行处理，充分利用频谱的局部相关性和全局结构特征，在保持轻量级设计的同时提升了模型的特征提取能力。通过在公共数据集和自建语料库上的系统性实验验证，本文所提方法能够在复杂的实录课堂环境中有效实现语音增强，并可在低配置设备上高效运行。

（4）实录课堂语音增强与转录系统开发及应用

本文依托双路径 Mamba+轻量级课堂语音增强方法配合现有语音识别技术，完成了实录课堂语音增强与转录系统的搭建工作。在系统开发期间，算法到工程落地存在不少难点：将离线训练的深度学习模型适配到实际应用环境，在保证处理效率的前提下处理长时课堂视频，大规模音频文件管理的数据流转与存储机制，以及将语音增强与自动转录模块有效集成形成完整的处理流程等等。应对上述难点时，系统采用前后端分离架构，运用模型轻量化部署、异步任务处理、模块化设计等技术手段，达成了视频上传、语音增强到文本转录的端到端处理。

1.5 论文组织结构安排

论文架构共分为六个章节，具体内容安排如下：

第一章，绪论。本章详细分析了语音增强技术在各个领域中的应用及其发展趋势，概述了国内外实录课堂语音增强研究的现状及在教育领域的应用情况，并探讨了语音增强方法在实录课堂分析应用中的优势与挑战。

第二章，相关理论与技术基础。本章介绍了语音增强的基本理论，深入探讨了深度学习技术及其在语音增强中的应用。详细讲解了本研究中使用的公共数据集及构建的实录课堂教师语音增强语料库，最后介绍如何通过不同的评价指标来衡量语音增强模型的性能。

第三章，基于外部双向 Mamba 的实录课堂语音增强方法。本章提出了基于外部双向 Mamba 的实录课堂语音增强基准框架，详细描述了该框架的设计思路、实现步骤及其构建流程，并通过在公共数据集和自建语料库上的实验验证了该方法在实际应用中的可行性。

第四章，基于双路径 Mamba+的轻量化实录课堂语音增强方法。本章提出了一种改进的轻量化语音增强方法，该方法结合双路径 Mamba+模块和子频带卷积。具体来说，本章详细介绍了该方法的核心组成部分，通过在公共数据集和自建语料库上验证方法的有效性。

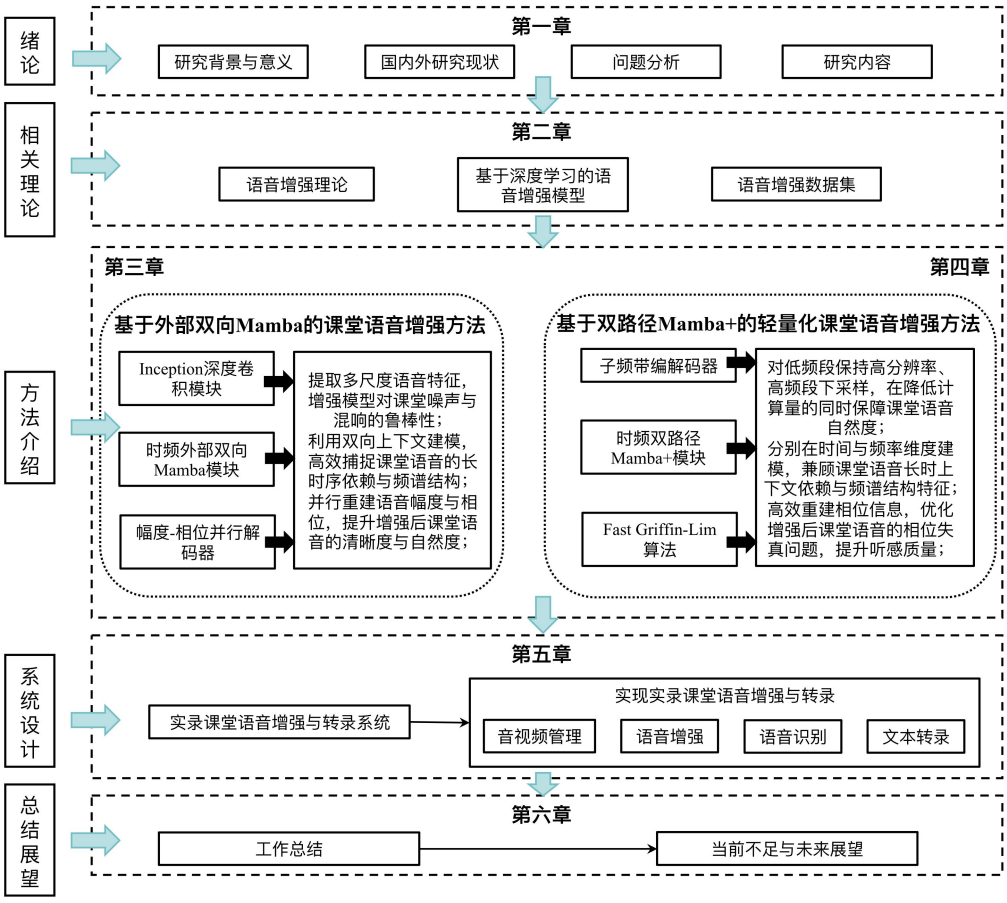


图 1.2 论文组织结构

第五章，实录课堂语音增强与转录系统设计与实现。本章基于前述的基于双路径 Mamba+的轻量级实录课堂语音增强方法，设计并开发了一个完整的实录课堂语音增强与转录系统。章节内容涵盖了需求分析、系统功能模块的设计、功能流程图的设计以及系统的实现过程。

第六章，总结与展望。本章对全文的研究内容进行了系统总结，回顾了本文在实录课堂语音增强领域的主要贡献和创新。

通过以上章节的详细介绍，本文从理论到实践、从算法到系统，全面探讨了基于双向 Mamba 的实录课堂语音增强研究，提出了一系列创新性的解决方案，并为语音增强技术在教学中的应用提供了有力支持。

第 2 章 相关理论和技术基础

本章主要介绍语音增强的相关理论及技术进行介绍。首先介绍语音增强的理论基础，其次介绍了基于深度神经网络的语音增强模型。最后介绍实验中使用的语音公开数据集及语音增强模型评价指标。

2.1 语音增强理论基础

2.1.1 语音信号概述

语音信号之所以呈现短时平稳的特点，是因为人在发声时声道、肌肉、肺等多个器官在配合工作。声带在呼吸、发声以及不发声这三种状态下功能表现各不相同，在发声状态时，声带会周期性地闭合，这种闭合让气流产生振动，进而生成声波信号。声道属于声学谐振腔体，其横截面积和形状发生改变时，声音的共振特性也会受到直接影响。口腔形状、舌头位置、唇部动作等生理因素与声道共振频率联系紧密，这些频率通过共振峰的形式表现出来。声带振动具有周期性，这种振动产生连续的声波信号，这些声波经过喉咙、口腔、鼻腔等共鸣腔体的调制作用，最终形成我们所听到的语音。区分不同说话人需要参考基音周期和基音频率这两个关键参数，它们体现了声带振动的频率特点和周期性规律。时变性、时频相关性以及非平稳特性等复杂特点存在于语音信号中，这些特点给语音处理和分析工作提供了充足的信息支撑[31]。

2.1.2 噪音信号概述

在语音增强这个研究方向上，噪声指的是那些跟目标语音混在一起、不需要的声音或者干扰信号。现实环境里噪声种类多、时空分布也复杂，如何有效抑制噪声来提高语音质量，是这个领域要解决的关键难题。按照噪声和原始信号的叠加形式来划分，噪声可以分成加性噪声和乘性噪声这两种类型。加性噪声在信号传输时跟原始信号能量相加，呈现的是原信号和噪声线性叠加的状态，在通信、音频处理这些应用场景里比较常见。乘性噪声跟原始信号能量成比例，一般是由信号失真或者系统非线性效应引起的，这类噪声的抑制和处理难度要大一些[32]。

本文重点放在加性噪声的研究和处理工作上。高斯白噪声、有色噪声、机

械噪声、电磁干扰噪声以及环境噪声，都是加性噪声中比较常见的类型，这些噪声在不同应用场景中，各类噪声对语音信号的影响程度不一样，频域能量分布特点也不同。风噪声的能量大多集中在低频段，具有低通特性；餐馆噪声的频谱分布则较为平坦，覆盖整个可听频率范围。噪声的存在使日常交流质量和舒适度下降，语音通信系统性能也降低，在军事通信、应急救援等关键领域还可能妨碍重要信息的准确传递，给系统可靠性和安全性造成威胁。

声学领域的基础内容包含对噪声产生机制、传播路径和接收端特性的研究。分析噪声信号一般从时域和频域两个维度入手，时域分析主要观察信号的瞬态与稳态表现，频域分析则用来呈现信号的频谱构成和能量分布状况。噪声信号具备低秩特点，在频域里可以用不多的基函数完成有效表达，该特点在噪声识别与处理环节具备理论层面的价值。

设计降噪算法，需要先对噪声分类，分析其特性，把瞬态与稳态噪声区分开，窄带与宽带噪声的识别同样重要，这是语音增强的基础工作，也是实现高质量处理的必要环节。噪声的相干性特点，对处理策略选择也有很大影响，这主要体现在噪声场类型上，相干与非相干条件下的处理方式存在差异，算法设计时必须考虑。在相干噪声场中，噪声与语音信号传播路径确定，算法可直接处理含噪语音，进入非相干噪声场后，噪声信号互不相干，处理时就得采用更复杂的方法。室内、车内等封闭空间构成混响环境，既给语音增强研究带来挑战性场景，在实际应用中也有重要价值，这类环境是检验算法性能的重要平台。

2.1.3 语音增强的基本原理与框架

语音增强是一种旨在从含噪、失真或降质的语音信号中恢复出清晰、高质量语音信号的信号处理技术。该技术的核心目标是在保持语音信号重要特征的同时，有效抑制或去除各种类型的噪声干扰，从而提升语音信号的清晰度、可懂度和整体感知质量。语音增强技术广泛应用于通信系统、助听设备、语音识别、视频会议等众多领域，是现代音频处理和人机交互系统的重要组成部分。

语音增强问题可以用数学模型来描述。最常见的是加性噪声模型，其中观测到的含噪语音信号可以表示为公式（2.1）：

$$y(t) = x(t) + n(t), \tag{2.1}$$

其中 $y(t)$ 表示含噪语音信号，$x(t)$ 表示原始清晰语音信号，$n(t)$ 表示加性噪声信

号。语音增强的目标就是根据观测到的 $y(t)$，估计出尽可能接近原始信号 $x(t)$ 的增强语音信号 $\hat{x}(t)$。

随着深度学习技术的发展，基于神经网络的语音增强方法已成为主流研究方向。深度学习语音增强系统通常采用端到端的处理框架，整个过程可以分为以下四个关键阶段：

（1）数据预处理阶段

原始的语音信号通常以时域波形的形式存在，但这种连续的一维信号并不适合直接输入到神经网络中进行处理。神经网络更擅长处理结构化、标准化的数据表示，因此需要将时域语音信号转换为更适合网络学习的格式。在这一阶段中，首先需要对原始语音信号施加预加重处理。由于语音信号的频谱具有随频率增加而衰减的特性（约以-6dB/octave 的速率下降），预加重通过高通滤波器来平衡频谱能量分布，高通滤波器计算公式如（2.2）所示：

$$H(z) = 1 - \alpha z^{-1}, \tag{2.2}$$

其中预加重系数 α 通常设置为 0.95-0.97。这个步骤不仅能够补偿语音产生过程中声门和嘴唇辐射的影响，还能够提升高频成分的相对能量，为后续的频域分析提供更均衡的频谱基础。

经过上述操作后，时域信号通过短时傅里叶变换（Short-Time Fourier Transform，STFT）转换到时频域表示。STFT 将每个语音帧变换为复数频谱 $X(m,k)$，计算公式如（2.3）所示：

$$X(m,k) = \sum_{n=0}^{N-1} x(n+mH)w(n)e^{-j2\pi kn/N}, \tag{2.3}$$

其中 m 表示时间帧索引，k 表示频率索引。这种时频表示不仅保留了信号的频率信息，还维持了时间分辨率，为神经网络提供了既包含频域特征又保持时序结构的二维输入格式。变换后得到的复数频谱可进一步分解为幅度谱和相位谱，为不同类型的网络架构和处理策略提供了灵活的输入选择。

（2）特征表示阶段

经过数据预处理后获得的时频域表示虽然包含了丰富的语音信息，但这种原始的频谱数据往往存在维度过高、信息冗余、对噪声敏感等问题，并不能直接作为神经网络的最优输入。神经网络的性能很大程度上取决于输入特征的质量和表达能力，因此需要从预处理后的数据中提取更加紧凑、鲁棒且具有判别

性的特征表示。

为了更好地模拟人类听觉感知特性，通常采用感知相关的特征表示。梅尔频率倒谱系数（Mel-Frequency Cepstral Coefficients，MFCC）是一种广泛应用的感知特征，其计算过程（2.4）首先将线性频率转换为梅尔频率：

$$\mathrm{Mel}(f) = 2595\log_{10}(1+\frac{f}{700}). \tag{2.4}$$

接着通过梅尔滤波器组对功率谱进行滤波处理，计算公式如（2.5）所示：

$$S(m) = \sum_{k=0}^{N/2-1} P(k)\cdot H_m(k), \tag{2.5}$$

其中 $S(m)$ 表示第 m 个梅尔滤波器的输出能量，$P(k)$ 表示第 k 个频率点的功率谱值，$H_m(k)$ 表示第 m 个梅尔滤波器在第 k 个频率点的响应，N 表示 FFT 变换长度，求和范围 $N/2-1$ 对应于奈奎斯特频率。

最后通过离散余弦变换（Discrete Cosine Transform，DCT）得到 MFCC 特征，计算公式如（2.6）所示：

$$\mathrm{MFCC}(n) = \sum_{m=1}^{M} \log S(m)\cdot\cos(\frac{n(m-0.5)\pi}{M}), \tag{2.6}$$

其中 $\mathrm{MFCC}(n)$ 表示第 n 个 MFCC 系数，M 表示梅尔滤波器的数量（通常为 23-40），$\log S(m)$ 表示第 m 个滤波器输出的对数能量，$m-0.5$ 用于调整滤波器的中心位置。

（3）神经网络处理阶段

在这一阶段，神经网络接收标准化的输入特征，通过多层非线性变换学习复杂的特征映射关系。整个神经网络的处理过程可以抽象为一个非线性函数，如公式（2.7）所示：

$$y = f_\theta(x), \tag{2.7}$$

其中 x 表示输入的含噪语音特征向量，y 表示网络的输出（可以是增强后的语音特征、各种类型的掩码或其他增强目标），$f_\theta(\cdot)$ 表示由参数 θ 确定的神经网络函数，θ 包含了网络中所有的权重和偏置参数。

网络的训练过程由最小化损失函数来优化参数 θ，计算公式如（2.8）所示：

$$\theta^* = \arg\min \mathrm{L}(\theta), \tag{2.8}$$

其中 θ^* 表示最优的网络参数，$\mathrm{L}(\theta)$ 表示损失函数，$\arg\min$ 表示使损失函数取

得最小值的参数。

损失函数的具体形式取决于网络的输出类型和任务目标。当网络输出为增强后的幅度谱时，常用的均方误差损失函数如公式（2.9）所示：

$$L_{\mathrm{MSE}} = \frac{1}{N}\sum_{i=1}^{N}\left\|y_i - t_i\right\|_2^2, \tag{2.9}$$

其中 N 表示训练样本的总数，y_i 表示第 i 个样本的网络输出，t_i 表示第 i 个样本的目标值（真实标签）。

当网络输出为掩码类型时，可以使用二元交叉熵损失，如公式（2.10）所示：

$$L_{\mathrm{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}[t_i \log(y_i) + (1-t_i)\log(1-y_i)], \tag{2.10}$$

其中 $1-t_i$ 和 $1-y_i$ 分别表示目标值和输出值的补集，负号用于将最大化似然转换为最小化损失。

为了进一步提升模型性能和泛化能力，现代语音增强常常采用多任务学习策略。多任务学习的总损失函数可以表示为公式（2.11）：

$$L_{total} = \sum_{j=1}^{J}\lambda_j L_j(\theta), \tag{2.11}$$

其中 L_{total} 表示多任务学习的总损失函数，j 表示任务总数，$L_j(\theta)$ 表示第 j 个任务的损失函数，λ_j 表示第 j 个任务的权重系数，用于平衡不同任务对总损失的贡献程度。

（4）后处理重构阶段

神经网络的输出虽然包含了丰富的增强信息，但通常以频域特征、掩码或其他中间表示的形式存在，并不能直接作为最终的增强语音信号使用。用户最终需要的是可以播放、存储和传输的时域语音波形，因此必须将网络的输出转换回时域信号。

根据神经网络输出类型的不同，系统需要采用相应的处理策略。当网络输出为掩码时，需要将其与原始含噪语音的频谱进行相乘操作来获得增强频谱，如公式（2.12）所示：

$$\hat{S}(m,k) = M(m,k) \odot Y(m,k), \tag{2.12}$$

其中 $\hat{S}(m,k)$ 表示增强后的复数频谱在第 m 个时间帧、第 k 个频率点处的值，

$M(m,k)$ 表示神经网络预测的掩码值，$Y(m,k)$ 表示原始含噪语音在对应位置的复数频谱值，⊙示逐元素相乘操作。

当网络直接输出增强后的幅度谱时，需要结合相位信息来重构完整的复数频谱。最常用的策略是保持原始含噪语音的相位，如公式（2.13）所示：

$$\hat{S}(m,k)=\left|\hat{S}(m,k)\right|\cdot e^{j\angle Y(m,k)}, \tag{2.13}$$

其中，$\left|\hat{S}(m,k)\right|$ 表示网络预测的增强幅度谱，$\angle Y(m,k)$ 表示原始含噪语音的相位谱。

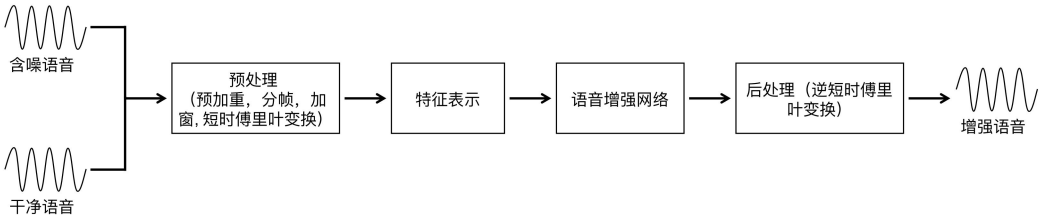


图 2.1 语音增强基本架构图

图 2.1 为语音增强的基本架构图。该图展示了一个典型的语音增强任务框架，整体流程包括数据预处理、特征表示、神经网络处理和后处理重构四个核心阶段。含噪语音信号经过数据预处理阶段进行预加重、分帧、加窗和短时傅里叶变换等处理，将时域信号转换为时频域表示。随后通过特征表示阶段提取多域声学特征并进行上下文建模和归一化处理，生成标准化的网络输入特征。神经网络处通过深度学习模型学习从含噪特征到增强目标的复杂映射关系，并采用适当的损失函数进行端到端训练。后处理重构阶段将网络输出通过逆时频变换等操作转换回时域信号，并应用各种后处理技术优化输出质量，最终生成清晰的增强语音。

2.2 基于深度神经网络的语音增强模型

2.2.1 基于卷积神经网络的语音增强算法

卷积神经网络（Convolutional Neural Networks，CNN）是一种专门用于处理具有网格状拓扑结构数据的深度学习模型，最初在计算机视觉领域取得了巨大成功。CNN 的核心思想是通过卷积操作来提取数据的局部特征，并通过多层网络结构实现从低级特征到高级语义表示的层次化学习。卷积操作是 CNN 的基础运算，它通过卷积核（滤波器）在输入数据上滑动，计算局部区域的加权和。

对于二维输入数据，卷积操作可以表示为公式（2.14）：

$$S(i,j)=(I*K)(i,j)\sum_{m}\sum_{n}I(i+m,j+n)K(m,n), \tag{2.14}$$

其中 I 为输入特征图，K 为卷积核，S 为输出特征图。卷积操作具有三个重要特性：局部连接性、权值共享和平移不变性，这些特性使得 CNN 能够有效地提取数据的空间特征并减少模型参数，图 2.2 为卷积神经网络模型结构示意图。

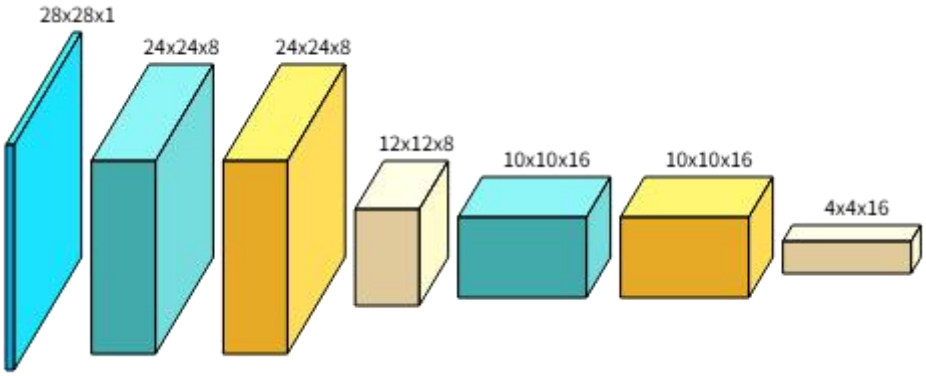


图 2.2 卷积神经网络模型结构示意图

在语音增强任务中，时域的一维语音信号通常被转换为时频域的二维表示，如短时傅里叶变换得到的频谱图。这种二维表示使得语音信号可以类似图像数据进行处理，为 CNN 的应用提供了理论基础。频谱图的行对应频率维度，列对应时间维度，每个像素值表示对应时频点的能量大小。2014 年，Xu[33]等人首次将 CNN 应用于语音增强任务，提出了基于回归的 CNN 模型直接预测理想二值掩码（Ideal Binary Mask，IBM）。该模型使用对数功率谱作为输入特征，通过三层卷积网络学习语音和噪声的频谱模式，在多种噪声环境下取得了显著的性能提升。随后的研究中，Park 和 Lee 提出了更深层的 CNN 架构，通过增加网络深度来提升模型的表达能力[34]。他们采用了批量归一化（Batch Normalization，BN）和残差连接等技术来训练更深的网络，进一步改善了语音增强效果。

2.2.2 基于循环神经网络的语音增强算法

循环神经网络（Recurrent Neural Networks，RNN）是一类专门用于处理序列数据的神经网络，其核心特征是具有循环连接结构，使得网络在处理当前时刻输入时能够利用之前时刻的信息。与前馈神经网络不同，RNN 通过引入隐藏状态（hidden state）来维护对历史信息的记忆，使其天然适用于建模具有时序依赖关系的数据。标准 RNN 的数学形式可以表示为公式（2.15）和公式（2.16）：

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h), \tag{2.15}$$

$$y_t = W_{hy}h_t + b_y, \tag{2.16}$$

其中 x_t 为时刻 t 的输入，h_t 为隐藏状态，y_t 为输出，W 为权重矩阵，b 为偏置向量。这种递归结构使得网络能够捕获序列中的时序依赖关系，理论上可以建模任意长度的序列依赖，图 2.3 为循环神经网络模型结构示意图。

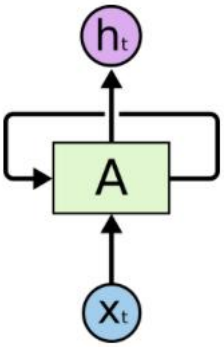


图 2.3 循环网络模型结构示意图

然而，传统 RNN 在实际应用中面临严重的梯度消失和梯度爆炸问题。在反向传播过程中，梯度需要通过多个时间步骤传播，当序列较长时，梯度会呈指数级衰减或增长，导致网络难以学习长期依赖关系。这一问题限制了传统 RNN 在长序列建模中的应用效果。长短期记忆网络 (Long Short-Term Memory, LSTM) 通过引入门控机制有效解决了传统 RNN 的梯度消失问题。LSTM 包含三个关键的门控单元：遗忘门、输入门和输出门，以及一个细胞状态用于长期信息存储，LSTM 的数学表示如公式（2.17）—公式（2.22）所示：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f), \tag{2.17}$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i), \tag{2.18}$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C), \tag{2.19}$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t, \tag{2.20}$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o), \tag{2.21}$$

$$h_t = o_t * \tanh(C_t), \tag{2.22}$$

其中 σ 为 sigmoid 激活函数，f_t 为遗忘门，i_t 为输入门，$\tilde{C}_t$ 为候选值，C_t 为细胞状态，o_t 为输出门，h_t 为隐藏状态。门控机制使 LSTM 能够选择性地遗忘、更新和输出信息，从而有效地建模长期依赖关系，图 2.4 为长短期记忆网络模型结构示意图。

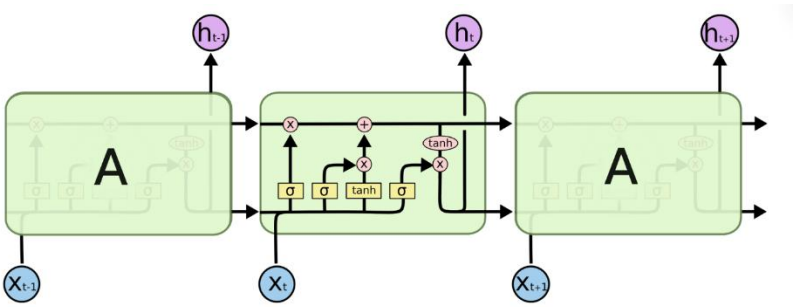


图 2.4 长短期神经网络模型结构示意图

门控循环单元（Gated Recurrent Unit，GRU）是 LSTM 的简化版本，由 Cho 等人于 2014 年提出。GRU 通过合并遗忘门和输入门为更新门，并将细胞状态和隐藏状态合并，减少了参数数量的同时保持了建模长期依赖的能力，GRU 的数学表示如公式（2.23）—公式（2.26）所示：

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r), \tag{2.23}$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z), \tag{2.24}$$

$$\tilde{h}_t = \tanh(W_h \cdot [r_t * h_{t-1}, x_t] + b_h), \tag{2.25}$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t, \tag{2.26}$$

其中 r_t 为重置门，z_t 为更新门，$\tilde{h}_t$ 为候选隐藏状态，h_t 为隐藏状态。GRU 的结构相对简单，在某些任务中表现出与 LSTM 相当的性能，同时具有更高的计算效率，图 2.5 为门控循环单元模型结构示意图。

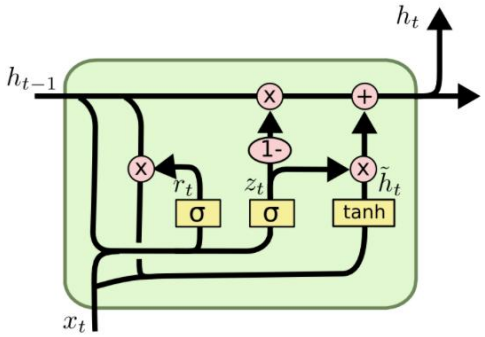


图 2.5 门控循环单元模型结构示意图

在语音增强任务中，语音信号具有明显的时序特性，相邻时刻的语音帧之间存在强相关性，这为 RNN 及其变体的应用提供了理论基础。循环神经网络能够通过其时序建模能力来学习语音信号的动态特征，有效区分语音和噪声成分。早期将 RNN 应用于语音增强的研究主要集中在利用传统 RNN 的时序建模能力。然而，由于梯度消失问题的限制，这些方法在处理长序列语音信号时效果有限。研究者们很快转向使用 LSTM 和 GRU 等改进的 RNN 变体。Weninger 等人最早将 LSTM 系统性地引入语音增强任务，提出了基于 LSTM 的掩码估计方法[35]。该方法通过训练 LSTM 网络预测理想比值掩码（Ideal Ratio Mask，IRM），在多种噪声环境下验证了 LSTM 相比传统方法和前馈神经网络的优势。实验结果表明，LSTM 在捕获语音时序特征方面具有显著效果。Kumar 和 Florencio 将 GRU 应用于语音增强任务，提出了基于 GRU 的掩码预测方法。实验结果表明，GRU 在保持与 LSTM 相当性能的同时，具有更少的参数和更快的训练速度，这使其在实际应用中更具优势。

2.2.3 基于 Transformer 的语音增强算法

Transformer 模型由 Vaswani[37]等人于 2017 年在论文“Attention is All You Need”中提出，最初用于机器翻译任务，后来在自然语言处理、计算机视觉等领域取得了巨大成功。与循环神经网络不同，Transformer 完全基于自注意力机制（Self-Attention），摒弃了循环结构，实现了高度并行化的计算，同时能够有效建模长距离依赖关系。自注意力机制是 Transformer 的核心组件，它允许模型在处理序列中的每个位置时，同时关注序列中的所有其他位置。对于输入序列，自注意力机制通过查询（Query）、键（Key）和值（Value）三个向量来计算注意力权重。自注意力的数学表示为公式（2.27）：

$$\text{Attention}(Q,K,V)=\text{softmax}(\frac{QK^T}{\sqrt{d_k}})V, \tag{2.27}$$

其中Q、K、V分别表示查询、键和值矩阵，d_k是键向量的维度。这种机制使得模型能够为序列中的每个位置分配不同的注意力权重，从而捕获位置间的复杂依赖关系。为了增强模型的表达能力，Transformer 使用多头注意力机制（Multi-Head Attention），将输入投影到多个不同的子空间，并行计算多个注意力头，最后将结果拼接，如公式（2.28）和公式（2.29）所示：

$$\text{MultiHead}(Q,K,V)=\text{Concat}(head_1,\ldots,head_h)W^O, \tag{2.28}$$

$$\text{head}_i=\text{Attention}(QW_i^Q,KW_i^K,VW_i^V), \tag{2.29}$$

其中h表示注意力头的数量，W_i^Q、W_i^K、W_i^V和W^O是可学习的权重矩阵。多头注意力机制允许模型同时关注不同类型的信息，提高了模型的表达能力。标准 Transformer 由编码器和解码器两部分组成。编码器由多个相同的层组成，每层包含多头自注意力机制和前馈神经网络，并使用残差连接和层归一化。解码器除了包含编码器的组件外，还增加了编码器-解码器注意力层，用于关注编码器的输出，图 2.6 为 Transformer 模型结构示意图。

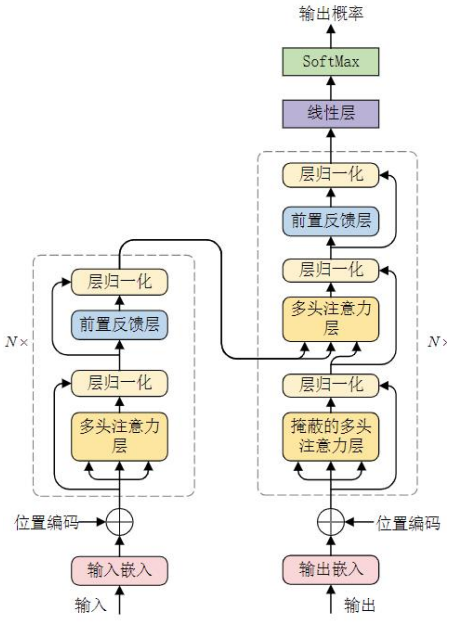


图 2.6 Transformer 模型结构示意图

随着 Transformer 在自然语言处理领域取得成功，研究者们开始探索将其应

用于语音增强任务的可能性。Yu[38]等人在 2022 年提出了 SETransformer 模型，这是较早将 Transformer 系统性应用于语音增强的工作之一。SETransformer 结合了 LSTM 和多头注意力机制，能够同时捕获语音频谱中的局部结构特征和长距离依赖关系。在频域建模方面，Dang[39]等人进一步发展了双路径 Transformer 的思想，于 2021 年提出了 DPT-FSNet。该方法专门针对频域语音增强任务进行了优化，通过双路径 Transformer 的内部路径和跨路径分别建模子带和全带信息。DPT-FSNet 的设计理念是充分利用子带模型在频谱图局部模式建模方面的优势，同时通过全带和子带信息的融合来提升整体性能。

2.2.4 基于 Mamba 的语音增强算法

Mamba 模型由 Gu 和 Dao[40]于 2023 年提出，是基于结构化状态空间模型（Structured State Space Models，SSMs）的新兴深度学习架构。该模型的设计初衷是解决 Transformer 在处理长序列时面临的二次复杂度问题，同时保持强大的序列建模能力。Mamba 的核心创新在于引入了选择性状态空间机制，使模型能够动态地选择和压缩序列信息，实现了线性复杂度的高效序列处理。状态空间模型是一种经典的动态系统建模方法，其基本思想是通过隐藏状态来建模系统的时间演化过程。在连续时间域中，线性时不变状态空间模型如公式（2.30）、公式（2.31）所示：

$$\frac{d}{dt}h(t) = Ah(t) + Bx(t), \tag{2.30}$$

$$y(t) = Ch(t) + Dx(t), \tag{2.31}$$

其中 $h(t)$ 是隐藏状态，$x(t)$ 是输入序列，$y(t)$ 是输出序列，A、B、C、D 是系统参数矩阵。

Mamba 是结构化状态空间模型系列的最新发展。S4（Structured State Space for Sequences）[41]首次将状态空间模型成功应用于深度学习，通过对角化技术实现了高效的并行训练。S5（Simplified State Space）[42]进一步简化了 S4 的复杂性，提高了计算效率。Mamba 在此基础上引入了选择性机制，使模型具备了内容感知的建模能力，在保持线性复杂度的同时显著提升了模型性能。Mamba 模型的基本构建单元是 Mamba 块，其结构包括输入投影、选择性 SSM 层、输出门控、残差连接，整个 Mamba 块的计算流程如公式（2.32）所示：

$$y = \mathrm{SSM}(\mathrm{SiLU}(xW_1)) \odot \mathrm{SiLU}(xW_2), \tag{2.32}$$

其中W_1和W_2是可学习的权重矩阵，图 2.7 为 Mamba 模型结构示意图。

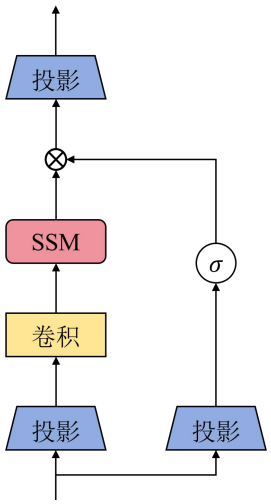


图 2.7 Mamba 模型结构示意图

Mamba 作为一种新颖的状态空间模型，在 2023 年提出后迅速在多个领域展现出潜力。在语音增强领域，Chao[43]等人在 2024 年率先进行了系统性的探索提出了 SEMamba 模型，其使用时频 Mamba 块同时处理幅度谱和相位信息进行双路径处理。Kuhne[44]等人进一步提出了 MambAttention 模型，这是首个将 Mamba 与多头注意力机制结合用于语音增强的混合架构。该模型将 Mamba 块与共享的时间和频率多头注意力模块相结合，通过权重共享机制使模型能够同时关注时间和频率特征。

2.3 语音增强公共数据集

在语音增强研究中，根据数据类型的不同，常用的公开数据集主要分为三类：第一类是纯净语音数据集，包括 Aishell[45]、TIMIT[46]、Librispeech[47]、VCTK[48]和 WSJ0[49]等；第二类是噪声数据集，如 DEMAND[50]、AudioSet[51]、WHAM![52]和 Noise-92[53]等；第三类是带噪语音数据集，包括 EARS[54]、Chime Challenge[55]、DNS-Challenge[56]和 VoiceBank+Demand 等，这些数据集为语音增强算法的训练和评估提供了标准化的基准。

本文第三、四章用到的数据集分别为 Voice Bank+DEMAD、DNS Challenge 2020 及自建的实录课堂教师语音增强语料库，下面将详细介绍使用的数据集。

（1）VoiceBank+DEMAND 数据集

VoiceBank+DEMAND 数据集包含采样率为 48kHz 的干净与嘈杂音频对。干净音频来自 28 名说话人的 11572 段训练音频和 2 名未见说话人的 824 段测试音频。嘈杂音频通过将干净音频与 10 种背景噪声（DEMAND 数据库的 8 种类型和 2 种人工噪声）混合生成。训练集中，干净音频与背景噪声按 0dB、5dB、10 dB 和 15dB 的 SNR 进行混合。测试集中，则采用 2.5dB、7.5dB、12.5dB 和 17.5dB 的 SNR 进行混合。实验中所有音频均重采样至 16kHz。VoiceBank+DEMAND 数据集音频分布如表 2.1 所示。

表 2.1 VoiceBank+DEMAND 数据集分布

数据集划分	音频条数	时长（小时）
训练集	11572	9.4
验证集	824	0.6
测试集	824	0.6
统计	12396	11.6

（2）Deep Noise Suppression Challenge 2020 数据集

DNS Challenge 2020 数据集包含来自 2150 名说话人的 500 小时干净音频和超过 180 小时的噪声音频。所有干净音频被划分为 10 秒片段，本文通过官方脚本生成 SNR 为-5dB 至 15dB 的 500 小时嘈杂音频训练数据。本文采用 DNS Challenge 2020 数据集提供的非盲测试集对模型进行评估，非盲测试集包含 20 名说话者的 4270 段音频及对应噪声，SNR 范围为 0dB 至 25dB。DNS Challenge 2020 数据集音频分布如表 2.2 所示。

表 2.2 DNS Challenge 2020 数据集分布

数据集划分	音频条数	时长（小时）
训练集	50000	500
验证集	4270	50
测试集	4270	50
统计	58540	600

2.4 语音增强自建数据集

近几年，深度学习技术已经在语音增强领域得到大量应用，语音质量改善工作有了不少突破。不过，在特定环境中，深度学习语音增强方法处理复杂噪

声环境时还有比较大的改进空间。特别是在课堂实录场景中，受到学生说话声、桌椅移动、空调运转、教室混响和录音设备质量等因素的干扰，语音信号往往混杂着多种不同类型的噪声，造成增强效果不佳，很难满足语音识别、教学分析等任务对音质的要求。这就让构建针对课堂场景的专用语音增强数据集成为必要。通过采集真实课堂环境下带噪语音及其对应的干净语音，能够为模型提供与实际应用更接近的训练样本，最终提升课堂语音增强的针对性和有效性。

目前已有的语音增强数据库包括 VoiceBank+DEMAND、DNS Challenge 为语音增强领域提供了基础数据支撑，这些数据集主要针对的是英文环境，噪声环境大多是人工模拟合成，跟真实课堂场景相比存在较大差异。VoiceBank+DEMAND 数据集尽管包含的噪声种类多、录音音质较好，但其噪声大多是环境噪声的简单叠加，缺少真实课堂中常见的混响、多说话人交叠、突发性噪声等复杂声学特性。DNS Challenge 数据集尽管数据量比较大，但同样通过人工混合方法生成带噪语音，无法彻底模拟真实课堂的声学环境另外，这些数据集都是英文语音，就语音特征、韵律模式、时长分布等方面来看与中文存在本质不同，直接用于中文课堂语音增强任务难以取得好效果。更为关键的是，现有数据集没有针对教育场景做专门设计，不能反映课堂教学中教师语音的特殊性，比如较长的连续发音、专业术语的高频使用、教学节奏的变化等特点这些局限性让传统数据集难以满足中文课堂语音增强任务的需求，特别是在真实噪声环境建模、长时语音处理和教学场景适配等关键问题上支持不足，迫切需要建立包含真实课堂录音、多样化噪声类型、教师语音特征的中文课堂语音增强数据集，以此完成复杂课堂环境下的高质量语音恢复。

2.4.1 实录课堂教师语音增强语料库构建

中文课堂语音增强数据不足，为弥补这一缺口，本节围绕实录课堂环境展开，建了一个面向中文课堂教师语音增强的语料库语料库涉及的语文和数学两个科目各份音频样本里都包含对应干净语音和带噪语音，噪声类型包含学生讨论声、课桌椅移动声、翻书写字声、走廊脚步声、空调风扇运转声、投影仪设备噪音、窗外环境噪音这些典型课堂背景噪声本节给中文课堂语音增强技术研究提供了新的数据资源支撑，也给教学音频资源质量优化提供了新思路借助所构建包含真实课堂声学特性的语音增强数据集，能够更有效地训练和评估面向

课堂场景的语音增强模型，给智能教育、在线学习、教学质量分析这些领域的发展提供有力支撑。如图 2.8 所示，本文介绍了语料库的详细创建框架，包括干净语音采集、课堂噪声采集、数据预处理、噪声混合与信噪比控制、数据集划分和数据存储整理。

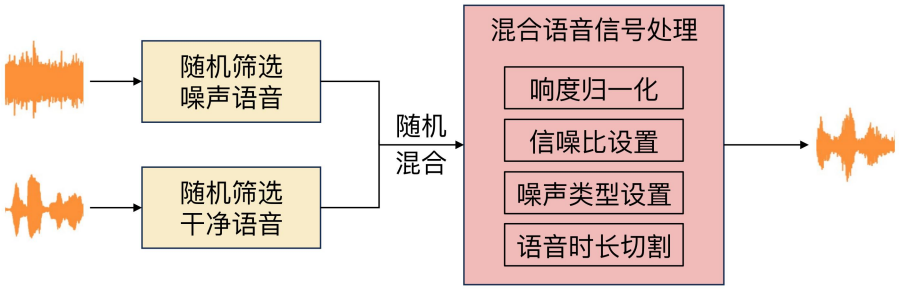


图 2.8 语料库框架创建流程

（1）干净语音采集

干净语音的获取渠道是 82 位教师实际授课的录音资料，涉及语文和数学这两个学科领域，累计 150 节课程，单节课程时长 40 分钟上下，录音时选用了专业录音笔或近场话筒这类设备，保证采集到的语音质量足够高。全部音频文件的采样率统一设定为 16kHz，采样精度设定为 16bit，采用单声道模式，每段录音都只有一位说话人，录音地点选在比较安静的教室或录播室内，教师头戴麦克风或用指向性话筒来完成授课录音，让环境噪声和混响的影响大幅减少。录音内容包含课堂讲解、知识点说明、例题解析等多种教学情形，能够体现教师授课时的语音特点，比如发音持续时间比较长、专业词汇出现次数多、语速和语调会跟着教学进度调整等特性。

（2）课堂噪声采集

课堂噪声同样来自线下真实课堂的实地录制，目的是让课堂场景的复杂性得到反映，采集噪声含多种课堂常见背景噪声类型，具体有学生讨论声、桌椅移动、翻书写字、走廊脚步、空调风扇运转、投影仪设备运转、窗外环境噪音等。所有噪声文件采用与干净语音相同的采样参数（16kHz，16 位 PCM），确保后续混合处理的一致性。

（3）数据预处理

在混合生成带噪语音之前，需要对干净语音和噪声文件进行预处理。对语音文件开展长度筛选，只保留时长超过 4 秒的语音片段，这样能保证语音片段具备充分语义内容与完整声学特征。对于时长超出 10 秒的较长语音文件，依照 10 秒固定长度完成切分，得到若干子片段，末尾片段保留剩余内容，防止因语

音序列过长引发内存与计算问题。音频片段切分处可能出现信号突变，为避免该现象，在每个语音信号的起始和结束位置均应用线性渐入渐出效果，渐变时长设定为 10 毫秒，利用平滑过渡去掉可能产生的爆破音或咔嗒声。预处理完成后，全部语音片段和噪声片段均满足后续混合处理要求，确保所生成带噪语音数据集拥有统一质量标准及时长分布。

（4）实录课堂带噪语音生成

采用响度归一化方法将干净语音与课堂噪声混合，生成不同信噪比条件下的带噪语音样本。混合时，首先为每条干净语音随机选取一个噪声文件，如果噪声时长不足，则拼接其他噪声文件直至长度满足要求，然后从中随机截取与语音等长的片段，保证噪声片段的多样性。之后，用响度测量工具算出干净语音和噪声片段各自的综合响度值，根按照目标信噪比（从负 5 分贝到 17.5 分贝范围内随机取值）确定噪声要达到的响度，算出对应的增益系数，缩放噪声，再和干净语音加在一起形成混合信号。由于直接相加可能导致信号削波，因此需要检测混合信号的幅度，一旦发现超出正常范围，就将目标信噪比提高 1 分贝并重新混合，直到信号幅度正常或达到信噪比上限为止。

（5）数据集划分

语料库按照说话人维度进行划分，确保同一说话人的语音不会同时出现在训练集和测试集中。从 80 余位教师中随机选取 2 位作为验证集说话人，3 位作为测试集说话人，其余教师的语音数据用于训练。按照这种划分方式，训练集、验证集和测试集的数据量比例约为 7：1：2。自建数据集音频分布如表 2.3 所示。

表 2.3 自建数据集分布

数据集划分	音频条数	时长（小时）
训练集	12716	90
验证集	1488	4
测试集	3043	6
统计	17247	100

2.5 评价指标

语音增强算法的核心目标在于提升语音的质量与可懂度，从而改善用户的听觉体验。然而，在面对不同的应用场景时，如何科学、客观地判断各种算法

的优劣，成为研究和开发过程中亟需解决的问题。评价指标为这一问题提供了可量化的解决途径，它们不仅能够客观反映语音增强后的效果，还为研究人员与工程师在算法优化与改进中提供了有力的参考。更重要的是，通过合理的指标体系，可以揭示算法在语音保真度、可懂度以及主观感受等方面的差距与不足，从而推动语音增强技术的持续进步。本节将介绍几类常用的语音增强评价指标。

语音感知评价（Perceptual Evaluation of Speech Quality，PESQ）是一种基于人类听觉感知模型的客观语音质量评价方法，被广泛应用于语音增强与语音通信领域。它通过比较增强语音与参考语音在时域与频域的差异，生成一个与主观听感高度相关的分数。根据适用频带范围的不同，PESQ 可分为窄带版本（Narrowband PESQ，NB-PESQ）和宽带版本（Wideband PESQ，WB-PESQ）。其中，NB-PESQ 主要覆盖 300Hz-3.4kHz 频段，最初用于评估传统电话语音的质量，仍在低带宽语音数据的研究中具有参考价值。而 WB-PESQ 扩展了频带范围（50Hz-7kHz），能够更准确地反映现代语音通信和语音增强场景中的感知质量，因此在当前研究中更为常用。

主观均值意见分（Mean Opinion Score）最初是一种依赖听音实验的主观评价方法，通过人工打分来衡量语音的整体质量。然而，在语音增强研究中，通常使用能够预测 MOS 的客观模型来代替人工测试，以提高评估效率和可重复性。常见的预测分数包括三类：语音信号失真预测分（Mean Opinion Score predicted signal distortion，CSIG），用于反映增强语音的保真度；背景噪声干扰预测分（Mean Opinion Score predicted background intrusiveness，CBAK），用于衡量增强算法在抑制噪声方面的效果；以及整体质量预测分 (Mean Opinion Score predicted overall quality，COVL），用于综合评估语音保真度与噪声抑制性能。

短时可懂度（Short-Time Objective Intelligibility，STOI）是一种专门用于评估语音可懂度的客观指标。它通过计算增强语音与参考语音在短时分段上的相关性，来量化听者理解语音内容的难易程度。STOI 的计算通常基于时间-频率掩蔽效应和语音感知特性，因此与实际听感中的语音可懂度具有较强的一致性。在语音增强任务中，STOI 常与 PESQ 和 MOS 互补，用于全面反映增强语音的可懂度与质量[57]。

信噪比指标（Scale-Invariant Signal-to-Distortion Ratio，SI-SDR）是一种常用于评估语音增强和语音分离算法性能的客观指标，用于衡量增强语音与参考

语音在信号层面的相似程度。与传统的信噪比（Signal-to-Distortion Ratio，SDR）不同，SI-SDR 在计算过程中引入了尺度不变性特性，通过对参考语音信号进行最优尺度匹配，消除了由于增益差异导致的评估偏差，从而能够更加准确地反映算法在语音重建精度方面的表现。其核心思想是将增强语音分解为与目标语音在尺度上最匹配的分量与残差分量，进而计算两者之间的能量比值。SI-SDR 的数值越高，表示增强语音中目标成分占比越大、失真越小，语音保真度越高。由于其具备物理意义明确、计算简洁、与听觉感知高度相关等优点，SI-SDR 已成为近年来语音增强模型性能评估的重要指标之一[58]。

2.6 本章小结

本章系统阐述了语音增强的深度学习理论基础、实验数据集以及常用的评价指标。首先，对语音增强的基本原理与整体框架进行了全面介绍。其次，详细说明了实验所使用的公开数据集及其规模与分布信息，并针对课堂教师语音增强的特定应用场景，介绍了自建实录课堂教师语音增强数据集的构建过程与数据特征。最后，对实验中采用的评价指标进行了系统介绍。通过上述内容的展开，本章为后续章节的研究工作奠定了坚实的理论与数据基础，后续章节将在此基础上进一步展开深入探讨与细化分析。

第 3 章 基于外部双向 Mamba 的课堂语音增强方法

本章提出基于外部双向 Mamba 的课堂语音增强方法。首先介绍全频带外部双向 Mamba 时频域语音增强模型的整体架构，其次详细阐述外部双向 Mamba 模块、Inception 深度卷积及幅度—相位并行解码等关键技术，最后通过对比实验和消融实验验证所提方法的有效性。

3.1 引言

语音增强技术通过抑制背景噪声和混响等干扰，显著提升语音的清晰度和可懂度，在自动语音识别、教学质量分析等领域发挥着重要作用。然而，现有方法多聚焦于通用场景，对于实录课堂这类包含长时序列、多样化噪声干扰的复杂声学环境缺乏针对性解决方案。实录课堂环境中，教师授课往往持续数十分钟，语音信号呈现出显著的长时依赖特性，同时课堂噪声类型复杂多样，包括学生讨论声、桌椅移动声、设备运转声等非平稳干扰，这对语音增强模型的长序列建模能力提出了更高要求。随着在线教育的快速发展，大量课堂视频亟需语音质量优化，构建高效准确的课堂语音增强方法具有重要的实用价值。当前主流的语音增强方法多采用 Transformer 或 Conformer 架构，其自注意力机制的二次复杂度限制了长时语音场景的应用效率。最近，Mamba 架构通过状态空间模型实现了线性复杂度建模，为处理长序列语音提供了新的技术路径。然而，现有基于 Mamba 的方法多采用单向因果计算，仅利用历史信息进行建模，未充分利用离线处理场景中未来信息的可用性。此外，这些方法通常采用大卷积核扩大感受野，但大卷积核带来的高内存访问开销制约了模型的实际部署。

针对上述问题，本章提出了基于外部双向 Mamba 的课堂语音增强方法（IEDM-TFNet）。该方法通过外部双向 Mamba 架构同时利用历史和未来语音信息，以线性计算复杂度捕获全局双向依赖关系。为解决大卷积核的内存开销问题，引入 Inception 深度卷积模块，将大卷积核分解为多个并行的小卷积核和带状卷积核，在保持多尺度特征提取能力的同时显著降低了计算成本。模型采用并行的幅度掩码解码器和相位解码器分别预测纯净语音的幅度谱和相位谱，实现幅度—相位联合优化，并结合感知对比度拉伸技术进一步提升语音的感知质量。实验表明，所提方法有效提升了课堂语音增强效果。

3.2 模型设计

3.2.1 模型概述

本章提出的全频带外部双向 Mamba 时频域语音增强模型采用编解码器架构，如图 3.1 所示。模型从含噪语音波形 $y \in R^L$ 中恢复出清晰的语音波形 $x \in R^L$，其中 L 表示波形长度。首先，利用短时傅里叶变换从含噪语音 y 中提取幅度谱 $Y_m \in R^{(T\times F)}$ 和相位谱 $Y_p \in R^{(T\times F)}$，其中 T 和 F 分别表示时间帧数和频率维度。为更精确地估计幅度掩码，对幅度谱 Y_m 进行幂律压缩处理，并将其与相位谱 Y_p 拼接形成双通道输入特征 $Y_{in} \in R^{(T\times F\times 2)}$。随后，编码器将 Y_{in} 压缩为时频域潜在表征，经过四个时频-外部双向 Mamba 层逐层处理后，并行的幅度掩码解码器和相位解码器分别预测出干净语音的幅度谱 $\hat{Y}_m \in R^{(T\times F)}$ 和相位谱 $\hat{Y}_p \in R^{(T\times F)}$。最后，通过逆短时傅里叶变换重构出增强后的语音波形 $\hat{x} \in R^L$。

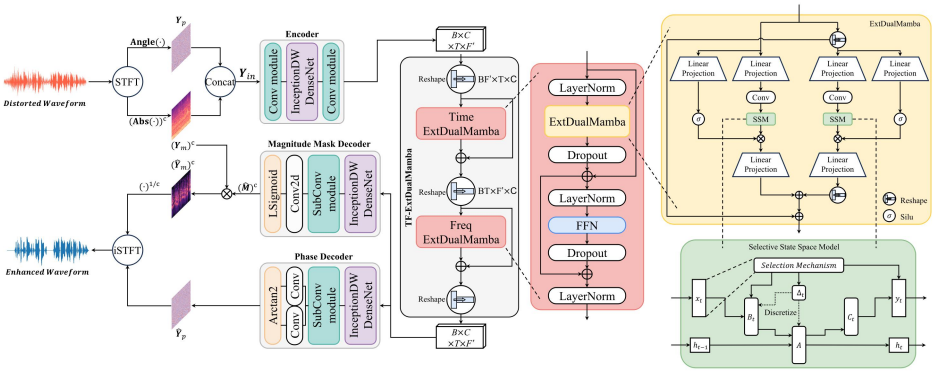


图 3.1 全频带外部双向 Mamba 的时频语音增强网络结构

3.2.2 编码器

编码器由基于 Inception 深度卷积的深度密集网络和两个卷积模块组成。与采用大卷积核的传统深度卷积不同，Inception 深度卷积在保持部分通道信息不变的同时，将一个大卷积核分解为一个小卷积核、两个带状卷积核以及一个恒等映射，三个卷积核的尺寸分别为 3×3、$1\times k_w$ 和 $k_h\times1$，有效提升了卷积计算速度。具体来说，对于输入特征 X，沿通道维度将其分为四组，分裂过程如公式（3.1）所示。

$$\begin{aligned} X_{\mathrm{hw}}, X_{\mathrm{w}}, X_{\mathrm{h}}, X_{\mathrm{id}} &= \mathrm{Split}(X) \\ &= X_{:,:g}, X_{:g,g:2g}, X_{:2g,2g:3g}, X_{:3g:}, \end{aligned} \tag{3.1}$$

其中 g 是卷积分支的通道数。本文设置一个比率 r_g 来确定分支通道数，即 $g = r_g C$ 。然后，分裂输入被馈送到不同的并行分支，卷积过程如公式（3.2）—（3.5）所示，其中

$$X'_{\mathrm{hw}} = \mathrm{DWConv}^{g \to g}_{k_s \times k_s} g(X_{\mathrm{hw}}), \tag{3.2}$$

$$X'_{\mathrm{w}} = \mathrm{DWConv}^{g \to g}_{1 \times k_b} g(X_{\mathrm{w}}), \tag{3.3}$$

$$X'_{\mathrm{h}} = \mathrm{DWConv}^{g \to g}_{k_b \times 1} g(X_{\mathrm{h}}), \tag{3.4}$$

$$X'_{\mathrm{id}} = X_{\mathrm{id}}, \tag{3.5}$$

k_s 表示小方核大小，默认设置为 3； k_b 表示带核大小，默认设置为 11。最后，将每个分支的输出连接起来，连接过程如公式（3.6）所示。

$$X' = \mathrm{Concat}(X'_{\mathrm{hw}}, X'_{\mathrm{w}}, X'_{\mathrm{h}}, X'_{\mathrm{id}}). \tag{3.6}$$

Inception 深度密集网络使用四个 Inception 深度卷积层, 分解比率 r_g 为 0.125。在每个 Inception 深度卷积层中引入 DenseNet 的密集连接，这不仅有助于防止梯度消失问题，而且还提高了网络的参数效率。每个卷积块由 2D 卷积层、实例归一化和参数修正线性单元激活组成。第一个卷积块通过增加卷积层中的通道数量来增加特征维度，而第二个卷积块通过扩大卷积层中的步幅来对特征进行下采样，将频率维度从 F 缩小为 F' = F/2 。Inception 深度卷积结构如图 3.2 所示。

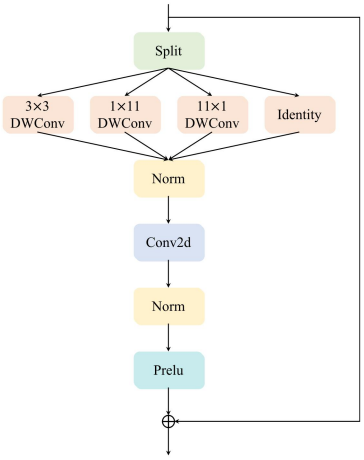


图 3.2 Inception 深度卷积网络结构

3.2.3 时频外部双向 Mamba 模块

相较于 Transformer 和 Conformer，Mamba 采用状态空间模型 SSM 及其优秀的选择机制，以允许模型自适应地调整其记忆长度，在能够有效捕获更长距离依赖关系的同时保持线性计算复杂度。SSM 如 Mamba 方法中所述，通过高维潜在状态 h 将输入 x 映射到输出 y 进行操作，如公式（3.7）和公式（3.8）所示：

$$h_n = \overline{A}h_{n-1} + \overline{B}x_n, \tag{3.7}$$

$$y_n = Ch_n, \tag{3.8}$$

其中 $\overline{A}$ 和 $\overline{B}$ 表示离散状态矩阵。离散化过程将连续参数 (Δ, A, B) 转换为离散对应参数 $(\overline{A}, \overline{B})$，使模型能够处理离散时间音频信号。此外，Mamba 将 H3 架构的组件和门控多层感知器块集成到堆叠结构中，从而将模型维度扩展了一个因子，并将大多数参数集中在线性投影中。

尽管 Mamba 具有“选择性”能力，但仍难以突破 SSM 固有的单向操作局限性，因此本文将原始的 Mamba 改进为外部双向 Mamba。在本文的语音增强任务中，外部双向 Mamba 会同时处理正向输入和反向输入的语音，所以 SSM 也会分别处理不同顺序的信息。在时频外部双向 Mamba 中，本文依次使用两个外部双向 Mamba 块分别对时间和频率维度之间的关系进行建模，使全频带外部双向 Mamba 的时频语音增强模型能够以线性计算复杂度捕获全局依赖性。如图 3.1 所示，输入的特征图尺寸为 $M \in \mathbb{R}^{(B\times T\times F'\times C)}$，特征图 M 首先被重塑为 $M^T \in \mathbb{R}^{(BF'\times T\times C)}$，以便在第一个 $M^T \in \mathbb{R}^{(BF'\times T\times C)}$ 块中捕捉时间依赖性，然后，输出的 M_o^T 与输入 M^T 按元素顺序相加，重塑成新的特征图 $M^F \in \mathbb{R}^{(BT\times F'\times C)}$，这样第二个外部双向 Mamba 块就能捕捉到频率依赖性，经过残差连接后，最终输出 $M' \in \mathbb{R}^{(B\times T\times F'\times C)}$ 重塑为解码器输入大小。对于每个时频外部双向 Mamba 块，时间外部双向 Mamba 层和频率外部双向 Mamba 层共享相同的结构，均由外部双向 Mamba 模块和前馈网络组成，并辅以层归一化和残差连接。

双向 Mamba 的构建方式可分为内部双向 Mamba 与外部双向 Mamba 两类，内部双向 Mamba 如图 3.3 所示。前者使用正向与反向两条 SSM 支路共享输入投影层与输出投影层，双向特征的融合在单一模块内部完成，而后者则为正向

与反向支路分别配置独立的输入投影层与输出投影层。外部双向 Mamba 由两个并行的 Mamba 模块构成，分别用于处理正向特征序列和反向特征序列，这是一种更简单、更直接的双向建模策略。两个 Mamba 模块的输出通过加法操作进行融合，并在外部双向 Mamba 层周围应用残差连接。

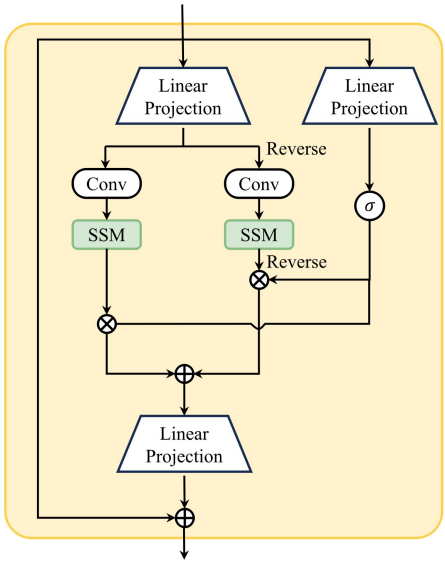


图 3.3 内部双向 Mamba 网络结构

3.2.4 幅度掩码解码器和相位解码器

本文提出的全频带外部双向 Mamba 时频域语音增强模型并行使用了两个解码器，即幅度掩码解码器和相位解码器，分别预测语音频谱的幅度掩码和相位。如图 3.1 所示，两个解码器的 Inception 深度密集网络与编码器结构相同。子像素卷积模块由子像素转置卷积、实例归一化和参数化修正线性单元激活组成，将频率维度从 F/2 上采样回 F 。对于幅度掩码解码器，使用二维卷积层将输出通道降至 1，并采用可学习参数β=2 的 Sigmoid 激活函数进行掩码估计。对于相位解码器，使用两个二维卷积层分别估计伪实部和伪虚部分量，然后通过反正切函数计算相位。

3.2.5 感知度对比拉伸

感知度对比拉伸（Perceptual Contrast Stretching，PCS）[59]是一种基于频谱处理的特征增强技术，它依据人类听觉系统对不同频率区域的敏感度差异，通

过在每个频率带上根据其感知重要性来调整信号的频谱幅度，从而优化语音的增强效果。具体地，对输入语音信号进行 STFT 以获取其复频谱，然后提取幅度谱并进行对数压缩，再依据预定义的怕频谱增益向量对幅度谱进行加权，形成增强后的幅度谱，最后利用原始相位信息并通过逆 STFT 还原为 PCS 增强后的语音。在本章中引入 PCS 作为增强过程之后的辅助步骤，旨在进一步改善语音信号的感知质量。

3.2.6 损失函数

本章使用了多级损失函数来训练所提出的全频带外部双向 Mamba 的时频语音增强模型。为了训练生成器，使用公式（3.9）作为损失函数：

$$L_G = \lambda_1 L_{Com} + \lambda_2 L_{Mag} + \lambda_3 L_{Pha} + \lambda_4 L_{Con} + \lambda_5 L_{Metric}, \tag{3.9}$$

其中 λ_1、λ_2、λ_3、λ_4 和 λ_5 是可调超参数。本文使用原始复数谱 $Y = Y_m \cdot e^{jY_p}$ 和增强复数谱 $\hat{Y} = \hat{Y}_m \cdot e^{j\hat{Y}_p}$ 之间的损失 L_{Com}，L_{Com} 的计算公式如（3.10）所示：

$$L_{Com} = \mathrm{E}_{(Y,\hat{Y})}\left[\left\|\mathrm{Real}(Y-\hat{Y})\right\|_F^2 + \left\|\mathrm{Imag}(Y-\hat{Y})\right\|_F^2\right], \tag{3.10}$$

其中 Real(·) 和 Imag(·) 分别表示从复数谱中提取实部和虚部的操作。

本章使用幅度谱损失 L_{Mag} 来衡量原始压缩幅度谱 $(Y_m)^c \in \mathbb{R}^{T\times F}$ 和增强压缩幅度谱 $(\hat{Y}_m)^c \in \mathbb{R}^{T\times F}$ 之间的均方误差损失，L_{Mag} 的计算公式如（3.11）所示：

$$L_{Mag} = \mathrm{E}_{(Y_m,\hat{Y}_m)}\left[\left\|((Y_m)^c - (\hat{Y}_m)^c)\right\|_F^2\right]. \tag{3.11}$$

由于原始相位谱 Y_p 和增强相位谱 $\hat{Y}_p$ 之间的绝对距离可能无法准确反映它们的实际距离，本章使用多级相位谱损失，L_{Pha} 的计算公式如（3.12）所示：

$$L_{Pha} = L_{IP} + L_{GD} + L_{IAF}. \tag{3.12}$$

同时，为了减轻相位缠绕引起的误差扩展，本文使用[60]提出的相位反缠绕函数，如公式（3.13）所示：

$$f_{AW}(t) = \left|t - 2\pi \cdot \mathrm{round}\left(\frac{t}{2\pi}\right)\right|, t \in \mathbb{R}. \tag{3.13}$$

基于上述的相位反缠绕函数，本章首先计算原始相位谱 Y_p 和增强相位谱 $\hat{Y}_p$ 之间的瞬时相位损失（the instantaneous phase loss，L_{IP}）。本章还考虑到语音信号在时间和频率轴上的相位连续性，计算群延迟谱损失（the group delay

spectrum loss，L_{GD}）和瞬时角频率谱损失（the instantaneous angular frequency spectrum loss，L_{IAF}），如公式（3.14）—（3.16）所示：

$$L_{IP} = E_{(Y_p,\hat{Y}_p)}\left[\left\| f_{AW}(Y_p - \hat{Y}_p)\right\|_1\right], \tag{3.14}$$

$$L_{GD} = E_{\Delta DF(Y_p,\hat{Y}_p)}\left[\left\| f_{AW}(\Delta DF(Y_p - \hat{Y}_p))\right\|_1\right], \tag{3.15}$$

$$L_{IAF} = E_{\Delta DT(Y_p,\hat{Y}_p)}\left[\left\| f_{AW}(\Delta DT(Y_p - \hat{Y}_p))\right\|_1\right], \tag{3.16}$$

其中$\|\cdot\|_1$表示 l1 范数，$\Delta DF(\cdot)$和$\Delta DT(\cdot)$是频率轴和时间轴上的微分算子。

为了保证增强复数谱$\hat{Y}$与$STFT(iSTFT(\hat{Y}))$之间的一致性，本章计算了它们的实部和虚部之间的一致性损失，定义如公式（3.17）所示：

$$L_{Con} = E_{\hat{Y}}\left[\left\|Real(\hat{Y} - STFT(iSTFT(\hat{Y})))\right\| + \right]\left\|Imag(\hat{Y} - STFT(iSTFT(\hat{Y})))\right\|_F^2. \tag{3.17}$$

本文还将度量判别器纳入生成对抗训练，并使用 PESQ 作为目标度量。本文将 PESQ 分数重新缩放为$(0,1)$，因此鉴别器输出缩放后的 PESQ 分数，并将干净的和增强的幅度谱对作为输入。判别器损失L_D第一项用于在输入为干净语音时训练 D 输出 1，第二项用于在输入为增强语音时训练 D 输出增强语音的归一化 PESQ。判别器损失L_D和生成度量损失L_{Metric}描述如公式（3.18）和（3.19）所示：

$$L_D = E_{Y_m}\left[\left\|D(Y_m, Y_m) - 1\right\|_2^2\right] + E_{(Y_m,\hat{Y}_m)}\left[\left\|D(Y_m, \hat{Y}_m) - Q_{PESQ}\right\|_2^2\right], \tag{3.18}$$

$$L_{Metric} = E_{(Y_m,\hat{Y}_m)}\left[\left\|D(Y_m, \hat{Y}_m) - 1\right\|_2^2\right], \tag{3.19}$$

其中 D 表示判别器，$Q_{PESQ} \in [0,1]$表示缩放后的 PESQ 分数。

3.3 实验与分析

3.3.1 实验环境与设置

本章实验所使用的操作系统为 Ubuntu，显卡为 NVIDIA GeForce RTX 3090，CPU 为 Intel(R) Xeon(R) Gold 6326，Python 为 3.9.20，CUDA 版本为 12.2。在训练阶段，所有音频都被切成 2 秒的片段。为了使用 STFT 从原始波形中提取输入特征，快速傅里叶变换点数、汉宁窗口大小和跳跃大小设置为 400、400（25 毫秒）和 100（6.25 毫秒），因此，频率点的数量 F=201。幅度谱压缩因子 c=0.3。

为了训练本文提出的 IEDM-TFNet，将批量大小 B、通道数 C、时频外部双向块数 N 分别设置为 4、64、4。最终生成器损失的超参数 λ_1、λ_2、λ_3、λ_4 和 λ_5 分别设置为 0.9、0.3、0.1、0.1 和 0.05。所有模型均使用 $\beta_1 = 0.8$ 和 $\beta_2 = 0.99$ 的 AdamW 优化器训练 200 个轮次，权重衰减为 0.01。学习率初始设置为 0.0005，每轮次以 0.99 的衰减因子递减。

3.3.2 评价指标

在 VoiceBank+DEMAND 数据集上，本文采用五种广泛使用的客观指标来评估增强语音质量：宽带语音质量感知评估 WB-PESQ、短时客观可懂度 STOI 以及三个综合指标（即 CSIG、CBAK 和 COVL）。WB-PESQ 用于评估宽带语音的感知质量，分数范围从-0.5 到 4.5，而 STOI 测量语音可懂度，取值范围从 0 到 1。指标 CSIG、CBAK 和 COVL 分别量化信号失真、背景噪声干扰和整体质量，均基于平均意见分数从 1 到 5 进行评分。在 DNS Challenge 2020 数据集上，除了 WB-PESQ 和 STOI 外，还使用 NB-PESQ 来评估窄带语音感知质量，并使用 SI-SDR 真比来量化增强语音与干净语音信号之间的失真。在自建数据集上, 本文使用语音增强任务中最常用的指标来评估增强语音质量 (WB-PESQ、CSIG、CBAK、COVL 和 STOI）。在所有指标中，数值越高表示性能越好。

3.3.3 对比实验

本章提出的全频带外部双向 Mamba 的语音增强方法属于时频域方法，于是将其与多个具有代表性的时域和时频域方法进行比较。在时域方法中，本章选择了 SEGAN、DEMUCS、TSTNN。在时频域方法中，本章选择了 PFPL、DB-AIAT、CMGAN、TridentSE、MP-SENet、MUSE 和 5 种使用状态空间模型的方法，即 S4DSE、S4ND-Unet、Spiking-S4、SEMamba、Mamba-SEUNet。如表 3.1 所示，本章提出的方法在所有指标上都优于所有其他语音增强方法，证明了其强大的去噪能力。值得注意的是，时域方法的性能普遍低于时频域方法，这表明时频域特性对语音去噪任务的重要性。此外，本章提出的基于时频外部双向 Mamba 的方法比最初使用状态空间模型的时域方法 S4DSE 有了很大的改进，与其相比，本方法的 PESQ、CSIG、CBAK 和 COVL 分数分别提高了 1.06，0.87，1.04 和 1.1。当结合 PCS 后，本章方法在 PESQ、CSIG 和 COVL 上的评

分进一步提升了 1.2、0.9 和 1.19。最后，本章方法的框架还在所有评估分数上优于最近改进的基于 Mamba 的方法，如 SEMamba 和 Mamba-SEUNet，而模型规模相对较小，仅有 2.63M 个参数。

表 3.1 在 VoiceBank+DEMAND 上的指标对比

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
Noisy	-	1.97	3.35	2.44	2.63	0.91
SEGAN(2017)[61]	43.18M	2.16	3.48	2.94	2.80	0.92
DEMUCS(2020)[62]	18.87M*	3.07	4.31	3.40	3.63	0.95
TSTNN(2021)[63]	0.92M	2.96	4.33	3.53	3.67	0.95
Spiking-S4(2024)[64]	-	3.39	4.92	2.64	4.31	-
PFPL(2021)[65]	6.93M*	3.15	4.18	3.60	3.67	0.95
DB-AIAT(2022)[66]	2.81M	3.31	4.61	3.75	3.96	-
CMGAN(2022)[67]	1.83M	3.41	4.63	3.94	4.12	0.96
TridentSE(2023)[68]	3.03M	3.47	4.70	3.81	4.10	0.96
MP-SENet(2023)[69]	2.05M	3.50	4.73	3.95	4.22	0.96
S4ND-UNet(2023)[70]	0.75M	3.15	4.52	3.62	3.85	-
MUSE(2024)[71]	0.51M	3.37	4.63	3.80	4.10	0.95
SEMamba(2024)[43]	2.25M	3.55	4.77	3.95	4.26	0.96
Mamba-SEUNet(L)(2025)[72]	6.28M	3.59	4.80	4.02	4.32	0.96
IEDM-TFNet	2.63M	3.61	4.82	4.04	4.35	0.96
IEDM-TFNet+PCS	2.63M	3.75	4.84	3.77	4.42	0.96

本章进一步将所提出的全频带外部双向 Mamba 的时频语音增强方法与 DNS Challenge 2020 数据集上的多种时频域语音去噪方法进行对比，包括两种基于复数频谱掩蔽的方法 (FullSubNet、FRCRN)、两种解耦风格的方法 (CTSNet 和 TaylorSENet)，一种基于频谱的短时离散余弦变换 (STDCT) 方法 (MFNet)。如表 3.2 所示，IEDM-TFNet 在与 SICRN 参数量相当的情况下，在所有评估指标上均显著优于这些基线方法。尤其是在 WB-PESQ 和 NB-PESQ 指标上，IEDM-TFNet 展现出了显著的优势，表明其能够有效提升语音的感知质量。

表 3.2 在 DNS Challenge 2020 上的指标对比

模型	参数量	WB-PESQ	NB-PESQ	STOI(%)
Noisy	-	1.58	2.45	91.52
FullSubNet(2021)[73]	5.64M	2.78	3.31	96.11
CTSNet(2021)[74]	4.35M	2.94	3.42	96.21
TaylorSENet(2022)[75]	5.40M	3.22	3.59	97.36
FRCRNt(2022)[76]	6.90M	3.23	3.60	97.69
MFNet(2023)[78]	-	3.43	3.74	97.78
SICRN(2024)[88]	2.16M	2.62	3.23	95.83
IEDM-TFNet	2.63M	3.63	3.93	98.09
IEDM-TFNet+PCS	2.63M	3.69	3.97	97.84

最后，为了评估本章方法的泛化能力，在自建数据集上与多个代表性的语音增强方法进行了对比实验，结果如表 3.3 所示。该数据集具有更丰富的噪声类型和更复杂的声学环境，能够更全面地考察模型在实际应用场景中的性能表现。从表 3.3 可以看出，未处理的带噪语音 WB-PESQ 为 1.52，STOI 为 0.88。在对比方法中，轻量级的 MUSE 以 0.51M 参数实现了 2.87 的 WB-PESQ。MP-SENet 取得了较好的性能，WB-PESQ 为 3.06，但参数量为 2.05M。基于 Mamba 的 SEMamba 达到 3.08 的 WB-PESQ，而更大规模的 Mamba-SEUNet(L)使用 6.28M 参数实现了 3.09 的 WB-PESQ。本章方法以 2.63M 参数取得了 3.11 的 WB-PESQ 和 4.40 的 CSIG，在所有指标上均达到最优或接近最优。特别是结合 PCS 后, 本章方法的 WB-PESQ 进一步提升至 3.20, CSIG 达到 4.42, COVL 达到 3.87，显著优于所有对比方法。与参数量相近的 SEMamba(2.25M)相比，本章方法的 WB-PESQ 提升 0.03，结合 PCS 后提升 0.12。与性能优异的 Mamba-SEUNet(L)相比，本章方法仅用其 42%的参数量，WB-PESQ 提升 0.02，结合 PCS 后提升 0.11。这充分证明了本章方法在复杂声学环境下的优越性能和良好的泛化能力。

表 3.3 在自建数据集上的指标对比

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
Noisy	-	1.52	3.16	2.13	2.43	0.88
DB-AIAT(2022)[66]	2.81M	2.83	4.19	3.30	3.44	0.91
CMGAN(2022)[67]	1.83M	2.90	4.16	3.59	3.55	0.92
MP-SENet(2023)[69]	2.05M	3.06	4.36	3.65	3.78	0.92
S4ND-UNet(2023)[70]	0.75M	2.67	4.11	3.29	3.41	0.91
MUSE(2024)[71]	0.51M	2.87	4.21	3.35	3.46	0.92
SEMamba(2024)[43]	2.25M	3.08	4.35	3.66	3.80	0.92
Mamba-SEUNet(L)(2025)[72]	6.28M	3.09	4.37	3.65	3.81	0.92
IEDM-TFNet	2.63M	3.11	4.40	3.68	3.82	0.92
IEDM-TFNet+PCS	2.63M	3.20	4.42	3.60	3.87	0.92

3.3.4 消融实验

为了验证本章方法中每个关键部分的作用，本章在 VoiceBank+DEMAND 数据集上进行了消融实验。本章首先对模型结构进行了消融研究，结果如表 3.4 所示，为了比较现流行的 Transformer，Conformer，xlstm，Mamba 的建模能力，本章将 TF-ExtDualMamba 模块中的 ExtDualMamba 替换为 Transformer（表示为图中的“w/ Transformer”），Conformer(表示为图中的 denoted as “w/ Conformer”)，xlstm(表示为图中的“w/ xlstm”)，Mamba(表示为图中的“w/ UniMamba”)。结果，这些模块的消融都会导致性能下降，不过值得注意的是，本章方法在使用 Conformer 的情况下，PESQ 仍能达到 3.53，而模型大小仅有 1.10M，优于表 3.1 中的 MP-SENet（PESQ 为 3.50，模型大小为 2.05）。通过比较这些强大的建模模块更凸显了本章提出的 TF-ExtDualMamba 模块对提高语音质量的贡献。

表 3.4 核心模块消融实验

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
w/ UniMamba	2.05M	3.55	4.76	4.00	4.28	0.95
w/ Transformer	1.66M	3.57	4.77	4.01	4.30	0.96
w/ Conformer	1.10M	3.53	4.74	3.96	4.27	0.95
w/ xlstm	2.02M	3.52	4.74	3.97	4.24	0.96
IEDM-TFNet	2.63M	3.61	4.82	4.04	4.35	0.96

此外，本章还研究了改变所提方法的时频外部双向 Mamba 块的数量 N 对语音增强性能的影响，结果如表 3.5 所示。当 N 从 0 增加到 3 时，包括 PESQ、STOI 和三个 MOS 分数在内的客观性能指标都有了持续改善，这表明添加时频外部双向 Mamba 块对提高语音质量很有效。当 N 增加到 4 时，所有指标都只有略微提升。然而当 N 进一步增加到 5 时，PESQ、COVL 及 STOI 的分数不再提升，甚至 CSIG 和 CBAK 的分数略有下降，这表明提出的 IEDM-TFNet 在 TF-ExtDualMamba 块数量为 4 的时候性能已经达到了最高点。

表 3.5 TF-ExtDualMamba 模块数量 N 对模型的性能影响

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
w/ 0 TF-ExtDualMamba	0.21M	3.21	4.25	3.39	3.81	0.93
w/ 1 TF-ExtDualMamba	0.80M	3.42	4.67	3.89	4.15	0.95
w/ 2 TF-ExtDualMamba	1.42M	3.56	4.77	4.00	4.30	0.96
w/ 3 TF-ExtDualMamba	2.03M	3.59	4.79	4.02	4.32	0.95
w/ 5 TF-ExtDualMamba	3.35M	3.61	4.80	4.03	4.35	0.96
IEDM-TFNet	2.63M	3.61	4.82	4.04	4.35	0.96

本章还对提出的 InceptionDWConv 以及包含 InceptionDWConv 的解码器进行了消融研究，结果如表 3.6 所示。将 InceptionDWConv 替换成普通的二维卷积会导致性能下降（表示为图中的“w/o InceptionDWConv”），说明 InceptionDWConv 在分解大核的同时可以提取更丰富的特征，当分别去掉幅度掩码解码器和相位解码器后（表示为图中的“w/o MagnitudeMaskDec.”和“w/o PhaseDec.”），结果大部分指标都显著降低，这归因于没有显式预测幅度和相位，导致幅度和相位之间的补偿问题。

表 3.6 InceptionDWConv 及解码器结构的消融实验

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
w/o InceptionDWConv	2.61M	3.53	4.71	3.90	4.17	0.94
w/o MagnitudeMaskDec.	2.56M	2.73	3.84	2.99	3.34	0.93
w/o PhaseDec.	2.56M	3.44	4.71	3.89	4.19	0.96
IEDM-TFNet	2.63M	3.61	4.82	4.04	4.35	0.96

最后, 本章对损失函数进行了消融实验, 去掉了相位损失, 复数损失及 STFT 一致性损失，结果如表 3.7 所示。结果进一步表明，显式预测幅度和相位对语音增强任务有非常重要的作用，STFT 一致性对模型的性能也有所贡献。最后，本章移除了度量鉴别器损失以专注评估生成器的训练能力，结果显示，本章提出的方法模型性能几乎与 MP-SENet 持平。

表 3.7 损失函数消融实验

模型	参数量	WB-PESQ	CSIG	CBAK	COVL	STOI
w/o PhaseLoss	2.63M	3.53	4.75	3.97	4.26	0.96
w/o ComplexLoss	2.63M	3.57	4.78	3.99	4.31	0.96
w/o ConsistencyLoss	2.63M	3.58	4.76	3.98	4.30	0.96
w/o MetricDiscriminator	2.63M	3.49	4.72	3.93	4.18	0.96
IEDM-TFNet	2.63M	3.61	4.82	4.04	4.35	0.96

3.4 本章小结

本章针对课堂语音增强任务，提出了基于外部双向 Mamba 的全频带时频域语音增强方法。针对现有方法在长时序列建模中存在的计算复杂度高和单向建模局限性问题，本章设计了时频外部双向 Mamba 架构，利用语音的历史和未来信息捕获全局依赖关系, 并引入 Inception 深度卷积模块对大卷积核进行分解以降低计算开销。该方法采用并行的幅度-相位掩码解码器预测纯净语音的幅度谱和相位谱。实验结果表明，所提方法在公共数据集和自建课堂数据集上均取得了优异性能。消融实验系统验证了各关键模块和损失函数的有效性。本章研究为基于 Mamba 的语音增强方法提供了新的思路，也为课堂语音增强的实际应用提供了有效解决方案。

第 4 章 基于双路径 Mamba+的轻量化课堂语音增强方法

本章提出基于双路径 Mamba+的轻量化课堂语音增强方法。首先介绍子频带双路径 Mamba+时频域语音增强模型的整体架构，其次详细阐述 Mamba+模块、子频带编解码器及 Fast Griffin-Lim 算法等关键技术，最后通过对比实验和消融实验验证所提方法的轻量化优势。

4.1 引言

在真实课堂环境下，课堂音视频采集设备如智能录播系统、教学一体机、便携式录音设备等通常配备有限的计算资源和内存容量，而现有的深度学习语音增强模型参数量大、计算复杂度高，难以在这些资源受限的边缘设备上高效运行。此外，现有方法通常采用全频带统一处理策略，忽视了人耳听觉系统对不同频段的差异化感知特性，特别是在对语音质量至关重要的低频区域建模精度不足，导致增强后语音的自然度下降。针对上述问题，本章提出了基于双路径 Mamba+的轻量化课堂语音增强方法，在编解码器中引入子频带处理策略，对低频段保持高分辨率以确保语音自然度，对高频段进行下采样以降低计算复杂度，同时设计改进的 Mamba+模块通过遗忘门机制延长有效记忆范围以更好地保留课堂长时语音的上下文信息，采用双路径结构分别在时间和频率维度建模，其中频率建模使用双向 Mamba+充分捕获频谱结构，时间建模使用单向 Mamba+保证模型的紧凑性和高效性，并引入卷积门控线性单元增强通道融合和 Griffin-Lim 算法优化相位谱。实验结果表明，所提方法在保持竞争力增强性能的同时，仅需极少的参数量和计算量，实现了性能与效率的良好平衡，适合部署于资源受限的课堂语音增强场景。

4.2 模型设计

4.2.1 模型概述

本章提出的子频带双路径 Mamba+的时频语音增强模型采用编解码器架构，如图 4.1 所示。模型处理语音过程与小节 3.2.1 中类似，不同点在于使用的是轻

量化编解码器及双路径 Mamba+模块，最后在 iSTFT 阶段引入 Fast Griffin-Lim 算法（FGLA）进一步增强语音。

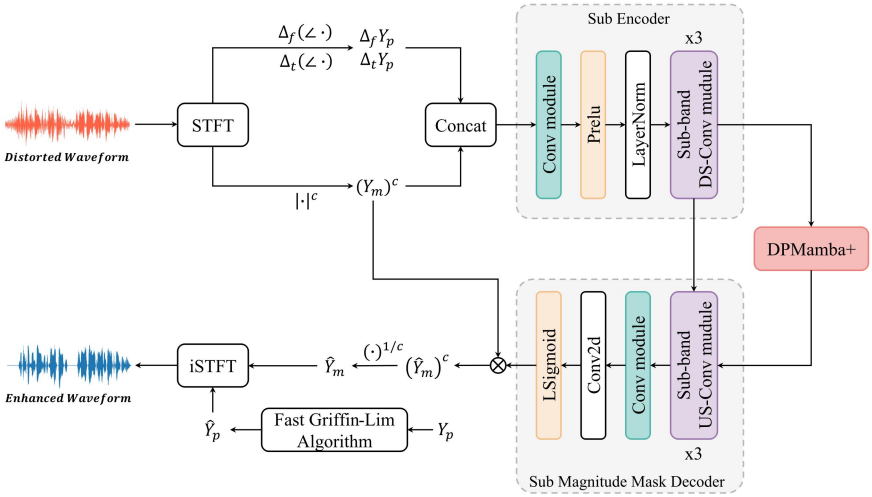


图 4.1 子频带双路径 Mamba+的时频语音增强网络结构

4.2.2 子频带编码器

子频带编码器负责将输入的时频域特征逐层压缩为紧凑的潜在表征。编码器由一个初始卷积模块和三个子频带下采样卷积模块组成，通过逐步降低频率维度来提取多尺度特征表示，同时利用跳跃连接将中间特征传递给解码器。

输入特征首先经过初始卷积模块进行通道维度扩展。该模块采用1×1卷积核，将输入通道数从 2（幅度谱和相位差）扩展到 4 个通道，在不改变时频分辨率的情况下增加特征表达能力。卷积层之后接层归一化对特征进行标准化处理，稳定训练过程。层归一化在通道维度和频率维度上计算统计量并进行归一化，使不同频段的特征分布保持一致。随后通过参数化修正线性单元激活函数引入非线性，该激活函数的形式如公式（4.1）所示，

$$\mathrm{PRELU}(x) = \max(0, x) + a \cdot \min(0, x), \tag{4.1}$$

其中 a 为每个通道独立学习的参数。相比传统 ReLU，参数化修正线性单元允许负值以可学习的斜率通过，避免神经元死亡问题，提高模型的表达能力。

经过初始特征提取后，编码器采用三个级联的子频带下采样卷积模块逐步降低频率分辨率。每个子频带下采样卷积模块将频率轴划分为低频段和高频段两个区域，对不同频段施加差异化处理策略。具体而言，模块首先确定低频段的边界，默认将频率轴的前四分之一划分为低频段，剩余部分为高频段。对于

低频段，采用卷积核大小为2×3、步长为1×1的二维卷积，保持频率维度不变，确保低频信息的完整保留。对于高频段，采用卷积核大小为2×5、步长为1×3的二维卷积进行下采样，将高频部分的频率分辨率降低为原来的三分之一。在卷积操作前，对输入特征进行常数填充，在时间维度上填充 1 帧，在频率维度两侧各填充 1 个频点，保证卷积后的时间维度保持因果性，频率维度尺寸符合预期。低频和高频两路卷积的输出在频率维度上拼接，得到频率维度减半的特征图，整体下采样因子为 2。拼接后的特征经过层归一化和参数化修正线性单元激活，完成一次子频带下采样操作。

第一个子频带下采样卷积模块将通道数从 4 扩展到 8，同时将频率维度从 257 降低到 128。该层的低频段包含前 64 个频点，高频段包含后 193 个频点，经过差异化卷积处理后拼接得到 128 个频点的输出特征。输出特征通过跳跃连接传递给解码器的对应层，为后续重建提供细节信息。第二个子频带下采样卷积模块将通道数从 8 扩展到 12，频率维度从 128 降低到 64。该层处理的低频段为前 32 个频点，高频段为后 96 个频点，下采样后输出同样通过跳跃连接传递。第三个子频带下采样卷积模块将通道数从 12 扩展到 16，频率维度从 64 降低到 32。经过三次下采样，原始 257 个频点的频率维度被压缩为 32 个频点，频率压缩比达到 8 倍，显著降低了后续处理的计算量。

这种层次化的编码设计结合了频率感知和计算效率优化两方面考虑。通过在每个下采样阶段保持低频段的完整分辨率，编码器能够精确捕获对语音质量至关重要的低频信息，包括基频、低频共振峰等关键特征。同时，对高频段进行激进下采样减少了特征图尺寸，降低了存储和计算开销。跳跃连接机制使解码器能够直接访问编码器不同层级的特征，将高级语义信息与低级细节信息有机结合，为精确的幅度掩码和相位估计提供了丰富的多尺度特征支持。编码器最终输出三个尺度的特征图，分别对应频率维度为 128、64 和 32 的中间表征，这些特征将作为解码器跳跃连接的输入，同时频率维度为 32 的最终输出将送入后续的双路径 Mamba+模块进行全局时频建模。

4.2.3 时频双路径 Mamba+模块

编码器通过逐层下采样将输入的时频特征压缩为紧凑的潜在表征，但这些特征仅经过局部卷积操作提取，尚未充分建模时间序列和频率维度的长距离依赖关系。课堂教师授课语音具有显著的长时连续性特征，一个完整的讲解片段

往往持续数秒甚至数十秒，句子之间、段落之间存在紧密的语义关联和韵律延续。例如，教师在阐述一个概念时，前面的定义、中间的解释和后面的举例构成连贯的逻辑链条，当前时刻语音的准确恢复需要依赖较长历史窗口的上下文信息。同时，语音信号的频谱结构也呈现出复杂的频带间相关性，低频段包含基频和主要共振峰信息，高频段包含辅音和细节特征，不同频带的能量分布和相位关系共同决定了语音的音色和清晰度。因此，需要一个既能高效处理长序列，又能准确捕获全局时频依赖关系的建模模块，为后续的掩码估计和相位重建提供高质量的特征表示。

第三章提出的外部双向 Mamba 通过前向和后向两个 Mamba 块并行处理，能够同时利用历史和未来信息捕获全局依赖关系，在离线语音增强任务中取得了优异性能。然而，原始 Mamba 块在处理长时语音序列时仍存在历史信息保留不足的问题。本文的 Mamba 块都采用双分支结构，第一分支将输入特征依次通过一维卷积模块和选择性状态空间模型进行处理，一维卷积捕获局部时序模式，状态空间模型负责建模长距离依赖关系。第二分支将输入特征送入 SiLU 激活函数生成门控信号，用于过滤第一分支的输出。虽然状态空间模块能够保留较长期的历史信息，但其输出会直接被门控信号过滤，这种机制倾向于优先保留近端信息而削弱远程历史信息。在轻量化课堂语音增强场景中，这一问题更为突出，因为模型参数受限且在时间维度采用单向因果建模，无法利用未来信息进行补偿，完全依赖历史上下文来估计当前时刻的纯净语音特征，对长时记忆能力的要求更高。为此，本章在第三章外部双向 Mamba 的基础上进一步改进，提出 Mamba+模块，通过引入遗忘门机制增强对长时历史信息的保留能力，使模型在参数受限的约束下仍能准确捕获课堂语音的长距离依赖关系。双路径 Mamba+网络结构如图 4.2 所示。

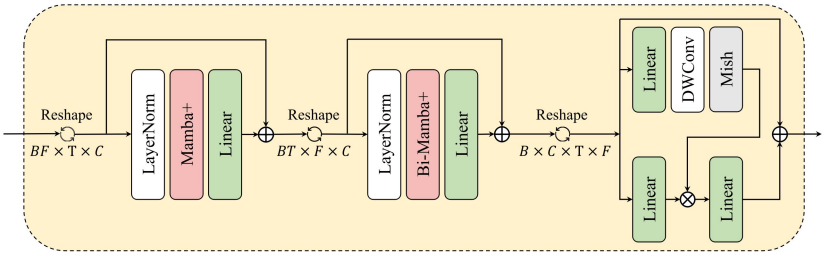


图 4.2 双路径 Mamba+块网络结构

Mamba+的核心改进在于引入遗忘门机制，通过互补的门控策略选择性地组合新特征与历史特征。如图 4.3 所示，Mamba+在原始 Mamba 双分支结构的

基础上，增加了一条从一维卷积输出到最终输出的直接通路。在第二分支中，输入特征经过线性层得到中间表示 z，该表示同时用于计算原门控信号和遗忘门信号。原门控信号通过公式（4.2）计算得到：

$$gate_{b2} = \sigma(z), \tag{4.2}$$

其值域在 0 到 1 之间，用于控制状态空间模型输出的保留程度。遗忘门信号则定义公式（4.3）：

$$gate_f = 1 - \sigma(z), \tag{4.3}$$

与原门控信号形成严格的互补关系，两者之和恒为 1。当原门控倾向于抑制状态空间模型的输出时，即 $\sigma(z)$ 较小，遗忘门 $gate_f$ 相应增大，反之亦然。这种设计确保了信息流的守恒，避免了简单门控可能导致的信息丢失。Bi-Mamba+网络结构如图 4.4 所示。

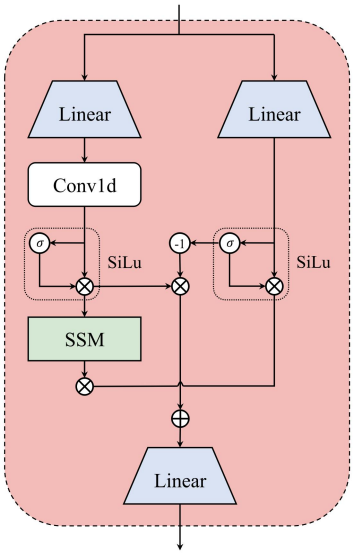


图 4.3 Mamba+结构图

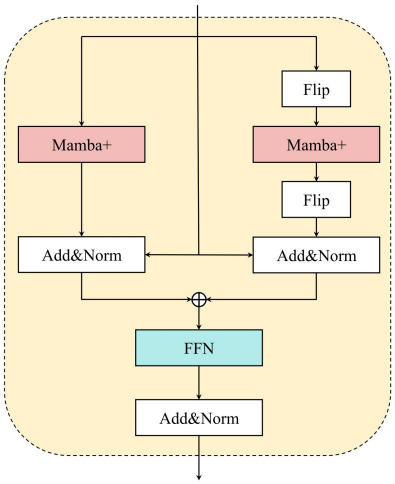


图 4.4 Bi-Mamba+结构图

在特征融合阶段，Mamba+同时利用两个门控信号对不同来源的特征进行加权组合。第一分支中，状态空间模型的输出 y 经过 SiLU 激活后的门控信号进行过滤，得到 $y \otimes \mathrm{SILU}(z)$，其中 $\otimes$ 表示逐元素乘法，$\mathrm{SILU}(z) = z/(1+\exp(-z))$。第一分支中一维卷积模块的输出 x' 则与遗忘门 $gate_f$ 相乘，得到 $x' \otimes gate_f$。最终输出通过将两部分相加得到，即 $y' = y \otimes SILU(z) + x' \otimes gate_f$。这种加法融合方式使得模型能够根据输入内容自适应地平衡长期历史信息和局部新特征。当遇到需要依赖长时上下文的语音片段时，状态空间模型的输出权重增大，充分利用其积累的历史信息。当遇到局部特征更为关键的片段时，一维卷积的输出权重增大，强化对当前邻域模式的捕获。两者以互补方式协同工作，既保留了状态空间模型建模长距离依赖的优势，又融合了卷积提取局部特征的能力，在更长的时间范围内保持对历史上下文的记忆，特别适合处理课堂教师语音中常见的长句连续发音场景。

在 Mamba+模块的基础上，本章采用双路径建模策略分别对时间维度和频率维度进行序列建模，充分捕获语音信号在两个维度上的依赖关系。编码器输出的特征图 M 维度为 (B,C,T,F')，其中 B 为批大小，C 为通道数，T 为时间帧数，F' 为压缩后的频率维度。双路径建模首先在时间维度上进行单向因果建模，然后在频率维度上进行双向建模，两个建模阶段通过特征图的重塑操作实现维度转换。

时间建模阶段负责捕获每个频带内的时序演化模式。将特征图 M 从 (B,C,T,F') 维度重塑为 (BF',T,C)，即将批维度和频率维度合并，使每个频带的时间序列能够独立处理。此时，输入可以看作 BF' 个长度为 T 的序列，每个

序列的特征维度为C。这些序列被送入时间 Mamba+块进行处理，该模块采用单向结构，仅包含前向 Mamba+模块，不包含后向分支。单向设计是为了保证模型的因果性和紧凑性，降低计算复杂度。在因果建模中，系统在 t 时刻只能访问 t 时刻及之前的历史信息，而无法获取 t+1 时刻及之后的未来信息，因此必须采用因果卷积和单向状态空间模型。时间 Mamba+块中的一维卷积采用因果填充，即仅在时间维度的左侧进行填充，确保当前时刻的输出不依赖未来输入。状态空间模型按照时间顺序递归计算，每个时刻的隐藏状态仅由前一时刻的隐藏状态和当前输入决定。经过时间 Mamba+块处理后，每个频带的时间序列都完成了长距离时序依赖关系的建模，捕获了语音信号在时间维度上的演化规律，如语音的起始、持续和衰减过程，以及不同音素之间的过渡模式。输出特征与输入特征进行残差连接，缓解梯度消失问题并促进信息流动，随后通过层归一化稳定特征分布。时间建模的输出特征随即重塑回(B,C,T,F')的原始维度，为后续的频率建模做准备。

频率建模阶段负责捕获每个时间帧内不同频带之间的相关性。将时间建模后的特征图从(B,C,T,F')维度重塑为(BT,F',C)，即将批维度和时间维度合并，使每个时间帧的频率序列能够独立处理。此时，输入变为BT个长度为F'的序列，每个序列代表某一时刻的频谱分布。与时间建模不同，频率维度不存在严格的因果性约束，语音的频谱结构是在同一时刻同时存在的，低频和高频之间可以相互参考。因此，频率 Mamba+块采用完整的双向结构，包含前向和后向两个 Mamba+模块。前向 Mamba+按照从低频到高频的顺序处理频率序列，捕获低频对高频的影响，例如基频对高次谐波的约束关系。后向 Mamba+块按照从高频到低频的顺序处理，捕获高频对低频的反馈，例如高频辅音信息对低频能量分布的调制。两个 Mamba+模块的输出通过逐元素加法进行融合，综合了双向的频谱上下文信息，使每个频点的特征表示同时包含了来自低频段和高频段的参考信息。融合后的特征与输入进行残差连接并经过层归一化，然后送入前馈网络进一步提取非线性特征。前馈网络由两个线性层和一个 GELU 激活函数组成，第一个线性层将特征维度扩展，增强表达能力，第二个线性层将维度恢复，输出经过残差连接和层归一化后得到频率建模的最终输出。该输出重塑回(B,C,T,F')维度，完成一次完整的时频双路径建模。

在时间和频率两个建模阶段之间，引入卷积门控线性单元作为通道混合器，增强不同特征通道之间的信息交互。卷积门控线性单元首先通过线性层对特征

进行通道维度的变换，然后应用深度可分离卷积聚合每个通道内的邻近信息，深度可分离卷积在每个通道上独立进行卷积操作，相比标准卷积大幅降低了参数量和计算量。卷积后的特征通过 Mish 激活函数生成门控信号，Mish 函数定义为公式（4.4）：

$$\mathrm{Mish}(x) = x \cdot \tanh(\ln(1+\exp(x))), \tag{4.4}$$

其平滑的非线性特性有利于梯度的稳定传播。门控信号对特征进行逐元素调制，实现细粒度的通道注意力，使模型能够自适应地强化重要通道、抑制冗余通道。卷积门控线性单元有效融合了不同通道捕获的互补信息，提升了特征的判别能力和鲁棒性。

整个时频双路径 Mamba+模块可以堆叠多次以增强建模能力，本章默认堆叠 2 次。每次堆叠包含一次完整的时间建模、通道混合和频率建模过程，多层堆叠使模型能够在不同抽象层次上建模时频依赖关系。第一层关注局部的时频模式，捕获短时音素特征和邻近频带的能量分布。第二层在第一层的基础上捕获更长时间跨度的韵律变化和更宽频率范围的频谱结构。经过时频双路径 Mamba+模块处理后，特征图在时间和频率两个维度上都完成了全局依赖关系的建模，既通过单向时间建模保留了因果性约束下的长时历史上下文，又通过双向频率建模充分利用了频谱的完整结构信息，为后续解码器生成准确的幅度掩码和相位估计提供了高质量的全局时频表示。

4.2.4 子频带幅度掩码解码器

解码器通过三个子频带上采样卷积模块将频率维度从 32 逐步恢复到 64、128 和 257，并最终预测幅度掩码。每个上采样模块在处理前，先与编码器对应层级的特征在通道维度上拼接，融合局部细节和全局语义信息。

子频带上采样卷积采用与下采样对称的非均匀处理策略。将频率轴的前四分之一划分为低频段，剩余部分为高频段。对于低频段，采用卷积核大小为 2×3、步长为 1×1 的二维卷积，保持频率维度不变。对于高频段，使用卷积核大小为 2×5 的二维卷积生成中间特征，然后通过因子为 3 的子像素重排操作将频率维度扩展为原来的三倍。子像素卷积通过周期性重排特征图元素实现分辨率提升，避免了转置卷积的棋盘效应。低频和高频两路输出在频率维度上拼接，经过层归一化和参数化修正线性单元激活后，完成一次上采样操作，整体上采样因子为 2。

三个上采样模块级联工作。第一个模块将频率维度从 32 上采样到 64，通道数从 16 降至 12，低频段 8 个频点保持不变，高频段 24 个频点扩展为 72 个频点。第二个模块将频率从 64 上采样到 128，通道数从 12 降至 8，低频段 16 个频点不变，高频段 48 个频点扩展为 144 个频点。第三个模块将频率从 128 恢复到 257，通道数从 8 降至 4，低频段 32 个频点保持分辨率，高频段 96 个频点扩展为 288 个频点，拼接后截取前 257 个频点以匹配输入语音的频率维度。

解码器最后使用二维卷积层将通道数降至 1，得到维度为 $(B,1,T,257)$ 的单通道特征。该特征经过可学习 Sigmoid 激活函数映射为幅度掩码，其定义为公式（4.5）：

$$\mathrm{LSigmoid}(x)=\beta/(1+\exp(-\alpha\cdot x)), \tag{4.5}$$

其中 β 固定为 2，α 为维度 257 的可学习参数向量。可学习 Sigmoid 通过 β 将值域扩展到 0 到 2，允许掩码进行适度的能量放大，α 参数为每个频点独立学习激活函数形状，使模型根据不同频带特性自适应调整掩码动态范围。输出的幅度掩码与输入的压缩幅度谱逐元素相乘，得到增强后的幅度谱估计。

4.2.5 Fast Griffin-Lim 算法

Fast Griffin-Lim 算法是由 Perraudin[80]等人于 2013 年提出的一种高效相位重建算法，用于从短时傅里叶变换（STFT）的幅度谱中估计和重建原始信号。在语音合成和音频处理领域，由于相位信息往往在处理过程中丢失或被忽略，如何从仅有的幅度信息中准确重建原始信号成为一个重要问题。FGLA 通过引入动量机制对传统 Griffin-Lim 算法进行改进，在保证重建质量的同时显著提高了收敛速度，减少了计算迭代次数，使其成为轻量化音频处理应用的理想选择。

FGLA 的核心创新在于利用迭代历史信息来加速收敛过程。算法在每次迭代时不仅考虑当前的投影结果，还结合前后两次迭代之间的变化趋势来动态调整更新步长。具体来说，FGLA 的更新规则如公式（4.6）所示：

$$c_n = Pc_1(Pc_2(c_{n-1}+a_n\Delta c_{n-1})), \tag{4.6}$$

其中 $\Delta c_n = c_n - c_{n-1}$ 表示相邻两次迭代之间的差值，a_n 为动量系数。通过引入动量项 $a_n\Delta c_{n-1}$，算法能够根据当前的收敛趋势自适应地调整步长：当算法朝着正确方向收敛时，动量项会加速这一过程，而当出现振荡时，动量项也能起到平滑作用。这种机制使得算法能够以更大的步长快速接近最优解，从而显著减少所需的迭代次数。相比传统方法通常需要数十甚至上百次迭代，FGLA 仅需少

量迭代即可获得满意的重建质量。

在算法的具体实现中，FGLA 涉及两个关键的投影操作。投影操作 Pc_1 通过完整的 Gabor 分析-合成过程来实现，即先对频域系数进行逆短时傅里叶变换得到时域信号，再对该信号进行短时傅里叶变换得到新的系数，这个过程保证了系数满足一致性准则。投影操作 Pc_2 则保持目标幅度不变的同时更新相位信息，即将系数的幅度替换为目标幅度而保留其相位角。这两个投影操作的交替执行，结合动量更新机制，构成了 FGLA 的核心迭代过程。

在本章中，FGLA 算法首先对输入的幅度谱进行解压缩处理。由于在特征提取阶段对幅度谱进行了压缩以改善其动态范围特性，因此在相位重建之前需要通过取指数运算将其还原到线性尺度，恢复原始的幅度信息。随后，算法采用随机初始化策略生成初始相位。在每次迭代过程中，算法使用当前的幅度和相位信息构造复数频谱，通过逆短时傅里叶变换重建时域信号，再对重建信号进行短时傅里叶变换得到新的频域表示，然后应用动量更新策略结合前一次迭代结果进行加权更新，最后从更新后的复数频谱中提取相位角度作为下一次迭代的输入。

4.2.6 损失函数

在语音增强任务中，损失函数的设计对模型的最终性能和感知质量具有重要影响。传统的损失函数通常计算估计频谱与目标频谱之间的 Lp 范数距离，但这种方法可能无法充分反映语音信号的感知质量。考虑到轻量级模型由于参数量较少，难以完全拟合复数域或相位域的复杂特征，本研究选择专注于对感知质量更为关键的幅度谱信息，设计了一致性幅度损失（Consistency Magnitude Loss，$L_{MagConsis.}$）作为训练目标。

一致性幅度损失的核心思想源于对短时傅里叶变换空间特性的深入理解。短时傅里叶变换空间与经过逆短时傅里叶变换后的实际语音信号空间之间存在本质差异。传统的基于复数域的方法通过计算经过逆短时傅里叶变换和短时傅里叶变换两次变换后的复数频谱与网络输出的复数频谱之间的最小距离来实现一致性约束，确保模型输出的频谱在时频域转换中保持一致。受此启发，本研究提出了一种更直接的方法：直接计算经过两次短时傅里叶变换后的语音幅度谱与干净语音幅度谱之间的最小距离，将优化目标集中在幅度信息上。具体而言，一致性幅度损失函数定义为公式（4.7）：

$$L_{\text{MagConsis.}} = \mathbb{E}_{(Y_m, Y_{consis})}\left[\left\|Y_m - Y_{consis}\right\|_2^2\right], \tag{4.7}$$

其中，Y_m 表示干净语音的幅度谱，Y_{consis} 表示模型估计的幅度谱经过逆短时傅里叶变换重建为时域信号后，再次通过短时傅里叶变换得到的幅度谱。该损失函数通过最小化这两个幅度谱之间的 L2 距离，确保模型输出的频谱在经过时域转换后仍能保持与目标频谱的一致性。

此外，为了进一步提升模型在客观评价指标上的表现，本研究还引入了度量损失（Metric Loss，L_{Metric}）。度量损失通过判别器网络将客观评价指标（如 PESQ）直接集成到损失函数中，使模型能够针对感知质量评分进行优化。判别器的训练目标是学习预测增强语音与干净语音之间的质量差异，其损失函数定义为公式（4.8）：

$$L_{\text{D}} = \mathbb{E}_{Y_{\text{m}}}\left[\left\|\text{D}(Y_{\text{m}}, Y_{\text{m}}) - 1\right\|_2^2\right] + \mathbb{E}_{(Y_{\text{m}}, Y_{consis})}\left[\left\|\text{D}(Y_{\text{m}}, Y_{consis}) - \text{Q}_{\text{PESQ}}\right\|_2^2\right], \tag{4.8}$$

其中 $\text{D}(Y_{\text{m}}, Y_{\text{m}})$ 表示判别器对干净语音自身的评分，理想情况下应该为 1。$\text{D}(Y_{\text{m}}, Y_{consis})$ 表示判别器对增强语音质量的评估，Q_{PESQ} 是对应的真实 PESQ 分数。通过这种方式，判别器学习到如何准确评估语音质量。

基于训练好的判别器，生成器的度量损失定义为公式（4.9）：

$$L_{\text{Metric}} = \mathbb{E}_{(Y_{\text{m}}, Y_{consis})}\left[\left\|D(Y_{\text{m}}, Y_{\text{consis}}) - 1\right\|_2^2\right], \tag{4.9}$$

该损失促使生成器输出的增强语音能够获得判别器的高分评价，从而间接优化 PESQ 等客观指标。

最终，模型的总损失函数由一致性幅度损失和度量损失加权组合而成，如公式（4.10）所示：

$$L_{\text{G}} = \lambda_1 L_{\text{MagConsis.}} + \lambda_2 L_{\text{Metric}}, \tag{4.10}$$

其中 λ_1 和 λ_2 分别是两种损失的权重系数，用于平衡频谱重建的准确性和感知质量评分的优化。通过调整这两个权重参数，可以在客观指标和主观感知质量之间找到最佳的平衡点。这种多目标损失函数的设计使得模型既能准确重建语音的幅度谱特征，又能在标准化的评价指标上取得优异表现，从而全面提升语音增强的效果。

4.3 实验与分析

4.3.1 实验设置

本章实验使用的操作系统和软件版本与 3.4.1 节相同。在特征提取阶段，同样采用汉宁窗进行短时傅里叶变换，但窗长设置为 512（32 毫秒），跳跃大小设置为 256（16 毫秒）。在网络结构配置方面，编码器和解码器中子频带卷积模块的输出通道数分别设置为{4，8，12，16}和{12，8，4，1}。对于 Mamba+模块，单向 Mamba+的隐藏状态维度设为 24，双向 Mamba+的隐藏状态维度设为 12。双路径 Mamba+模块在网络中堆叠 2 层，FGLA 算法的迭代次数设为 2，动量系数设为 0.99。损失函数方面，一致性幅度损失和度量损失的权重系数 λ_1 和 λ_2 分别设置为 0.09 和 0.05。训练过程采用 AdamW 优化器，总训练周期为 100，批量大小设为 4。为防止梯度爆炸，梯度裁剪的 L2 范数阈值设为 5.0。学习率初始值设为 5×10^{-4} ，并在每个训练周期以 0.98 的衰减因子进行递减。

4.3.2 对比实验

为了全面评估本章提出的轻量级语音增强方法的性能，在 VoiceBank+DEMAND 数据集上与多个具有代表性的轻量级语音增强模型进行了对比实验。

FullSubNet 是一个开创性的全频带和子频带融合模型，通过串联连接全频带模型和子频带模型来捕获全局频谱信息和局部频谱模式。Fast FullSubNet 在此基础上进行了大幅优化，通过在梅尔频域进行子频带处理并采用下采样策略，将计算复杂度降至原模型的 13%。DeepFilterNet 采用感知驱动的两阶段增强策略，第一阶段使用 ERB 尺度增益增强频谱包络，第二阶段使用深度滤波技术增强周期性语音成分。CCFNet+(Lite)采用轻量级的两阶段复数频谱增强网络，利用可学习的复数矩形带宽滤波器组提取紧凑特征，并引入跨阶段跳跃连接和复数注意力机制。FSPEN 是一个超轻量级模型，通过全频带和子频带融合架构以及帧间路径扩展方法，代表了当前轻量级语音增强模型的先进水平。

表 4.1 展示了各模型在 VoiceBank+DEMAND 数据集上的详细对比结果。从表中可以看出，未经处理的带噪语音的 WB-PESQ 为 1.97，STOI 为 0.921。在对比模型中，FullSubNet 取得了 2.89 的 WB-PESQ，但其 5.64M 参数量和 30.87G 计算复杂度相对较高。Fast FullSubNet 将计算复杂度降至 4.14G，但参数量仍为

6.84M。DeepFilterNet 使用 1.80M 参数和 350M 计算复杂度，在计算效率和性能之间取得了良好平衡。CCFNet+(Lite)将参数量压缩至 160K，展现了优秀的轻量化设计能力。FSPEN 在 79K 参数和 89M 计算复杂度下实现了 2.97 的 WB-PESQ。相比之下，本章方法使用 49K 参数和 68M 计算复杂度，取得了 3.13 的 WB-PESQ 和 0.942 的 STOI，在所有对比模型中实现了最优性能。

具体而言，与参数量最接近的 FSPEN 相比，本章方法的参数量减少了 38%，计算复杂度降低了 24%，同时 WB-PESQ 提升了 0.16，SI-SDR 提升了 2.5 dB。与 CCFNet+(Lite)相比，参数量降至其 30.6%，计算复杂度为其 17.4%，而 WB-PESQ 提升了 0.19。与 DeepFilterNet 相比，参数量仅为其 2.7%，计算复杂度为其 19.4%，但 WB-PESQ 提升了 0.32，充分展现了本章方法在极致轻量化条件下的卓越性能。

表 4.1 在 VoiceBank+DEMAND 上的指标对比

模型	参数量	Macs	WB-PESQ	STOI
Noisy	-	-	1.97	0.921
FullSubNet*(2021)[73]	5.64M	30.87G	2.89	0.940
DeepFilterNet(2022)[24]	1.80M	350M	2.81	0.942
Fast FullSubNet*(2022)[81]	6.84M	4.14G	2.79	0.935
CCFNet+(Lite)(2023)[82]	160K	390M	2.94	-
FSPEN(2024)[83]	79K	89M	2.97	0.942
IEDM-TFNet	2.63M	34G	3.61	0.963
本章方法	49K	68M	3.13	0.942

本章进一步在 DNS Challenge 2020 数据集上与多个代表性语音增强模型进行了对比实验。

PoCoNet 采用频率位置嵌入的 2D U-Net 架构结合 DenseNet 块和自注意力机制，通过半监督学习扩充对话数据，但 50M 参数量限制了其实际应用。FullSubNet+引入多尺度时间敏感通道注意力模块，使用幅度谱、实部和虚部充分利用相位信息，通过 TCN 块替代 LSTM 提升效率。FS-CANet 提出全频带-子带交叉注意力模块实现全局和局部信息的深度交互融合，显著提升了特征融合效果。Inter-SubNet 创新性地通过子带交互模块直接提取全局频谱信息，避免了引入独立的全频带模型。SICRN 将状态空间模型与原位卷积相结合，避免下采样操作保留原始特征完整性，且作为因果网络不依赖未来帧信息。

表 4.2 展示了各模型的对比结果。未经处理的带噪语音 WB-PESQ 为 1.58, STOI 为 91.52%。PoCoNet 虽取得 2.75 的 WB-PESQ，但参数量达 50M。FullSubNet+以 8.67M 参数实现 2.98 的 WB-PESQ 和 96.69%的 STOI。FS-CANet 将参数量压缩至 4.21M, 取得 3.02 的 WB-PESQ 和 96.74%的 STOI。Inter-SubNet 以 2.29M 参数实现 3.00 的 WB-PESQ 和 96.61%的 STOI。SICRN 使用 2.16M 参数取得 2.62 的 WB-PESQ 和 95.83%的 STOI。相比之下，本章方法仅用 49K 参数便取得 3.13 的 WB-PESQ 和 96.34%的 STOI, 以最少的参数量实现了最优或接近最优的性能。

与参数量最接近的 SICRN 相比，本章方法参数量仅为其 2.3%，WB-PESQ 和 STOI 分别提升 0.51 和 0.51%。与性能优异的 FS-CANet 相比，参数量降至其 1.2%，WB-PESQ 仍提升 0.11。这充分证明了本章方法在极致轻量化条件下仍能保持卓越的增强性能。

表 4.2 DNS Challenge 2020 上的指标对比

模型	参数量	WB-PESQ	NB-PESQ	STOI(%)
Noisy	-	1.58	2.45	91.52
PoCoNet(2020)[84]	50M	2.75	-	-
FullSubNet+(2022)[85]	8.67M	2.98	3.50	96.69
FS-CANet(2022)[86]	4.21M	3.02	3.51	96.74
Inter-SubNet(2023)[87]	2.29M	3.00	3.50	96.61
SICRN(2024)[88]	2.16M	2.62	3.23	95.83
IEDM-TFNet	2.63M	3.63	3.93	98.09
本章方法	49K	3.13	3.62	96.34

最后，为了验证本章方法在更复杂场景下的表现，在自建数据集上进行了对比实验，结果如表 4.3 所示。从表 4.3 可以看出，未处理语音的 WB-PESQ 为 1.52，STOI 为 0.881。FullSubNet 在该数据集上的 WB-PESQ 降至 2.61，STOI 为 0.913，相比公开数据集性能明显下降。DeepFilterNet 取得 2.54 的 WB-PESQ, STOI 为 0.917。值得注意的是, Fast FullSubNet 尽管参数量达 6.84M, 但 WB-PESQ 仅为 2.46，表现不及原始 FullSubNet，这可能与其在梅尔频域的处理方式在复杂噪声环境下的适应性有关。CCFNet+(Lite)和 FSPEN 分别取得 2.73 和 2.85 的 WB-PESQ。本章方法以 49K 参数达到 3.06 的 WB-PESQ 和 0.931 的 STOI。对比分析显示，本章方法相比 FSPEN，WB-PESQ 提升达 0.21，这一提升幅度在自建

数据集上尤为显著。相比参数量更大的 DeepFilterNet(1.80M)，性能优势达 0.52。实验结果表明，本章方法在面对复杂声学环境时展现出更强的鲁棒性和适应能力。

表 4.3 在自建数据集上的指标对比

模型	参数量	Macs	WB-PESQ	STOI
Noisy	-	-	1.52	0.881
FullSubNet*(2021)[73]	5.64M	30.87G	2.61	0.913
DeepFilterNet(2022)[24]	1.80M	350M	2.54	0.917
Fast FullSubNet*(2023)[81]	6.84M	4.14G	2.46	0.905
CCFNet+(Lite)(2023)[82]	160K	390M	2.73	0.924
FSPEN[83]	79K	89M	2.85	0.929
IEDM-TFNet	2.63M	34G	3.11	0.928
本章方法	49K	68M	3.06	0.931

4.3.3 消融实验

为了验证本章方法中各组件的有效性，在 VoiceBank+DEMAND 数据集上进行了消融实验，结果如表 4.4 所示。首先对模型的核心模块进行了消融研究。将子带卷积替换为普通卷积（w/o sub-band Conv）后，参数量从 49K 降至 40K，WB-PESQ 从 3.13 下降至 3.05，STOI 从 0.942 降至 0.940。移除 ConvGLU 模块（w/o ConvGLU）使参数量降至 43K，WB-PESQ 降至 3.02，STOI 降至 0.939。冻结 LSigmoid 中的可学习参数 (w/o LSigmoid) 后，WB-PESQ 降至 3.11，STOI 降至 0.941。这些结果验证了各模块的必要性。其次研究了 DPMamba+模块数量 N 的影响。完全移除 DPMamba+模块（w/0 DPMamba+）时，参数量仅 15K，但 WB-PESQ 急剧下降至 2.75，STOI 降至 0.920，说明 DPMamba+是核心组件。使用 1 层 DPMamba+时，参数量 32K，WB-PESQ 为 3.04，STOI 为 0.937。当 N=2 时，参数量 49K，WB-PESQ 达到 3.13，STOI 为 0.942。增加到 3 层时，参数量 67K，WB-PESQ 为 3.12，STOI 为 0.943，性能提升已不明显。使用 4 层时，参数量增至 84K，WB-PESQ 保持 3.13，STOI 反而下降至 0.941。综合考虑，N=2 是最佳选择，在 49K 参数和 68M 计算复杂度下实现了 3.13 的 WB-PESQ 和 0.942 的 STOI，继续增加层数会带来参数和计算量的显著增加，但性能提升有限。

表 4.4 核心模块消融实验

模型	参数量	Macs	WB-PESQ	STOI
w/o sub-band Conv	40K	65M	3.05	0.940

w/o ConvGLU	43K	59M	3.02	0.939

续表 4.4 核心模块消融实验

模型	参数量	Macs	WB-PESQ	STOI
w/o LSigmoid	49K	68M	3.11	0.941
w/ 0 DPMamba+	15K	26M	2.75	0.920
w/ 1 DPMamba+	32K	47M	3.04	0.937
w/ 2 DPMamba+	49K	68M	3.13	0.942
w/ 3 DPMamba+	67K	88M	3.12	0.943
w/ 4 DPMamba+	84K	109M	3.13	0.941
本章方法	49K	68M	3.13	0.942

最后，本章验证了 FGLA 对相位重建的有效性，结果如表 4.5 所示。直接使用带噪相位（FGLA(Noisy Phase)）时，WB-PESQ 仅为 3.07。应用 FGLA 后，性能得到显著提升。当 k=1 时，WB-PESQ 提升至 3.10。将迭代次数增加到 k=2 时，WB-PESQ 进一步提升至 3.13。继续增加到 k=3 时，性能不再提升，保持在 3.13。整个实验过程中，不同迭代次数的参数量和计算复杂度均保持在 49K 和 68M。实验结果表明，2 次迭代（k=2）对于性能收敛已经足够。

表 4.5 FGLA 迭代次数 k 对模型的性能影响

模型	参数量	Macs	WB-PESQ	STOI
FGLA(Noisy Phase)	49K	68M	3.07	0.942
FGLA(k=1)	49K	68M	3.10	0.942
FGLA(k=2)	49K	68M	3.13	0.942
FGLA(k=3)	49K	68M	3.13	0.942
本章方法	49K	68M	3.13	0.942

4.4 本章小结

本章针对课堂语音增强场景，提出了基于子频带双路径 Mamba+的轻量化时频域语音增强方法。针对现有方法计算复杂度高、参数量大以及长时记忆能力不足的问题，本章设计了子频带编解码器架构，对低频段保持高分辨率以确保语音自然度，对高频段进行下采样以降低计算开销。在此基础上，提出了改进的 Mamba+模块，通过引入遗忘门机制增强对长时历史信息的保留能力，并

采用双路径建模策略，在时间维度使用单向 Mamba+保证模型的紧凑性和高效性，在频率维度使用双向 Mamba+充分捕获频谱结构。此外，引入卷积门控线性单元增强通道融合，并采用 Fast Griffin-Lim 算法优化相位重建，进一步降低计算开销。实验结果表明，本章方法在公开和自建课堂数据集上均取得了优异性能，以极少的参数量和计算量实现了显著的语音质量提升。消融实验验证了子频带卷积、卷积门控线性单元等关键模块的有效性，双路径 Mamba+模块堆叠两层时达到最佳性能平衡。本章研究实现了增强性能与计算效率的良好平衡，适合部署于资源受限的边缘设备，为低配置教学设备上的语音增强提供了可行的技术方案。

第 5 章 实录课堂语音增强与转录系统开发及应用

本章节重点完成实录课堂语音增强与转录系统的搭建工作，具体说明系统从设计到落地的全过程，内容涉及需求分析、架构设计、功能实现以及界面布局等核心环节系统把实现高质量课堂语音增强与精准语音转录当作核心任务，借助最新语音增强算法与语音识别模型的融合技术，给实录课堂教学视频配备智能音频处理和文本转写功能。设计阶段，系统在功能完备性和使用体验之间做了较好平衡，目的是构建简洁易用的操作界面使用者能够借助该界面便捷地上传课堂教学视频，系统会自动对语音增强处理工作，同时快速输出精确的语音转录文本结果，让教学音频处理在效率和便利性上都有明显改善。系统围绕实录课堂教学这一场景展开，流程覆盖视频上传、语音提取、降噪处理、语音识别到文本生成的完整链条系统按照模块化思路完成搭建，把语音增强模块和语音转录模块进行整合，依托后端算法改进来保证音频增强效果以及识别结果的准确和稳定。另外，系统也具备转录结果的可视化呈现和多格式导出功能，方便使用者后续分析课堂内容和评估教学效果。借助本系统，教师和教研人员既能获得清晰的课堂音频，也能得到准确的语音转录文本，还能根据识别结果详细分析教学语言使用状况、课堂互动特点等反映教学质量的指标，给优化教学方法和提高教学效果提供数据依据。

5.1 需求分析

针对实录课堂场景开展的语音处理与识别研究，当前数量还不多，现有工作多围绕语音增强或语音识别做单独开发，未将两者结合，没有把这两项技术整合起来形成面向实际应用的完整方案。当前工作多停留在算法层面，尚未延伸到完整系统的设计与实现，缺少面向用户需求的功能整合、流程改进与体验优化。这让研究成果难以直接服务于实际教育场景，难以为用户提供便捷友好的操作界面，也难以满足教师和研究者在实录课堂音频处理与教学数据分析中的实际需要。实录课堂环境存在特殊的声学特点：教室内通常存在较强的混响效应与多种背景噪声（例如空调声、桌椅摩擦声、学生讨论声等），还有录音设备离说话人较远造成的信噪比偏低等问题。这些因素让语音识别准确率和转录文本可用性都受到很大影响。现有通用语音识别系统通常没有针对这类特定

场景做优化，直接用在实录课堂视频上时识别准确率不高，不能满足教学研究的实际需要。为解决上述问题，本文设计并实现了面向实录课堂的语音增强与转录系统。这套系统整合了先进的语音增强算法与语音识别模型，也充分考虑了用户的实际使用需求，依托功能整合与流程优化，给用户提供一站式的音频处理与文本转写解决方案。

5.2 系统设计

5.2.1 技术难点

（1）深度学习模型的工程化部署

深度学习模型在离线训练阶段通常使用 PyTorch 等研究框架，而实际应用环境需要考虑推理效率、跨平台兼容性和部署便捷性。本系统采用 ONNX (Open Neural Network Exchange）作为中间表示格式，将训练好的 PyTorch 模型导出为 ONNX 格式，实现模型与框架的解耦。在推理阶段，使用 ONNX Runtime 作为推理引擎，相比原生 PyTorch 推理速度提升约 30%，且支持 CPU 和 GPU 的灵活切换。此外，针对模型输入输出的预处理和后处理流程，设计了标准化的接口规范，确保模型在不同环境下的一致性表现。

（2）长时课堂视频的高效处理

实录课堂视频时长通常为 45 至 90 分钟，单个视频文件可能包含数万帧音频数据。如果采用同步处理方式，会导致用户长时间等待，严重影响用户体验。本系统采用异步任务队列机制，利用 Celery 分布式任务框架将视频处理任务提交到后台队列，主线程立即返回任务 ID 给用户。后台 Worker 进程从队列中获取任务并执行处理，处理过程中定期更新任务进度状态，前端通过轮询或 WebSocket 实时获取处理进度并展示给用户。此外，针对长时音频，采用滑动窗口分块处理策略，将完整音频分割为多个重叠的片段（如 2 秒片段，重叠 0.5 秒），分别进行语音增强后再拼接，既保证了处理的连续性，又避免了显存溢出问题。

（3）数据流转与存储机制设计

系统需要管理用户上传的原始视频、提取的音频、增强后的音频以及转录文本等多种数据类型，同时保证数据的安全性和可追溯性。本系统设计了分层存储架构：元数据（如用户信息、任务状态、文件路径）存储在 MySQL 关系

型数据库中，便于结构化查询和事务管理；大文件（如视频、音频）存储在本地文件系统或对象存储服务中，通过唯一标识符关联。为避免重复处理，系统对上传文件计算 MD5 哈希值，相同文件直接返回已有结果。数据生命周期管理方面，设置了自动清理机制，对超过保存期限的临时文件进行定期清理，节省存储空间。

（4）语音增强与自动转录的模块集成

语音增强模块和 ASR 模块属于两个独立的处理环节，需要设计合理的数据传递和错误处理机制。本系统采用管道式处理架构，增强模块的输出直接作为 ASR 模块的输入。在数据格式方面，统一采用 16kHz 采样率的单声道 WAV 格式，避免格式转换带来的质量损失。在错误处理方面，对每个模块的输出进行有效性检查，如增强后的音频信噪比过低或 ASR 模块返回空结果，则记录日志并返回错误信息给用户。此外，针对 ASR 模块可能出现的专业术语识别错误，预留了自定义词典接口，支持后续优化。

5.2.2 系统功能模块设计

本文将系统分为用户登录注册、教师语音增强、教师语音转录三个模块，每个模块包含若干子功能，系统架构图如图 5.1 所示。

用户登录模块包括用户的身份信息登录和注册功能，教师语音增强模块包括课堂视频文件上传、视频音频分离提取、语音增强、增强视频下载功能，教师语音转录模块包括语音识别转录、转录文本格式化、结果可视化展示、数据导出与保存功能。

（1）用户登录模块

该模块承担着用户身份管理工作，具体配置了登录与注册两项核心服务。在登录环节，系统设置了身份验证机制，支持管理员及用户凭账号密码进入系统，以此保障数据安全，维护用户隐私。注册功能服务新用户，账号创建流程较为方便，填写基本信息后即可建立个人账户，系统同步完成信息采集与权限分配，用户建好后马上能用各项功能，系统也借此建立起用户管理与追踪体系。

（2）教师语音增强模块

该模块重点改善课堂录制音频质量，借助专业音频处理流程来完成语音增强。第一步，用户能够上传课堂录制的视频文件，系统支持 MP4、AVI、MOV 这些主流格式。之后，系统借助 ffmpeg 的音视频分离技术，自动从视频里精准

提取高质量音频流，保留原始音频采样率与比特率。下一步，用深度学习降噪算法处理音频背景噪声，智能识别并消除空调声、学生讨论声、设备噪音这类环境干扰，并保留教师语音完整与自然度。最后一步，借助音量归一化、动态范围压缩、音色均衡等技术增强优化音频，提升教师声音响度与清晰度，生成适用于教学的高质量音频文件，让学生获得清晰流畅的听课体验。

（3）教师语音转录模块

该模块负责将课堂语音内容转换为文字形式，给教师提供一套完整的语音转写服务方案，教师提交转录申请之后，系统会立即启动语音识别引擎，把课堂讲解内容准确转成文字，这块既支持普通话、各类方言和中英文混说，也能有效处理教学场景里的专业术语和特定词汇。语音转成文字后，系统利用自然语言处理技术对原始文本做智能排版，自动添加标点符号、划分段落、修正识别错误并调整语句结构，让文本符合书面表达规范，处理好的转录内容会通过直观的可视化界面展示给用户查看，系统最后还提供了灵活多样的数据导出和保存功能。

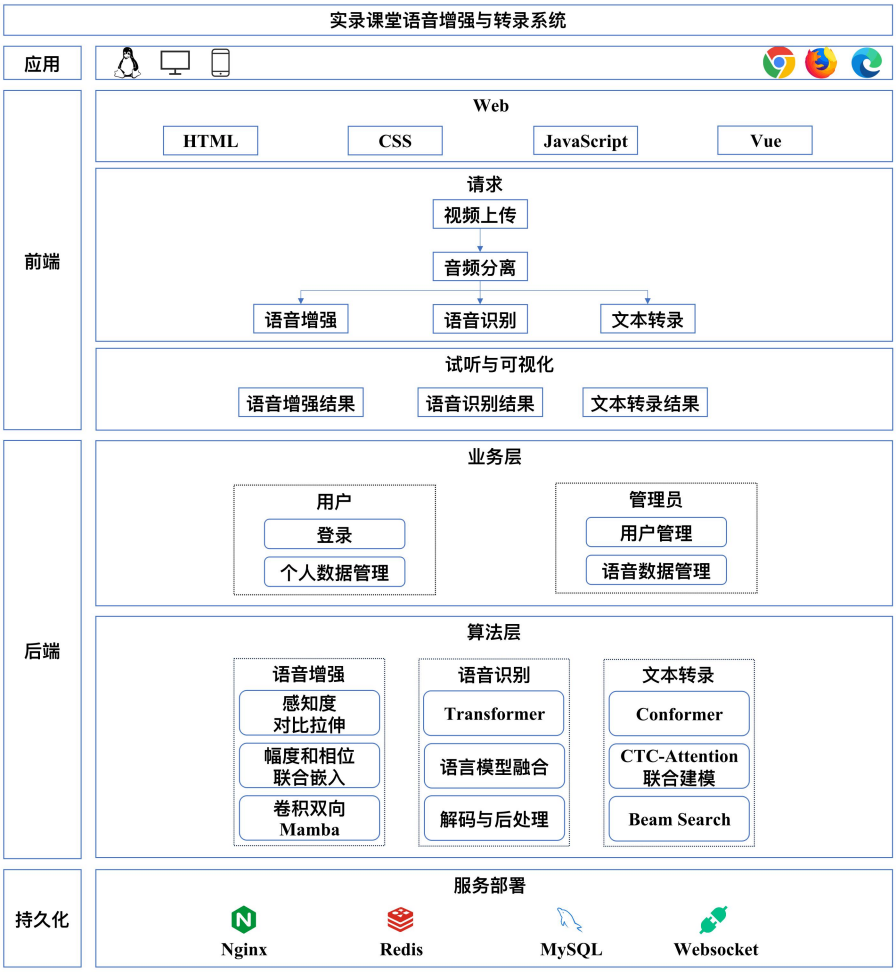


图 5.1 系统架构图

5.2.3 系统流程图设计

本文设计的系统把前端和后端分开搭建，用于完成课堂教学视频的语音优化以及文字转换功能。用户在前端页面上传本地保存的教学视频文件，系统会把这些数据传输到后端模块进行处理后端在接收到视频文件后，先开展音频分离工作，从视频里把音频流抽出来，让视频画面和音频轨道分开，形成单独的音频文件然后进入语音增强阶段，系统对提取出的含噪音频做降噪处理，用深度学习算法找出并去掉背景噪声，同时保住教师语音的完整，产出清晰的音频数据接下来做音量分析，系统对增强后的音频开展音量标准化和动态范围调整，让音频质量满足转录要求，给后面的语音识别任务准备好高质量的音频输入。随后系统开展文本转录操作，调用语音识别引擎把增强后的音频内容转换为文

字文本，再开展格式化处理和错误修正，形成规范化的课堂转录文稿。最后，后端把处理完成的转录结果传回前端模块，借助可视化界面展示给用户，用户能够查看并导出转录文本。系统的流程图如图 5.2 所示。

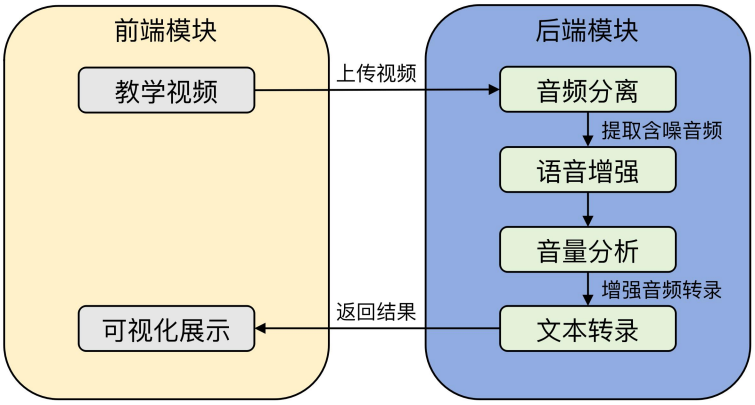


图 5.2 系统流程图

5.3 功能实现及界面展示

本文设计了一个实录课堂语音增强与转录系统，主要用于提升课堂实录音频质量并实现文字转录，面向教师及相关教学管理人员。系统注重简洁易用的界面和高效流畅的操作流程，前端采用 Vue 技术栈构建响应式用户界面，后端基于 FastAPI 框架实现高性能的音频处理服务，集成深度学习语音增强算法和语音识别算法完成核心功能开发。以收集的实录课堂教学视频为例，展示了系统的前端功能界面，包括用户登录注册、视频文件上传、音频分离与增强、语音转录处理、转录结果可视化展示、数据导出与保存等功能模块。

5.3.1 用户登录模块

用户登录模块是实录课堂语音增强与转录系统的安全入口，主要负责用户身份认证与权限管理。系统采用前后端分离架构，前端基于 Vue3、TypeScript 与 Vite 构建响应式登录界面，包含用户名、密码输入、记住密码及登录校验等功能。后端采用 FastAPI 搭建 RESTful API，并结合 JWT 实现身份认证。用户登录时，系统通过 HTTPS 加密传输账号信息，后端使用 BCrypt 对密码进行哈希验证，认证成功后生成 Token 用于后续接口访问。同时，系统结合 RBAC 权限控制机制，实现管理员与教师等不同角色的权限管理，并支持登录状态保持、异常登录检测与操作日志记录，从而提高系统安全性与用户使用体验。系统的

用户登录界面如图 5.3 所示。

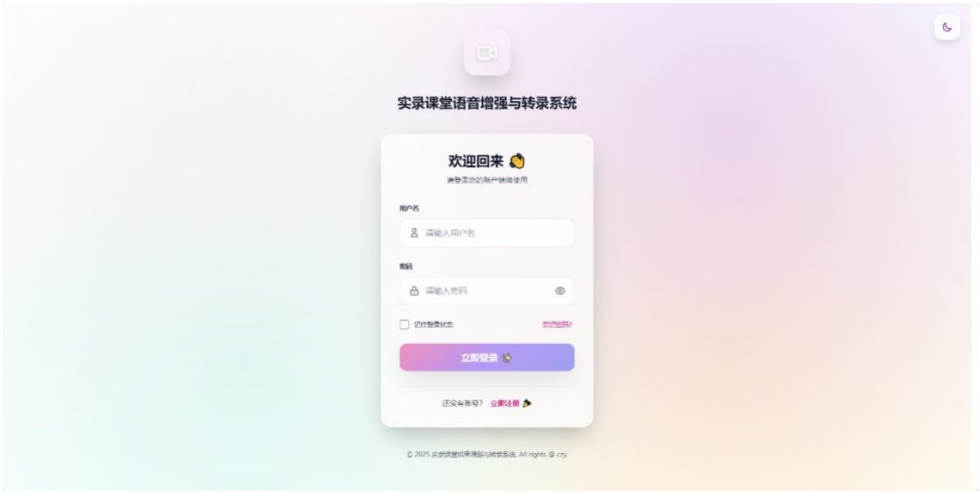


图 5.3 系统用户登录界面

5.3.2 教师语音增强

视频上传模块用于实现课堂视频文件的提交与管理。前端基于 Vue3 与 Element Plus 构建拖拽式上传界面，支持 MP4、AVI、MOV、WMV 等格式文件上传，并提供标题填写、视频描述及文件大小校验功能。后端采用 FastAPI 实现分片上传与异步存储，结合 FFmpeg 完成视频预处理，为后续语音增强与实时转录提供数据支持。系统的上传视频界面如图 5.4 所示。



图 5.4 系统上传视频界面图

视频完成上传后，平台自动转入语音增强处理界面，显示视频的基本情况，涵盖文件大小、时长、上传时间这些信息，同时具备完整的视频播放预览功能。页面底部列出两个音频播放选项，分别是“原始视频提取的音频”和“增强的音频”，两段音频都配置了独立的播放控制器和进度条，教师能够对照播放原始音频和处理后的音频，直接体会降噪和音质改善的效果，保证语音增强处理符合预期的教学质量要求。系统的语音增强界面如图 5.5 所示。

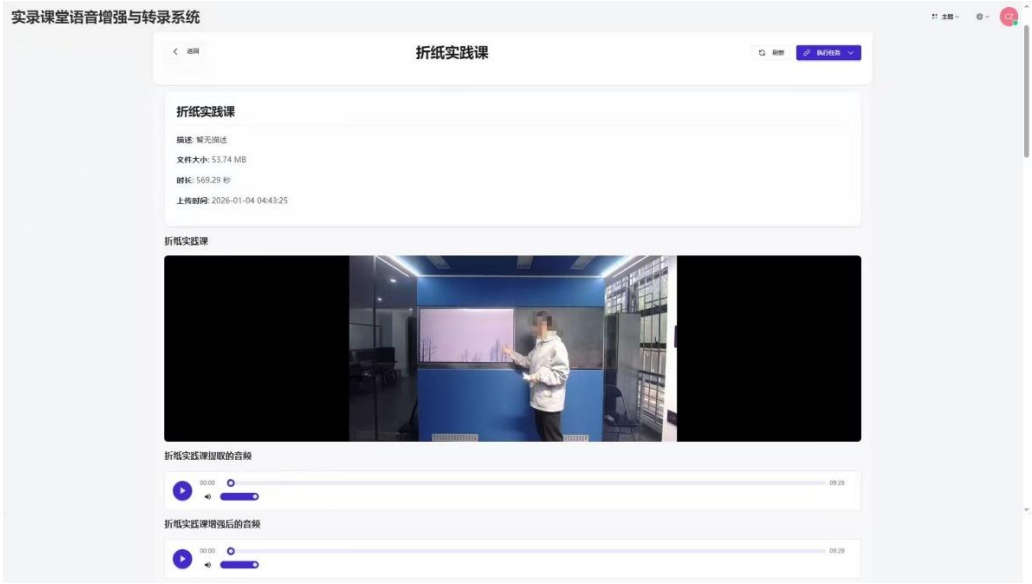


图 5.5 系统语音增强界面

在音量分析界面里，基于 Web Audio API 实现音频分贝分析，前端定时计算时域能量并转换为 dB 值，通过 ECharts 动态渲染折线图，实时展示音频随时间的音量变化，实现课堂音频质量的可视化监控。系统的音量分析界面如图 5.6 所示。

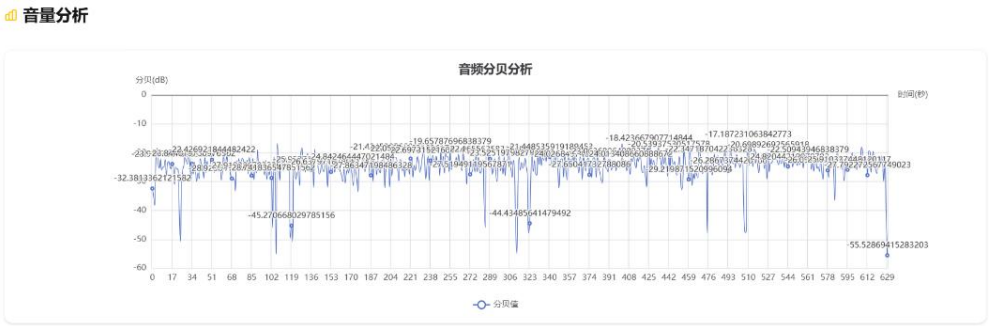


图 5.6 系统音量分析界面

5.3.3 教师语音转录

文字转录界面呈现的是课堂语音识别的最终输出，具体见 5.7 所示，实际课堂存在环境噪声干扰，对含噪语音开展转录时，识别结果中会出现部分语句漏识或识别错误的情况，这让转录文本在完整性和准确性方面受到一定影响。图 5.8 呈现的是对应语音经过增强处理后的文字转录结果，其中红色方框标注的位置对应图 5.7 里未能正确识别或出现错误的语音片段。能够发现，经过语音增强处理后，上述位置的转录内容得以有效恢复，文本连续性和可读性改善明显，系统能够更准确还原教师课堂讲解内容，还能自动完成标点符号的补全与段落划分。对比图 5.7 和图 5.8 的转录结果说明，本文采用的语音增强方法在抑制课堂环境噪声干扰、提升语音识别鲁棒性上效果较好，给课堂语音内容的记录和后续分析提供了更可靠的文本数据基础。


音频转录

教师课堂言语内容

00:00:05 - 00:00:07 上课同学们好。
00:00:08 - 00:00:19 今天呢在正式上课之前呢，老师想问一个老师想问大家一个问题，提到冬天大家想的大家的第一反应是什么？
00:00:19 - 00:00:28 哎，好，我听前这位同学说他想的是下雪雪花，然后现在呢老师给大家看这幅图片。
00:00:28 - 00:00:36 大家可以看到这是一幅雪景的图片，它是在冬天可以看到这白雪皑皑的图片。
00:00:37 - 00:00:42 大家想知道这么多的雪花，这么多的雪是由什么构成的吗？
00:00:42 - 00:00:55 老师现在告诉大家，这么多的血是由大量的雪花聚集而成的。然后现在呢我们给大家看一下一片一片的雪花是什么样子的。
00:00:56 - 00:01:06 我们可以看到它这个雪雪花是这种，它这里有很多种的形状，像这个是这种右角的棱形。
00:01:06 - 00:01:07 这个也是。
00:01:08 - 00:01:13 还有这个大的也是就是它的这个枝干上面有非常多的这个。
00:01:14 - 00:01:16 类似于叶子的形状。
00:01:17 - 00:01:22 然后大家如果觉得这个图片太杂的话，我们可以看一个单纯一点的图片。
00:01:23 - 00:01:28 它长这个样子，这个是一个很基础的一个雪花的形状的图片。
00:01:29 - 00:01:33 看到这么美丽的雪花的图片，同学们想。
00:01:34 - 00:01:38 想象一下可以用什么方法留住它。
00:01:38 - 00:01:42 哎，我听到这位同学说可以用绘画的方式。
00:01:42 - 00:01:44 那还有什么方式吗？
00:01:44 - 00:01:52 好，看到同学们都抓耳挠腮的，在仔细的想啊，那现在老师给大家介绍一种新的方法。
00:01:52 - 00:01:54 它就是折纸。
00:01:55 - 00:01:56 剪纸应该。
00:01:56 - 00:01:57 停止。
00:01:59 - 00:02:07 说到节日，其实大家都不陌生，大家应该都参加过婚礼。那个婚礼上面会有一个大大的小字。
00:02:08 - 00:02:11 那个喜字也就是剪纸做的。
00:02:11 - 00:02:19 然现在呢我们是来用剪纸来记录一下我们的这个雪花。想要记录这个雪花呢，我们首先看。
00:02:22 - 00:02:24 我们首先看这个图片。
00:02:29 - 00:02:42 就是刚刚的这个雪花图片，我们看我们观察到它有一个，就比如说我遮挡不住这边，它的这边可以翻折过来，这个叫什么？对，这就是我们学过的对称性。
00:02:42 - 00:02:48 然后你看它不仅是这样对称，它也可以这样对称也可以这样对称。
00:02:48 - 00:03:04 相当于它的每一条线都是它的一个对称线。我们可以根据这个对称的原理来简单的绘制一下。就像我们之前画圆形的时候，我们可以把纸对折，然后用我们的半圆就是那个。
00:03:04 - 00:03:05 叫什么？

图 5.7 系统带噪课堂语音文本转录结果



图 5.8 系统语音增强处理后文本转录结果

5.4 本章小结

本章依托已提出的音频增强方法，运用 Vue+FastAPI+MySQL 开发完成实录课堂语音增强与转录系统，此涵盖用户注册与登录、视频文件上传、音频分离与提取、语音优化处理、音量检测分析、语音转录识别，以及转录结果的可视化呈现等模块。本节说明了系统整体操作步骤，保证用户能迅速掌握并高效运用系统，同时以实录课堂教学视频为实例，完整呈现了系统功能与界面布局。借助实际案例的呈现，证实了系统具备可行性与实用价值。这套系统可完成视频上传至音频优化，并到语音文字转换、最后到结果呈现的完整过程，所生成的高质量音频与精准转录文字为用户带来清晰的课堂记录，协助教师迅速回顾课堂教学完整内容，为教学反思、课堂分析以及教学资源建设提供重要的数据支撑和技术保证。

第 6 章 总结与展望

6.1 总结

本文聚焦于实录课堂语音增强，针对课堂场景中的复杂声学环境及语音质量提升的特定需求，提出了基于双向 Mamba 改进的课堂语音增强算法，并设计实现了实录课堂语音增强与转录系统。第一章主要介绍了语音增强的研究背景和意义，总结了语音增强技术、轻量化研究及实录课堂语音增强的国内外现状，阐述了现存问题及本文研究内容。第二章介绍了相关理论与技术基础，包括语音增强理论基础、基于深度神经网络的语音增强模型、实验所用公开数据集及评价指标，并详细介绍了自建数据集的构建过程。第三章提出了基于外部双向 Mamba 的课堂语音增强方法，介绍了全频带外部双向 Mamba 的时频语音增强模型，并通过对比实验和消融实验验证了模型的有效性。第四章提出了基于双路径 Mamba+的轻量化课堂语音增强方法，介绍了子频带双路径 Mamba+的轻量级时频语音增强模型，通过实验验证了其在轻量化语音增强中的优势。第五章将该算法集成到实录课堂语音增强与转录系统中，从需求分析、系统设计到功能实现与界面展示，实现了课堂教学视频的语音增强和转录。

本文的主要工作总结如下：

（1）构建了面向实录课堂场景的教师语音增强专用语料库。针对中文课堂语音增强研究中专用数据资源匮乏的问题，本文采用线下实录方式收集了 82 位中学教师在语文和数学两门学科共 150 节课的真实授课音频，总时长 100 小时，采样率 16kHz。同时在真实课堂环境中采集了多种典型噪声，涵盖学生活动噪声、设备运转噪声、环境干扰噪声等类型。基于响度归一化技术，将纯净教师语音与课堂噪声在-5dB 到 17.5dB 信噪比区间内进行混合，模拟真实课堂声学条件下的带噪语音。采用按说话人划分的方式，将数据按 7：1：2 比例分配到训练集、验证集和测试集，确保模型评估的客观性，为本文的研究提供了高质量的数据基础，也为未来研究提供了可复用的资源。

（2）提出了基于外部双向 Mamba 的课堂语音增强方法。针对传统 Mamba 单向处理的局限性，构建外部双向 Mamba 架构实现全局依赖建模，并引入 Inception 深度卷积结构降低计算开销。模型采用编解码结构，通过幅度掩码和相位重建分支联合预测纯净语音频谱，结合感知度对比拉伸优化听感质量。在

VoiceBank+DEMAND 数据集上，本方法 WB-PESQ 达 3.61，相比当前最优的 Mamba-SEUNet(L)(3.59)提升 0.02，且参数量仅为其 42%。结合 PCS 后 WB-PESQ 进一步提升至 3.75，超越 Mamba-SEUNet(L)0.16。在 DNS Challenge 2020 上，WB-PESQ 达 3.63，超越最优的 MFNet(3.43)0.20。在自建数据集上，WB-PESQ 达 3.11，结合 PCS 后提升至 3.20，相比 Mamba-SEUNet(L)提升 0.11。实验表明该方法在抑制课堂背景噪声和保持语音自然度方面表现出色。

(3) 提出了基于双路径 Mamba+的轻量化课堂语音增强方法。针对边缘设备计算资源限制，设计子频带双路径 Mamba+轻量化架构，通过遗忘门控机制增强长时记忆能力，时间轴采用单向 Mamba+保证因果性，频率轴采用双向 Mamba+挖掘频谱相关性，结合子频带卷积降低参数规模，采用 Fast Griffin-Lim 算法优化相位估计。在 VoiceBank+DEMAND 数据集上，本方法以 49K 参数和 68M 计算量达到 WB-PESQ 的 3.13，相比参数量接近的 FSPEN（79K 参数，WB-PESQ 为 2.97）提升 0.16，参数量减少 38%，计算量降低 24%。在 DNS Challenge 2020 上，WB-PESQ 达 3.13，超越参数量为其 44 倍的 SICRN（2.16M 参数，WB-PESQ 为 2.62）0.51。在自建数据集上，WB-PESQ 达 3.06，相比 FSPEN 提升 0.21。实验表明该方法实现了性能与效率的良好平衡，适合部署于资源受限设备。

(4) 设计并开发了实录课堂语音增强与转录系统。基于提出的语音增强算法，本文设计并实现了实录课堂语音增强与转录系统，采用 PyTorch+Vue+Fastapi 进行开发设计，集成了视频上传、语音增强、语音识别、转录结果可视化等核心功能。用户可通过该系统便捷地上传课堂教学视频，获取高质量的增强音频和语音转录文本。该系统界面简洁直观，操作流程清晰，为实录课堂音频智能处理领域的研究提供了技术平台支持，且系统在增强效果和用户体验方面均表现良好。

6.2 展望

本文在实录课堂语音增强领域取得了一定的研究成果，但仍存在一些不足之处和值得进一步探索的方向。未来的研究工作可以从以下几个方面展开:

(1) 扩展语料库的规模与多样性。当前构建的实录课堂教师语音增强语料库虽然涵盖了中学的语文和数学两门学科，但学科种类相对有限，且主要集中

在中学阶段。未来可以进一步扩充语料库，增加物理、化学、英语等更多学科的课堂录音，同时覆盖小学、高中和大学等不同教育阶段，收集不同地区、不同方言背景的教师语音数据，以提升模型的泛化能力和适应性。此外，还可以丰富噪声类型，采集更多真实课堂场景下的复杂噪声环境，如多人同时发言、突发噪声事件等，为模型训练提供更加全面的数据支撑。

(2) 探索多模态融合的语音增强方法。当前的研究主要聚焦于单一的音频模态处理，而实录课堂场景中包含丰富的多模态信息，如视频中的教师面部表情、唇动信息以及幻灯片内容等。未来可以探索将视觉信息与音频信息进行深度融合，利用视听多模态学习机制，通过唇动识别辅助语音增强，或结合教学内容的语义信息指导噪声抑制过程，从而进一步提升复杂场景下的语音增强效果和鲁棒性。

(3) 增强模型对未知噪声的适应能力。当前模型主要在已知噪声类型上进行训练和测试，对于训练集中未出现的新型噪声或极端声学环境，模型的泛化能力仍有提升空间。未来可以引入迁移学习或强化学习机制，使模型能够快速适应新的噪声环境，或通过无监督学习方法利用未标注的课堂音频数据进行持续优化，增强模型在开放环境下的鲁棒性和实用性。

参考文献

[1] 王天平, 安静芸. 《教育强国建设规划纲要（2024—2035 年）》推动基础教育高质量发展[J]. 中国教育信息化, 2025: 11-24.

[2] 教育部等九部门关于加快推进教育数字化的意见[J]. 中国教育信息化, 2025: 3-8.

[3] 国务院印发《关于深入实施“人工智能+”行动的意见》[J]. 工业控制计算机, 2025: 45.

[4] 王雷. 信息赋能创课堂智慧化学铸新人——教育信息化下高中化学信息化教学的价值与策略[J]. 教育实践与研究(B), 2025: 113-116.

[5] 王卓艺. AI 助教赋能高校课堂教学模式创新研究与实践[J]. 信息系统工程, 2025: 158-161.

[6] van den Heuij K, Goverts T, Neijenhuis K, et al. Challenging listening environments in higher education: An analysis of academic classroom acoustics[J]. Journal of Applied Research in Higher Education, 2021: 1213-1226.

[7] 李润润. 依托人工智能技术提升大学英语教学质量[N]. 宁夏日报, 2025-04-05(003).

[8] Chhetri S, Joshi M S, Mahamuni C V, et al. Speech enhancement: A survey of approaches and applications[C]//2023 2nd International Conference on Edge Computing and Applications (ICECAA). 2023.

[9] 马青峰. 基于改进型谱减法的声音信号传输噪声抑制[J]. 电声技术, 2025: 44-46.

[10] 张嘉伟, 聂亚杰, 祁自建, 等. 一种自适应维纳滤波器在 γ 能谱降噪中的应用[J]. 辐射防护, 2024: 50-56.

[11] 张越, 沈建明, 王庆祥, 等. 一种新的变步长 LMS 算法及其在语音降噪中的应用[J]. 电子制作, 2023: 93-96.

[12] 董胡, 陈伟, 彭高丰, 等. 基于信号子空间和 DNN 的语音增强方法[J]. 微型电脑应用, 2025: 32-34+38.

[13] 王红娟, 尚莹莹. 基于小波变换的语音信号去噪算法优化[J]. 电声技术, 2024: 67-69.

[14] Mahmmod B M, Abdulhussain S H, Ali T M, et al. Speech Enhancement: A Review of Various Approaches, Trends, and challenges[C]//2024 17th International Conference on Development in eSystem Engineering (DeSE). 2024.

[15] Pandey A, Wang D L. A new framework for CNN-based speech enhancement in the time domain[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019: 1179-1188.

[16] Chen J, Wang D L. Long short-term memory for speaker generalization in supervised speech

separation[J]. The Journal of the Acoustical Society of America, 2017: 4705-4714.

[17] Westhausen, Nils L.,Meyer,et al. Dual-signal transformation LSTM network for real-time noise suppression[C]//21st Annual Conference of the International Speech Communication Association, INTERSPEECH 2020. 2020.

[18] Kim, Eesung,Seo,et al. SE-conformer: Time-domain speech enhancement using conformer[C]//22nd Annual Conference of the International Speech Communication Association, INTERSPEECH 2021. 2021.

[19] Julius Richter,Simon Welker,Jean-Marie Lemercier,et al. Speech Enhancement and Dereverberation with Diffusion-based Generative Models[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023: 1-13.

[20] Chao, Rong,Cheng,et al. An Investigation of Incorporating Mamba For Speech Enhancement[C]//2024 IEEE Spoken Language Technology Workshop (SLT). 2024.

[21] 陈文一.基于深度学习的轻量级语音增强算法研究[D].杭州电子科技大学,2025.

[22] Jean-Marc Valin. A Hybrid DSP/Deep Learning Approach to Real-Time Full-Band Speech Enhancement[C]//2018 IEEE 20th International Workshop on Multimedia Signal Processing (MMSP). 2018.

[23] Jean-Marc Valin,Umut Isik,Neerad Phansalkar,等 . A Perceptually-Motivated Approach for Low-Complexity; Real-Time Enhancement of Fullband Speech[C]//2020 国际语音通讯联合会年度会议. 2020.

[24] Schröter, Hendrik , Escalante,et al. Deepfilternet: A Low Complexity Speech Enhancement Framework for Full-Band Audio Based On Deep Filtering[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. 2022.

[25] Luo, Yi,Chen,et al. Dual-Path RNN: Efficient Long Sequence Modeling for Time-Domain Single-Channel Speech Separation[C]//ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020.

[26] Le, Xiaohuai,Chen,et al. DPCRN: Dual-path convolution recurrent network for single channel speech enhancement[C]//22nd Annual Conference of the International Speech Communication Association, INTERSPEECH 2021. 2021.

[27] Rong, Xiaobin, Sun,et al. GTCRN: A Speech Enhancement Model Requiring Ultralow Computational Resources[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024.

[28] Stracke C M. The quality of MOOCs: how to improve the design of open education and online courses for learners?[C]//International Conference on Learning and Collaboration Technologies. Cham: Springer International Publishing. 2017.

[29] Feng X, Wang Y, Luo F. Application of AI-Powered Audio Noise Reduction System in Remote Education[C]//Proceedings of the 2024 2nd International Conference on Information Education and Artificial Intelligence. 2024.

[30] Shield B M, Dockrell J E. The effects of environmental and classroom noise on the academic attainments of primary school children[J]. The Journal of the Acoustical Society of America, 2008: 133-144.

[31] 纳跃跃,王子腾,付强,等.终端智能语音处理技术与应用[M].电子工业出版社:202504:379.

[32] 潘超,陈景东.声信号处理与智能分析[M].人民邮电出版社:202302:177.

[33] Xu, Y (Xu, Yong),et al. An Experimental Study on Speech Enhancement Based on Deep Neural Networks[J]. IEEE Signal Processing Letters, 2014: 65-68.

[34] Park, Se Rim,Lee,et al. A Fully Convolutional Neural Network for Speech Enhancement[C]//18th Annual Conference of the International-Speech-Communication-Association (INTERSPEECH 2017). 2017.

[35] Felix Weninger,Hakan Erdogan,Shinji Watanabe,et al. Speech Enhancement with LSTM Recurrent Neural Networks and its Application to Noise-Robust ASR[C]//2015 Latent Variable Analysis and Signal Separation (LVA). 2015.

[36] Kumar, Anurag,Florencio,et al. Speech Enhancement In Multiple-Noise Conditions using Deep Neural Networks[C]//Interspeech 2016. 2016.

[37] Vaswani, Ashish,Shazeer,et al. Attention Is All You Need[C]//NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. 2017.

[38] Weiwei Yu,Jian Zhou,HuaBin Wang & Liang Tao. SETransformer: Speech Enhancement Transformer[J]. Cognitive Computation, 2022: 1152-1158.

[39] Dang, Feng,Chen,et al. DPT-FSNET: DUAL-PATH TRANSFORMER BASED FULL-BAND AND SUB-BAND FUSION NETWORK FOR SPEECH ENHANCEMENT[C]//47th IEEE International Conference on Acoustics, Speech, and Signal Processing, ICASSP 2022. 2022.

[40] Dao, Tri, Gu,et al. Transformers are SSMs: generalized models and efficient algorithms through structured state space duality[C]//ICML'24: Proceedings of the 41st International Conference on Machine Learning. 2024.

[41] Gu, Albert,Goel,et al. EFFICIENTLY MODELING LONG SEQUENCES WITH STRUCTURED STATE SPACES[C]//10th International Conference on Learning Representations, ICLR 2022. 2022.

[42] Smith, Jimmy T.H.,Warrington,et al. SIMPLIFIED STATE SPACE LAYERS FOR SEQUENCE MODELING[C]//11th International Conference on Learning Representations, ICLR 2023. 2023.

[43] Chao, Rong,Cheng,et al. An Investigation of Incorporating Mamba For Speech Enhancement[C]//2024 IEEE Spoken Language Technology Workshop (SLT). 2024.

[44] Kühne N L, Jensen J, Østergaard J, et al. MambAttention: Mamba with multi-head attention for generalizable single-channel speech enhancement[J]. IEEE Transactions on Audio, Speech and Language Processing, 2026.

[45] Bu, Hui,Du,et al. AISHELL-1: an open-source mandarin speech corpus and a speech recognition baseline[C]//2017 20th Conference of the Oriental Chapter of the International Coordinating Committee on Speech Databases and Speech I/O Systems and Assessment (O-COCOSDA). 2017.

[46] Garofolo J S, Lamel L F, Fisher W M, et al. TIMIT acoustic-phonetic continuous speech corpus[J]. Linguistic Data Consortium, 1993.

[47] Vassil Panayotov,Guoguo Chen,Daniel Povey. LIBRISPEECH: AN ASR CORPUS BASED ON PUBLIC DOMAIN AUDIO BOOKS[C]//ICASSP 2015 - 2015 IEEE International Conference on Acoustics, Speech and Signal Processing. 2015.

[48] Veaux, Christophe,Yamagishi,et al. The voice bank corpus: Design, collection and data analysis of a large regional accent speech database[C]//2013 International Conference Oriental COCOSDA held jointly with 2013 Conference on Asian Spoken Language Research and Evaluation. 2013.

[49] Garofolo J S, Graff D, Paul D, et al. Csr-i (wsj0) complete[J]. Linguistic Data Consortium, 1996.

[50] Thiemann J, Ito N, Vincent E. The diverse environments multi-channel acoustic noise database (demand): A database of multichannel environmental noise recordings[C]//Proceedings of Meetings on Acoustics. Acoustical Society of America. 2013.

[51] Gemmeke, Jort F.,Ellis,et al. AUDIO SET: AN ONTOLOGY AND HUMAN-LABELED DATASET FOR AUDIO EVENTS[J]. 2017 IEEE INTERNATIONAL CONFERENCE ON

ACOUSTICS, SPEECH AND SIGNAL PROCESSING (ICASSP), 2017: 776-780.

[52] WICHERN G, ANTOGNINI J, FLYNN M, et al. WHAM!: Extending speech separation to noisy environments[C]//Proc of Interspeech 2019. 2019.

[53] Varga A, Steeneken H J M. Noisex-92: A database and an experiment to study the effect of additive noise on speech recognition systems[J]. Speech Commun, 1993: 247-253.

[54] Richter, Julius,Wu,et al. EARS: An Anechoic Fullband Speech Dataset Benchmarked for Speech Enhancement and Dereverberation[C]//25th Interspeech Conferece 2024. 2024.

[55] Barker, J(Barker, Jon),et al. The PASCAL CHiME speech separation and recognition challenge[J]. COMPUTER SPEECH AND LANGUAGE, 2013: 621-633.

[56] Chandan K.A.Reddy,Vishak Gopal,Ross Cutler,et al. The INTERSPEECH 2020 Deep Noise Suppression Challenge:Datasets;Subjective Testing Framework,and Challenge Results[C]//Annual Conference of The International Speech Communication Association 2020. 2020.

[57] Hu Y, Loizou P C. Evaluation of objective quality measures for speech enhancement[J]. IEEE Transactions on audio, speech, and language processing, 2007: 229-238.

[58] Le Roux J, Wisdom S, Erdogan H, et al. SDR–half-baked or well done?[C]//2019 IEEE International Conference on Acoustics, Speech and Signal Processing. 2019.

[59] Chao, Rong,Yu,et al. Perceptual Contrast Stretching on Target Feature for Speech Enhancement[C]//23rd Annual Conference of the International Speech Communication Association, INTERSPEECH 2022. 2022.

[60] Ai Y, Ling Z H. Neural speech phase prediction based on parallel estimation architecture and anti-wrapping losses[C]//2023 IEEE International Conference on Acoustics, Speech and Signal Processing. 2023.

[61] Pascual, Santiago,Bonafonte,et al. SEGAN: Speech Enhancement Generative Adversarial Network[C]//18th Annual Conference of the International-Speech-Communication-Association. 2017.

[62] Défossez, Alexandre,Synnaeve,et al. Real time speech enhancement in the waveform domain[C]//21st Annual Conference of the International Speech Communication Association, INTERSPEECH 2020. 2020.

[63] Kai Wang,Bengbeng He,Wei-Ping Zhu. TSTNN: Two-Stage Transformer Based Neural Network for Speech Enhancement in the Time Domain[C]//2021 IEEE International

Conference on Acoustics, Speech and Signal Processing. 2021.

[64] Du, Yu, Liu,et al. Spiking Structured State Space Model for Monaural Speech Enhancement[C]//2024 IEEE International Conference on Acoustics, Speech and Signal Processing. 2024.

[65] Hsieh, Tsun-An,Yu,et al. Improving perceptual quality by phone-fortified perceptual loss using wasserstein distance for speech enhancement[C]//22nd Annual Conference of the International Speech Communication Association, INTERSPEECH 2021. 2021.

[66] Yu, Guochen , Li,et al. Dual-Branch Attention-In-Attention Transformer for Single-Channel Speech Enhancement[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. 2022.

[67] Cao, Ruizhe,Abdulatif,et al. CMGAN: Conformer-based Metric GAN for Speech Enhancement[C]//23rd Annual Conference of the International Speech Communication Association, INTERSPEECH 2022. 2022.

[68] Yin, Dacheng,Zhao,et al. TridentSE: Guiding Speech Enhancement with 32 Global Tokens[C]//24th International Speech Communication Association, Interspeech 2023. 2023.

[69] Lu, Ye-Xin,Ai,et al. MP-SENet: A Speech Enhancement Model with Parallel Denoising of Magnitude and Phase Spectra[C]//24th International Speech Communication Association, Interspeech 2023. 2023.

[70] Ku, Pin-Jui,Yang,et al. A Multi-dimensional Deep Structured State Space Approach to Speech Enhancement Using Small-footprint Models[C]//24th International Speech Communication Association, Interspeech 2023. 2023.

[71] Lin, Zizhen,Chen,et al. MUSE: Flexible Voiceprint Receptive Fields and Multi-Path Fusion Enhanced Taylor Transformer for U-Net-based Speech Enhancement[C]//25th Interspeech Conferece 2024. 2024.

[72] Wang, Junyu,Lin,et al. Mamba-SEUNet: Mamba UNet for Monaural Speech Enhancement[C]// 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2025.

[73] Hao, Xiang,Su,et al. Fullsubnet: A Full-Band and Sub-Band Fusion Model for Real-Time Single-Channel Speech Enhancement[C]//2021 IEEE International Conference on Acoustics, Speech, and Signal Processing, ICASSP 2021. 2021.

[74] Li A, Liu W, Zheng C, et al. Two heads are better than one: A two-stage complex spectral

mapping approach for monaural speech enhancement[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021: 1829-1843.

[75] Li, Andong,You,et al. Taylor, Can You Hear Me Now? A Taylor-Unfolding Framework for Monaural Speech Enhancement[C]//31st International Joint Conference on Artificial Intelligence, IJCAI 2022. 2022.

[76] Zhao, Shengkui , Ma,et al. FRCRN: Boosting Feature Representation Using Frequency Recurrence for Monaural Speech Enhancement[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. 2022.

[77] Yi Luo,Jianwei Yu. Music Source Separation With Band-Split RNN[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023: 1-10.

[78] Liu, Liang,Guan,et al. A Mask Free Neural Network for Monaural Speech Enhancement[C]//24th International Speech Communication Association, Interspeech 2023. 2023.

[79] Man Li,Ya LiuCA,Li ZhouCA1. DeConformer-SENet: An efficient deformable conformer speech enhancement network[J]. Digital Signal Processing, 2025: 104787.

[80] Perraudin, Nathanael,Balazs,et al. A FAST GRIFFIN-LIM ALGORITHM[C]//2013 IEEE Workshop on Applications of Signal Processing to Audio and Acoustics. 2013.

[81] Hao X, Li X. Fast fullsubnet: Accelerate full-band and sub-band fusion model for single-channel speech enhancement[J]. arXiv preprint arXiv:2212.09019, 2022.

[82] Dang F, Chen H, Hu Q, et al. First coarse, fine afterward: A lightweight two-stage complex approach for monaural speech enhancement[J]. Speech Communication, 2023: 32-44.

[83] Yang, Lei, Liu,et al. Fspen: an Ultra-Lightweight Network for Real Time Speech Enahncment[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024.

[84] Umut Isik,Ritwik Giri,Neerad Phansalkar,et al. PoCoNet:Better Speech Enhancement with Frequency-Positional Embeddings;Semi-Supervised Conversational Data,and Biased Loss[C]//Annual Conference of The International Speech Communication Association 2020. 2020.

[85] Jun Chen,Zilin Wang,Deyi Tuo,et al. FullSubNet+: Channel Attention Fullsubnet with Complex Spectrograms for Speech Enhancement[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022.

[86] Chen, Jun,Rao,et al. Speech Enhancement with Fullband-Subband Cross-Attention Network[C]//23rd Annual Conference of the International Speech Communication Association, INTERSPEECH 2022. 2022.

[87] Chen, Jun, Rao,et al. Inter-Subnet: Speech Enhancement with Subband Interaction[C]//48th IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP 2023. 2023.

[88] Zhao, Changjiang, He,et al. SICRN: Advancing Speech Enhancement through State Space Model and Inplace Convolution Techniques[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP).2024.

攻读学位期间发表的学术论文和研究成果

1.学术论文发表情况

[1] Cui, Z., Zhou, M., Zhou, J., Ren, W., Wu, D., & Gan, J. (2025). Time-Frequency Domain Speech Enhancement Based on External DualMamba. 2025 International Conference on Virtual Reality and Visualization (ICVRV), 642-647.（CCF）

[2] Jiang, L., Mei, J., Cui, Z., Li, J., Wang, J. (2025). Classroom Speaker Diarization Based on Multi-density Feature Clustering. In: Huang, L., Greenhalgh, D. (eds) Proceedings of 17th International Conference on Machine Learning and Computing. ICMLC 2025.

2.专利授权及受理情况

甘健侯，崔自渊，周明涛，李俊宏，黄铭卿，周菊香，吴迪.一种基于卷积双向 Mamba 的课堂语音增强方法，已受理，申请号：CN202510649955.8.

甘健侯，吴迪，崔自渊，王俊，邹伟.一种基于动态任务调度的教师课堂视频姿态估计识别结果展示方法，已受理，申请号：CN202410650704.7.

3.参与的项目情况

[1] 云南省科技计划重点研发项目《教育数智化关键技术研究及应用示范》，202402AD080002，2024.01-2028.12.

[2] 国家自然科学基金项目《基于课堂视频图像分析的教学效果评价及应用研究》，62107034，2022.01-2025.12.

[3] 国家自然科学基金项目《民族教育信息资源多模态知识融合与服务研究》，62166050，2022.01-2025.12.

致谢

在本论文的完成过程中，我得到了许多帮助与支持。在此，我谨向所有给予我帮助的人表达诚挚的谢意。

首先，我衷心感谢我的导师周老师。在研究思路的梳理、实验方案的制定以及论文写作的各个阶段，周老师都给予了我耐心、细致而深刻的指导。周老师严谨的治学态度、扎实的专业素养以及对科研的热情，为我树立了良好的榜样，使我在整个研究过程中受益匪浅。在课题研究和技术细节上，周老师给予了我许多宝贵的建议与支持，使我能够顺利克服研究中的困难。

同时，我要感谢实验室为本研究提供的设备支持，这些完善的实验条件为论文的顺利完成提供了重要保障。

再次向所有关心、支持和帮助过我的老师、同学和家人表示最诚挚的感谢!