分类号_____ 密级_____

UDC _____ 编号_____





硕士研究生学位论文

论文题目：面向多场景的多样性问题生成算法研究

英文题目： **A Study of Diversity Question Generation Algorithms for Multiple Scenarios**

学　院 信息学院

专业名称 计算机应用技术

研究方向 自然语言处理

研究生姓名 周明涛 学号 2123100056

导师姓名 周菊香 职称 副教授

2024 年 5 月 18 日

中国知网 https://www.cnki.net

摘要

自 21 世纪以来，问题生成逐渐崭露头角，成为自然语言处理领域的核心研究方向。随着 GPU 硬件技术和算力资源的发展，基于传统人工编制规则的问题生成方法逐渐被深度学习技术所替代。然而，在当前基于深度学习的问题生成研究中，依然存在语义结构信息丢失、问题单词重复、忽视上下文的全局结构信息等问题，最终影响问题生成的质量。为进一步提升问题生成模型的性能，同时需要满足多场景下特定领域对问题生成的多样性需求，本文针对有答案感知的问题生成、有答案感知多样性问题生成和无答案感知多样性问题生成三类任务进行深入研究，主要工作包括以下几个方面：

（1）针对现有问题生成模型在多阶段编码和解码过程中序列信息和语义结构信息易丢失的问题，本文提出了一种基于多阶段时序和语义信息增强的模型。该模型首先通过双向长短时记忆网络（Bi-directional Long Short-Term Memory，BiLSTM）分别编码文本句子和答案的信息，利用对齐机制将上下文和答案信息进行交互，然后将编码器多个阶段编码的信息进行融合，有效减少语义结构信息丢失，接着将多阶段编码后的语义信息输入到解码器，利用迭代图神经网络在解码的每个时间步融入上一时刻的语义结构信息，进一步缓解解码过程中语义信息的丢失。在公开数据集上的多组对比实验表明，本章提出的问题生成模型，在多个评估指标上均有显著提升，有效改善了问题生成质量。

（2）针对现有多样性问题生成容易出现问题单词重复导致可回答性低的问题，本文提出了一种基于对比搜索算法的多样性问题生成模型。该模型通过在编码阶段引入答案信息改善问题生成的可回答性，在解码端引入对比搜索策略，在解码阶段的每一时间步选择若干个最优的文本单词，并通过超参数 α 控制文本的退化现象，进而缓解解码过程中问题单词重复现象。为了更全面评估多样性问题生成效果，本文利用现有段落级多样性问题生成数据集构建一个句子级的多样性问题生成数据集。通过多组对比实验表明，所提方法能一定程度减少问题词汇的重复，在段落级和句子级的评估指标均有显著提升，有效改善生成问题的可回答性。

（3）针对现有无答案感知问题生成算法在进行问题关键词预测时易丢失

中国知网 https://www.cnki.net

上下文全局结构信息的问题，本文提出了一种基于 Transformer 编码器问题关键词预测的问题生成模型。该模型利用 Transformer 编码器双向编码的特征抽取能力强，且不易丢失上下文的全局语义结构信息等优势，通过 Transformer 编码器对外部的问题关键词进行预测，并结合卷积神经网络和多层感知器对编码器-解码器模型的输入端进行加强，有效改善文本的全局和局部语义信息，确保模型在解码的起始阶段学习到有意义的语义表示。通过在公共数据集上多组实验对比表明，该模型在 Distinct 自动评估和人工评估指标均有显著提升，在无答案感知问题生成多样性和特殊性方面表现优越。

关键词：问题生成；多阶段时序；图神经网络；对比搜索；关键词预测；

中国知网 https://www.cnki.net

Abstract

Since the 21st century, question generation has gradually emerged as a core research direction in the field of natural language processing. With the development of GPU hardware technology and arithmetic resources, question generation methods based on traditional manually compiled rules are gradually replaced by deep learning technology. However, in the current deep learning-based question generation research, there are still problems such as the loss of semantic structure information, the repetition of question words, and the neglect of the global structure information of the context, which ultimately affect the quality of question generation. To further improve the performance of the question generation model, it is also necessary to satisfy the diversity of domain-specific demands for question generation in multiple scenarios, this paper conducts an in-depth study on three types of tasks, namely, answer-aware question generation, answer-aware diversity question generation, and no-answer-aware diversity question generation, and the main work includes the following aspects:

(1) Aiming at the problem that sequence information and semantic structure information are easy to be lost during multi-stage encoding and decoding of existing question generation models, this paper proposes a model based on the enhancement of multi-stage temporal and semantic information. Firstly, the information of text sentences and answers are encoded separately by Bi-directional Long Short-Term Memory (BiLSTM), and the context and answer information are interacted by using the alignment mechanism, and then the information encoded in multiple stages of the encoder is fused to effectively reduce the loss of semantic structural information, and then the multi-stage encoded semantic information is input to the decoder, which uses iterative graph neural network to incorporate the semantic structure information of the previous moment at each time step of decoding to further mitigate the loss of semantic information in the decoding process. Multiple sets of comparison experiments on public datasets show that the question generation model proposed in this chapters shows significant improvement in a lot of evaluation metrics, which effectively improves the quality of question generation.

中国知网 https://www.cnki.net

(2) Aiming at the existing diversity question generation which is prone to the problem of low answerability due to the repetition of question words, this paper proposes a diversity question generation model based on the contrastive search algorithm. The model improves the answerability of question generation by introducing answer information at the encoding stage, introduces a contrast search strategy at the decoding, selects a number of optimal text words at each time step of the decoding stage, and controls text degradation through the hyperparameter α, thus alleviating the problem of word repetition in the decoding process. To evaluate the effect of diversity question generation more comprehensively, this paper uses the existing paragraph-level diversity question generation dataset to construct a sentence-level diversity question generation dataset. Through multiple comparative experiments, it is shown that the proposed method can reduce the repetition of question words to a certain extent, and significantly improve the evaluation indexes at both paragraph and sentence levels, which effectively improves the answerability of the generated questions.

(3) Aiming at the problem that existing no-answer-aware question generation algorithms are prone to lose contextual global structural information when performing question keyword prediction, this paper proposes a question generation model based on question keyword prediction with Transformer encoder. The model takes advantage of the Transformer encoder's strong feature extraction capability of bidirectional encoding and the fact that it is not easy to lose the global semantic structure information of the context, etc. The model predicts external question keywords through the Transformer encoder and combines with convolutional neural network and multilayer perceptron to strengthen the input side of the encoder-decoder model, which effectively improves the text's global and local semantic information, ensuring that the model learns a meaningful semantic representation at the onset of decoding. Comparison of multiple sets of experiments on a public dataset shows that the model shows significant improvement in both Distinct automatic and manual evaluation metrics, and superior performance in diversity and specificity for no-answer perception questions generation.

Key words：Question Generation; Multi-Stage Temporal Sequences; Graph Neural Networks; Contrastive Search; Question Keywords Prediction

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 基于答案感知的问题生成.....4
1.2.2 基于答案感知的多样性问题生成.....6
1.2.3 基于无答案感知的多样性问题生成.....8
1.3 研究内容.....9
1.4 文章组织结构.....10
1.5 本章小结.....11
第 2 章 相关技术及理论.....12
2.1 问题生成任务.....12
2.2 数据集.....13
2.2.1 SQuAD.....13
2.2.2 MS MARCO.....13
2.2.3 Amazon 数据集.....14
2.3 问题生成相关研究.....15
2.3.1 基于规则的问题生成.....16
2.3.2 基于神经网络的问题生成.....18
2.4 评估指标.....24
2.4.1 BLEU 指标.....24
2.4.2 METEOR 指标.....25
2.4.3 ROUGE-L 指标.....25
2.4.4 Distinct 指标.....26
2.5 本章小结.....26
第 3 章 基于多阶段时序和语义信息增强的问题生成.....27
3.1 研究动机.....27
3.2 模型结构介绍.....28
3.2.1 基于多阶段拼接的编码器.....28
3.2.2 引入 IGNN 的解码器.....32
3.2.3 训练和测试.....34
3.3 实验与分析.....34
3.3.1 实验参数及基线模型.....34
3.3.2 实验结果与分析.....36
3.3.3 案例分析.....39

中国知网 https://www.cnki.net

3.4 本章小结.....40
第 4 章 基于对比搜索算法的多样性问题生成.....41
4.1 研究动机.....41
4.2 模型结构介绍.....42
4.2.1 基于 ProphetNet 的预训练模型微调.....42
4.2.2 引入对比搜索策略的解码器.....45
4.3 实验与分析.....46
4.3.1 实验参数.....46
4.3.2 评估指标.....48
4.3.3 实验结果与分析.....48
4.3.4 案例分析.....51
4.4 本章小结.....54
第 5 章 基于问题关键词预测的多样性问题生成.....55
5.1 研究动机.....55
5.2 模型结构.....56
5.2.1 基于 Transformer 问题关键词预测.....57
5.2.2 编码器-解码器架构.....58
5.2.3 训练和测试.....60
5.3 实验及分析.....60
5.3.1 实验参数设置.....60
5.3.2 实验结果与分析.....61
5.3.3 案例分析.....66
5.4 本章小结.....69
第 6 章 总结及展望.....70
6.1 总结.....70
6.2 未来展望.....71
参考文献.....73

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景及意义

自 2017 年 3 月，中国政府首次将人工智能写入政府工作报告，表明我国对人工智能这一领域的高度重视。这些相关工作报告和政策的相继印发不仅显示了政府对人工智能行业远景预期的积极态度，也为该行业提供了明确的政策导向，进一步明确了我国新一代人工智能发展的战略目标和重点任务。随着技术的不断演进，人工智能的应用也在不断拓展。从传统的错别字识别、语音识别、图像处理到跨足医疗、金融、制造业等多个实际应用领域，人工智能的应用呈现出多样性和广泛性，尤其是自然语言处理领域下的相关研究更是呈现出势不可挡的趋势，这一趋势为我国实现创新驱动发展、提高产业竞争力提供了新的动力。

自然语言处理领域的巨大发展趋势源于深度学习技术的崛起，这种技术革新模仿人类大脑的神经网络结构，使得计算机能够更有效地处理复杂的任务，为自然语言处理等复杂任务提供强有力的工具。这些技术进展如同一场革命，从传统深度学习的基础模型逐渐演变为大语言模型。这些大语言模型以其惊人的语言理解和生成能力引起了广泛关注，如 ChatGPT、讯飞星火认知大模型等。这些模型的成功标志着大型预训练模型在自然语言处理中的巨大潜力，推动了这一领域的发展。此外，深度学习在自然语言处理的应用范围还涉足医疗[1]、金融[2]、教育[3]等领域，为各行各业带来了创新的解决方案。

在深度学习研究的背景下，研究人员开始关注自然语言处理方向下的问题生成[4-6]、摘要生成[7-8]以及更深层次的机器翻译[9-10]等具体研究任务。这些任务研究的重要性在于，它们直接关系到人工智能系统对自然语言的理解和生成能力。通过解决这些任务可以更好地实现智能对话、自动问答等应用，提升人工智能系统在各个领域的实用性和适应性，有助于提高用户体验，为创新型应用和解决现实世界问题提供有力支持。因此，研究生成任务的推进不仅是学术界的追求，更是推动人工智能技术迈向实际应用的关键一步。在这些研究任务中，问题生成又被认为是当前这些任务中最具有挑战性的任务。问题生成涉及到对语义理解、逻辑推理、语境分析等多个方面的深度处理，要求系统能够准确捕

中国知网 https://www.cnki.net

捉信息并以自然而流畅的方式生成问题，这对于实现高质量的智能对话和自动问答至关重要。因此，问题生成的进展对于推动人工智能技术的发展和应用具有重要意义。例如，在检索式的问答系统[11]中，由于互联网出现的网站含有大量文章和新闻、以及学术论文和文学作品等，导致大量的信息不能使用到对应的检索系统，给人类造成了巨大的困扰。尽管可以使用人工标注的方式进行提问，但是出现费时费力的问题。基于目前出现的现象，问题生成恰好被用来解决这些应用场景。此外，问题生成可被广泛应用于教育[12]、电商[13]、医疗[14]、自动对话机器人[15]等领域。在教育领域中，问题生成用来解决教育领域的智能出题，减轻教师负担。同时，问题生成在教育领域中还被用来做教学评估，相关案例如表 1.1 所示。

表 1.1 生成单个问题的任务案例

案例 1	句子 1：Swann reveals that L'Amricain is a hotel in Tangier. 黄金问题：Where is the L'Americain hotel? 答案：Tangier
案例 2	句子 2：Sand, who was six years older than the composer, and who had had a series of lovers, wrote at this time: I must say I was confused and amazed at the effect this little creature had on me. 黄金问题：How much older was george sands than chopin? 答案：six years

在电商领域，问题生成主要用来解决商品文本信息描述缺失以及客服对话等问题。面对海量的商品文本信息描述，客户的需求是多样的，生成多样性问题，提醒商家弥补文本信息缺失的描述，防止客户流失，被认为是极为重要的，相关案例如表 1.2 所示。同时，问题生成在电子商务领域的对话系统中，可以被应用于人机对话。通过客户的回答生成多轮对话问题，从而带给客户优质体验，提高用户的体验度。在医疗领域，可以作为心里健康临床工具的评估工具，应用于网站 QA 开发，极大的促进人工智能的发展。在自动对话机器人领域，聊天机器人可以进行多轮对话，并通过以问题的形式来开启对话，增强人机交互的持久性，带给用户更好的体验。因此问题生成技术的相关研究，已经成为当前的一个研究热点。

中国知网 https://www.cnki.net

表 1.2 问题生成多样性任务案例

示例 1	句子 1：Sensilla mighty pops - 6 high quality bra free silicone ice pop popsicle molds - 100 % money-back lifetime guarantee! Free 50 ice pop recipes e-book - food storage, jell freezer pop molds make your own healthy, tasty & refreshing homemade ice lowly ...	
	黄金问题	Where is this product, does it leak? Where can we buy pieces separately? Where is this product manufactured?
示例 2	句子 2：Sharp el-1197piii heavy duty color printing calculator with clock and calendar. A 12-digit calculator is perfect for the everyday advanced user, especially in a busy office setting. Extra heavy-duty durability is perfect …	
	黄金问题	How do I get instruction for this calculator? Does it have a build in clock and calendar? Can anyone here tell me how to set the decimal point on this calculator?

为了更好满足当前社会的需求，改善生成问题的质量，进一步将问题生成应用落地。本文通过深度学习中的神经网络研究三类问题生成，分别为有答案感知的问题生成、有答案感知的多样性问题生成、无答案感知的多样性问题生成。改善有答案感知的问题生成、有答案感知的多样性问题生成、无答案感知的多样性问题生成出现的生成问答单词语义结构信息丢失问题、生成解码过程中问题单词重复导致可回答性低的问题、忽视上下文的全局结构信息导致预测问题关键词不精准问题，并满足于特定的教育领域和电商领域。通过这三类问题生成的研究，不仅可以推动自然语言处理的发展，而且可以促进问题生成在教育、电商领域的发展，通过将问题生成技术应用于实际场景，有望在教育和商业领域实现更加智能化和个性化的服务，解决教育和商业领域的问题，推动社会各个领域的创新和进步。

1.2 国内外研究现状

由于问答对话的广泛应用以及深度神经网络的进一步发展，自然语言处理

中国知网 https://www.cnki.net

中的问题生成最近几年也受到极大的关注。问题生成被认为是人工智能领域中一个重要且富有挑战的问题，旨在通过各种输入格式生成和上下文文本内容相关、符合人类需求的问题。在过去几十年里，人们提出许多不同类型的问题生成模型，从传统基于规则的方法到目前最先进的基于深度学习框架下的神经网络方法。其中，基于神经网络的问题生成方法被分为有答案感知的问题生成和无答案感知的问题生成。有答案感知的问题生成任务侧重于根据给定的上下文和相关答案生成与之相关的问题，这类任务常见于问答系统、教育应用和信息检索等领域。为了提供更具深度和个性化的问题，以推动对话和交互的质量发展，有答案感知的多样性问题生成开始被研究。无答案感知的问题生成任务注重于在给定的上下文中直接生成符合需求的问题，这种类型的问题生成被广泛应用于语言生成模型的训练、对话系统的改进、电子商务领域下商品信息识别等，旨在提供更具灵活性和多样性的问题。因此，本章节将从基于答案感知的问题生成、基于答案感知的多样性问题生成和基于无答案感知的多样性问题生成三个方面，对问题生成研究领域的国内外相关研究进行综述。

1.2.1 基于答案感知的问题生成

现有的有答案感知的问题生成方法主要集中在序列到序列的问题生成，主要通过使用循环神经网络研究端到端的自动问题生成。基于答案感知的问题生成，最初由 Du 等[16]首次研究，在文中使用基于注意力机制的编码器-解码器框架[17]解决现有手工编织规则的问题生成。同时针对段落级和句子级的问题生成进行研究，无论在机器自动评估指标上，还是人工评价中，均具有明显的优势。然而，这些生成的问题多数不能被所给的文本所回答。因此，Zhou 等[18]通过提取答案的丰富特征位置信息，并提取文本段落中命名实体识别等语言特征。然后将其融入段落级文本中，最终利用指针复制机制[19]有效的提高问题生成的质量，使生成的问题尽可能的可以被文段中的内容回答。Zhao 等[20]提出门控自注意力机制和最大指针机制相结合的方式改善问题生成，门控自注意力机制用于解决段落中的上下文冗余信息的获取，最大指针机制用于获取文本中重要的信息。然而这些方法和模型并未有效的编码目标答案，无法更好的与段落信息进行交互，进而影响问题生成的质量。

因此，Kim 等[21]在前人研究的基础上，发现以往基于神经网络的问题生成

中国知网 https://www.cnki.net

存在一个严重的问题，即生成的问题单词中会包含大量答案中的单词，从而导致非预期问题的生成，进而导致生成的问题不具有现实意义。根据发现的问题，提出答案分离序列到序列模型。该模型可以更好地利用了文章和目标答案的信息。首先该模型利用一种特殊标记来替换原始段落中的目标答案，使模型识别应该使用哪个疑问词。同时引入一个名为关键词网络新模块，有助于模型更好地捕捉目标答案中的关键信息，并生成适当的问题。最后，通过实验结果表明，答案分离的研究方式可以显著减少包含答案的问题数量，有效改善有答案感知的问题生成质量。之后，Song 等[5]设计一个利用多视角匹配的编码器捕获目标答案与段落之间的信息，并利用强化学习进一步改善模型。段建勇等[22]提出两种语义增强策略改善问题生成，并分别编码段落和答案信息。Zeng 等[4]发现现有的深度神经网络研究问题生成模型，总是受到目标答案的不充分表示以及生成的问题单词重复的影响。为了解决这些问题，在文中提出了一个可扩展的答案感知网络,该网络使用基于单词的覆盖机制进行训练，并使用不确定感知波束搜索进行解码。可拓展的答案感知网络主要通过其周围带有编码器的句子来表示目标答案，并使用门控段落-答案注意力机制将扩展答案合并到段落表示中，以解决目标答案的不充分表示问题。在文中，为了减少不必要引入重复上下文单词的问题，利用基于单词的覆盖机制，在训练不同的时间阶段重复注意相同的单词。同时，不确定感知波束搜索将不确定性分数结合到波束搜索中，以减轻文本退化并减少段落的重复复制单词。最后通过在两个基准数据集上的实验结果证明段落级问题生成方法的有效性。

然而，基于序列到序列的问题生成主要使用循环神经网络作为编码器-解码器结构，只能捕获文本中的表层语境关系，无法模拟句子之间的远距离关系。随着图神经网络的快速发展，一些研究者开始尝试将图神经网络引入到问题生成的模型中。这些研究通过利用图结构强大的表征能力，构建如实体关系和语义关系的结构对象，从而对句子之间的关系进行长距离编码，有效学习长文本之间的语境关系，并解决语义等信息丢失问题。

在使用图神经网络研究问题生成中，Chen 等[23]发现先前的神经问题生成存在三个问题：（1）在深度神经网络编码上下文的信息时，容易忽略隐藏在文本中的丰富结构信息；（2）解码过程中仅仅依赖交叉熵损失，导致暴露偏差问题；（3）在编码过程中，未能充分利用答案信息。因此，为了解决以上的这三个问题。首先提出了一个基于强化学习的图到序列问题生成模型，该模型包括一

中国知网 https://www.cnki.net

个图到序列的生成器和一个混合评估器。其中图到序列的生成器是一个新颖的基于双向门控图神经网络的编码器来嵌入段落，混合评估器具有结合交叉熵和强化学习损失的混合目标，以确保生成语法和语义有效的文本。最后引入一个有效的深度对齐网络，用于将上下文和答案信息进行整合。同时，这一模型是端到端可训练的模型，并通过大量的实验结果表明，该方法具有显著的优点，可以有效改善问题生成的质量。胡月等[24]在解码端利用图 Transformer[25]和 BERT[26]两个编码层加强文本语义表示，获取足够多的背景信息，生成更加丰富且多样化的问题。Fei 等[27]为了解决先前模型存在无法保证生成问题的复杂性问题，提出一种控制问题生成的框架，这一框架由基于遗传算法的密钥实体提取器和受控生成的密钥实体提取器组成。首先从输入的文档中构建实体图，然后使用图注意力网络[28]提取出现在多跳推理链中的关键实体，以确保生成的问题具有复杂而完整的推理链。Ma 等[29]通过设计一个答案感知的段落表示模块整合段落中的信息，并利用图神经网络增强文本段落信息。Guan 等[30]为了更好的解决深度问题生成，提出一种语义丰富的强化学习深度问题生成（SRL-DQG）模型，该模型更好地利用了基于门控图神经网络的文档表示语义图，同时使用强化学习优化具体的指标，综合考虑四个评估因素。最近，李亚峰等[31]提出双图交互机制研究问题生成。以上模型采用图到序列的模型研究问题生成，但是依然存在序列信息和语义结构信息丢失的问题。在基于答案感知的问题生成中，如何解决图到序列中存在的序列信息和语义结构信息丢失的问题，目前有待研究和探讨。

1.2.2 基于答案感知的多样性问题生成

以往基于答案感知的多样性问题生成，通常使用手工编织规则的方式[32-33]进行研究。但是人工手动编制规则，不仅需要专业领域的专业人士，而且会导致规则的不通用，无法实现更好的迁移，其中最为弥足珍贵的是人工手动编制规则会浪费大量的人力资源和时间成本。随着深度学习的快速发展，各种模型铺天盖地而来，带给问题生成领域的研究者们许多启发。因此，研究者开始转向研究的角度。

近期，使用深度神经网络研究基于答案感知的多样化问题生成，主要关注给定一段文本和答案自动生成不同语境和不同表达方式的问题。Cho 等[34]提出

中国知网 https://www.cnki.net

一种创新的方法，专注于答案感知的多样性问题生成，并引入一个通用的选择器模块，明确地将多样性从生成过程中分离出来，能指导已有的编码器-解码器模型。在多样性阶段，通过专家混合对源序列的不同二进制掩码进行采样，实现多样内容的选择。考虑到文本信息的离散不可微性质和二进制标签的缺乏，他们采用了基本事实掩码的代理方法，并应用随机 Hard-EM（Hard-Expectation Maximization, Hard-EM）进行训练。之后，Wang 等[35]在该论文的研究基础上，发现问题生成可以产生一对多的问题，且可以提出不同语境和不同表达方式的问题，并从两个方面探讨问题生成的多样性。首先通过条件变分自动编码器[36]中的一个连续潜在变量选择上下文的内容，将其作为一个内容选择器与上下文和内容选择器联系起来，接着在条件变分编码器中，采用多模态先验分布的技巧，选择更多样化的内容。同时，为了考虑各种表达方式，并对问题的类型进行显示建模，进一步提出一种多样性的促进算法。最后，将所提出来的模型在公共数据集上进行验证，实验结果表明，这一提出的方法可以显著提高生成问题的多样性。特别是从使用不同问题类型的角度来看，该文提出的方法可以有效的改善问题生成的多样性，并在生成质量和多样性之间实现了更好的折衷。

为了更进一步的研究基于答案感知的问题生成多样性，Pan 等[37]开始研究一个更复杂的问题生成任务，即为每组关键词生成一系列一对多的问题。为了解决这一难题，不仅提出了一种新的深度神经生成模型，而且收集了一个包含 62835 个问题和 12567 组关键词的中文数据集。该深度神经生成模型通过结合上下文信息和控制信号，从给定的固定关键字集产生多个不同的问题。其中控制信号旨在通过从整个数据集中捕获不同的模式来增加问题的多样性，上下文信息用于保证生成的问题和给定关键字高度相关。并通过实验结果表明该模型能够产生多样化和有意义的问题。Rathod 等[38]在大型自然语言处理生成模型的帮助下，提出一种新颖研究基于答案感知的问题生成多样性的任务，即多问题生成。以往对于每个预期的答案，通常只生成一个问题。但在现实情境中，针对同一答案可能需要多个语义相似但词汇不同的问题来评估同一概念。基于此，该论文首先提出一个基于结果问题的理想质量评估框架，然后在两个问题生成条件下比较多个问题生成方法的结果，并在问题可回答性和两个问题之间的词汇多样性之间的进行折衷。这一模型不仅抽取多个问题的初步结果探索生成两个以上的问题，而且还进一步探索向学生展示多种不同的问题措辞的教育影响。

但是，以上在研究基于答案感知的多样性问题生成中，模型会存在退化现

中国知网 https://www.cnki.net

象以及会生成大量问题单词重复的现象，导致可回答性低的问题。为了更进一步提升问题生成多样性的质量，改善可回答性，在解码端进行改进是一项改善问题生成多样性的良好举措。

1.2.3 基于无答案感知的多样性问题生成

基于无答案感知的问题生成，主要分为两个研究方向。一种是基于无答案感知的单个问题生成，另外一个研究是基于无答案感知的多样性问题生成。

基于无答案感知的单个问题生成，即不给定答案提示的前提下，直接通过一段文本以端到端的方式生成单个问题。Du 等[16]在文中使用基于注意力机制的编码器-解码器框架，为更进一步研究模型的有效性，验证了无答案感知的单个问题生成，表明所提方法的鲁棒性。同时，Duan 等[39]提出基于检索式的卷积神经网络模型和基于生成式的循环神经网络模型，用于提升无答案感知的问题生成质量。Guo 等[40]利用多任务学习来改进文本的摘要，然后进一步研究问题生成，改善问题生成的质量。在无答案感知的单个问题生成研究中，会经常出现生成问题单词重复的现象。为了防止生成问题过程中的重复问题，Chali 等[41]将覆盖机制引入基于循环神经网络的序列到序列问题生成中，用于解决未登录词问题以及问题单词重复的现象。

基于无答案感知的多样性问题生成，通常被用于研究特定的领域。Wu 等[42]提出一种问题类型驱动框架，用于研究无答案感知问题生成的多样性，这一框架首先通过预测问题的类型，然后生成遵循特定问题类型模型的问题。并设计一种新的复制损失函数来增强复制机制，从而增加从源句中复制关键词的概率，在实际应用中，被广泛应用于问答，同样可以被应用于电商领域的对话系统。Zhang 等[43]提出一种新的研究方法，通过研究无答案感知的多样性和特殊性问题生成，来解决电子商务领域的商品信息缺失问题。该方法通过卷积神经网络预测问题的关键词，然后再使用基于注意力机制的循环神经网络作为模型的基础架构，最后将预测的问题关键词通过多层感知器输入到编码器和解码器的两端，进一步提高生成多样性问题的质量。最近 Roitman[44]提出基于 T5[45]模型和 LTD 相结合的方式研究无答案感知的多样性问题生成，但使用预训练模型生成问题会产生代价过于昂贵的问题。因此，基于无答案感知的多样性问题生成，目前还处于研究的初步探索阶段。如何有效的改善生成问题的多样性质量，依然是目前存在的一个难点。

中国知网 https://www.cnki.net

综上所述，在当前不同方式的问题生成研究中，尽管基于答案感知的问题生成引起了广泛关注，但仍然存在一些不足之处需要进一步优化。特别是在采用图到序列模型时，面临着序列信息和语义结构信息丢失的问题。此外，在特定领域中，无法提供更个性化和多样化问题的挑战也是一个问题。同时，基于答案感知的多样性问题生成也存在一些质量问题，比如问题单词重复等，这些问题影响了问题的可回答性和质量。虽然基于无答案感知的多样性问题生成被认为能够缓解特定领域中的信息缺失问题，但其在预测问题关键词时却忽视了上下文的全局结构信息，导致问题关键词不够精准，从而最终影响了问题生成的质量。因此，有必要进一步研究和探讨这三种类型的问题生成方法，以改进其在各个领域中的应用。

1.3 研究内容

使用深度神经网络研究自动问题生成是自然语言处理中新兴的研究方向，已然引起了越来越高的关注度。为了改善上述自动问题生成技术中生成问题的质量，生成更加符合实际意义和领域需求的问题，本文分别对基于有答案感知的问题生成、基于答案感知的多样性问题生成-和基于无答案感知的问题生成三类任务进行研究，具体研究内容包括以下三个方面：

（1）基于多阶段时序和语义信息增强的问题生成

在研究有答案感知的问题生成时，发现当前序列到序列的问题生成模型在编码器的多阶段编码和解码过程中存在序列信息和语义结构信息丢失的问题。为了解决这些问题，本章设计了一种基于多阶段时序和语义信息增强的模型，旨在提高问题生成的质量。首先，对段落和答案进行编码，并在对它们进行一系列编码操作后，将不同阶段编码的段落语义信息融合，然后输入到循环神经网络中进行编码。接着，在解码阶段引入迭代图神经网络，将编码后的段落信息与先前生成的文本问题中的丰富语义结构信息相结合。最后，利用基于注意力机制的循环神经网络生成问题。最终，在多个数据集上进行验证，并与多组先进模型进行比较，以验证提出模型的有效性。

（2）基于对比搜索算法的多样性问题生成

最近多样性问题生成研究工作主要聚焦在段落级的问题生成研究，且多样性问题生成过程中存在生成单词重复问题导致可回答性低。因此，本文通过研

中国知网 https://www.cnki.net

究段落级和句子级的多样性问题生成，并提出基于对比搜索算法的多样性问题生成模型。首先构造句子级的问题生成多样性数据集，然后通过微调预训练语言模型来适应下游任务，直接生成多个语义相似，词汇多样的问题，最后为了解决问题生成中的单词重复问题提高可回答性，在解码端引入对比搜索的解码方法，研究分析文本生成中多种解码方法间对问题生成多样性之间的影响。在公开数据集的实验结果表明，在问题生成的多样性研究中引入对比搜索算法的方法优于其它的解码方法。

（3）基于问题关键词预测的多样性问题生成

本章通过研究无答案感知的多样性问题生成，旨在解决电子商务网站中潜在的商品信息缺失问题。目前，KPCNet 模型是应对该问题的最先进方法，其提出了无答案感知的多样性问题生成，强调在问题生成中的多样性和特殊性。然而，该模型使用 TextCNN 对问题关键词进行预测，存在丢失上下文结构信息的问题，导致问题关键词预测不够精准，最终影响了问题生成的多样性和特殊性质量。为弥补这一不足，本文提出了 TEKPCNet 模型。该模型采用 Transformer 编码器对外部的问题关键词进行预测，并结合卷积神经网络和多层感知器来强化编码器-解码器模型的输入端，以进一步提升问题生成的多样性和特殊性。通过在 Home & Kitchen 和 Office 数据集上进行自动评估和人工评价，对生成的问题进行全面评估。

1.4 文章组织结构

本研究一共被共分成了六个章节进行详细描述，具体的各章节内容简要介绍如下：

第 1 章为绪论。主要阐述了研究问题生成的背景及意义，以及国内外问题生成研究的现状，对当前问题生成还存在的问题和挑战进行了阐述，并引入本文所要研究的内容。

第 2 章为相关技术及理论概述。首先简单介绍问题生成的两个基本定义，然后系统的介绍本文研究所需要的主要技术以及发展历程，其中包括问题生成相关技术的研究工作、问题生成中使用的数据集以及评估指标。

第 3 章专注于研究基于多阶段时序和语义信息增强的问题生成。针对图到序列的问题生成模型在编码器的多阶段编码和解码过程中导致段落中序列信息

中国知网 https://www.cnki.net

和语义结构信息的丢失，本章节设计了一种新型的基于多阶段时序和语义信息增强的模型。通过在多个公开数据集上进行验证，对比多个先进模型的实验结果显示，本章节提出的模型在自动评估和人工评价指标上均具有显著提升，进而证明本章所提出模型的有效性。

第 4 章为基于对比搜索算法的多样性问题生成。针对研究多样性问题生成中，容易出现问题单词重复的问题。提出基于对比搜索算法的多样性问题生成模型，通过在解码端引入对比搜索策略，解决解码过程中问题单词重复的现象，改善问题生成多样性的质量。最后，通过在公开数据集 SQuAD 上进行验证，实验结果表明，在问题生成的多样性研究中引入对比搜索算法的方法优于其它的解码方法，且在可回答性、多样性、流畅度之间做出平衡。

第 5 章为基于问题关键词预测的多样性问题生成。针对问题生成中的多样性和特殊性，目前先进的 KPCNet 模型使用卷积神经网络对问题关键词进行预测，容易丢失上下文的全局结构信息，从而导致问题关键词预测不精准，最终影响了问题生成多样性和特殊性的质量，因此本章提出了 TEKPCNet 模型。并通过在公开数据集 Home & Kitchen 和 Office 上进行验证，实验结果表明，提出的模型在自动评估指标和人工评价指标上均具有更优的表现。

第 6 章为总结与展望。主要对全文的内容进行总结，分析问题生成方法的研究现状以及基于现有研究存在的不足，并展望问题生成未来的研究方向和思路。

1.5 本章小结

第一章是全文的绪论。首先通过第一小节来介绍问题生成研究的背景以及意义，接着在第二小节深入分析目前基于深度学习的问题生成相关研究的国内外研究现状，从三个方面进行详细的阐述，并在结尾对三种类型的问题生成总结，然后在第三小节针对国内外现状出现的问题，引出本文的三个研究内容，最后对文章的总体架构进行阐述。

中国知网 https://www.cnki.net

第 2 章 相关技术及理论

本章节首先在第一小节简单介绍两种常见问题生成任务的定义，然后在第二小节介绍了本文研究问题生成所需要的数据集，接着在第三小节中全面概述了问题生成从基于手工编织规则的问题生成研究到基于神经网络的问题生成研究，并将基于规则的问题生成划分为三类，将基于神经网络的问题生成研究划分为四类。最后在第四小节中分别阐述了关于问题生成使用到的机器评估指标，并在第五小节对本章节进行总结。

2.1 问题生成任务

问题生成不仅仅存在自然语言处理领域，同样存在于计算机视觉领域，本文主要探讨自然语言处理领域下的问题生成。自然语言处理领域下的问题生成任务，通常是指给定一段文本或文本和答案自动生成有意义和可回答的问题。

目前，自然语言处理领域下的问题生成存在两种形式化定义，分别为：给定一个文本$C=\{c_1,c_2,...,c_m\}$，目标是为了生成自然语言问题$Q=\{q_1,q_2,...,q_n\}$，即最大化问题Q的概率。具体公式如（2.1）和（2.2）：

$$\bar{Q}=argmax\ P(Q|C) \tag{2.1}$$

$$\bar{Q}=\underset{q}{\text{argmax}}\sum_{i=1}^{n}logP(q_i|C,n<i) \tag{2.2}$$

其中，c_i表示输入文本中的一个单词，m表示输入文本的长度，C表示整段文本序列；q_i表示生成问题中的一个单词，n表示生成问题句子长度，Q表示生成问题的序列。

第二种形式化定义为：给定一个文本$C=\{c_1,c_2,...,c_m\}$和答案$A=\{a_1,a_2,...,a_p\}$，目标是为了生成自然语言问题$Q=\{q_1,q_2,...,q_n\}$，即最大化问题Q的概率。具体公式如（2.3）和（2.4）：

$$\bar{Q}=argmax\ P(Q|C,A) \tag{2.3}$$

$$\bar{Q}=\underset{q}{\text{argmax}}\sum_{i=1}^{n}logP(q_i|C,A,n<i) \tag{2.4}$$

其中，a_i表示输入答案中的一个单词，p表示输入答案的长度，A表示一段答案序列。

中国知网 https://www.cnki.net

2.2 数据集

2.2.1 SQuAD

SQuAD1.1[46]（Stanford Question Answering Dataset 1.1）：该数据集被斯坦福大学创建发布，广泛的应用于机器阅读理解任务，它是一个基于文本段落的问答数据集，主要是为推动机器阅读理解技术的发展。该数据集的数据文本主要从维基百科中抓取，并由人工生成相应的问题，包含超过 10 万个问题，覆盖了 500 多篇文本段落，且每个问题都与相应文本段落中的答案相关联，答案是从文本中抽取出来的连续片段。

SQuAD1.1 数据集被认为是一个极为重要的机器阅读理解基准数据集，不仅仅是推动机器阅读理解技术研究和应用发展的关键资源之一，同时推动了问题生成的研究。它的真实性、多样性和复杂性使得使用这个数据集进行模型训练和评估能够更加贴近实际的应用场景。通过在 SQuAD1.1 上的研究和改进，可以促进问题生成技术的进一步提升，并在问答系统、文本理解与摘要、信息检索与知识图谱等领域产生广泛的应用。

为公平起见，论文中报告的数据结果所采纳的是公开的两种数据集划分方式，这两组分割方法是目前问题生成领域公认的划分方式。其中第一种划分方式[16]为：保留原始训练集的数据集，将验证集以 1:1 的比例分离为验证集和测试集。第二种划分方式[18]为：将原始数据集中的验证集作为测试集，将训练集以 9:1 的比例拆分为训练集和验证集。数据集中训练集、验证集、测试集的数据如表 2.1 所示。本文对数据集中的段落、问题、答案的平均长度进行了统计分析，具体如表 2.2 所示。

2.2.2 MS MARCO

MS MARCO[47]（Microsoft Machine Reading Comprehension）：数据集是由亚洲微软研究院发布的一个用于机器阅读理解任务的数据集，旨在推动自然语言处理领域下的机器阅读理解技术的发展。该数据集是一个基于真实的搜索引擎日志和用户查询构建，由 10 万个问题和答案对组成，答案是通过人工或从文本中抽取的方式得到，覆盖了多个主题和领域，是一种大规模的英文阅读理解数据集。该数据集具备真实性、多样性、复杂性三个显著的特点，表明该数据集和 SQuAD1.1 数据集一样具有权威性。总之，MS MARCO 数据集是一个重要的机器阅读理解基准数据集，并在搜索引擎优化、问答系统研究等领域产生广泛的应用。

中国知网 https://www.cnki.net

本文选择的是该数据集的子集进行研究，将原始验证集作为测试集，并随机的以 9：1 的比例划分原始训练集为训练集和验证集。数据集中训练集、验证集、测试集的数据如表 2.1 所示。本文对数据集中的段落、问题、答案的平均长度进行了统计分析，具体如表 2.2 所示。

表 2.1 SQuAD 和 MS MARCO 数据集样本数目的统计

数据集	训练集	验证集	测试集
SQuAD	75,500	17,934	11,805
SQuAD	86,635	8,965	8,964
MS MARCO	51,289	5,698	6,922

表 2.2 SQuAD 和 MS MARCO 数据集文本、问题、答案的平均长度统计

	训练集			验证集			测试集		
数据集	文本	问题	答案	文本	问题	答案	文本	问题	答案
SQuAD-split1	33.29	12.36	3.58	34.37	12.51	3.73	33.28	12.70	3.02
SQuAD-split2	32.53	12.29	3.16	33.54	12.39	3.35	33.54	12.43	3.36
MS MARCO	84.10	7.10	13.95	84.31	7.05	14.28	84.22	7.12	13.73

2.2.3 Amazon 数据集

该数据集主要来自 Amazon 的一些商品描述，旨在提供关于这些产品的详细信息以及用户的评价和反馈。本文主要通过对 Amazon 数据集中的 Home & Kitchen 数据集和 Office 数据集进行研究。具体数据输入如表 2.3 所示。

Home & Kitchen[48-49]：该数据集收集了各种不同类型的家居和厨房产品等描述信息，具体包括产品信息、产品描述、用户评价等。Home & Kitchen 数据集作为 Amazon 商品数据集中大型的一个数据集，应用十分广泛。首先，对于消费者来说，这个数据集可以提供丰富的产品信息和用户评价，帮助他们做出明智的购买决策。其次，对于厂商和零售商来说，他们可以通过分析用户评价和反馈，改进产品质量和功能，提高用户满意度和口碑。最后，研究人员还可以利用该数据集进行产品推荐、市场分析等研究工作。但是 Home & Kitchen 数据集可能存在一些挑战，如数据质量不一致、用户评价的主观性等问题。

为了实验数据的公平性，通过使用由 Rao and Daume[50]处理后的数据集，该数据集主要由三部分组成，分别是训练集，验证集和测试集。每部分都有上下文和一个问题组成，同时，每一个上下文的描述中对应 3-10 个问题（平均有七个问题），具体数据如表 2.3 所示。

中国知网 https://www.cnki.net

Office[48-49]：该数据集同样来自于 Amazon 的一些商品描述，该数据集收集了各种不同类型的办公产品等描述信息，具体包括办公产品信息、产品描述、用户评价等，且在现实生活中应用非常广泛。首先对于办公人员来说，这个数据集可以提供丰富的办公产品信息和用户评价，帮助他们选择适合自己需求的设备和用品。其次，对于办公设备制造商和零售商来说，他们可以通过分析用户评价和反馈，改进办公产品质量和性能。

为了公平起见，采用和 Home & Kitchen 数据集一样的设置，同样将一个数据集划分成三种类型的数据集，每部分都有上下文和一个问题组成，每一个描述中对应 3-10 个问题（平均有六个问题），具体数据如表 2.3 所示。

表 2.3 Amazon 数据集统计数据

数据集	段落	问题	训练集	验证集	测试集
Home & Kitchen	23,859	145,536	19,119	2,435	2,305
Office	2,731	13,775	2,190	285	256

2.3 问题生成相关研究

问题生成被认为是自然语言处理领域中一项最重要的研究任务，被大量的研究者所研究。目前该领域的研究被分为两类，分别是基于规则的问题生成和基于神经网络的问题生成[51-52]。其中基于规则的问题生成主要包括三个方面，分别是基于模板的问题生成、基于语法的问题生成、基于语义的问题生成。基于神经网络的问题生成主要包括基于序列到序列的问题生成、基于预训练语言模型的问题生成、基于图神经网络的问题生成、基于生成式的问题生成。问题生成的方法研究流程图如图 2.1。

中国知网 https://www.cnki.net

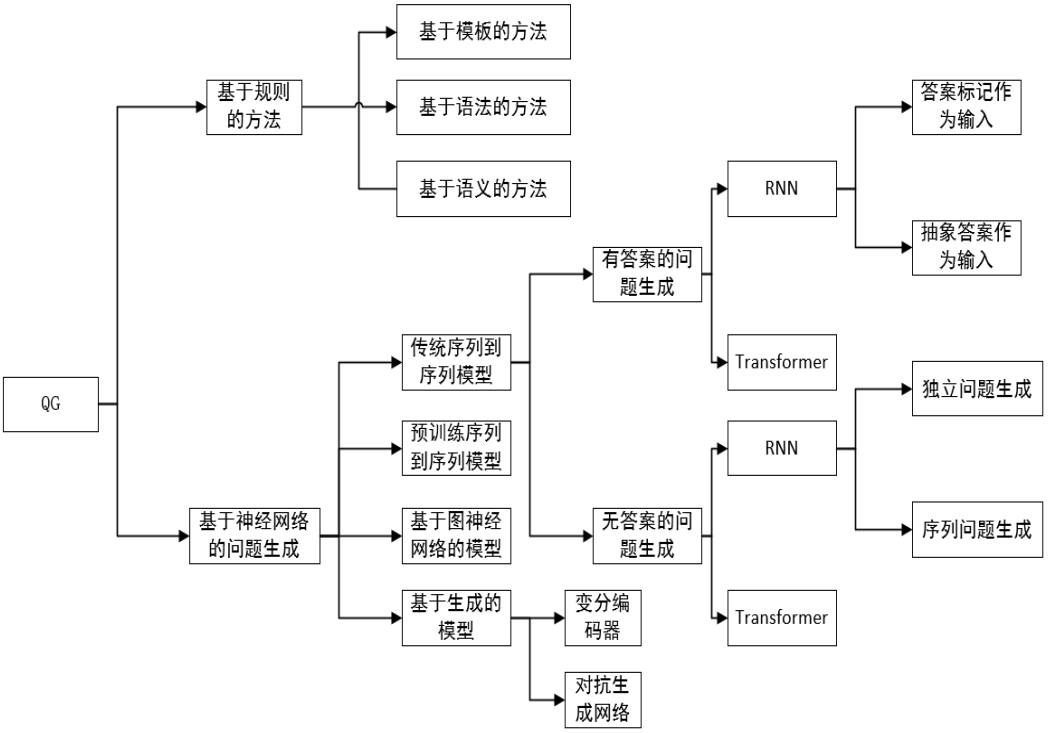


图 2.1 基于问题生成方法研究流程图

2.3.1 基于规则的问题生成

问题生成的提出最早起源于二十世纪七十年代，在斯坦福大学的一份报告中，由 Wolfe[53]所提出，之后由于技术等原因，问题生成一直处于沚泻状态。在 2008 年以后，经过召开一系列问题生成国际研讨会的情景下，问题生成开始引起了人们的广泛关注。2017 年以前，主要使用基于规则的方法研究问题生成。其中基于规则的问题生成主要分为三类，分别是基于模板的问题生成、基于语法的问题生成、基于语义的问题生成。

（1）基于模板的问题生成

基于模板的问题生成就是预先设计好问题的模板，然后根据模板来生成相应的问题。例如：在 2010 年始，Heilman 和 Smith[32]开始研究如何自动从阅读材料中生成问题用于教育领域的实践和评估。该论文中通过使用基于模板的问题生成方法，首先将句子转换为简单的陈述句，从输入的句子中根据定义良好的模板创建生成的多个问句，然后使用基于监督学习的排序器进行排序，最后通过选出排序在前边的高质量更容易接受的问题作为输出，并使用人工注释的方式对接受的问题进行验证。Zheng 等[33]在论文中提出一种中文问题自动生成的框架，帮助读者获得中文文本的主要内容，方便中国读者有目的的进行阅读，从而提高阅读的质量。该论文中提出的方法是基于模板的方式研究中文问

中国知网 https://www.cnki.net

题生成，首先建立一种基于模板的方法来构造更多的变体问题，然后使用多特征神经排序模型的思想，对生成的问题进行排序，最后通过大量的实验结果表明，该方法与以往的模型相比，在困惑度和人工评价方面均具有显著的提升。

最近几年，基于模板的问题生成方法依然有学者在研究，Fabbri 等[54]通过提出一个简单基于检索和模板的问题生成方法，并不使用原始文本中的语句生成问题，经过大量的实验结果以及消融实验，验证生成问题的质量明显有了较大的提升。

（2）基于语法的问题生成

基于语法的问题生成方法就是对文本的语言，通过构造相关的语法树或利用文本的相关语法知识，将陈述句改为疑问句，以便生成满足需求的问题。例如：Mannem 等[55]在第三届问题生成研讨会提出段落级别的问题生成，要求在给定一段文本的前提下，使用句子的谓词参数结构以及语义信息来从段落中生成问题，然后对生成的问题进行排名，选出每个段落中产生范围不同的六个最佳问题。Kunichika 等[56]介绍了关于英语故事内容的自动问题生成方法，为了向不同理解状态的学习者给出合适的问题，通过研究智能英语学习系统，提出了五种基于语法分析的固定规则：询问一个句子的内容、使用同义词或反义词，使用出现在复数句中的修饰语、使用关系代词询问复数句所代表的内容、以及询问时间和空间的关系，从而生成相应的问题。并在日本初中学生教科书中的句子生成疑问句，验证生成问题的语义正确性 。

（3）基于语义的问题生成

基于语义的问题生成主要是通过分析文本词与词之间的语义关系，然后依靠精心设计的规则或人工创建的模板，将一段给定的文本转换为相应可回答的问题。例如：Lindberg 等[57]发现在教育领域下问题生成所存在的一些问题，当教师为学生准备材料时，可以使用自然语言处理技术自动生成合适的问题，但是在使用到的自然语言处理技术中，未充分利用包含在学习材料中的语义信息或完整的上下文信息。因此，通过引入一种基于模板的复杂方法，将具有语义角色的标签，合并到问题自动生成中，以便支持在线学习系统，并从教育者的角度和学习者的角度出发评估问题生成的质量。Mazidi 等[58]描述了一个自动问题生成器，使用语义模式识别来创建不同深度类型的问题，将其应用于自学和辅导，并探讨语言因素如何影响系统设计等问题。

综上所述，基于规则的问题生成方法在 2017 年以前是该领域的主流方法，因为当时的自然语言处理中的神经网络发展正处于低估期，硬件资源不足以支撑训练的资源，且使用人工总结出来的问题模板，在使用时不会出现过多的语法问题和逻辑问题，而且具有很高的结构化，从而使得当时的问题生成句子更

中国知网 https://www.cnki.net

加流利。但是缺点极为明显，由于传统基于规则的问题生成模板总是有限，在面对大量数据且数据结构形式化不明显的情况下，这种基于模板的问题生成方法很难奏效。而且，传统基于规则的问题生成总是需要人工进行参与，浪费了大量的人力和时间。因此，在 2017 以后，大量的学者开始使用深度学习的方法研究问题生成。

2.3.2 基于神经网络的问题生成

利用深度学习中的模型提取文本的特征，得到的词嵌入向量具有丰富的信息量和可区分性。相比传统基于规则的问题生成方法更具优势，是问题生成领域的一个重要突破。因此，在 2017 年以后 Du 等[16]使用神经网络完成问题生成，实现了端到端的问题生成，且生成的问题质量比传统基于规则的方法更优。因此，问题生成领域的大量研究者开始将神经网络模型作为研究问题生成主流的方式。目前基于神经网络的问题生成主要聚焦在基于序列到序列的问题生成、基于预训练模型的问题生成、基于图神经网络的问题生成、基于生成式的问题生成四种研究方式。

（1）基于序列到序列的问题生成

现有的工作多数基于序列到序列网络，并结合注意力机制和指针复制机制所形成的框架。这一框架主要是为了解决将一个答案和段落（句子）进行结合的问题生成任务，即有答案感知的问题生成。有答案感知的序列到序列问题生成模型图如图 2.2 所示。但是为了更全面的总结序列到序列的问题生成，本章对无答案感知的序列到序列问题生成，也进行了简单阐述。

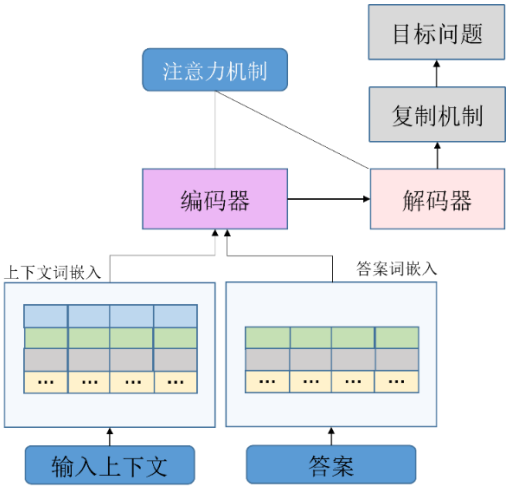


图 2.2 有答案感知的序列到序列的问题生成模型图

中国知网 https://www.cnki.net

基于神经网络的问题生成由 Du 等[16]首次在 2017 年国际会议提出，不需要依赖手工规则和自然语言处理中语法和语义的分析进行处理，而是使用序列到序列的方式，针对句子级和段落级的问题生成进行研究。而且与之前传统基于规则的方法相比，基于深度学习中的神经网络问题生成模型在问题流畅性等多方面都表现出了巨大的优势，比起基于规则的问题生成，在效果上具有明显提升。Zhou 等[18]提出采用基于循环神经网络（RNN）的序列到序列模型，并将答案位置编码和词汇特性与上下文词汇进行融合，使用这些特征更好的建模文本中有意义的语义信息，进一步将问题生成的数据结果精确度提升到相对较高的位置。Zhao 等[20]针对段落级别问题生成出现的问题，本身的模型仍旧沿用指针生成网络框架，但是在复制概率计算时提出改进。在获取文本单词级别的特征以及句子特征以后，提出门控融合机制得到输出段落的表示，并对复制机制中出现多次重复的问题词汇，提出一种最大指针机制，改善问题生成的质量。Zhou 等[59]针对问题类型和答案不匹配的问题，提出根据输入答案上下文自动预测问题类型的方式，将其融入序列到序列的模型中，以此来提升问题生成的质量。

在国内，关于序列到序列的问题生成相关研究，同样引起了大量研究者的关注。易也难等[60]发现现有问题生成研究中，编码器对输入语句进行建模时，无法有效捕获上下文单词之间的相互关系，在解码端依然无法有效利用原始输入语句提取的语义信息，因此提出一种新的模型-改进的注意力机制问题生成模型。该模型在编码器端加入自注意力机制，获取输入单词之间的关系，以便在解码端有效利用该信息，并在解码器的多层输出中，联合计算全局注意力权重，充分在解码过程中利用语法语义信息提高问题生成的质量。曾碧卿等[61]发现序列到序列的段落级问题生成中无法最大程度的利用段落中的上下文信息，存在冗余信息等问题，因此提出一种基于注意力的段落级问题生成模型。该模型首先使用注意力机制，有效融合段落信息和答案信息，使用门控机制动态分配权重将答案信息融合到上下文的段落信息中，然后在解码端使用单向循环神经网络进行解码，最后在解码过程中，对指针生成网络进行改进，从而生成改善问题生成的质量。段建勇等[22]在研究问题生成中发现现有模型存在语义偏离给定的上下文和答案信息，因此提出将义原知识编码到上下文中，然后在编码层融入双向注意力流，增强文本和答案之间的交互，进而改善两者之间的语义表征，最终改善问题生成的质量。

以上研究是基于答案非抽象的问题生成，但是无法解决答案是抽象的问题生成。在答案是抽象的问题生成研究中，许多研究者的工作重点是如何有效编码抽象答案，将编码后的抽象答案与上下文进行结合，有效提升带有抽象答案

中国知网 https://www.cnki.net

的问题生成。Wang 等[62]设计一种弱监督的鉴别器，并分别对答案和段落进行编码，然后捕获更多与答案相关的信息，最后使用基于注意力机制的 LSTM 解码，并利用复制机制解决词汇量不足的问题。武恺莉等[63]为了提高问题生成的质量，从改善预测问题出发，利用 BERT 模型预测问题的类型，然后结合惩罚机制进一步提高问题生成的性能。Kim 等[21]为了解决生成非预期问题，在文中提出答案分离的序列到序列模型。首先通过一个特殊的标记替换原文章中的答案信息，然后对掩码的段落和答案进行编码，更好的捕获文章中目标答案的信息，最后采用检索式单词生成器，更好的捕获生成问题过程中的单词语义信息。

在对序列到序列的有答案感知的问题生成研究下，研究者提出更具有挑战性的话题-无答案感知的问题生成。目前，已经存在一些工作正在研究关于如何提高无目标答案监督情境下的问题生成质量，多数基于无答案感知的问题生成模型如图 2.3 所示。为了提高无答案感知问题生成的效果，有研究学者分别针对段落级别和句子级别的问题生成进行了研究。在段落级别输入文本的问题生成研究中，Duan 等[39]提出基于检索式的卷积神经网络模型和基于生成式的循环神经网络模型，这两种模型相辅相成，用于提升无答案感知的问题生成质量。在句子级别的问题生成方面，Guo 等[40]利用多任务学习来改进文本的摘要，教会模型学习如何寻找重要的文本信息，然后根据这些重要信息生成相应的问题，以进一步提升问题生成的质量。Wu 等[42]提出一种问题类型驱动框架，用于研究无答案感知问题生成的多样性，这一框架首先通过预测问题的类型，然后生成遵循特定问题类型模型的问题。并设计一种新的复制损失函数来增强复制机制，从而增加从源句中复制关键词的概率，更好的生成高质量的多样性问题。

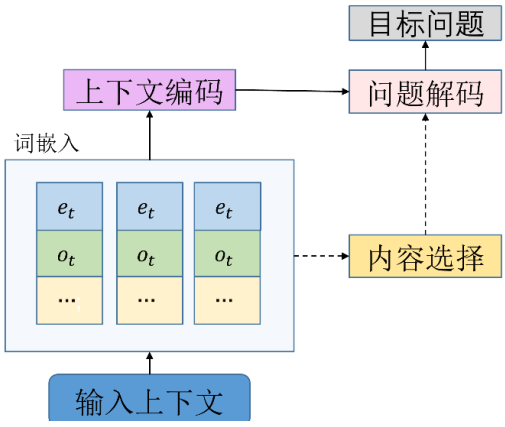


图 2.3 无答案感知的序列到序列的问题生成模型图

在无答案感知的问题生成研究中，经常会出现生成问题重复的现象。为防止生成问题过程中的重复问题，Chali 等[41]将覆盖机制引入基于循环神经网络的序列到序列问题生成中，用于解决未登录词问题以及问题词汇复制重复的现象。

中国知网 https://www.cnki.net

（2）基于预训练模型的问题生成

随着深度学习下的神经网络飞速发展，基于大规模预训练语言模型已经成为一种趋势。不仅可以更好的提高各种自然语言处理的性能，而且只需要在下游对需要求解的任务进行微调，即可更好的求解相应的目标，得到更好的效果。因此，在问题生成领域，研究者开始不断尝试使用大规模预训练模型提升问题生成的性能。在现有的大规模预训练模型中，BERT[26]是最突出的一种，许多工作利用微调 BERT 模型，得到很好的训练结果。因此，一些工作尝试利用 BERT 来提升问题生成的质量，但是由于 BERT 是为了语言理解任务设计的，直接将 BERT 使用到自然语言生成任务是不可行的。因此，Chan 等[64-65]第一个发现 BERT 在问题生成任务上存在的缺陷，并提出三种建立在 BERT 上的神经架构。首先验证直接使用 BERT 进行问题生成，生成的问题效果极为不佳；然后，再此基础上提出 BERT-SQG 模型；最后，为了更好的生成问题，更进一步提出了 BERT-HLSQG 模型。

此后，Dong 等[66]提出一种 UniLM 的预训练语言模型，该模型使用三种不同的掩码方式进行自注意力机制，来控制预测词标记上下文，在问题生成数据集的验证中，取得了当时最优的效果。Xiao 等[67]提出一种增强多流序列到序列的预训练和微调框架（ERNIE-GEN），该框架结合填充生成机制和噪声感知生成方法，来缓解暴露偏差，成功获得当时最好的效果。Wang 等[68]提出一种基于 Transformer 的大型预训练语言模型，是一种简单有效的知识蒸馏模型 MiniLM，并在问题生成的数据集进行测试，从而证明该预训练模型可以有效提升问题生成的效果。Qi 等[69]提出一种预训练模型 ProphetNet，通过在每个时间步学习之前的上下文的词汇，并在每一个时间步预测未来的 N 元组，提前预知问题的下一个词汇，以此提升各个下游任务的效果。Lamba 等[70]利用 T5 模型完成问题生成，并在论文中提出逻辑约束、经验约束和基于数据的三项约束，同时在损失函数中引入额外的惩罚或奖励项。

（3）基于图神经网路的问题生成

近年来，基于神经网络的问题生成模型工作主要聚焦在序列到序列和预训练语言模型的研究，但只能捕获文本中的表层语境关系，无法模拟句子之间的远距离关系。为了解决这些问题，一些研究者开始使用图神经网络研究问题生成，这些研究多数利用图结构的表示能力，构建如实体关系和语义关系的结构对象，从而对句子之间的关系进行长距离编码，有效学习长文本之间的语境关系。

中国知网 https://www.cnki.net

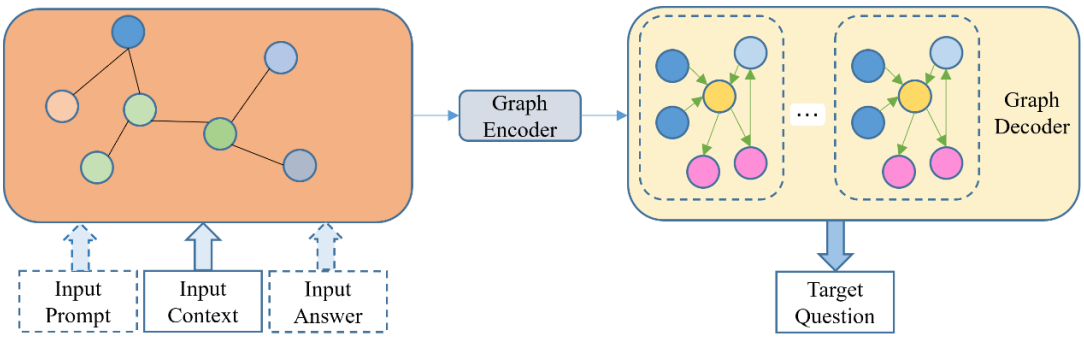


图 2.4 基于图神经网络的问题生成抽象图

多数基于图神经网络的问题生成构建抽象流程图如图 2.4 所示。首先构建一个关于文本语境之间的图结构；然后根据图模型，从构造的文本信息中有效学习图嵌入；最后，使用不同的解码方式生成高质量的问题。例如： Chen 等[23]在研究基于图神经网络的问题生成时，发现先前使用神经问题生成存在三个问题：其一是在深度神经网络编码上下文的信息时，由于序列到序列模型总是捕获文本的序列信息，很容易忽略隐藏在文本中的丰富语义以及语法结构信息；其二是在解码过程中仅仅依赖交叉熵损失，容易导致暴露偏差问题；其三是在编码过程中，虽然融合了答案的信息，但是依然未能充分利用答案信息。因此，为了解决以上的这三个问题。首先提出了一个基于强化学习的图到序列问题生成模型，该模型包括一个图到序列的生成器和一个混合评估器。其中图到序列的生成器是一个新颖的基于双向门控图神经网络的编码器来嵌入段落，混合评估器具有结合交叉熵和 RL 损失的混合目标，以确保生成语法和语义有效的文本。最后还引入了一个有效的深度对齐网络，用于将上下文和答案信息进行整合。同时，这一模型是端到端可训练的模型，并通过大量的实验结果表明，该方法具有显著的优点，可以有效改善问题生成的质量。Chai 等[71]研究如何在双图交互下进行半自回归的序列问题生成。Huang 等[72]发现先前的工作未能同时捕获隐藏在上下文中的序列信息和结构信息，因此提出使用图卷积神经网络和 BiLSTM 来同时捕获上下文结构信息和序列信息，并结合实体引导的方式从答案中获取问题的类型，因此提高问题生成的质量。Fei 等[73]发现以往的研究忽略了隐藏在先前生成文本中的丰富结构信息以及上下文词汇对文章的影响。因此设计了基于迭代图网络的解码器（IGND），在每个解码步骤使用图神经网络对上一次的生成进行建模，并利用图神经网络模型捕捉促进问题生成通道中的依赖关系。

Fei 等[27]为了解决先前模型无法保证生存问题的复杂性问题，提出了一种控制问题生成的框架，这一框架由基于遗传算法的密钥实体提取器和受控生成的密钥实体提取器组成。首先从输入文档构建实体图，然后使用图注意力网络提

中国知网 https://www.cnki.net

取出现在多跳推理链中的关键实体，以确保生成的问题具有复杂而完整的推理链。Ma 等[29]为了有效地利用答案信息并捕获文章的结构和语义信息，提出了一个图增强序列到序列（GA-Seq2Seq）模型。首先设计了一个答案可感知的模块，将答案信息整合到文章中；然后为了发现文章的结构和语义信息，提出了一种由图编码器和序列编码器组成的图增强文章编码器；最后利用一个基于注意力的长短期记忆解码器来生成问题。Guan 等[30]为了更好的解决深度问题生成，提出一种语义丰富的强化学习深度问题生成（SRL-DQG）模型，该模型更好地利用了基于门控图神经网络（GGNN）的文档表示的语义图，同时使用强化学习优化具体的指标，综合考虑四个评估因素。

（4）基于生成式的问题生成

生成式的问题生成模型主要基于变分自编码器[74]（VAE）以及生成式对抗网络[75]（GAN）两种方法研究，VAE 实现问题生成的最终目标是最大化数据似然估计的下界，而 GAN 的目标是利用生成器和鉴别器之间的最大-最小博弈，生成更高质量的问题。

VAE 是一种潜在变量生成模型，通过引入后验概率简化学习。在文本的生成中，Wang 等[76]提出两种新的答案引导语义连贯的对话问题生成模型, 将 VAE 分别集成到强化学习框架和 GAN 框架中，采用强化学习和对抗学习对答案信息进行挖掘，用于控制具有合理类型的问题生成，从而提高问题生成的质量。Lee 等[77]提出第一个利用分层条件 VAE 研究问答的生成式模型，这是一种新颖的研究方法。Li 等[78]提出一种批量标准化条件 VAE 问答对生成模型，使用批量归一化层来防止 KL 散度发散消失问题，并设计从文本内容中提取时空特征的模块。此外，在问题生成的解码器中，采用自注意力机制，进一步提高结果的准确性和召回率，从而生成给定文本的 QA 对。以上工作利用编码器将观察变量映射到潜在变量，然后利用解码器从潜在变量映射到观察变量。有效利用 VAE 的变体模型研究问题生成这项工作。

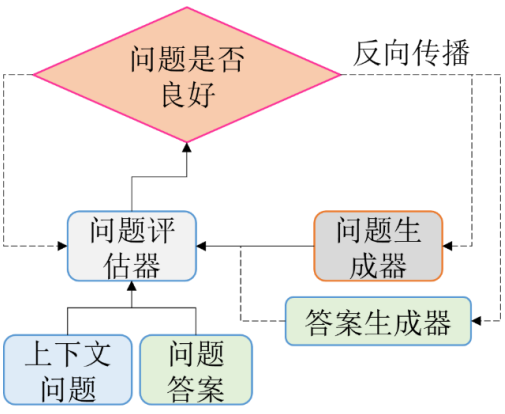


图 2.5 GAN 网络模型的问题生成抽象流程图

中国知网 https://www.cnki.net

GAN是一种对抗生成式的网络，主要利用生成器和鉴别器之间的最大-最小博弈完成相应的任务。最近的一些工作，研究者利用生成器生成问题，鉴别器评估生成的问题。具体实现如图2.5所示。早期的Bao等[79]在为解决特定领域下无标记数据的问题，提出一种双重对抗网络模型，利用领域分类鉴别器和问答鉴别器之间的相互作用，共同提高目标域上生成问题的质量。Hosking等[80]使用最大似然估计训练的生成器，为训练集中的每一个语境-答案对生成问题，利用鉴别器从训练数据中学习奖励，生成质量更好的问题。Xie 等[81]提出一种新颖的问题生成，首先使用知识提取器从知识库中提取与原始问题相关的先验知识，然后引入注意力机制和门控机制，选择性的提取先验知识，进行重写。此外，利用鉴别器模块促进生成的语义信息，以便在语义上接近原始问题和基本事实。

2.4 评估指标

2.4.1 BLEU 指标

BLEU（Bilingual Evaluation Understudy，BLEU）指标[82]最初应用于机器翻译中，翻译质量越好，越接近真实翻译文本，得出的指标值越大。最初是由IBM的Kishore Papineni等人在2002年提出的一种自动化评估机器翻译质量的方法，BLEU 指标的全称为 Bilingual Evaluation Understudy，即双语评估理解。其中 BLUE 指标的核心思想是基于 N 元组，通过统计候选文本中出现在参考文本中的所有 N 元组次数，求出该次数占该候选文本中总的 N 元组个数的比例，所得结果即为评测结果。由于 N 元组会被重复利用，因此，提出修正的 N 元组精确度解决这一问题。评估指标的计算公式如式（2.5）和（2.6）。

$$BP=\begin{cases}1, & if\ \ NMT_output_len > refer_len \\ exp(\dfrac{1-NMT_output_len > refer_len}{refer_len}), & otherwise\end{cases} \tag{2.5}$$

$$BLEU = BP \times exp(\sum_{i=0}^{n}\frac{1}{n}\times logp_n) \tag{2.6}$$

其中，BP 是惩罚因子，用来避免过短的对照得分。p_n是 N_gram 的精度，即机器翻译中的 n-gram 和参考翻译的 n-gram 的匹配比例。当 n=1 时，计算结果为 BLEU1，n=2 时，计算结果为 BLEU2，目前，在问题生成的评估指标中，使用最多的为n等于 1，2，3，4。

中国知网 https://www.cnki.net

2.4.2 METEOR 指标

METEOR（Metric for Evaluation of Translation with Explicit Ordering，METEOR）指标[83]最初是评估机器翻译的度量指标，该度量指标的核心思想是为了平衡精确度和召回率两个评估指标。这一度量指标被用来设计修正 BLEU 指标的某些缺陷，人们希望该指标在句子和语段层面与人类判断产生良好的相关性。METEOR 度量指标的基本评估单位是句子，并非单独的某一个单词。目前该指标已经被用来当作问题生成的评估指标，并在问题生成中广泛使用。METEOR 分数的计算公式如式子（2.7）到式子（2. 11）。

$$P = \frac{m}{w_t} \tag{2.7}$$

$$R = \frac{m}{w_r} \tag{2.8}$$

$$F_{mean} = \frac{10PR}{(1-\alpha)R + \alpha P} \tag{2.9}$$

$$p = \beta(\frac{c}{u_m})^{\gamma} \tag{2.10}$$

$$M = F_{mean}(1-p) \tag{2.11}$$

其中，m 表示候选问题中，存在于人工编写参考问题的 unigram 数。w_t是候选问题中的 unigram 数，w_r是参考问题中的 unigram 数，P 表示精确度，R 表示召回率。c 表示“块“的概念，u_m是被映射的 unigram 数，p 表示惩罚因子，M 表示最终的计算指标，其中α，β，γ表示超参数，默认分别为$\alpha = 0.9$，$\beta = 0.5$，$\gamma = 3$。

2.4.3 ROUGE-L 指标

ROUGE-L（Recall-Oriented Understudy for Gisting Evaluation，ROUGE）指标[84]最初使用在自动摘要生成的任务中，基本思想是将系统自动生成的摘要与人工生成的参考摘要对比，计算两者之间的重叠基本单元数目，评判摘要的质量。目前，这一指标适用于问题生成，通过使用生成的问题和参考的黄金问题计算重叠词汇数目，评估问题生成的好坏，只考虑召回率，不考虑精确度。具体使用的公式如式（2.12）（2.13）（2.14）。

中国知网 https://www.cnki.net

$$R_{lcs} = \frac{LCS(X,Y)}{m} \tag{2.12}$$

$$P_{lcs} = \frac{LCS(X,Y)}{n} \tag{2.13}$$

$$ROUGE-L = F_{lcs} = \frac{(1+\beta^2)R_{lcs}P_{lcs}}{R_{lcs}+\beta^2 P_{lcs}} \tag{2.14}$$

上式中 X 表示标准问题，Y 表示系统自动生成的问题，m 表示 X 的长度，n 表示 Y 的长度。*LCS*(*X*,*Y*)表示两者的最长公共子序列长度，β是一个超参数，需要自行设置。

2.4.4 Distinct 指标

Distinct 指标[85]是对话生成的一个评估指标，用来评估文本生成的多样性，生成的重复问题越少，该指标值越大。同样，该评估指标可以用来评估问题生成多样性，帮助评估模型生成的问题在词汇多样性方面的表现。Distinct 指标的结果范围通常在 0 到 1 之间。较高的 Distinct 值表示生成的文本中包含更多不重复的词，反之则表示生成的文本较为重复。Distinct 指标可以量化模型生成的文本是否存在重复问题。高 Distinct 值意味着生成文本更加丰富多样，低 Distinct 值可能暗示着生成的文本存在过度重复的情况。需要注意的是，Distinct 指标并不能完全代表生成文本的质量和可读性，仅仅是从词汇多样性的角度提供了一种评估指标。因此，在实际应用中，通常需要结合其他评估指标和人工评估结果来综合衡量生成模型的性能。总之，Distinct 指标是一种简单且常用的自然语言处理评估指标，用于度量生成文本中不重复词语的数量，以评估模型在词汇多样性方面的表现。它在生成任务中具有一定的应用价值，但需与其他评估指标相结合，以得到更全面的模型评估结果。

2.5 本章小结

本章节主要针对问题生成领域相关的理论知识进行梳理，为了后续模型的研究提供理论支撑。本章节主要对本文涉及到的问题生成相关研究使用到的相关技术进行详细阐述，为第三章节、第四章节、第五章节作为铺垫。

中国知网 https://www.cnki.net

第 3 章 基于多阶段时序和语义信息增强的问题生成

本章首先介绍研究的动机，基于该动机提出一种基于多阶段时序和语义信息增强的问题生成模型，接着通过与基础模型进行对比表明本章提出的模型有效提升问题生成的质量，然后使用消融实验表明本文模型各个模块提出的有效性，最后通过案例分析进行展示本文所提出的模型与基础模型之间具体的差异性。

3.1 研究动机

自然语言处理中的问题生成主要专注于在给定段落和提示答案的情境下，生成语法正确、语义相关、能够被回答的问题。近年来，问题生成技术因其在各个领域的广泛应用而受到越来越多研究者的关注。在问答领域[86]，问题生成被看作是问答系统的互补任务，通过创造大规模的问答训练语料库，有望进一步提升问答系统的质量。在教育领域[12]方面，问题生成可协助教师生成大量的阅读练习题，支持教学评估的完成。而在会话系统和聊天机器人[15]中，问题生成则扮演着开始对话或请求反馈的关键组成部分。通过问题生成，不仅能够创造出更具挑战性和多样性的问题，也有望提高系统的自然性和用户体验。

最近，各种神经网络模型在问题生成研究中被广泛提出并应用，成为当前最受欢迎的研究方法之一。这些模型和方法主要借鉴了机器翻译[87]、摘要生成[88]等序列到序列任务的理念。然而，当前主流的基于循环神经网络的序列到序列问题生成模型未能充分利用图神经网络来编码段落信息，从而容易忽略段落中蕴含的丰富语义结构信息。为解决这一问题，一些研究者提出采用图到序列的问题生成模型[23-25][29-31][89-91]，然而，这仍然存在着序列信息和语义结构信息可能遗漏的问题。这表明，尽管神经网络模型在问题生成研究中表现出色，但仍需关注其在处理语义结构时的不足之处。图到序列的问题生成模型的提出为弥补这一缺陷提供了一种潜在的解决方案，但尚存在对序列信息和语义结构信息的不充分利用。因此，为了更全面地理解和表达段落信息，需要继续改进和探索更为创新的神经网络模型和方法，以更有效地应对问题生成任务中的挑战。

因此，为了有效应对在编码和解码不同阶段出现的不同程度信息丢失问题，本章提出了一种基于多阶段时序和语义信息增强的模型。该模型通过融合编码器在不同阶段的编码语义信息，然后利用双向长短时记忆网络对融合后的段落信息进行编码，得到进一步增强的段落语义信息。最终，将增强后的段落语义

中国知网 https://www.cnki.net

信息与解码阶段先前生成的文本问题中的丰富语义结构信息相结合，以最小化解码过程中可能发生的语义结构信息丢失，从而实现生成高质量的问题。

3.2 模型结构介绍

本章的模型架构首先在嵌入层进行处理，通过融入多种段落信息的特征，增强段落中词汇的语义表示信息，有效改善词汇的语义表示能力；然后利用神经网络中的循环神经网络、图神经网络以及对齐机制等对段落和答案进行编码处理；接着为了提取丰富的语义信息，将编码后多个阶段的词嵌入向量进行融合，输入到单层的循环神经网络进行学习；最后利用迭代图神经网络解决解码过程中语义结构信息丢失问题。模型的具体实现如图 3.1 所示。

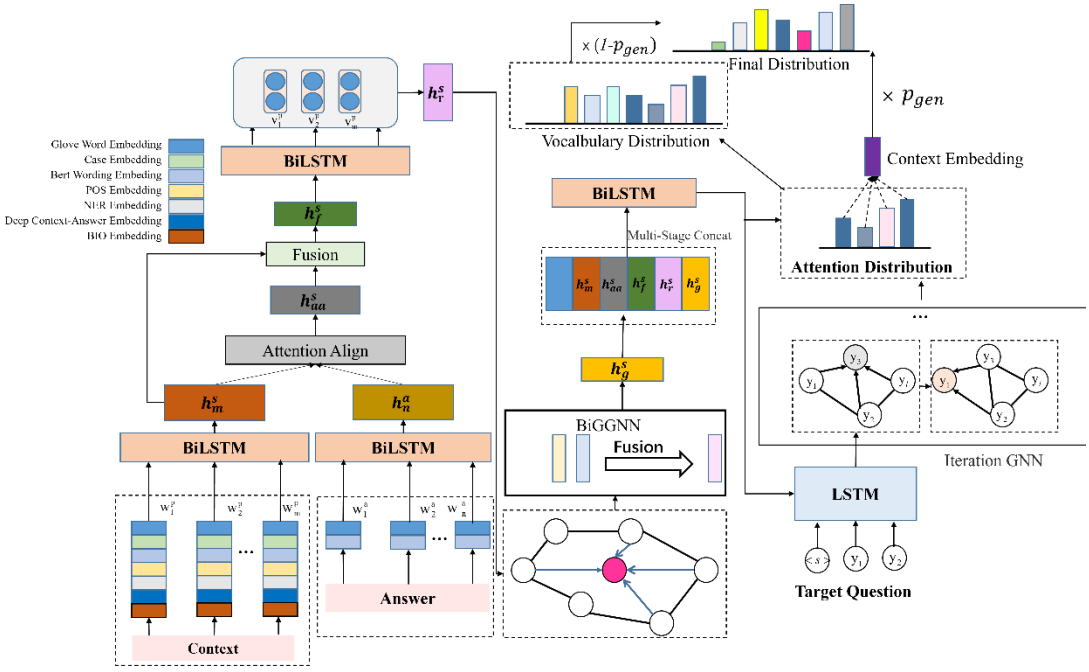


图 3.1 总体模型框架

3.2.1 基于多阶段拼接的编码器

（1）段落和答案的表示

在问题生成中，文章段落的单词表征扮演着至关重要的角色。在实际应用中，通过捕获文章段落单词之间的关联信息，可以充分利用段落单词之间的不同特征，能够获得更为丰富的表征信息。在融合多种段落语义信息特征中，不仅可以提供更深层次的语义信息，还能帮助模型全面理解文本段落。同时，将答案与文章段落信息相结合，有助于模型更好地捕捉以答案为中心的语义信息，

中国知网 https://www.cnki.net

从而进一步提升问题生成的效果，改善问题生成的可回答性。

在模型输入端的嵌入层，需要融合多种语义信息，其中包括基于 BERT 的段落单词嵌入、基于 Glove[92]的段落单词嵌入、词性标注（Part-Of-Speech tagging，POS）、大小写转换（CASE）、命名实体识别（Named Entity Recognition, NER）、融合答案特征的段落以及答案位置标签（Begin-Inside-Outside, BIO），答案语义信息包括基于 BERT 的答案单词嵌入、基于 Glove 的答案单词嵌入，并通过以下方式得到。

首先将一个答案 X^a 和段落 X^s 中的每一个单词根据 Glove 词嵌入转换成答案的词嵌入向量 e_g^a 和段落单词的词嵌入向量 e_g^s，并利用注意力机制得到该阶段的答案与段落对齐的词嵌入 e_a^s。接着利用斯坦福 NLP 工具包提取段落的 POS、CASE、NER、BIO，并在训练阶段将其分别表示为 $e_p^s, e_c^s, e_n^s, , e_{bi}^s$，对应的词嵌入维度分别表示为 12，3，8，3。然后使用典型的 Bert 预训练的词嵌入得到答案单词的词嵌入向量 e_{bert}^a 和段落单词的词嵌入向量 e_{bert}^s，且维度均为 1024。最后将得到答案的 Glove 词嵌入向量以及段落的多个特征向量进行拼接和答案的 Bert 词嵌入向量进行拼接，得到最终模型初始化的段落嵌入向量 w_m^s 和答案词嵌入向量 w_n^a，分别表示如下：

$$w_m^s = [e_a^s; e_g^s; e_p^s; e_n^s; e_c^s; e_{bi}^s; e_{bert}^s] \tag{3.1}$$

$$w_n^a = [e_g^a; e_{bert}^a] \tag{3.2}$$

其中[;]表示拼接操作。

接着将答案和段落得到的初始化词嵌入向量分别使用 BiLSTM[93]进行编码，进而可以有效捕获答案和段落的两种序列信息。具体公式（3.3）-公式（3.6）如下：

$$\overrightarrow{h_t^s} = BiLSTM(w_t^s, \overrightarrow{h_{t-1}^s}) \tag{3.3}$$

$$h_t^s = BiLSTM(w_t^s, h_{t-1}^s) \tag{3.4}$$

$$h_t^s = [\overrightarrow{h_t^s}; \overleftarrow{h_t^s}] \tag{3.5}$$

$$h_m^s = [h_1^s, h_2^s, ..., h_m^s] \tag{3.6}$$

其中，w_t^s 表示第 t 时间步的隐藏层段落单词表示，$\overrightarrow{h_t^s}$ 和 $\overleftarrow{h_t^s}$ 表示 t 时间步的段落隐藏层第 t 个单词的前向和后向隐藏层状态，h_t^s 表示第 t 个时间步的段落单词表示，h_m^s 表示经过 BiLSTM 编码后的段落序列上下文隐层表示。具体如公式（3.7）-公式（3.10）：

$$\overrightarrow{h_k^a} = BiLSTM(w_k^a, \overrightarrow{h_{k-1}^a}) \tag{3.7}$$

$$\overleftarrow{h_k^a} = BiLSTM(w_k^a, \overleftarrow{h_{k-1}^a}) \tag{3.8}$$

中国知网 https://www.cnki.net

$$h_k^a = [\overrightarrow{h_k^a}; \overleftarrow{h_k^a}] \tag{3.9}$$

$$h_n^a = [h_1^a, h_2^a, ..., h_n^a] \tag{3.10}$$

其中，w_k^a 表示第 k 时间步的隐藏层答案单词表示，$\overrightarrow{h_k^a}$ 和 $\overleftarrow{h_k^a}$ 表示段落隐藏层第 k 个单词的前向和后向隐藏状态，h_k^a 表示第 k 时间步隐藏层的答案单词表示，h_n^a 表示经过 BiLSTM 编码后的最终答案上下文表示，该向量融合了答案单词的所有信息。

（2）语义丰富的段落和答案表示

为了将得到的答案信息可以有效的与段落信息进行结合，从而得到语义序列信息更丰富的段落表示。首先利用注意力机制将段落和答案信息进行对齐,得到融合答案信息的段落表示。

$$e_{i,j} = (h_j^a)^T (h_i^s) \tag{3.11}$$

$$h_i^s = \sum_{k=1}^{M} \frac{exp(e_{i,j})}{\sum_{k=1}^{M} exp(e_{k,i})} h_j^a \quad i = 1,\ 2,\ \ldots,\ m \tag{3.12}$$

$$h_{aa}^s = [h_1^s, h_2^s, ..., h_m^s] \tag{3.13}$$

其中，T 表示转置，$e_{i,j}$ 表示第 j 个答案单词与第 i 个段落单词之间的注意力分值。h_{aa}^s 表示融入答案信息的段落序列信息。

然后利用融合机制增强段落表示和被对齐的段落表示之间的交互，进一步得到增强的段落表示。

$$h_f^s = F([h_m^s, h_{aa}^s, h_m^s - h_{aa}^s, h_m^s \cdot h_{aa}^s]) \tag{3.14}$$

其中，h_f^s 表示融合后的段落序列表示。F(·)表示一层前馈神经网络（FFNN），主要用于进行线性变换。⊙表示数学中点积运算中的乘积。

接着将最终融合得到的段落序列表示 $h_f^s = [f_1^s, f_2^s, ..., f_m^s]$ 输入到 BiLSTM 中。

$$\overrightarrow{h_t^s} = BiLSTM(f_t^s, \overrightarrow{h_{t-1}^s}) \tag{3.15}$$

$$\overleftarrow{h_t^s} = BiLSTM(f_t^s, \overleftarrow{h_{t-1}^s}) \tag{3.16}$$

$$h_t^s = [\overrightarrow{h_t^s}; \overleftarrow{h_t^s}] \tag{3.17}$$

其中，f_t^s 表示融合后得到的段落中第t个时间步的单词表示，公式中 $\overrightarrow{h_{t-1}^s}$、$\overrightarrow{h_t^s}$、$\overleftarrow{h_{t-1}^s}$、$\overleftarrow{h_t^s}$、$h_t^s$ 的向量表示与公式(3.3)-式子(3.5)相同。

最终得到如下的答案感知段落序列表示 $h_r^s = [v_1^s, v_2^s, ..., v_m^s]$。

（3）多阶段信息融合和语义信息增强的段落和答案表示

为了更好地捕获上下文段落的语义结构信息，本章首先利用依存分析树构

中国知网 https://www.cnki.net

建段落图。随后，采用双向门控图神经网络（BiGGNN）对段落图中的节点进行编码，其中包括使用答案感知的段落表示 h_r^s 来初始化节点嵌入。最后，通过 K 次迭代，每个节点嵌入将根据其前向和后向邻域节点的表示进行聚合更新。

K 次迭代后，节点嵌入可以捕获其 K 跳邻域内的结构信息。为了方便解释节点嵌入的 K 次迭代更新过程，本章以迭代 K 次时段的节点 v ∈ V 的嵌入更新过程为例进行描述。

首先，将段落文本构造成一个图结构 G =（V,E），其中 V 用来表示图中的节点，E用来表示构建图的边。接着，为了有效利用节点的信息，通过将节点V的前向邻居聚合成前向聚合向量，后向邻居聚合成后向聚合向量，其中聚合的方式采用均值聚合器：

$$h_{\aleph_{\vdash(v)}}^k = MEAN(\{h_v^{k-1}\}\bigcup\{h_u^{k-1}, \forall u \in \aleph_{\vdash(v)}\}) \tag{3.18}$$

$$h_{\aleph_{\dashv(v)}}^k = MEAN(\{h_v^{k-1}\}\bigcup\{h_u^{k-1}, \forall u \in \aleph_{\dashv(v)}\}) \tag{3.19}$$

其中，$h_{\aleph_{\vdash(v)}}^k$ 和 $h_{\aleph_{\dashv(v)}}^k$ 表示节点 v 聚合信息的方向，k∈ {1,2,3}表示迭代的次数，本章 k 的跳数大小设置为 3。

接着，使用融合操作来聚合前向和后向的节点信息，并且聚合向量如下:

$$h_{\aleph_{(v)}}^k = \text{Fuse}(h_{\aleph_{\vdash(v)}}^k, h_{\aleph_{\dashv(v)}}^k) \tag{3.20}$$

$$\text{Fuse}(x, y) = z \odot x + (1 - z) \odot y \tag{3.21}$$

$$z = \sigma(W_z[x; y; x \odot y; x - y] + b_z) \tag{3.22}$$

其中,融合操作 Fuse(·,·)表示对两个向量进行门控操作：W_z 和 b_z 是模型可训练的参数，$\sigma(\bullet)$ 是 sigmoid 函数。

最后，通过采用 GRU 更新节点的嵌入 h_v^k：

$$h_v^k = GRU(h_{\aleph_{(v)}}^k, h_v^{k-1}) \tag{3.23}$$

在经过 K 次迭代，节点 v 的表示为 $h_v = h_v^K$。最终，$h_g^s = [h_1^g, h_2^g, ..., h_m^g]$ 表示增强的文本段落经过图神经网络编码后的段落信息。

在对段落进行多次编码后，会不同程度上失去其中的序列信息和语义结构信息。因此，本章提出了一种解决方案，即通过融合各个阶段编码的段落信息，有效地减少了在编码过程中发生的信息丢失问题，从而加强对段落语义信息的表示。接下来，经过融合的段落信息被输入到 BiLSTM 模型中进行学习，最终得到被编码的段落表示向量，这对于问题生成的质量产生着重要的影响。具体的公式表述如下：

中国知网 https://www.cnki.net

$$h_i^c = [h_i^w; h_i^m; h_i^{aa}; h_i^f; h_i^r; h_i^g] \tag{3.24}$$

$$\overrightarrow{s_k^s} = \text{BiLSTM}(h_k^c, \overrightarrow{s_{k-1}^s}) \tag{3.25}$$

$$s_k^s = \text{BiLSTM}(h_k^c, s_{k-1}^s) \tag{3.26}$$

$$s_k^s = [\overrightarrow{s_k^s}; \overleftarrow{s_k^s}] \tag{3.27}$$

其中 $h_i^w, h_i^m, h_i^{aa}, h_i^f, h_i^r, h_i^g, h_i^c$ 分别表示各个编码段落阶段的第 i 个隐藏层单词嵌入，k 表示在段落中的第 k 个单词。s_m^s 表示编码段落信息的最终上下文向量，并将其作为解码器起始隐藏层的初始状态。

3.2.2 引入 IGNN 的解码器

本章的解码部分采用了与其他问题生成模型相似的结构。解码器是一个结合了注意力机制、复制机制和覆盖机制的单向循环神经网络，同时与 IGNN 相结合。这样的解码器设计旨在处理先前生成问题单词中的语义结构信息，以及对段落的影响，特别是复制单词的影响。

解码器的初始化：为了得到有效的上下文信息，使用两个独立的全连接层，作为初始隐藏状态 s_0 和初始上下文向量 c_0:

$$s_0 = \tanh\left(\mathbf{W}_{t2} tanh\left(\mathbf{W}_{t1} s_m^s + b_{t1}\right) + b_{t2}\right) \tag{3.28}$$

$$c_0 = s_0 \tag{3.29}$$

其中 tanh 表示激活函数，$\mathbf{W}_{t1}$ 和 $\mathbf{W}_{t2}$ 表示模型可训练的参数，b_{t1} 和 b_{t2} 表示偏置项。

角色标签：在问题生成的解码中，在使用 IGNN 处理问题单词前，需要引入角色标签，需要将角色标签信息添加到问题单词的节点嵌入中。其中，角色标签的定义为：

$$tag_i = \begin{cases} 0 & x_i\text{表示已经被复制} \\ 1 & x_i\text{表示答案的一部分} \\ 2 & x_i\text{表示未被复制} \end{cases} \tag{3.30}$$

在问题生成的解码中，指导模型合并依赖关系，进而生成和答案相关的问题，其中角色标签的维度在本章中设置为 3。 在解码步骤 t 中，每个节点 $q_{d_i}^t$ 的嵌入被重新初始化:

$$q_{d_i}^t = [h_i^n; r_i^t] \tag{3.31}$$

其中，h_i^n 表示当前隐藏层的向量表示，r_i^t 表示角色标签的嵌入向量。

中国知网 https://www.cnki.net

此外，利用 BiGGNN 和均值聚合来更新节点嵌入，同第 3.2.1 节（3）中图神经网络编码的内容。在经过 n 跳计算后，可以得到解码器图中嵌入 $q_{d_i}^t$ 的最终节点表示。

LSTM 解码：对于时间步长 t，首先拼接前一个单词嵌入 e_{t-1}^q 和前一个基于注意力的上下文向量 c_{t-1}，将它们馈入 LSTM[94]网络模型中，并结合前一个隐藏层状态 q_{t-1}，以获得当前解码器隐藏层状态:

$$q_t = \text{LSTM}(F([e_{t-1}^q; c_{t-1}]), q_{t-1}) \tag{3.32}$$

其中 $\boldsymbol{q}_t$ 表示当前解码状态下目标问题的隐藏层状态。

覆盖机制：本章使用覆盖向量来跟踪关注解码器的历史信息。首先覆盖向量 u_t 被更新为 $u_t = u_{t-1} + \alpha_t$，注意力分布 α_t 计算如下:

$$\alpha_{t,j} = \frac{exp(e_{t,j})}{\sum_{k=1}^{N} exp(e_{t,k})} \qquad j = 1, 2, \ldots, k \tag{3.33}$$

$$e_{t,j} = \mathbf{V}^T tanh(\mathbf{W}_s s_j + \mathbf{W}_q q_t + \mathbf{W}_u u_{t-1,j}) \tag{3.34}$$

其中 $\mathbf{W}_s$， $\mathbf{W}_q$， $\mathbf{W}_u$ 和 $\mathbf{V}^T$ 是可训练参数，s_j 表示经过编码器最终编码段落的第 j 个向量。覆盖向量可以被视为在段落单词上的非标准化分布，用于记录每个单词迄今为止从注意机制接收到的覆盖程度。

注意力分布 α_t 作为单词的概率分布，并且用于产生上下文向量 $\mathbf{c_t}$:

$$c_t = \sum_{j=1}^{K} \alpha_{t,j} s_j \tag{3.35}$$

接着连接解码器状态 q_t 和上下文向量 c_t，并将它们馈送到具有 Softmax 层的一层 FFNN 中，以获得词汇分布:

$$p_{vocab} = \text{soft}\max(F[q_t, c_t]) \tag{3.36}$$

复制机制：复制机制用于从词汇表中生成一个单词，或者从文章中复制一个单词，以解决未登录词（OOV）问题。该方法将注意力分布与词汇分布结合，形成最终的概率分布，用于预测目标问题的单词。这样的设计使得模型在生成问题时不仅能考虑词汇表中的词语，还可以灵活地复制文章中已出现的单词。简而言之，它将注意力分布整合到词汇分布中，以生成最终的概率分布，用于预测目标问题的单词 ***w***:

$$P(\mathbf{w}) = p_{gen} p_{vocab}(w) + (1 - p_{gen}) P_{attn}(w) \tag{3.37}$$

中国知网 https://www.cnki.net

$$p_{gen} = \sigma(F[c_t, q_t, e_{t-1}^q]) \tag{3.38}$$

$$P_{attn}(w) = \sum_{j:w_j=w} \alpha_{t,j} \tag{3.39}$$

其中 p_{gen} 是一个 0-1 之间的概率值。

p_{vocab} 是如式子（3.36）中所描述的词汇分布，并且 $P_{attn}(w)$ 是通过合并重复单词的概率是基于注意力分布 α_t 来计算的，这是通过如式子（3.39）中所描述。

3.2.3 训练和测试

本章中使用的损失函数通过将交叉熵损失和覆盖损失两者结合进行优化。覆盖损失被定义为：

$$covloss_t = \sum_j min(\alpha_{t,j}, u_{t-1,j}) \tag{3.40}$$

联合损失函数被定义为：

$$L = \sum_t -logP(y_t^* \mid \mathbf{X}^p, \mathbf{X}^a, y_{<t}^*) + \lambda covloss_t \tag{3.41}$$

其中，y_t^* 表示引用的第 t 个单词，λ 是一个超参数。

在训练阶段使用教师强迫机制[95]缓解暴露偏差带来的问题，该机制采用自回归训练方式。其中，在每个时间步，将当前输入以 0.75 的概率替换为目标序列值，以避免训练阶段错误的累积。同时，以 0.25 的概率将当前时间步预测的目标值作为下一个时间步的输入，以提高模型的准确度和自适应能力。在测试阶段，采用集束搜索生成问题，并将集束大小设置为 5。

3.3 实验与分析

为了验证本章节提出模型的性能，在第三小节主要通过与多组基础模型在多组评估指标上进行对比，验证本章模型的性能。为了更全面的评估本章节提出模型各个模块的性能，本小节还提供了消融实验。消融实验通过逐步移除或替换模型的特定组件，以评估每个组件对整体性能的影响，有助于识别每个模块的相对重要性。并使用案例分析具体地说明模型在任务中的应用效果。

3.3.1 实验参数及基线模型

（1）实验参数

中国知网 https://www.cnki.net

实验是利用 Python3.7 以及深度学习框架 Pytorch1.11 进行实现，在 GPU 上进行训练、验证以及测试。该实验所使用的相关硬件资源如表 3.1 所示。

本章实验超参数的设置如下：首先，采用固定的 300 维 Glove 预训练词嵌入向量对 SQuAD 和 MS MARCO 数据集的词汇表进行训练。其中，SQuAD 数据集训练了 70000 个单词，MS MARCO 训练了 101000 个单词，特殊字符使用[UNK]代替。段落和答案使用的 BERT 词嵌入是 24 层词嵌入每一层输出的加权和，每个单词是 1024 个维度的 BERT 词嵌入向量。为了防止过拟合，采用了 Dropout[96]，分别应用于 BERT 嵌入层和 RNN 层的输出，Dropout 率分别设置为 0.4 和 0.3。

表 3.1 硬件环境相关配置

硬件	参数
处理器	Intel (R)
操作系统	Linux
GPU 块数	2 块
GPU 型号	GeForce GTX 3090
GPU 大小	24GB

其他具体设置包括将 BiLSTM 的隐藏层设置为 150 维，其他神经网络模型的隐藏层设置为 300 维，答案位置信息的维度设置为 3 维，GNN 的跳数设置为 3，覆盖损失比例 λ 设置为 0.4。在训练期间，初始教师强迫概率设置为 0.75，并在每个训练步骤中以 0.75 * 0.9999^k 递减，其中 k 是训练步骤。在测试过程中，使用集束搜索大小为 5 来生成问题。采用 Adam 作为优化器，设置批量大小为 32，初始学习率为 0.001。如果验证集的 BLEU-4 分数在三个 Epoch 内没有改善，则将学习率降低 0.5 倍。当连续 10 个 Epoch 没有任何改善时，停止训练。

（2）基线模型

NQG 模型[16]：该模型首次将序列到序列模型与注意力机制相结合，提出端到端的问题生成，研究有答案感知的问题生成，并验证该文提出的模型同样适用于无答案感知的问题生成，是神经网络中经典的问题生成模型。

NQG++模型[18]：仍然延续了 NQG 模型的框架，但是在编码阶段引入了丰富的答案特征，并在解码阶段引入指针复制机制，解决未登录词(OOV)问题，可以有效改善问题生成的质量。

S2sa–at–mp–gsa 模型[20]：该模型对序列到序列模型进行改进，在编码阶段引入门控自注意力机制，更好的聚合段落中的信息，防止信息的丢失，并在解码阶段采用注意力机制和最大指针生成器相结合的方式，解决解码阶段词汇重复问题。

SEK-DAPQG 模型[22]：该模型利用外部知识-基于义原知识和双向注意力流

中国知网 https://www.cnki.net

机制研究问题生成，解决现有问题生成模型存在的问题，即自动生成问题容易生成语义信息偏离给定的上下文和答案。因此，该模型通过融入外部知识捕获更小粒度的语义知识，增强文本的语义特征，改善问题生成的质量，并有效结合双向注意力流增强上下文和答案信息之间的语义表征。

JQT-PMQG 模型[63]：该论文提出一种融合问题类型及惩罚机制的问题生成模型，改善问句的质量，该模型结合预训练 BERT 模型对问题的类型进行分类，得到对应问题类型的表示方法，并有效的利用门控机制融合源端句子和问题的类型，并在解码阶段提出一种惩罚机制，在损失函数种加入对重复词的惩罚。

KE-BGINN 模型[31]：该模型引入一种双图交互机制捕获隐藏句法结构信息，减少段落信息的丢失。

G2s+RL+BERT 模型[30]：论文中提出基于强化学习的图到序列模型研究问题生成。探讨了深度对齐网络编码文本和答案信息的有效性，以及对静态图和动态图对问题生成的影响。

DAPQG 模型[61]：该模型提出双注意力机制的段落级问题生成，解决生成的问题存在大量冗余，无法聚焦重点句子的问题。

Multi-stage Atte 模型[6]：一个基于序列到序列的模型，模型通过利用多阶段注意力机制，有效改善段落的表达能力。

EAN–QG 模型[4]：该模型提出了可扩展答案感知的网络模型。从段落文本中抽取和答案相关的文本作为扩展答案，与段落文本进行融合。为了缓解在解码阶段生成问题重复的现象，引入不确定性分数对集束搜索进行改进，提高问题生成的质量。

GA–SeqSeq 模型[29]：提出图增强的序列到序列模型。设计一个答案感知的段落表示模块整合段落中的信息，然后利用图增强文本段落信息，并集合注意力机制、指针复制机制、覆盖机制完成问题的生成。

3.3.2 实验结果与分析

本章提出的模型经过与多组数据集和多个模型的对比，实验结果详见表 3.2 和表 3.3。在表中，“-”表示原始论文中未提供的数据，“*”表示使用原始论文代码进行复现的数据结果。引文后的参考文献表示原始论文中未提供的数据结果，但在引用的论文中出现。数值加粗表示在所对比的模型中达到最优的结果。

（1） 自动评估结果

通过对比表 3.2 和表 3.3 的实验结果，针对 SQuAD 数据集，本文提出的模型与问题生成领域经典模型以及先进的 GA-Seq2Seq 模型进行了实验比较。结果显示，本文的模型通过融合多阶段的语义信息，有效减少了编码阶段段落序列

中国知网 https://www.cnki.net

信息的丢失和语义结构信息的丢失。同时，在解码阶段引入IGNN，改善了解码过程中先前语义信息的丢失。相对于经典的 NQG 模型，在 SQuAD 数据集上，本文提出的模型实验结果提升了 6.73%，达到了 19.01%。与先进的 GA-Seq2Seq 模型相比，尽管由于该模型多阶段编码导致的语义信息丢失，本文模型在 BLEU-4 指标上仍然提高了 0.89%。与最新的 KE-BGINN 模型相比，本文提出的模型在BLEU-4、METEOR、ROUGE指标上分别提高了0.6%、0.65%、0.60%。这表明本文提出的模型在提升问题生成质量方面取得了显著效果。

表 3.2 问题生成 SQuAD-split1 数据集自动评估的结果

模型	BLEU1	BLEU2	BLEU3	BLEU4	METEOR	ROUGEL
NQG[16]	43.09	25.96	17.50	12.28	16.62	39.75
S2sa-at-mp-gsa [20]	43.47	28.23	20.40	15.32	19.29	43.91
Multi-stage Atte[6]	45.13	30.44	23.40	17.09	21.25	45.81
G2s+RL+BERT* [30]	46.92	31.64	23.30	17.69	21.71	45.82
SEK-DAPQG [22]	46.70	31.07	22.90	17.48	-	-
GA-Seq2Seq [29]	47.54	32.49	24.16	18.49	22.23	46.87
GA-Seq2Seq* [29]	46.92	31.93	23.70	18.12	21.87	46.60
Our	**47.83**	**32.99**	**24.70**	**19.01**	**22.59**	**47.48**

表 3.3 问题生成 SQuAD-split2 数据集自动评估的结果

模型	BLEU1	BLEU2	BLEU3	BLEU4	METEOR	ROUGEL
NQG++ [18]	42.60	29.48	21.54	16.37	20.68	44.73
JQT-PMQG [63]	-	-	-	18.52	21.82	47.57
G2s+RL+BERT [30]	-	-	-	18.30	21.70	45.98
G2s+RL+BERT* [30]	47.20	31.95	23.78	18.35	22.09	46.32
Multi-stage Atte [6]	46.60	31.94	23.44	17.76	21.56	45.89
EAN-QG [4]	47.25	31.46	23.13	17.56	21.51	45.00
DAPQG [61]	45.82	30.31	22.11	16.67	20.97	44.21
GA-Seq2Seq [29]	49.13	33.61	25.16	19.43	22.81	47.41
GA-Seq2Seq* [29]	48.14	32.96	24.74	19.19	22.77	47.42
KE-BGINN [31]	49.17	33.37	24.81	19.06	22.72	47.30
Our	**49.22**	**33.75**	**25.36**	**19.69**	**23.37**	**47.90**

此外，在表 3.4 中，使用 MS MARCO 数据集验证了本文模型的有效性。实验结果显示，在 BLEU-1、BLEU-2、BLEU-3、BLEU-4、ROUGE-L 指标上都取得了显著的提升。综合两个数据集的实验结果，本文提出的模型在一定程度上成功避免了编码解码过程中的序列信息和语义信息丢失，有效改善了问题生成

中国知网 https://www.cnki.net

的质量。

表 3.4 问题生成 MS MARCO 数据集自动评估的结果

模型	BLEU1	BLEU2	BLEU3	BLEU4	METEOR	ROUGEL
NQG++ [29]	46.62	32.67	22.98	16.13	20.22	46.35
Multi-stage Atte [6]	41.43	29.97	23.01	18.25	19.43	42.77
G2s+RL+BERT* [30]	49.93	36.54	27.18	20.57	26.98	51.47
GA-Seq2Seq [29]	52.40	38.47	28.61	21.79	26.91	51.66
GA-Seq2Seq* [29]	52.14	38.29	28.52	21.71	26.69	51.53
Our	**52.95**	**39.13**	**29.27**	**22.41**	**27.17**	**52.19**

（2） 人工评估结果

为了验证生成问题的质量，本章还采用人工评价的方式，主要从流畅度、相关度、可回答性三个方面进行评估。

流畅度：生成的问句在语法语义方面是否符合语法规范，得分从 1 到 5。

相关性：生成的问句是否与输入的段落内容相关，得分从 1 到 5。

可回答性：生成的问句是否可以从文本中回答，是否与所给的答案相符，使用 0 和 1 表示不可回答和可回答。

首先，从测试集中随机抽取了 200 个（文本，问题，答案）三元组，其中问题由 GA–Seq2Seq 模型和本章提出的模型生成。接着，邀请了三位英语相关专业的志愿者，按照上述评判标准对生成的问题进行人工评分。最终，统计了人工评分，具体的分数如下表 3.5 所示。表 3.5 的结果清晰显示，本文提出的模型在人工评价中同样表现出显著的优势。

表 3.5 人工评价结果

模型	流畅度	相关性	可回答性
GA-Seq2Seq	3.21	2.91	0.76
本章的模型	3.81	3.05	0.78

（3） 消融实验

通过设计多组消融实验，对模型中的各个模块进行了探究，以了解它们对实验结果的影响。对原有提出的模型进行验证，具体修改后的模型如下：

w/o MS（多阶段融合）：在编码阶段不使用多阶段融合以增强文本的序列语义信息和语法结构信息，但在解码阶段使用迭代图神经网络进行解码。

w/o IGNN：在解码部分不使用迭代图神经网络，但在编码阶段使用多阶段融合以增强文本的序列语义信息和语法结构信息。

w/o Multi–Features：在编码器输入阶段，不添加段落句子的 POS、NER、CASE 特征。

中国知网 https://www.cnki.net

消融实验主要采用 SQuAD-split1 数据集进行对模型各个模块性能的验证，实验结果如下表 3.6，加粗的数据为最佳实验结果。对结果进行分析主要包含以下几个方面：

首先，在不使用多阶段融合（w/o MS）的情况下，发现原始模型的各项指标下降较多，表明多阶段融合对模型的性能有较大影响。其次，在不使用迭代图神经网络（w/o IGNN）的情况下，发现原始模型的各项指标有所下降，说明引入的 IGNN 能够提高问题生成的质量。最后，分析了在不使用段落中的多种特征情境下（w/o Multi–Features），模型的性能略微下降，表明段落的文本特征对问题生成的质量有一定影响。

表 3.6 基于 SQuAD-split1 数据集的消融实验结果

模型	BLEU-1	BLEU-2	BLEU-3	BLEU-4	METEOR	ROUGE-L
Our	**47.83**	**32.99**	**24.70**	**19.01**	**22.59**	**47.48**
w/o MS	47.49	32.52	24.23	18.55	22.29	47.10
w/o IGNN	47.54	32.63	24.34	18.69	22.47	47.33
w/o Multi–Features	47.52	32.61	24.31	18.66	22.54	47.39

3.3.3 案例分析

本章从测试集的 GA-Seq2Seq 模型和本章模型生成的问题中随机抽取了一些示例，用于分析生成问题的质量。在表 3.7 中，展示了本章提出的基于多阶段时序和语义信息增强的模型和 GA-Seq2Seq 模型生成的问题。

以下是对表中部分示例的分析：

句子 1 表明，本章提出的模型生成的问题与标准问题最为接近，而且使用本章模型生成的问题在语法和语义上都具有优势。

句子 2 显示，本章提出的模型生成的问题具有更多的提示信息，这表明模型能够更全面地理解段落内容。

句子 3 指出，本章提出的模型在语法上具有优势，而 GA-Seq2Seq 模型生成的问题可能存在语法错误。

这些案例的分析结果表明，本章提出的模型能够生成与段落文本更相关、语法和语义更优的问题。因此，该模型确实有效地改善了问题生成的质量。

中国知网 https://www.cnki.net

表 3.7 在 SQuAD Split1 数据集中的案例

句子 1：Swann reveals that L'Amricain is a hotel in **Tangier**
标准问题：Where is the L'Americain hotel ?
GA 模型：Where is swann 's hotel located ?
本章的模型：Where is L'Américain 's hotel located ?
句子 2：Sand, who was **six years** older than the composer, and who had had a series of lovers, wrote at this time : I must say I was confused and amazed at the effect this little creature had on me.
标准问题：How much older was george sands than chopin?
GA 模型：How old was sand?
本章的模型：How old was sand older?
句子 3：West 's perfectionism led the college dropout to have its release postponed **three** times from its initial date in august 2003.
标准问题：How many times was the college dropout 's release put off?
GA 模型：How many times did the college dropout have?
本章的模型：How many times did the college dropout release?

3.4 本章小结

本章的主要目标是有效改善段落编码和解码阶段中序列信息和语义结构信息的丢失问题，并为此提出了一种新颖的基于多阶段时序和语义信息增强的模型。该模型的关键特点包括在编码阶段通过融合多个阶段编码的段落信息，并输入到 BiLSTM 中，以及在解码阶段引入迭代图神经网络，以解决解码阶段序列信息和语义结构信息丢失的问题。最后，通过注意力机制捕获段落的全局语义信息，结合循环神经网络生成高质量的问题。

为验证本章模型的有效性，进行了与多个基线模型在多个数据集上的对比。此外，通过进行消融实验和案例分析，详细验证了本章模型在缓解段落编码和解码阶段序列信息和语义结构信息丢失问题方面的性能。总体而言，本章提出的基于多阶段时序和语义信息增强的模型通过创新性地整合多个阶段的语义信息融合和迭代图神经网络，缓解问题生成过程中的信息丢失问题，为问题生成任务提供了一种有效的解决方案。

中国知网 https://www.cnki.net

第 4 章 基于对比搜索算法的多样性问题生成

为了更好的满足教育领域下的实际需求，在第三章节的基础上，本章节从有答案感知的多样性问题生成进行研究。本章节首先简单介绍研究的动机，基于该动机提出了一种基于对比搜索算法的多样性问题生成模型，然后通过与基础模型进行对比表明本章提出的模型有效提升了问题生成的质量，最后通过案例分析进行展示。

4.1 研究动机

问题生成旨在根据给定的语境生成符合需求的问题，是一项被广泛应用于各个领域的任务。在教育领域中，不仅可以为阅读理解材料生成多个问题，还可以辅助教师和学生从多个方面理解材料的内容。在问答领域，问题生成可以拓展问答对，用作数据增强。在检索领域，可以用来辅助完成高效的检索任务。

近年来，研究者提出使用神经网络的方法研究该项任务，取得了重大进展。但基于序列到序列的问题生成，未能充分利用上下文的语义信息。随着预训练语言模型的发展，一些研究者开始注意到，使用预训练模型研究问题生成，可以更好的利用预训练语言模型强大特征表示的能力，使模型充分理解上下文的语义信息，更有效的改善问题生成的质量。然而，以上的问题生成研究仅仅研究给定相关段落生成一个问题。在实际教育教学中，生成多种语义相似，词汇多样的问题，不仅可以个性化满足学生的需求，打破传统课堂教学的刻板模式，还可以提高学生的学习效率，培养学生的思维，为知识的深度吸收和长久记忆打下坚实的基础。因此，有些研究者提出段落级问题生成的多样性。但无法更好的满足课堂上的实际需求，且在基于给定上下文段落和答案生成问题中，依然存在单词重复问题以及可回答性低的问题。

因此，本章节首先通过构建句子级的多样性问题生成数据集，来研究段落级和句子级的多样性问题生成；然后为了改善多样性问题生成中存在的单词重复问题，提高可回答性，提出基于对比搜索算法的多样性问题生成模型。该模型首先利用预训练语言模型 Prophetnet 特征表示能力强以及语言建模能力强的特点，使模型充分理解上下文的语义信息，并微调模型解码器的输入端，强制模型在训练阶段学习到有效的信息，以便在测试阶段直接生成符合条件的多个问题。然后为了缓解问题生成过程中单词重复现象，提高可回答性，本章引入一种新型的对比搜索解码方法，进一步提高问题生成多样性的质量。

中国知网 https://www.cnki.net

本章的贡献如下：

（1）构建句子级的多样性问题生成数据集，研究段落级和句子级的多样性问题生成。

（2）本文提出基于对比搜索算法的多样性问题生成模型，利用预训练语言模型微调适应下游任务，然后利用对比搜索解码方法改善多样性问题生成的质量，提高可回答性。

（3） 通过在数据集上进行实验分析，研究讨论多种解码方法对多样性问题生成的影响。

4.2 模型结构介绍

4.2.1 基于 ProphetNet 的预训练模型微调

本章利用一种编码器-解码器架构的预训练模型 ProphetNet 微调多样性问题生成任务，并在解码端引入对比搜索算法。它是基于 Transformer 的一种编码器-解码器架构。ProphetNet 引入一种 N-Stream 的自注意力机制和未来 N-gram 语法预测的自监督目标机制，更好的预测多步生成的问题单词，提高预测单词的准确度。其中图 4.1 显示基于对比搜索算法的多样性问题生成模型的架构。

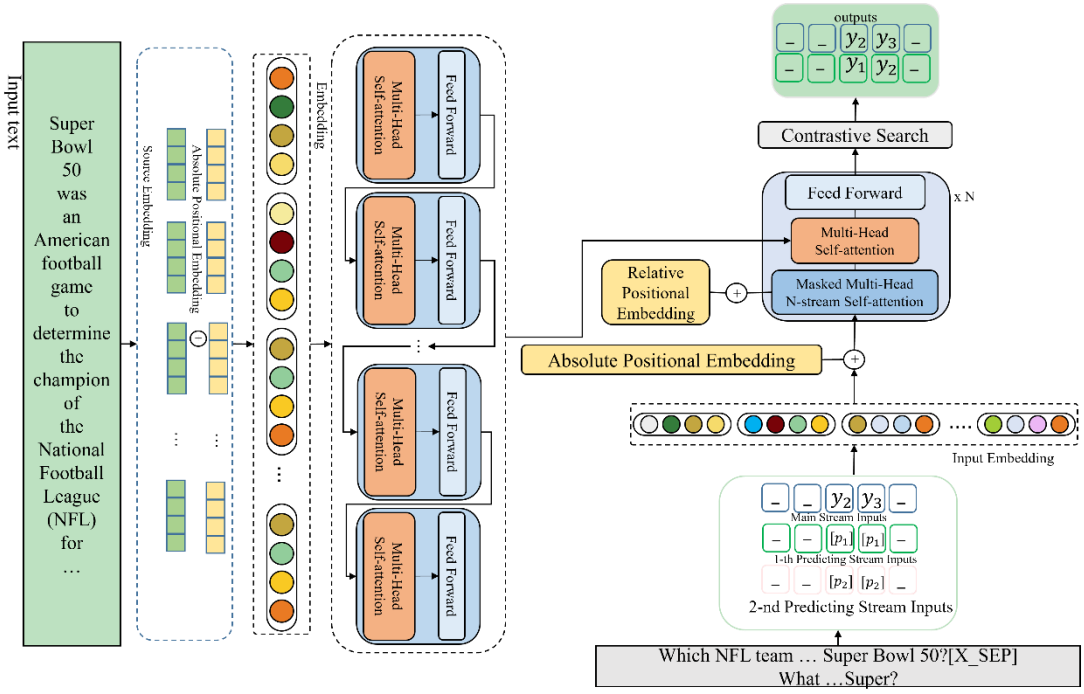


图 4.1 基于 ProphetNet 的预训练模型微调

中国知网 https://www.cnki.net

（1）多样化问题生成任务

本章研究的多样性问题生成主要是给定一段输入文本$C=\{c_1,c_2,...,c_m\}$和相关答案$A=\{a_1,a_2,...,a_p\}$，目标是生成多个与输入信息相关、语义相似、词汇多样的问题$Q=\{q_1^1,q_2^1,...,q_{n_1}^1,[X_{SEP}],q_1^2,q_2^2,...,q_{n_2}^2\}$。其中 c 表示上下文段落中的单词，m 表示上下文段落的单词个数；a 表示答案的单词，p 表示相关答案单词的个数；q 表示生成问题中的单词，n_1表示生成第一个问题单词个数，n_2表示生成第二个问题单词个数，q 的上标表示生成的第几个问题。

该任务被公式化为条件序列生成，且该模型以最大化条件对数似然 P(Q|C)被优化,如等式 1 所示。实际上，对数似然性可以被分解成单词或子单词级别的预测，最终利用最大似然估计完成多样性问题生成，具体公式如式子（4.1）：

$$Q=argmaxProb\left(Q\mid C,A\right) \tag{4.1}$$

（2）N-Stream 自注意力机制

为有效的表征上下文语义信息，在解码时刻，除了原始 Transformer 解码器的 Mask 多头自注意力机制外，该模型的 N-Stream 自注意力机制结合了 n 个额外的自注意力预测流，在每个时间步分别预测下一个连续的 n 个未来单词。具体来说，第 i 个预测流负责对概率$p(q_{\mathrm{t}+i-1}|q_{<\mathrm{t}},C)$进行建模。

第 i 个预测流根据每个时间步的前一个主流隐藏状态，预测问题生成过程中的下一个第 i 个问题单词$q_{\mathrm{t}+i-1}$。当 N=2 时，则第 1 个预测流的隐藏状态计算为:

$$Q^g=g_{t-1}^{(k)} \tag{4.2}$$

$$K^g=H_{<t}^{(k)}\oplus g_{t-1}^{(k)} \tag{4.3}$$

$$V^g=H_{<t}^{(k)}\oplus g_{t-1}^{(k)} \tag{4.4}$$

$$g_{t-1}^{(k+1)}=\mathbf{MultiHead}(Q^g,K^g,V^g) \tag{4.5}$$

其中$g_{t-1}^{(k+1)}$表示时间步长为 t−1 生成问题单词的第 1 层预测流的第 k+1 层隐藏状态，$\oplus$表示拼接操作。

当注意力的值和关键字是主流的前 t 个隐藏状态时，为了计算$g_{t-1}^{(k+1)}$时，将$g_{t-1}^{(k)}$作为注意力的查询。另外，由于解码时刻需要位置信息，将$g_{t-1}^{(k)}$作为注意力值和键来使$g_{t-1}^{(k+1)}$成为位置感知。最后使用$g_{t-1}^{(k+1)}$来预测q_t。

类似地，第 2 个预测流的隐藏状态计算公式为:

$$Q^s=s_{t-1}^{(k)} \tag{4.6}$$

$$K^s=H_{<t}^{(k)}\oplus s_{t-1}^{(k)} \tag{4.7}$$

中国知网 https://www.cnki.net

$$V^s = H_{<t}^{(k)} \oplus s_{t-1}^{(k)} \tag{4.8}$$

$$s_{t-1}^{(k+1)} = \textbf{MultiHead}(Q^s, K^s, V^s) \tag{4.9}$$

其中 $s_{t-1}^{(k+1)}$ 表示第 2 个预测流在时间步长 t−1 处的第 k+1 层隐藏状态，最终用于预测 q_{t+1}。

通过上述的公式发现，q_t 预测的 g_{t-1} 和 q_{t+1} 预测的 s_{t-1} 的计算方法非常相似。为防止生成相同的语义信息，区分两者之间的区别，通过利用不同的初始化标记、绝对位置嵌入和相对位置嵌入之间的区别进行计算。为防止每个预测流都是用特殊单词而不是前一个单词初始化得到的，将绝对位置嵌入和 T5 提出的桶相对位置计算相结合，有效增强解码器中位置信息，以便模型在训练和测试阶段更好的学习到语义位置信息。

（3）未来 N-gram 预测

为了更好的编码上下文的语义信息，ProphetNet 在每一时间步 t，将原来预测的下一个字符 $p(q_t \mid q_{<t}, x)$ 转换为 $p(q_{t:t+n-1} \mid q_{<t}, x)$。其中 $q_{t:t+n-1}$ 表示下一个连续的 n 个未来单词字符，即同时预测下一个 n 个未来的单词字符。为了从多个角度更有效的捕获上下文的语义信息，使用一个具有多头自注意力机制的多层 Transformer 编码器和一个具有所提出多头流的自注意力机制的多层 Transformer 解码器。

为了微调 ProphetNet 模型，适应多样性问题生成。首先将编码器的输入端改写成 $\mathrm{X} = (A, C)$，即 $\mathrm{X} = (a_1, a_2, ..., a_p, c_1, c_2, ..., c_m)$。为了方便表示序列，将 X 表述为 $(x_1, x_2, ..., x_{p+m})$。然后使用 ProphetNet 模型的编码器对 X 进行编码，具体公式如下:

$$H_{encoder} = \textbf{Encoder}(x_1, x_2, \ldots, x_{p+m}) \tag{4.10}$$

其中$H_{encoder}$表示编码后的源序列表示。

在解码器方面，为了更好的预测下一个单词，不仅仅预测下一个单词，而且在每个时间步，该模型的解码器均预测未来的 n 个单词。预测未来生成问题的 n 个单词的具体公式如下：

$$p\left(q_t \mid q_{<t}, x\right), \ldots, p\left(q_{t:t+n-1} \mid q_{<t}, x\right) = \textbf{Decoder}(q_{<t}, H_{encoder}) \tag{4.11}$$

其中解码器在每个时间步长输出 n 个概率。

在训练阶段，为了更有效的进行反向传播，更新权重信息，未来的 n-gram 预测目标的损失函数为:

$$\mathcal{L} = -\sum_{j=1}^{n-1} \alpha_j \bullet (\sum_{t=1}^{T-j} log p_\theta(q_{t+j} \mid q_{<t}, x)) \tag{4.12}$$

中国知网 https://www.cnki.net

n−1 个未来问题单词预测损失中，为防止暴露偏差导致模型产生的误差越来越大的问题，使用传统的教师强迫机制[95]，在每一步提供给模型真实的问题单词，从而迫使模型在训练阶段有效的预测未来目标生成的问题单词。鼓励模型在未来单词预测中可以进行有计划性的学习生成问题单词的语义信息，以避免在生成问题单词过程中存在的局部相关性方面过度拟合问题。为有效的平衡模型复杂性和泛化性，引入α_j来平衡两者，功率衰减函数α_j设为:

$$\alpha_j = \frac{\gamma^j}{\sum_{i=0}^{n-1}\gamma^i} \tag{4.13}$$

其中 γ 是衰减系数。

4.2.2 引入对比搜索策略的解码器

基于最大似然估计的解码方式（例如：贪婪解码、集束搜索）的神经语言模型往往导致生成的文本是不自然的，且重复单词的现象。现有的方法通过采样的方法或修改训练目标来引入随机性，进而降低某些单词生成的概率。然而，使用这些解码方式往往导致解决方案缺乏连贯性。因此，在生成多样化问题解码的过程中，引入一种对比搜索策略[97]，保持生成文本连贯性的同时改善单词的多样性生成。

在解码器生成问题单词的每一步骤中，输出从模型预测最可能的候选集合中选择，以更好地保持生成文本与人类编写的前缀之间的语义一致性，并保留生成文本的标记相似矩阵的稀疏性，以避免退化。

在每个解码步骤中，生成的输出应该从模型预测最可能的候选集合中选择且生成的输出应该与之前的上下文有足够的区别。这样，生成的文本可以更好地保持相对于前缀的语义一致性以及语义信息的丢失，同时避免生成重复的问题单词。形式上，在每一个时间步 t，给定已经生成的问题单词$Y=(q_1^1,q_2^1,...,q_{n_2}^2)$，选择输出的$q_t^1$表示如下：

$$q_t^1 = \underbrace{argmax}_{v\in V^{(k)}}\left\{(1-\alpha)\times p_\theta\left(v\mid q_{<t}^1\right)-\alpha\times(\max\{s\left(h_v,h_{q_j}\right):1\le j\le t-1\})\right\} \tag{4.14}$$

其中$V^{(k)}$模型概率分布的前 k 个预测集，$p_\theta\left(\bullet\mid q_{<t}^1\right)$和 k 通常设为 3 ~ 10。在等式（4.14）中，第一项$p_\theta\left(v\mid q_{<t}^1\right)$为模型置信度，是模型预测的候选 v 的概率。第二项$\max\{s\left(h_v,h_{q_j}\right):1\le j\le t-1\}$为退化惩罚，衡量候选 v 相对于之前的上下文 q，

中国知网 https://www.cnki.net

具体定义为 v 的表示与 x<t 中所有标记的表示之间的最大余弦相似度。v 的退化惩罚越大意味着它与上下文更相似，因此更有可能导致模型退化。

在这里，候选表示 h_v 是由给定 x<t 和 v 串联的模型计算的。直观上，v 的退化惩罚越大意味着它与上下文更相似，因此更有可能导致模型退化。超参数 $\alpha\epsilon[0,1]$ 调节这两个分量的重要性。当 α=0 时，对比搜索退化为贪婪搜索方法。

4.3 实验与分析

为了验证本章节提出模型的性能，在第三小节首先介绍了本章节使用到的实验参数，然后通过与基础模型在多组评估指标上的对比，验证本章模型的性能。最后使用案例分析具体地说明模型的效果，为模型的性能提供深入的理解，以便更好地理解模型的优势、局限性。

4.3.1 实验参数

（1） 数据集

段落级数据集：为了进一步研究段落级的多样性问题生成，采用由 Rathod 等[38]完成的数据集，该数据集是由公开 SQuAD 数据集经过一系列神经网络模型将问题进行转化完成第二问题的生成。具体相关案例如表 4.2 所示。

句子级数据集：为了更好的研究句子级的多样性问题生成，本章通过对 Rathod 等[38]完成的数据集进行提取，利用相应的算法完成句子级的数据集构造。具体构造的算法流程如表 4.1 所示。具体相关案例如表 4.2 所示。

表 4.1 句子级多样性问题生成数据集算法流程

算法 1 如何制作句子级多样性问题生成数据集?
输入← 段落级多样性问题
for i, sequence in enumerate (Input) do
三元组 (上下文，问题，答案)
if sequence[answer] in sequence[context] then
更新←上下文
else
移除
结束判断
新列表 ← 上下文
结束循环

中国知网 https://www.cnki.net

表 4.2 多样性问题生成的案例研究

	Paragraph-Level	Sentence-Level
Context	Meanwhile, producer Joe Pasternak, who had been successfully producing light musicals with young sopranos for Universal's German subsidiary, repeated his formula in America. Teenage singer Deanna Durbin starred in Pasternak's first American film, Three Smart Girls (1936). The film was a box-office hit and reputedly restored the studio's solvency. The success of the film led Universal to offer her a contract, which for the first five years of her career produced her most successful pictures.	According to Johnson and Grim (2013), Buddhism has grown from a total of 138 million adherents in 1910, of which 137 million were in Asia, to 495 million in 2010, of which 487 million are in Asia.
Answer	1936	487 million
Question1	In what year was Three Smart Girls made?	How many buddhists are in Asia?
Question2	Is three smart girls a good year?	How many buddhist are there in Asia?

（2） 实验参数

实验是基于 Python3.8 和深度学习框架 Pytorch1.11 实现，在 2×24GB 的 NVIDIA 3090 GPUs 上训练、测试的，训练过程中使用 12 个 epoch 对模型进行预训练微调。加载预训练模型 ProphetNet，编码器和解码器的架构超参数分别设置为 12 层编码器、12 层解码器、1024 维的隐藏层大小、12 个注意力头，具有 1024 维的前馈神经网络隐藏层大小和 4096 维的前馈神经网络隐藏层大小。考虑到训练成本，在实验中将 ProphetNet 的 N 设为 2，学习率为 1×10^{-5}，最大输入目标的长度为 256，Batch size 设置为 1，优化器使用 Adam 优化器，每 100 步迭代更新一次参数，每 1000 步保存一次预训练模型的参数。在预训练语言模型训练时，训练一个 epoch 需要 2 个小时，共需要 24 小时。在解码阶段，不同的解码方式需要的时间为 10 分钟到 30 分钟。

解码设置：本章利用对比搜索算法进行解码。对比度惩罚参数设置为 0.4，候选集合的参数设置为 6。其它的解码方式，相应的 beam search 参数设置为 8，采样参数 top-p 设置为 0.95。解码阶段生成最大的问题长度设置为 120，编码阶段设置的最大长度设置为 256，多样性采样的组设置为 2。

中国知网 https://www.cnki.net

4.3.2 评估指标

本章主要与多种多样化文本生成的方法相比，其中包括 Beam search[98-99]，Diverse beam search[100]，Top-p (核) 采样[101]，Top-k[102-103]，Multinomial sampling 多项采样[104]。为了有效验证生成的多个问题之间的语义相似性、问题生成的多样性、可回答性、流畅度等，本章拟从以下多个评估指标进行验证。

PINC[38]：启发式评估指标，使用 PINC 来测量问题对之间的 n-gram 重叠。对于生成的两个问题 q1 和 q2，计算 PINC 分数。

QA[109]：问答系统的评估指标，基于标记的衡量标准以及考虑部分单词匹配所提出的，为了衡量生成的问题质量，在给定上下文的情况下是否可以被用于回答。本章分别使用 QA1， QA2 评估生成两个问题的质量。

SBERT[110]：使用余弦相似度测量生成问题之间的语义相似性，从而确保问题评估相同的内容以及单词的多样性。

Top-1 metric 指标[35]：这测量生成的 k 个最佳假设中 Top-1 的准确性。使用语料库级度量来测量精度，即 BLEU-4 的指标。

METEOR[83]：用于衡量黄金问题与生成问题之间的准确率和召回率，考虑句子单词之间的流畅性以及同义词对语义的影响。

ROUGE[84]：利用最长公共子序列计算生成问题单词出现的次数与黄金问题单词之间的召回率，评估生成问题的语义相似性。

4.3.3 实验结果与分析

（1）自动评估

本章从生成两个问题的多样性任务进行研究，首先研究段落级的多样性问题生成，并在多种解码方式下的多种指标，分析讨论生成两个问题之间的语义相似性以及可回答性等。然后研究并分析与现有先进预训练语言模型在多项评估指标上与研究生成段落级的第一个问题生成进行对比，最后研究并分析句子级的多样性问题生成。

在表 4.3 中，给出段落级多样性问题生成的评估结果，从实验结果发现，相比其它的解码方法，使用本章引入对比搜索算法的方法完成段落级多样性问题生成，在多项评估指标上存在明显的优势，可以更好平衡生成两个问题之间的语义相似性以及问答分数。同时通过各项评估指标表明，引入对比搜索算法可以缓解问题单词重复的问题，改善可回答性，提高问答分值，有效提升问题生成的多样性质量。

中国知网 https://www.cnki.net

在表 4.3 中，生成的第一个问题与第二个问题相比，第一个问题的问答分数更高，这是符合常理的。无论是任何一种解码方法，均会存在此种现象。因为直接生成第二个问题时，会由于暴露偏差的问题导致生成的第二个问题与上下文的信息不一致，无法有效的结合上下文的信息，进而导致生成的第二问题出现问答分数下降的问题。在表 4.3 中发现，相比于其它的解码方法，当使用对比搜索算法生成多个问题时，会减少重复单词的生成，进而会降低 PINC 的分数，提高可回答性的分数。这表明当生成的两个问题之间的 PINC 分数较高时，生成问题的可回答性就会变差，问答的分数会明显的下降，进一步解释了 PINC 分数和问答分数之间存在一种权衡。同时，实验结果表明生成的两个问题之间的 PINC 得分与 SBERT 相似度之间呈反比关系，这表明生成的两个问题词汇内容的多样化，是需要以生成的两个问题之间的语义相似性折扣为牺牲的。

表 4.3 多种解码方法的评估实验结果-段落级数据集

Evaluation indicators	Q1-Q2		SBERT	Q1	Q2
Method	Acc↑	Acc↑	MSE↓	Acc↑	Acc↑
Beam Search	11.10	97.26	5.39	86.21	83.35
Random Sample	14.42	97.67	5.24	86.82	83.50
Random Sample +Temperature	**19.14**	96.47	6.67	86.67	81.67
Top-p Sample	14.60	97.64	5.17	86.98	83.73
Top-k Sample	14.83	97.59	5.27	86.86	83.46
Multinomial sampling	14.50	97.63	5.26	87.03	83.75
Beam_search + Multinomial sampling	14.38	97.66	5.22	86.99	83.72
Diverse beam search	15.16	97.44	5.54	87.04	83.48
Our	12.10	**98.06**	**4.69**	**87.42**	**84.49**

为了评估段落级的多样性生成问题的流畅度、语义性等。本章从生成多个问题中抽取了第一个问题，并评估第一个问题的质量。在表 4.4 中对比先进的预训练语言模型，先基于本章的数据集进行微调相关大模型，然后利用微调后的模型生成多个问题，在微调后分别使用测试集的数据进行验证。实验结果表明，本章提出的模型在 BLEU 和 ROUGE 评估指标上均优于先进的模型。这表明本章提出的模型与先进的预训练语言模型相比，在生成问题的流畅度和语义性具有优势。在 METEOR 评估指标上有所下降，因为多样性词汇的生成，导致相似度有所下降。本文使用的预训练模型参数均从 huggingface[1]官网下载。

[1] https://huggingface.co/

中国知网 https://www.cnki.net

表 4.4 基于 question1 的实验评估结果-段落级数据集

Evaluation indicators Model	Top-1 metric↑	METEOR↑	ROUGE-L↑
e2e-bert-qg[2] [26,65]	12.03	30.09	30.87
T5-small-qg-hl[3] [45,105]	11.40	29.61	29.48
BART-small-qg[4] [106,107]	10.72	28.95	29.06
BART-large-qg[5] [106,107]	11.81	**30.12**	30.64
Flan-t5-small-qg[6] [45,108]	11.50	29.73	29.80
Flan-t5-large-qg[7] [45,108]	12.22	29.73	31.08
ProphetNet-large-qg[8] [38]	17.76	27.90	40.88
Our	**19.01**	28.94	**42.54**

在表 4.5 中，给出基于对比搜索算法的句子级多样性问题生成的评估结果，从实验结果发现，使用对比搜索算法进行解码的方法优于多项评估指标上。这表明，在句子级的问题生成中，引入对比搜索算法不仅可以平衡生成两个问题之间的语义相似性，而且还可以缓解问题单词重复的问题，改善问答分数，有效提升问题生成的多样性质量。

表 4.5 多种解码方法的评估实验结果-句子级数据集

Evaluation indicators	Q1-Q2	SBERT		Q1	Q2
Method	Acc↑	Acc↑	MSE↓	Acc↑	Acc↑
Beam Search	45.75	86.30	11.79	83.79	71.87
Random Sample	55.35	82.41	32.06	81.60	67.35
Random Sample +Temperature	52.66	84.36	13.52	81.93	69.60
Top-p Sample	51.70	84.98	13.00	82.43	69.88
Top-k Sample	53.87	84.59	12.81	82.55	70.03
Multinomial sampling	**55.48**	82.31	14.75	81.07	66.79
Beam_search+ Multinomial sampling	54.48	82.88	14.21	81.08	67.27
Diverse beam search	53.16	81.41	15.08	81.97	67.03
Our	46.35	**87.16**	**11.48**	**84.82**	**72.41**

[2] https://huggingface.co/sravn/e2e-qg-bert
[3] https://huggingface.co/valhalla/t5-small-qa-qg-hl
[4] https://huggingface.co/lmqg/bart-base-squad-qg
[5] https://huggingface.co/lmqg/bart-large-squad-qg
[6] https://huggingface.co/lmqg/flan-t5-base-squad-qg
[7] https://huggingface.co/lmqg/flan-t5-large-squad-qg
[8] https://huggingface.co/microsoft/prophetnet-large-uncased-squad-qg

中国知网 https://www.cnki.net

（2）人工评价

为了评估生成问题与真实问题之间的性能，本章使用人工评估的方式与多种解码方法生成的问题进行评估。首先聘请十名英语专业人士参与评估问题类型的注解工作，并根据以下的四个评估指标对生成的问题进行评分：

流畅度：评估生成的多个问题的语法和结构流畅性，对生成的两个问题求平均分数。流畅度的划分区间为 0-3。

可回答性：生成问题的可回答程度，可回答性的划分区间为 0-3。

可阅读性：可阅读性的评估需要注释者阅读相关上下文，对生成的问题进行测试，理解力得分在 0-3 分之间。分数越高，说明阅读水平越高。

多样性：生成问题之间的词汇多样性。多样性的划分区间为 0-3。

其中，0-3 的分值越高表明生成多样性的问题质量越高。

为了更好的评估生成的多个问题，本章首先从测试集中抽取 200 个段落和对应的答案，使用四种不同的解码方法进行多样性的问题生成，然后对生成的问题进行四个方面的评估。在得到十位评估者的得分后，将四个评估的得分分别取其平均值，并将其放入表 4.6 中。在表 4.6 中的结果表明，本章使用对比搜索方法得到的问题生成多样性比其它的解码方法有明显的优势。在表中观察到多样性指标分值比流畅性和可阅读性高，这表明本章提出的模型可以改善多样性的问题生成质量，满足于特定的教学需求。此外，生成问题的可回答性得分比其它的三个指标均高，这表明本章提出的解码方法生成的问题具有更好的可回答性，并且在答案中涵盖了更广泛的内容。但通过表 4.6 发现，生成的问题在流畅度得分较低，原因在于多样性的生成会影响流畅度的得分，需要进一步探索优秀的模型来提高两者的指标，以便更好的满足教育领域下的需求。

表 4.6 多种解码方法的人工评价结果

	流畅度	可回答性	可阅读性	多样性
Beam Search	1.275	2.284	1.546	1.994
Random Sample	1.358	2.314	1.498	2.018
Diverse beam search	1.386	2.321	1.623	2.176
Our	**1.692**	**2.623**	**1.952**	**2.429**

4.3.4 案例分析

为方便教育者在实践中可以更好观察到本章的问题生成任务，首先在表 4.7 根据数据集中的一段文章生成多个问题以及在表 4.8 根据数据集的句子生成多样性问题。且在表 4.7 和表 4.8 分别给出使用不同解码方法和本章提出的模型研究

中国知网 https://www.cnki.net

段落级生成多个问题以及研究句子级生成的多个问题，并进行分析。

表 4.7 段落级多样性问题生成的案例研究

Context1		Concerns were raised over whether Levi's Stadium's field was of a high enough quality to host a Super Bowl. During the inaugural season, the field had to be re-sodded multiple times due to various issues, and during a week 6 game earlier in the 2015 season, a portion of the turf collapsed under Baltimore Ravens kicker Justin Tucker, causing him to slip and miss a field goal, although the field has not had any major issues since. As is customary for Super Bowl games played at natural grass stadiums, the NFL re-sodded the field with a new playing surface. A hybrid Bermuda 419 turf. NFL and Atlanta Braves field director Ed Mangan stated that the field was in "great shape" for gameday. However, the turf showed problem throughout the game, with a number of players needing to change their cleats during the game.
Answer		Baltimore Ravens
Ref	Q1	What team did Justin Tucker play for?
	Q2	What team did Justin Tucker play in and why did he play?
Top-p	Q1	What team did justin tucker play for?
	Q2	What team did justin tucker play for?
Our	Q1	What team did justin tucker play for?
	Q2	What team did justin tucker play for and why did he play?
Context2		In honor of the 50th Super Bowl, the pregame ceremony featured the on-field introduction of 39 of the 43 previous Super Bowl Most Valuable Players. Bart Starr (MVP of Super Bowls I and II) and Chuck Howley (MVP of Super Bowl V) appeared via video, while Peyton Manning (MVP of Super Bowl XLI and current Broncos quarterback) was shown in the locker room preparing for the game.
Answer		Peyton Manning
Ref	Q1	Who was the MVP of Super Bowl XLI?
	Q2	Who is the MVP of Super Bowl XLI?
Top-p	Q1	Who is the most valuable player in the super bowl XLI?
	Q2	Who was the most valuable player in the super bowl XLI?
Our	Q1	Which player of the super bowl was present in the locker room before the game?
	Q2	Who was present in the locker room before the game?

中国知网 https://www.cnki.net

表 4.8 句子级多样性问题生成的案例研究

Context1		But the Broncos defense halted the drive on the 26-yard line, and it ended with no points when Graham Gano hit the uprights on a 44-yard field goal attempt.
Answer		Graham Gano
Ref	Q1	Who missed a field goal for the Panthers?
	Q2	Who misses a field goal in the Panthers' first half?
Top-p	Q1	Which offensive team's final goal tied the game at 23- 25 tie - breaking with the seahawks at a 19 - yard mark?
	Q2	What team's final goal tied the game at 23-23 tie with the seahawks at 19-25 tie - breaking with the seahawks at a 19-yard mark.
Our	Q1	Which broncos kicker ended the game with a 44 - yard field goal attempt?
	Q2	Who makes a team miss a 44-yard field goal?
Context2		After World War II, under a Communist regime set up by the conquering Soviets, the "Bricks for Warsaw" campaign was initiated, and large prefabricated housing projects were erected in Warsaw to address the housing shortage, along with other typical buildings of an Eastern Bloc city, such as the Palace of Culture and Science, a gift from the Soviet Union
Answer		an Eastern Bloc city
Ref	Q1	What were the structures built by the Soviets typical of?
	Q2	What were Soviet buildings typical of?
Top-p	Q1	Of what culture and sphere was the palace of culture and science a part?
	Q2	What were the cultural and sphere of realms that were the part of the palace of culture and science?
Our	Q1	Of what was the palace of culture and science an example of?
	Q2	What is the example of the palace of culture and what are some examples?
Context3		In 1927 a zoological garden was established on the park grounds.
Answer		1927
Ref	Q1	When was a zoological garden established in the Praga Park?
	Q2	What are the zoological gardens in the Praga Park?
Top-p	Q1	In which year to a zoological garden at pliskett park be established?
	Q2	What year did a zoological garden at pliskett park be established?
Our	Q1	Which year the fort became a zoo with a zoological garden?
	Q2	Which was established in 1939 at the national park in new york city.

中国知网 https://www.cnki.net

在表 4.7 中，通过案例研究生成的多个问题来对比本章模型与其 top-p 采样生成的问题。结果显示，在使用对比搜索算法时，生成的两个问题词汇更加多样且更具可回答性。表 4.7 中第二个例子显示，使用本章方法生成的问题在问题类型上经常有所不同，表现出更多的多样性，证明了本章使用对比搜索算法可以有效减少重复单词的生成，改善可回答性，提高多样性问题生成的质量。

此外，在表 4.8 中，给出了句子级多样性问题生成的三个案例。对比发现，在第三个案例中，使用对比搜索算法生成的两个问题单词之间的词汇更加多样，且更具可回答性，说明本章的方法可以缓解问题生成过程中生成的单词重复，改善问题生成的质量。这进一步验证了对比搜索算法在提高问题生成多样性和可回答性方面的有效性。

4.4 本章小结

本章通过研究段落级和句子级的多样性问题生成，旨在更好地确保学生对一个概念有全面理解，提高学生的学习能力。本章提出了一种基于对比搜索算法的多样性问题生成模型，直接生成多个语义相似、词汇多样的问题，缓解了多样性问题生成中单词重复的问题，改善了可回答性。通过在 SQuAD 数据集上研究不同解码方法对问题生成多样性的影响，结果表明引入对比搜索算法生成的多样性问题优于其他解码方法。

为了更深入研究问题生成的多样性并提升生成质量，未来的工作可以考虑构建上下文的语义图并将其融入解码过程。这样做有望更有效地改善多样性问题生成过程中可能出现的语法错误，并更深层次地挖掘文本的语义信息。这种方法有望进一步提高问题生成的质量，使其更符合学生的学习需求。

中国知网 https://www.cnki.net

第 5 章 基于问题关键词预测的多样性问题生成

在第四章节研究的基于答案感知的多样性问题生成有效缓解了教育领域中的窘境，但依然无法更好的处理电子商务领域下信息缺失信息的问题。为了更好的满足电子商务领域下的实际需求，在第四章节的基础上，本章节从无答案感知的多样性问题生成进行研究。本章节首先简单介绍研究的动机，然后基于该动机提出了基于 Transformer 编码器问题关键词预测的问题生成模型，接着通过与多组基础模型在多个评估指标上进行对比，表明本章提出的模型有效提升了问题生成的质量，最后使用消融实验表明本文模型所提出各个模型的有效性，并使用案例分析展示本章节模型与基础模型之间的差异。

5.1 研究动机

随着互联网、大数据、云计算以及人工智能的发展，电子商务交易越来越普遍，为消费者提供愉快的购物体验，是每一个商家追求的目标。目前许多消费者渴望在购买商品时，可以获得足够多的信息去了解所购买的商品，从而达到消费的目的。但由于消费者个性特征和购物需求的多样性，商家往往不能完全了解消费者的需求。他们的商品信息文字描述往往会遗漏一些被消费者认为重要的信息，导致消费者未能找到自己需要的商品信息描述，从而失去购买欲望，使商家蒙受巨大的损失。如果通过人工的方式去寻找商品描述中的缺失信息，在面对海量的商品信息描述，商家显得力不从心。因此，通过挖掘文本中的信息内容，以生成问题的形式提醒商家，显得额外重要。

早期的问题生成，需要依赖问题中的答案提示和上下文的部分信息，解决阅读理解中的自动问题生成。Du 等[16]首次将深度学习引入到问题生成中，提出一种通过将注意力机制引入到编码-解码架构中进行问题生成。Zhou 等[18]提出通过编码器读取给定的输入文本以及答案所在的位置，然后产生一个有答案感知的输入向量，最后将该向量传递到解码器，以便生成一个以答案为中心的问题。以答案为焦点的问题生成，采用预训练模型改善问题生成的质量，主要的方式是通过融合各种新模型进行各种问题生成的复杂处理。虽然提高了问题生成的质量，但无法帮助商家解决此项问题。

因此，Rao 等[111]在 2018 年首次通过构建深度网络模型与完美信息的期望价值相结合来解决了这一问题。Rao 等[50]在 2019 年又一次通过构建两种模型结构，提出解决问题生成的特殊性，并且实验证明使用编码器-解码器模型，会生成高

中国知网 https://www.cnki.net

度通用的问题。之后 Zhang 等[43]提出基于 KPCNet 的网络架构，不仅解决了生成高度通用的问题，同时提出了问题生成的多样性，但该模型对关键词的预测，依然存在次优的全局多样性和特殊性问题。最近 Roitman 等[44]提出基于 T5 模型和 LTD 相结合的方式对问题生成进行改进，但使用预训练模型生成问题会产生代价过于昂贵的问题。

介于这些局限性，本章提出 TEKPCNet 模型，在问题生成中使用 Transformer 编码器[95]对上下文的信息进行建模，来预测问题关键词，并将每次预测的问题关键词向量信息在次通过卷积神经网络提取语义信息。最终，使用线性映射的方式输入到编码器-解码器模型的输入端，使问题生成的特殊性和多样性上有更好的性能。本章的主要贡献总结如下：

（1）鉴于 Transformer 编码器的特征抽取能力强且基于双向编码，不易丢失上下文的结构信息等优势，通过引入 Transformer 编码器改善基于上下文预测问题关键词的准确度。

（2）在得到问题关键词之间的语义信息基础上，通过文本卷积神经网络和线性映射的方式，将提取问题关键词的语义信息融入到编码器和解码器的起始端，强制模型在起初阶段学习有意义的数据。

（3）本章提出 TEKPCNet 模型，结合基于 Transformer 编码器的问题关键词预测器和增强的编码器-解码器模型，有效的提高了问题生成的多样性和特殊性。

5.2 模型结构

该部分为本章的方法模型架构。首先简单介绍关于本章提出的 TEKPCNet（Transformer Encoder of Keyword Predictor keyword-Conditioned Network）模型；接着对该模型的核心算法部分进行详细阐述；然后介绍基于 Transformer 编码器问题关键词预测模型，最后介绍增强的编码器-解码器部分。

本章模型总体架构如图 5.1 所示，利用基于 Transformer 编码器的问题关键词预测器，采用传统的编码器-解码器模型，分为两个阶段生成问题。在第一阶段，通过 Transformer 编码器预测问题关键词的逻辑概率，将这些概率与问题关键词的词向量进行内积运算，从而获得关键问题关键词的语义信息。在第二阶段，利用基于 GRU 的编码器-解码器模型，借助卷积神经网络提取问题关键词的语义信息，并通过线性映射的方式将提取的语义信息输入到编码器和解码器的输入端，从而改善编码器-解码器模型的性能。通过在 5.2.1 节和 5.2.2 节分别阐述每一个阶段的原理和作用。

中国知网 https://www.cnki.net

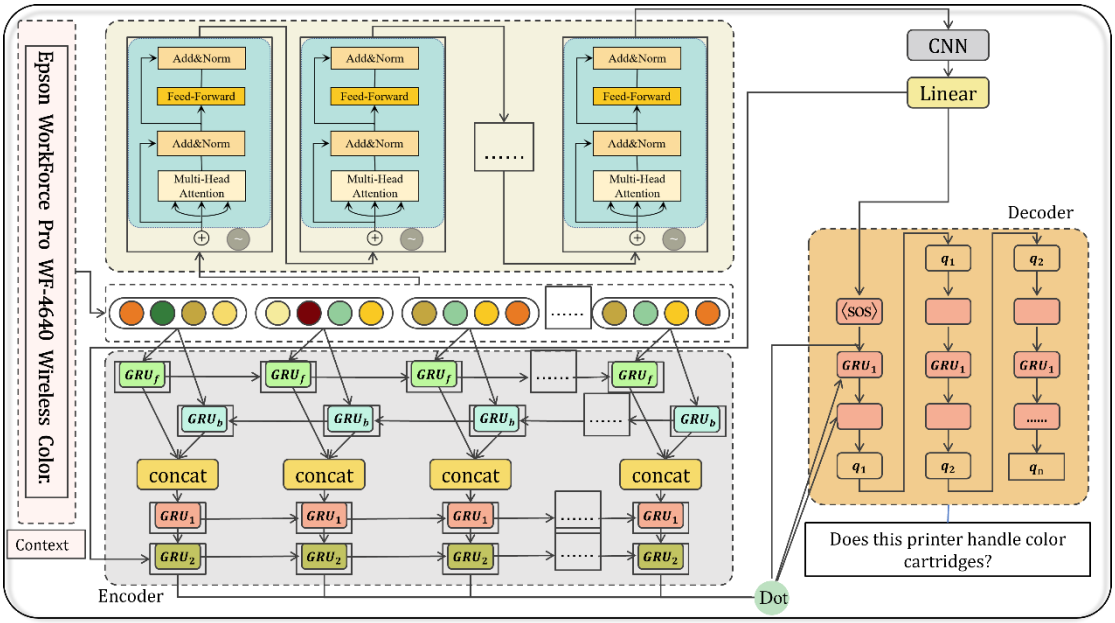


图 5.1 基于 TEKPCNet 模型

5.2.1 基于 Transformer 问题关键词预测

本部分主要通过使用 Transformer 编码器编码上下文语义信息，预测问题关键词的概率。在这项工作中，关键词作为一个关键信息标记为 $K=(k_1,k_2,...,k_l)$（其中每个 k 表示提取关键词的单词）。其中关键词主要包含固定不同的词汇，或者是问题中出现的动词以及形容词。

为了简化模型，假设每个关键词 k 的概率独立于给定的上下文，使用 Transformer 编码上下文的语义信息，来预测关键词之间的语义信息，如式子（5.1）和式子（5.2）：

$$k^l = Transformer - Block(c^{l-1}) \tag{5.1}$$

$$p(k \mid c) = soft\max(k^l) \tag{5.2}$$

使用概率值表示 $P(k \mid C)=\prod_{k \epsilon K} P(k \mid C)$ 提取关键词的概率，在训练过程中的每一个关键词的训练损失函数为二进制交叉熵，如式子（5.3）：

$$Loss_{keyword} = -\frac{1}{N}\sum_{n=1}^{N}\sum_{c=1}^{C} k_{n,c} log(p_{n,c}) \tag{5.3}$$

其中，$k_{n,c}$ 作为二进制指标，$p_{n,c}$ 表示在关键词典 K 中的第 n 个样本的关键词的第 c 个关键词被预测的概率。在训练中，通过选择关键字集 k，训练目标是给定上下文 c 和关键字 k，目的是使所有问题的对数似然最大化，等同于最小化目标函数，如式子（5.4）：

中国知网 https://www.cnki.net

$$Loss_{mle} = -\frac{1}{N}\sum_{n=1}^{N}\log(p(q_n \mid c_n, k_n)) \tag{5.4}$$

在获得掩码目标之后，为了防止数据的过拟合，采取 Dropout 进行随机失活。为了更好的生成多样性目标函数，对每一个时间步采取 Top-K 策略。

5.2.2 编码器-解码器架构

GRU 网络在解决长短序列之间的时间序列依赖问题上表现突出，能够有效地编码时间序列信息。相比传统的 LSTM 网络结构，GRU 网络更为简洁，使用更少的参数信息，因此能够提升模型的性能。在编码器中，多层双向 GRU 被用来对文本的序列信息进行编码，将上下文文本的词嵌入e_i^c作为输入，然后传递给编码器。编码器利用双向 GRU 体系结构，首先前向传播和后向传播两个方向处理上下文文本$C=(c_1,c_2,...,c_m)$，捕获更多的上下文文本信息；然后从前向传播和后向传播中，得到前向和后向隐藏层向量$\overrightarrow{h_t}=(\overrightarrow{h_0},\overrightarrow{h_1},...,\overrightarrow{h_m})$和$\overleftarrow{h_t}=[\overleftarrow{h_0},\overleftarrow{h_1},...,\overleftarrow{h_m}]$；最后拼接前向和后向隐藏层向量，得到最终的隐藏层向量$h_t=[h_0,h_1,...,h_m]$。为了使编码器在第一时间步，就能学习到有效的信息。本章将文本卷积神经网络提取的问题关键词的语义信息，经过多层感知器进行线性映射，然后作为第一个时间步的隐藏层输入，最后将该隐藏层向量与上下文的起始输入字符向量作为第一个时间步的输入，一起输入到 GRU 模型中。通过以这种方式处理上下文文本，模型能够有效地编码上下文的语义信息，同时考虑到周围的上下文以及问题中的关键词信息，最终导致更准确的预测和更好的整体性能。

因此，编码器编码上下文每一个 token 的每一时间步计算公式如下:

$$h(t_0)=e(k) \tag{5.5}$$

$$\overrightarrow{h_t}=BiGRU(e_t^c,\overrightarrow{h_{t-1}}) \tag{5.6}$$

$$\overleftarrow{h_t}=BiGRU(e_t^c,\overleftarrow{h_{t-1}}) \tag{5.7}$$

$$h_t=[\overrightarrow{h_t};\overleftarrow{h_t}] \tag{5.8}$$

其中$e(k)$表示提取问题关键词的词嵌入，$h(t_0)$表示编码器第一个 token 起始隐藏层的嵌入。$\overrightarrow{h_t}$和$\overleftarrow{h_t}$表示 GRU 前向传播的隐藏层向量和后向传播的隐藏层向量。

对于上下文中的所有单词序列的输入序列$C=[h_0,h_1,...,h_m]$。最终的隐藏层向量h_m将作为解码器隐藏层的起始输入。

在解码时刻，通过利用另外一个单层单向 GRU 作为解码器，生成问题单词

中国知网 https://www.cnki.net

序列，并将编码器的最终隐藏层向量h_m作为解码器隐藏层初始的隐藏层向量h_0^d。为了更好的融合提取的问题关键词语义信息，将使用 MLP 映射的问题关键词语义信息词嵌入向量替换解码器的起始字符[SOS]。具体表达公式如下：

$$h_0^d = h_m \tag{5.9}$$

$$e_0^p = e(SOS) \tag{5.10}$$

$$e_0^p = e(k) \tag{5.11}$$

其中，e_0^p表示解码器目标词汇第一个时间步t_0的词嵌入向量。e(*SOS*)表示解码器第一个时间步t_0的随机初始化向量。

在解码器的每一个时间步 t，都需要按照以下顺序生成目标问题的 token。首先在解码时间步 t 的时刻，GRU 解码器将目标词汇的词嵌入输入和上一时间步 t-1 时刻的隐藏层向量作为当前时间步 t 的输入进行解码。具体表达式如下：

$$h_t^{q,d} = GRU(e_t^q, h_{t-1}^{q,d}) \tag{5.12}$$

接着，将时间步 t 生成的目标问题词嵌入$h_t^{q,\mathrm{d}}$，与上下文词嵌入向量 C 做内积，得到当前 t 时刻目标词汇与上下文信息之间的权重信息$\alpha_{t,\mathrm{i}}^q$。该权重信息表示在当前时刻 t，上下文信息会对目标词汇生成产生一定的影响，而这个影响的大小由权重来衡量。为了更加准确地度量模型生成结果的置信度，可以更好地控制权重大小并且提高注意力机制的性能。因此使用 softmax 函数对这组权重进行归一化。具体的表达式如下：

$$\alpha_{t,i}^q = \frac{exp(h_t^{q,d}\ \mathbf{W}^b\ h_i)}{\sum_{i=1}^{m} exp(h_t^{q,d}\mathbf{W}^b\ h_i)} \tag{5.13}$$

其中，i 表示上下文中词汇中的第 i 个单词，h_i则表示上下文输出的第 i 个单词嵌入。$\mathbf{W}^b$表示模型可训练的参数。

将得到的注意力分数与上下文做内积，得到与上下文语义相关的目标问题词嵌入，使当前时间步 t 中的目标问题得到的注意力分数有选择性地聚焦于上下文中更重要的词汇，帮助提高问题生成结果的准确性和连贯性。

最终，将得到具有上下文语义信息的目标词嵌入与当前经过 GRU 解码的目标输出作拼接，经过线性映射和线性激活函数后，在使用 Softmax 函数来获取序列中每个位置的词汇生成概率分布，最终根据概率分布得到输出的目标词汇向量。具体表达式为：

$$\mathbf{O}_t = softmax(\mathbf{W}^o tanh(\mathbf{W}^c[h_t^{q,d}; \alpha_{t,i}^q\ h_t^{q,d}])) \tag{5.14}$$

其中，$\mathbf{W}^o$和$\mathbf{W}^c$表示模型可训练的参数，tanh 表示激活函数，$\mathbf{O}_t$表示每个位置

中国知网 https://www.cnki.net

词汇生成的概率分布。

5.2.3 训练和测试

教师强迫在解码的训练中发挥着重要的作用，它有助于模型更好地学习序列中的依赖关系并在优化过程中降低误差。在训练过程中，采用一种被称为教师强迫的技术，该机制在每个解码时刻以一定的概率使用目标问题的 token 作为当前时间步的输入，以预测目标输出，而非使用采样预测的 token 作为当前时刻目标的输入。这一策略强制模型在训练阶段学习，加速模型的收敛和优化，并减少误差的累积，从而缓解暴露偏差。

在测试阶段，解码器依赖于基于词库的概率分布来选择最可能产生的词。这个过程包括选择概率最高的几个词作为该时刻的生成词，并将其作为下一个解码步骤的输入。解码器重复这个过程，直到生成结尾字符[EOS]。

总体而言，这种解码策略允许模型通过利用其内部知识和外部环境来生成高质量的输出，同时确保生成的输出保持连贯性和合理性。教师强迫在训练中的引入，使得模型更好地适应任务目标，提高了生成结果的准确性和一致性。

5.3 实验及分析

为了验证本章节提出模型的性能，在第三小节主要通过与多组基础模型在多组评估指标上进行对比，验证本章模型的性能。接着本小节还提供了消融实验，通过评估每个模块对整体性能的影响，有助于识别每个模块的重要性。并使用案例分析具体地说明模型在特定场景或任务中的应用效果。

5.3.1 实验参数设置

为了和原来模型在效果上进行公平比对，本章尽量把参数和对比模型的参数设置相同。实验中将问题的最大长度设置为 20；上下文的最大长度设置为 100，不足位数进行补 0 操作，超出部分采取截取操作（可能存在上下文语义丢失的现象）。

对于 TEKPCNet 的模型，基于 Transformer 编码器问题关键词预测器的参数设置如下，注意力机制采用 8 头的注意力机制以及 6 层编码器，层间 dropout 设置为 0.2，实验中使用的学习率为 0.0003，输入批处理大小为 128，优化器使用 Adam。编码器-解码器架构采用 GRU 网络，编码器和解码器的隐藏层使用 100

中国知网 https://www.cnki.net

个隐藏神经元，输入的词向量嵌入为 200 维度，层间 dropout 设置为 0.3。对于两种数据集的词嵌入，由于 Home & Kitchen 的数据集的数量较大，在数据集 Home & Kitchen 主要采用 word2vec 词向量；对于数据集 Office，由于该数据集的数量较小，采用 Glove 词向量；对于词嵌入的维度全部采用 200 维度进行表示。

5.3.2 实验结果与分析

下边将从三部分对实验结果进行分析和讨论，第一部分通过采取与基线模型进行对比的方式，在 Home & Kitchen 和 Office 数据集进行自动评估和人工评价；第二部分使用 Office 数据集分析各模块对实验的影响；第三部分从实验生成的结果中抽取部分实例与之前模型的实验结果所抽取的部分实例进行比较，定性分析本模型提出的方法的优势。其中“-”表示原始论文中未涉及的数据，加粗的数据是对比模型中最好的数据。

（1）对比实验

MLE[50]：基线模型，首次通过编码器-解码器模型研究问题生成，使用最大似然估计对（上下文，问题）二元组目标进行评估。

hMup[112]：主要用来对机器翻译的生成进行整体质量和多样性的良好平衡。

KPCNet[43]：针对多样性和具体性提出了挑战，通过经典的编码器-解码器模型构建一个 KPCNet 模型，解决问题生成的多样性和特殊性。

表 5.1 是在 Home & Kitchen 的数据集上机器自动评价的结果。模型的实验结果在 P@5 和 Distinct 等各项指标上都达到了理想的效果，但是在 BLEU 指标上的结果未能达到最优，这是由于问题多样性和特殊性的生成会影响问题流畅性生成的结果。通过自动评估的实验结果表明，准确预测问题关键词的分布和在编码器和解码器的输入端进行改进两部分相结合，有很大的潜力可以改善问题生成的多样性和特殊性。在复现原始论文模型的实验结果时，发现无法精确复现原始论文的结果，可能由于实验环境等各个方面的局限性，本章将复现的实验结果使用加*的方法进行展示。

如表 5.2 所示显示的组级问题生成人工评价结果。可以看到，模型在产生问题的评估结果中，相关性、特殊性、有用性都优于对比的基线模型。虽然在新信息方面没有使用传统的 MLE 模型得分高，但是 MLE 模型需要以更高的冗余度为代价，往往生成的问题重叠度较高，不能满足多样性指标。本章生成的问题在逻辑性上有些欠缺，可能是多样性生成导致，虽然未能达到最优，但是在其他三项主要的性能指标上，具有较好的效果。这说明本章的模型可以提高问

中国知网 https://www.cnki.net

题生成的多样性和特殊性质量。

表 5.1 Home & Kitchen 数据集的自动评价指标

	P@5	Distinct-1	Distinct-2	Distinct-3	BLEU	METEOR
ref	-	-	-	69.34	-	-
MLE[50]	-	2.7	5.7	7.77	**18.13**	14.86
hMup[112]	-	2.3	9.6	11.11	17.76	15.40
KPCNet[43]	47.0	3.4	9.6	15.30	17.77	16.18
KPCNet*[43]	46.8	4.00	10.91	16.08	14.48	15.66
TEKPCNet	**47.9**	**4.12**	**11.56**	**18.39**	15.22	**16.29**

表 5.2 Home & Kitchen 数据集的人工评价指标

	New info [0-1]	Relevant [0-1]	Logical [0-1]	Specific [0-4]	Useful [0-3]	Redundant [0-2]
ref	0.947	0.990	1.000	2.530	2.680	0.120
KPCNet	**0.823**	0.963	**0.863**	1.877	1.760	**0.190**
TEKPCNet	0.802	**0.967**	0.802	**1.926**	**1.927**	0.164

如表 5.3 显示的自动评价指标结果，TEKPCNet 在 Distinct 系列指标、BLEU、METEOR 指标上优于复现后的 KPCNet。实验结果表明，通过使用 Transformer 编码器编码上下文来预测问题关键词，结合增强的编码器-解码器模型，可以有效提高问题生成的多样性和特殊性质量。

表 5.3 Office 数据集的自动评价指标

	P@5	Distinct-1	Distinct-2	Distinct-3	BLUE	METEOR
ref	-	-	-	75.54	-	-
MLE[50]	-	-	-	20.33	**14.73**	13.81
hMup[112]	-	-	-	15.31	10.45	12.52
KPCNet[43]	47.0	-	-	30.99	13.84	15.29
KPCNet*[43]	46.8	10.88	23.29	32.00	13.67	13. 95
TEKPCNet	**49.5**	**11.91**	**24.76**	**33.15**	14.39	**14.12**

表 5.4 显示了组级问题生成的人工评价结果，在新信息方面，模型在小数据集上会有相对较好的性能。实验数据显示，TEKPCNet 在大多数指标上都优于 KPCNet 和 MLE，特别是在相关性、特殊性和有用性方面，这表明 TEKPCNet 可以在不同的数据集上提高问题生成的多样性和特殊性。

中国知网 https://www.cnki.net

表 5.4 Office 数据集的人工评价指标

	New info [0-1]	Relevant [0-1]	Logical [0-1]	Specific [0-4]	Useful [0-3]	Redundant [0-2]
ref	0.993	0.997	0.993	2.713	2.420	0.330
KPCNet	0.803	0.940	**0.817**	1.903	1.470	**0.190**
TEKPCNet	**0.822**	**0.948**	0.776	**1.920**	**1.601**	0.127

如图 5.2 和图 5.3 所示，分别使用不同的模型在数据集 Home & Kitchen 上对问题关键词预测，进行了实验对比，并使用 P@5、P@10、P@20 三个评估指标，对问题关键词预测准确度进行评估。

图 5.2 和图 5.3 显示的结果表明，使用 Transformer 编码器对问题关键词进行预测，性能相比于其它模型预测的性能更好。使用 BiGRU 预测问题关键词，并没有使用卷积神经网络提取语义信息预测问题关键词性能好，但是使用卷积神经网络和残差网络结合的方式预测问题关键词具有良好的性能。本章的实验结果表明，使用 Transformer 编码器预测问题关键词性能更优。

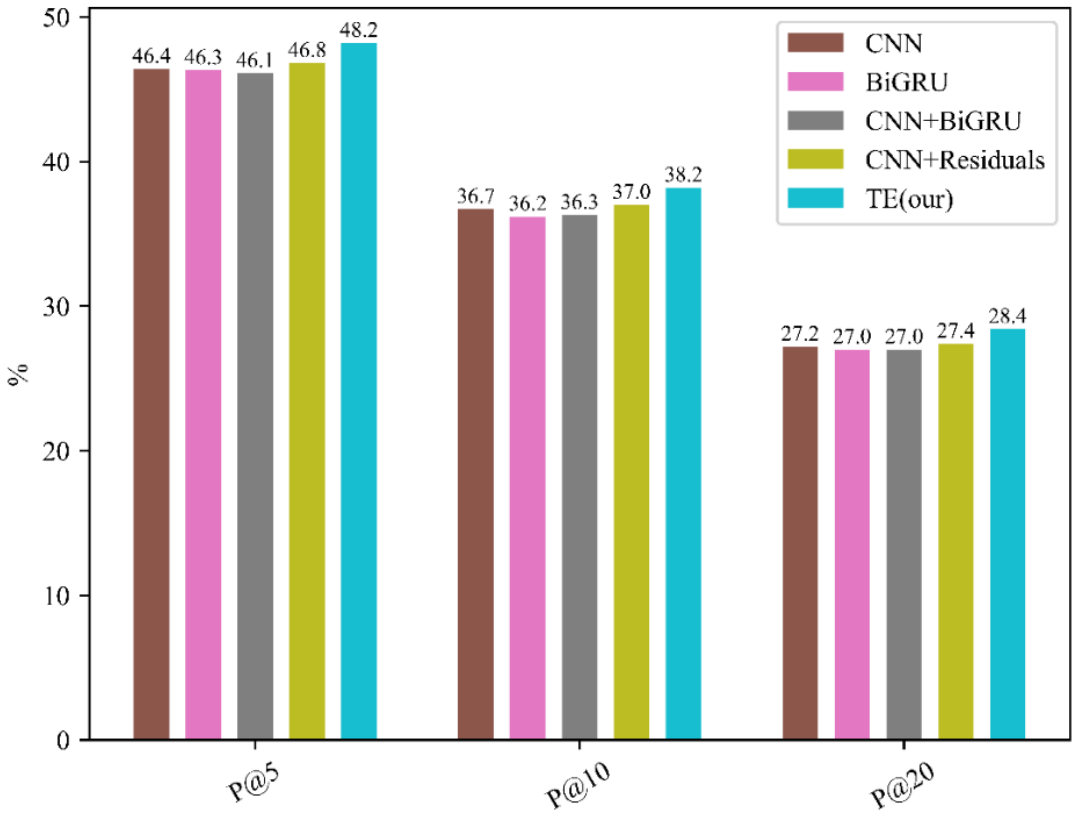


图 5.2 Home & Kitchen 数据集在问题关键词预测评估结果

中国知网 https://www.cnki.net

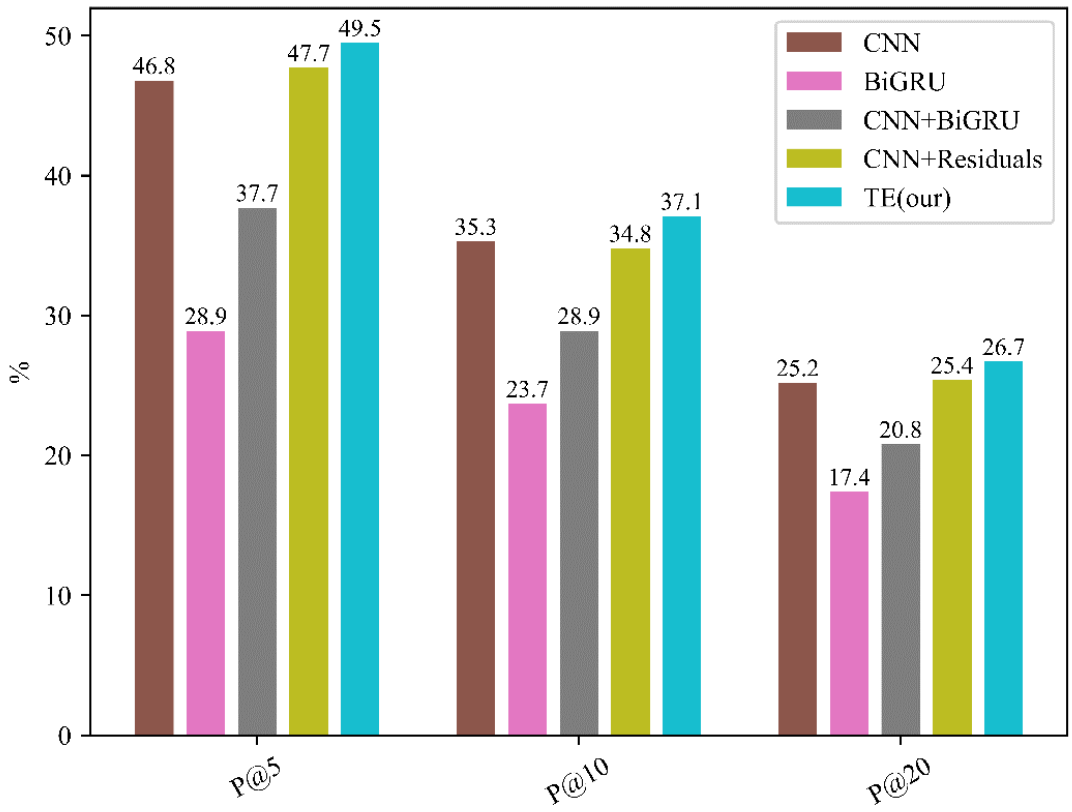


图 5.3 Office 数据集在问题关键词预测评估结果

（2）消融实验

本部分使用两个数据集分别设计了四组实验进行比较，来进行消融实验，通过在 TEKPCNet 模型的基础上进行修改，使用 Home & Kitchen 数据集和 Office 数据集来验证不同模型模块对实验数据的影响，具体实验数据结果如表 5.5 和表 5.6 所示。之后使用 Office 数据集验证模型中隐藏层参数对实验结果的影响，具体实验结果如表 5.5 所示。

表 5.5 基于 Home & Kitchen 数据集验证不同模块之间的实验结果

模型	Distinct-1	Distinct-2	Distinct-3	BLUE	METEOR
KPCNet	4.00	10.91	16.08	14.48	15.66
TEKPCNet-CNN	4.03	10.95	16.73	14.77	15.99
TEKPCNet-基于 Transformer 编码器问题关键词预测器	3.97	11.55	18.38	13.44	15.77
TEKPCNet	**4.12**	**11.56**	**18.39**	**15.22**	**16.29**

中国知网 https://www.cnki.net

表 5.6 基于 Office 数据集验证不同模块之间的实验结果

模型	Distinct-1	Distinct-2	Distinct-3	BLUE	METEOR
KPCNet	10.88	23.29	32.00	13.67	13. 95
TEKPCNet-CNN	**12.33**	**26.46**	**35.74**	11.10	13.97
TEKPCNet-基于 Transformer 问题关键词预测器	11.26	22.87	31.19	**14.82**	**14.38**
TEKPCNet	11.91	24.76	33.15	14.39	14.12

基于表 5.5 数据结果显示，在数据集 Home & Kitchen 上，删除基于 Transformer 问题关键词预测模型，使用卷积神经网络预测问题关键词，并使用增强的编码器-解码器，本章模型的性能指标分别在 Distinct-1、Distinct-2、Distinct-3、BLUE、METEO 上降低了 0.12%、0.01%、0.01%、1.78%、0.52%。使用基于 Transformer 编码器问题关键词预测模型后，未使用增强的编码器-解码器模型，模型的性能指标分别 Distinct-1、Distinct-2、Distinct-3、BLUE、METEO 上降低了 0.09%、1.00%、1.66%、0.45%、0.3%。使用本章的模型相比于原始的网络模型在 Distinct-1、Distinct-2、Distinct-3、BLUE、METEOR 性能指标上分别增加了 0.12%、2.04%、2.31%、0.74%、0.63%。

基于表 5.6 数据结果显示，在数据集 Office 上，不使用基于 Transformer 编码器问题关键词机制，使用卷积神经网络预测问题关键词，并使用增强的编码器-解码器，本章模型的性能指标分别在 Distinct-1、Distinct-2、Distinct-3 上降低了 0.65%、1.89%、1.96%。使用基于 Transformer 编码器问题关键词预测模型后，未使用增强的编码器-解码器模型，模型的性能指标分别 BLUE、METEO 上降低了 3.29%、0.15%。使用本章的模型相比于原始的网络模型在 Distinct-1、Distinct-2、Distinct-3、BLUE、METEOR 性能指标上分别增加了 1.03%、1.47%、1.15%、0.72%、0.17%。

综上所述，本章提出的 TEKPCNet 模型，在两个数据集上都获得良好的性能。说明在使用 Transformer 编码器编码上下文来预测问题关键词时，可以更准确的捕获文本的结构信息，但是单独使用 Transformer 编码器来预测问题关键词，不使用文本卷积神经网络提取关键词的语义信息，模型依然存在一些不足。因此在使用 transformer 编码器对上下文进行编码，预测问题关键词之后，使用卷积神经网络对问题关键词的语义信息进行提取，输入到编码器和解码器的输入端，增强编码器-解码器，对问题生成的质量有着积极作用。

图 5.4 验证模型的隐藏层维度参数对实验结果的影响。根据表的实验结果显示，使用不同维度的隐藏层，实验结果不同。隐藏层维度越高，模型学习的能力越强，在 Distinct 系列指标的实验结果越好。同时，消融测试的结果显示，随

中国知网 https://www.cnki.net

着 Distinct 指标的增加，伴随着 BLEU 指标性能的减少，可能的原因是由于多样性和特殊性导致的。

实验结果显示，当隐藏层维度为 200 时，各项指标相对较好。但是为了和基准模型公平对比，对比实验中选择了和基准模型的隐藏层维度参数一致。本章的对比实验中，使用的隐藏层维度为100。本章中消融实验验证的隐藏层维度参数分别为 100、200、400、800、1600。

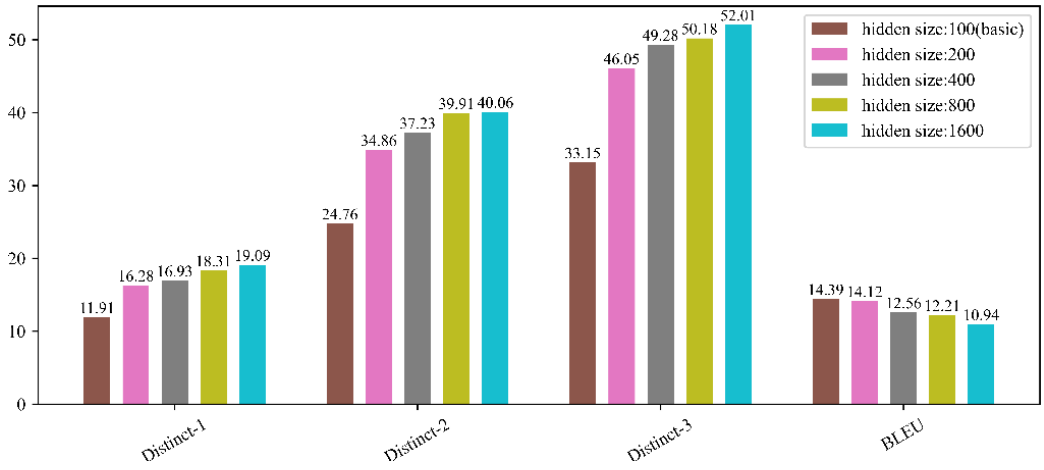


图 5.4 基于 Office 数据集验证不同隐藏层维度大小之间的实验结果

5.3.3 案例分析

这里分别从数据集 Home & Kitchen 和 Office 中随机抽取两个案例进行比较分析，同时比对之前的模型产生的案例，以便于更好的完成对比实验的分析。基于 Home & Kitchen 数据集的案例分析如表 5.7 所示。基于 Office 数据集的案例分析如表 5.8 所示。

表 5.7 列举了在数据集 Home & Kitchen 上的测试集中的三个问题生成实例。第一个例子通过列举不锈钢法式咖啡机商品信息的描述，第二个例子通过列举卡其色搅拌机盖商品信息的描述，然后根据两个商品信息的描述，分别列举了引用的三个问题、Chatgpt 的三个问题、KPCNet 生成的三个问题以及本章提出的 TEKPCNet 模型生成的三个问题。最后并分别对生成的问题的特殊性进行人工评价，对出现的问题进行标注。在表中发现，使用 KPCNet 网络模型生成的问题出现了多数生成的问题重复以及生成的问题拼写错误现象，使用文本提出的 TEKPCNet 网络模型在此处案例中仅出现问题重复现象且重复现象不明显。Chatgpt 在语法和语义方面具有较好的性能，但是针对特殊的方面，依然存在泛化现象，无法有效的完成特定的任务。因此，本文提出的模型在生成问题的特殊性方面，具有和标准参考问题接近的性能表现。

中国知网 https://www.cnki.net

表 5.7 Home & Kitchen 数据集的问题生成的案例分析

Product1	Francois et Mimi large stainless steel double wall French coffee press,50oz. Enjoy fresh coffee every day with this elegantly designed coffee press. Product features a no-drip spout, and the large size accommodates 4-5 standard coffee cups…		
System	Generation group	特殊性	问题
ref (3)	Where was it manufactured? Where do you purchase replacement screens for the 50 oz press? Does this really hold 50oz?	3 4 4	
ChatGPT	What are the specific design elements of the Francois et Mimi coffee press? Can you share more information about the material? How does the no-drip spout of the Francois?	2 1 3	问题泛化 问题泛化
KPCNet	Is this stainless steel? Is it stainless steel? Where can i get a replacement filter for this coffee maker ?	3 3 2	问题重复 问题重复
TEKPCNet	Is this made of stainless steel? How many cups does it hold? Is this made in the usa?	3 3 3	
Product2	Kitchenaid khaki cover for tilt-head stand mixer ksmct1kb. Keep your kitchenaid tilt-head stand mixer looking like new with this khaki mixer cover. designed to neatly fit over any kitchenaid tilt-head style stand mixer, this convenient quilted cover is made from 100 % cotton…		
ref (3)	Will this fit the kitchen aid artisan? Will this fit pro 600 series? Does it fit with the bowl attached for storing?	3 3 2	
ChatGPT	What are the dimensions for the tilt-head stand mixer? Could you provide details about material composition? How does the quilted design of the Kitchenaid?	2 2 3	问题重复 问题重复
KPCNet	Will this fit a 4.5-quart mixer? Will this fit a 4.5 qt mixer? Will this fit the 720?	2 2 3	问题重复 拼写错误
TEKPCNet	Will this fit a kitchen aid artisan mixer? Will this grate fit a kitchen aid artisan mixer? Will this grate fit a kitchen aid artisan?	3 2 2	问题重复 问题重复

中国知网 https://www.cnki.net

表 5.8 Office 数据集的问题生成的案例分析

Product1	Epson workforce pro wf-4640 wireless color all-in-one inkjet printer with scanner and copier. Workforce 4640 wireless all-in-one inkjet printer…		
System	Generation group	特殊性	问题
ref (3)	How many pages per minute?	3	
	Does it support air print?	3	
	I recall seeing that this printer can print labels directly On to DVD and cd disks does the wf- 4640?	4	
ChatGPT	What are the key features and capabilities its?	2	问题重复
	Can you provide details about the scanning and copying functions of the Workforce 4640 printer?	2	问题泛化
	How does the wireless connectivity enhance the overall functionality?	3	
KPCNet	Does it come with toner?	3	
	Does this printer come with toner cartridges?	3	问题重复
	Does it come with toner cartridges?	2	问题重复
TEKPCNet	Does this printer handle color cartridges?	3	
	Does this printer handle legal size paper?	3	逻辑问题
	Does this printer print two sided?	3	
Product2	Workez standing desk conversion kit. Affordable adjustable height angle laptop sits to stand up desktop riser converter and negative tilt keyboard tray. Workez standing desk – a simple, affordable, and effective standing desk …		
ref (3)	How easy is the tray to move?	4	
	Can this hold two monitors?	3	
	Will this work for my imac that is 21.5-inch monitor that is 12.5 pounds?	4	
ChatGPT	What are the specific adjustable height settings available in the Workez standing desk conversion kit?	3	
	Could you provide details about the negative tilt keyboard tray feature in the Workez standing desk?	3	
	How does the Workez standing desk contribute to creating an effective and ergonomic workspace?	2	问题重复
KPCNet	What size laptop does it hold?	2	问题重复
	What size is it?	3	问题泛化
	What size laptop it holds?	2	语法错误
TEKPCNet	What size laptop does it support?	3	
	Is this product possible to hold an 17 inch laptop?	3	语法错误
	Is this item possible to hold a 23-inch laptop?	3	

中国知网 https://www.cnki.net

表 5.8 列举了在数据集 Office 上的测试集中的三个问题生成实例。第一个例子通过列举无线彩色一体式喷墨打印机商品信息的描述，第二个例子通过列举坐立式桌面升降转换器商品信息的描述，第三个例子通过列举计算机商品信息的描述。然后根据三个商品信息的描述，分别列举了参考引用的三个问题、KPCNet 生成的三个问题以及本章提出的 TEKPCNet 模型生成的三个问题；最后并分别对生成问题的特殊性进行人工评价，对出现的问题进行标注。在表中发现，使用 KPCNet 网络模型生成的问题出现了问题重复、语法缺失和语法错误现象。使用本章提出的 TEKPCNet 网络模型在此处案例中出现问题重复、语法错误和逻辑错误现象。Chatgpt 虽然并未出现语法错误和逻辑错误，但是针对特殊的方面，依然存在泛化现象，无法有效的完成特定的任务。在生成问题的特殊性方面，相比于 KPCNet 网络模型和 Chatgpt 的特殊性方面具有更好的性能。

针对本章和KPCNet网络中出现的语句缺失和语法错误，本章进行了深入分析。发现生成问题的过程中出现未登录词的问题，被称为 OOV。解决此问题的方法，在问题生成的前人研究中已经有人提出，主要使用指针网络进行解决。由于本章主要针对提高问题关键词预测概率，引入外部条件提高问题生成的多样性和特殊性。

综上所述，通过提供 KPCNet 和 TEKPCNet 在两个数据集上生成的结果案例，来对比问题生成的质量。对于每组生成的六个问题，采取通过 Zhang 等提出的聚类问题关键词的方式，只选取其中三个问题作为比较。在人工进行组级别的评估过程中，KPCNet 存在问题重复的现象，并且生成的问题和原文信息有过多的重合等现象。对于本章模型生成的问题，冗余现象明显减弱，语法和逻辑也具有较好的效果，但是同样存在逻辑有问题的问句等问题。因此，通过基于 Transformer 编码器问题关键字预测器并结合改进的编码器-解码器模型，有效提升了生成问题的质量。

5.4 本章小结

本章节针对改善问题生成的多样性和特殊性这一难题，构建了 TEKPCNet 模型。这个模型利用 Transformer 编码器改善问题关键词的预测，达到增强外部知识信息的效果，同时结合增强编码器-解码器模型的输入端，提高问题生成的质量。通过与基线模型的对比实验结果在 Home & Kitchen 数据集和 Office 数据集分别进行评估，生成问题的质量由自动评估和人工评估方式进行验证，证明本章的模型可以有效提升问题生成中多样性和特殊性的质量。同时，本章通过消融实验验证每个模块的有效性，并使用案例分析进行证明。

中国知网 https://www.cnki.net

第 6 章 总结及展望

6.1 总结

问题生成任务在人工智能领域中起着极为重要的作用，无论在教育、电商、医疗等不同的应用场景中都具有极大的研究意义。因此，问题生成的研究在未来仍然是研究的热点话题之一。本文紧跟技术发展的方向，基于深度学习下的神经网络研究问题生成。在问题生成研究中发现目前的问题生成依然存在以下三个问题。首先是在有答案感知的问题生成中存在的语义结构信息丢失的问题，其次有答案感知的多样性问题生成中存在的生成问题单词重复的问题，最后是无答案感知的多样性问题生成中存在的忽视上下文的全局结构信息导致预测问题关键词不精准问题。因此，本文基于以上存在的三个问题提出了三种模型来改善问题生成的质量。

首先，针对图到序列模型的问题生成中，依然存在编码器的多阶段编码以及解码过程中容易丢失段落中丰富的序列信息和语义结构信息的问题，本文提出多阶段时序和语义信息增强的模型。该模型通过将不同阶段编码的上下文信息和答案信息进行融合，有效的改善编码阶段语义信息丢失的问题。接着在解码阶段引入迭代图神经网络有效改善先前解码阶段语义结构信息丢失问题，最后结合注意力机制、指针复制机制等技术生成相应的问句。在 SQuAD 数据集上，与最新的 KE-BGINN 模型相比，本文提出的模型，在 BLEU-4、METEOR、ROUGE 的指标上分别提升了 0.6%、0.65%、0.60%。在第二个 MS MARCO 数据集中的实验结果表明，在 BLEU、METEOR、ROUGE 评估指标上同样均优于现有的先进模型，均超越基线模型。这表明本文提出的模型可以有效的提升问题生成的质量。

其次，针对有答案感知的多样性问题生成中存在的问题单词重复问题，本文提出基于对比搜索算法的多样性问题生成模型。该模型首先充分利用预训练语言模型拥有丰富的语义信息的特征，使用预训练语言模型微调多样性问题生成的参数，然后通过在解码端引入对比搜索策略，解决解码过程中生成问题单词重复的现象，提高可回答性，改善问题生成多样性的质量，并通过构建句子级数据集研究句子级的多样性问题生成。在 SQuAD 数据集与多种解码方法在多个评估指标上进行实验对比，并通过案例分析表明本文提出的模型可以改善可回答性以及多样性问题生成的质量。在段落级的多样性问题生成数据集上的问答分数与基线采样方法相比的 Q1 评估指标提升了 0.44%、Q2 评估指标上提升

中国知网 https://www.cnki.net

了 0.76%，在句子级的多样性问题生成数据集上的问答分数与基线采样方法相比的 Q1 评估指标提升了 2.39%、Q2 评估指标上提升了 2.52%。

最后，针对无答案感知的多样性问题生成中存在的忽视上下文的全局结构信息导致预测问题关键词不精准，最终导致影响问题生成质量的问题，本文提出基于 Transformer 编码器问题关键词预测的问题生成模型。该模型通过 Transformer 编码器对外部的问题关键词进行预测，可以改善预测问题类型不精准问题，使用 Transformer 编码器对问题关键的预测，可以有效改善问题生成的质量。然后结合卷积神经网络和多层感知器对编码器-解码器模型的输入端进行加强，利用卷积神经网络提取文本的局部信息，进一步提升问题生成多样性和特殊性的质量。最后结合注意力机制、Top-k 和 Top-p 策略生成多样性和特殊性问题。 实验结果表明，在大型公开数据集 Home & Kitchen 上，多样性 Distinct-1、Distinct-2、Distinct-3 评估指标分别提升了 0.12%、0.65%、2.29%，在小型数据集 Office 中，多样性 Distinct-1、Distinct-2、Distinct-3 评估指标分别提升了 1.03%、1.47%、1.15%，这表明本文提出的模型能有效提升问题生成的质量。

通过对上述问题的研究，较好的解决了问题生成领域下语义结构信息丢失、生成问题单词重复、无答案感知的多样性问题生成中存在的忽视上下文的全局结构信息导致预测问题关键词不精准等关键问题。并将其应用于解决现实生活中的问题，将其应用于教育、电子商务等领域，这表明该项研究依然具有极大的研究价值和参考意义。

6.2 未来展望

本文通过对基于神经网络的多样性问题生成进行研究，在文中提出了三种模型改善问题生成的质量。首先对于有答案感知的问题生成进行研究，接着对有答案感知的多样性问题生成进行研究，最后更进一步研究更加复杂的问题生成-无答案感知的多样性和特殊性问题生成，并通过在电商数据集进行验证。但是，经过对模型生成的问题进行研究发现，在问题生成中过程中依然存在诸多问题，需要在以后的工作中进行改进。

（1）针对图神经网络的问题生成研究，本文认为可以从以下三个方面进一步进行改进：首先可以考虑利用更优的图神经网络捕获更多段落单词之间的语义结构信息。然后针对解码器部分，可以考虑结合多种解码策略改善重复的问题生成。最后，在未来研究如何有效解决不同时间步重复生成目标问题单词的问题。

中国知网 https://www.cnki.net

（2）针对预训练语言模型的问题生成，是未来自然语言处理领域备受关注的一种研究趋势。随着预训练语言模型在语义理解方面的不断增强，未来的问题生成研究将更加专注于提高模型对复杂语境和多义性的理解，以生成更准确、连贯的问题。同时，针对用户特定的需求，未来的研究可能会探索如何使预训练语言模型能够生成更具个性化、定制化的问题，以更好地服务不同用户群体。

（3）针对问题生成多样性和特殊性研究，在未来的工作中，应该使用指针生成网络、预训练模型和图神经网络嵌入，进一步改善问题生成的多样性和特殊性。同时，问题生成的多样性和特殊性主要应用于电子商务领域，应用范围比较狭隘。如何将其应用到教育领域，辅助教师识别教案信息中的缺失信息，是未来需要进行研究的一项重要课题。

（4）针对不同类型的问题生成，有着不同模块的功能，在未来如何确保问题生成的算法可以商业化，如何将自动生成填空式问题、自动生成多语义的问题以及自动生成多项选择题问题等多种问题生成算法有效结合，依然存在巨大的瓶颈，也是目前的一个挑战。

中国知网 https://www.cnki.net

参考文献

[1] Kathamuthu N D, Subramaniam S, Le Q H, et al. A deep transfer learning-based convolution neural network model for COVID-19 detection using computed tomography scan images for medical applications[J]. Advances in Engineering Software, 2023, 175: 103317.

[2] Rasappan P, Premkumar M, Sinha G, et al. Transforming sentiment analysis for e-commerce product reviews: Hybrid deep learning model with an innovative term weighting and feature selection[J]. Information Processing & Management, 2024, 61(3): 103654.

[3] Kukkar A, Mohana R, Sharma A, et al. Prediction of student academic performance based on their emotional wellbeing and interaction on various e-learning platforms[J]. Education and Information Technologies, 2023: 1-30.

[4] Zeng H, Zhi Z, Liu J, et al. Improving paragraph-level question generation with extended answer network and uncertainty-aware beam search[J]. Information Sciences, 2021, 571: 50-64.

[5] Song L, Wang Z, Hamza W, et al. Leveraging context information for natural question generation[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2018: 569-574.

[6] Tuan L A, Shah D, Barzilay R. Capturing greater context for question generation[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(05): 9065-9072.

[7] 崔少国, 王奥迪, 杜兴. 融合流注意力机制的中文摘要生成方法[J]. 小型微型计算机系统,2023: 1-8.

[8] 王骞, 雷景生, 唐小岚. 融合多层注意力表示的中文新闻文本摘要生成[J]. 计算机应用与软件, 2023, 40(10): 191-198.

[9] 于志强,余正涛,黄于欣,等.基于多策略原型生成的低资源神经机器翻译[J]. 软件学报, 2023, 34(11).

[10] 占思琦,徐志展,杨威,等.基于深度编码注意力的 XLNet-Transformer 汉-马低资源神经机器翻译优化方法[J]. 计算机应用研究, 2024, 41(03).

[11] 胡佩邑.检索式问答系统扩展问题的生成[J].北京邮电大学,2021.

[12] Jia X, Zhou W, Sun X, et al. Eqg-race: Examination-type question generation[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(14): 13143-13151.

[13] Du Y, Jin X, Yan R, et al. Sentiment enhanced answer generation and information fusing for product-related question answering[J]. Information Sciences, 2023, 627: 205-219.

[14] Zhu H, Togo R, Ogawa T, et al. Diversity Learning Based on Multi-Latent Space for Medical Image Visual Question Generation[J]. Sensors, 2023, 23(3): 1057.

[15] Shao T, Cai F, Chen W, et al. Self-supervised clarification question generation for ambiguous multi-turn conversation[J]. Information Sciences, 2022, 587: 626-641.

[16] Du X, Shao J, Cardie C. Learning to Ask: Neural Question Generation for Reading Comprehension[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics. 2017: 1342-1352.

[17] Song J, Kim S, Yoon S. AligNART: Non-autoregressive Neural Machine Translation by Jointly Learning to Estimate Alignment and Translate[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 1-14.

中国知网 https://www.cnki.net

[18] Zhou Q, Yang N, Wei F, et al. Neural question generation from text: A preliminary study[C]//Natural Language Processing and Chinese Computing: 6th CCF International Conference, NLPCC 2017, Dalian, China, November 8–12, 2017, Proceedings 6. Springer International Publishing, 2018: 662-671.

[19] Gülçehre Ç, Ahn S, Nallapati R, et al. Pointing the Unknown Words[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. 2016: 140-149.

[20] Zhao Y, Ni X, Ding Y, et al. Paragraph-level neural question generation with maxout pointer and gated self-attention networks[C]//Proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 3901-3910.

[21] Kim Y, Lee H, Shin J, et al. Improving neural question generation using answer separation[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 6602-6609.

[22] 段建勇, 徐丽闪, 刘杰, 等. 基于义原知识和双向注意力流的问题生成模型[J]. 数据分析与知识发现, 2022, 6(5): 44-53.

[23] Chen Y, Wu L, Zaki M J. Reinforcement Learning Based Graph-to-Sequence Model for Natural Question Generation[C]//International Conference on Learning Representations. 2020.

[24] 胡月, 周光有. 基于 Graph Transformer 的知识库问题生成[J]. 中文信息学报, 2022, 36(2): 111-120.

[25] Cai D, Lam W. Graph transformer for graph-to-sequence learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(05): 7464-7471.

[26] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 4171-4186.

[27] Fei Z, Zhang Q, Gui T, et al. CQG: A simple and effective controlled generation framework for multi-hop question generation[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. 2022: 6896-6906.

[28] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//International Conference on Learning Representations. 2018.

[29] Ma H, Wang J, Lin H, et al. Graph augmented sequence-to-sequence model for neural question generation[J]. Applied Intelligence, 2023, 53(11): 14628-14644.

[30] Guan M, Mondal S K, Dai H N, et al. Reinforcement learning-driven deep question generation with rich semantics[J]. Information Processing & Management, 2023, 60(2): 103232.

[31] 李亚峰,叶东毅,陈羽中.用于问题生成的知识增强双图交互网络[J]. 小型微型计算机系统, 1-9, 2023.

[32] Heilman M, Smith N A. Good question! statistical ranking for question generation[C]//Human language technologies: The 2010 annual conference of the North American Chapter of the Association for Computational Linguistics. 2010: 609-617.

[33] Zheng H T, Han J, Chen J, et al. A novel framework for automatic Chinese question generation based on multi-feature neural network model[J]. Computer Science and Information Systems, 2018, 15(3): 487-499.

[34] Cho J, Seo M, Hajishirzi H. Mixture Content Selection for Diverse Sequence Generation[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language

中国知网 https://www.cnki.net

Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 3121-3131.

[35] Wang Z, Rao S, Zhang J, et al. Diversify question generation with continuous content selectors and question type modeling[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. 2020: 2134-2143.

[36] Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.

[37] Pan Y, Hu B, Chen Q, et al. Learning to generate diverse questions from keywords[C]//ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 8224-8228.

[38] Rathod M, Tu T, Stasaski K. Educational multi-question generation for reading comprehension[C]//Proceedings of the 17th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2022). 2022: 216-223.

[39] Duan N, Tang D, Chen P, et al. Question generation for question answering[C]//Proceedings of the 2017 conference on empirical methods in natural language processing. 2017: 866-874.

[40] Guo H, Pasunuru R, Bansal M. Soft Layer-Specific Multi-Task Summarization with Entailment and Question Generation[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 687-697.

[41] Chali Y, Baghaee T. Automatic opinion question generation[C]//Proceedings of the 11th International Conference on Natural Language Generation. 2018: 152-158.

[42] Wu X, Jiang N, Wu Y. A Question Type Driven and Copy Loss Enhanced Frameworkfor Answer-Agnostic Neural Question Generation[C]//Proceedings of the Fourth Workshop on Neural Generation and Translation. 2020: 69-78.

[43] Zhang Z, Zhu K. Diverse and specific clarification question generation with keywords[C]//Proceedings of the Web Conference 2021. 2021: 3501-3511.

[44] Roitman H, Singer U, Eshel Y, et al. Learning to Diversify for Product Question Generation[J]. arXiv preprint arXiv:2207.02534, 2022.

[45] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. The Journal of Machine Learning Research, 2020, 21(1): 5485-5551.

[46] Rajpurkar P, Zhang J, Lopyrev K, et al. SQuAD: 100,000+ Questions for Machine Comprehension of Text[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. 2016: 2383-2392.

[47] Nguyen T, Rosenberg M, Song X, et al. Ms marco: A human-generated machine reading comprehension dataset[J]. 2016.

[48] McAuley J, Targett C, Shi Q, et al. Image-based recommendations on styles and substitutes[C]//Proceedings of the 38th international ACM SIGIR conference on research and development in information retrieval. 2015: 43-52.

[49] McAuley J, Yang A. Addressing complex and subjective product-related queries with customer reviews[C]//Proceedings of the 25th International Conference on World Wide Web. 2016: 625-635.

[50] Rao S, Daumé III H. Answer-based Adversarial Training for Generating Clarification Questions[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 143-155.

中国知网 https://www.cnki.net

[51] 凌雪. 基于端到端的问题生成方法研究[D]. 哈尔滨工业大学, 2020.

[52] 察胜男. 基于中文文本的多样化问题生成[D]. 山东大学, 2022.

[53] Wolfe J H. An Aid to Independent Study through Automatic Generation (Autoquest)[C]//SIGCSE. 1975, 76: 104-112.

[54] Fabbri A R, Ng P, Wang Z, et al. Template-Based Question Generation from Retrieved Sentences for Improved Unsupervised Question Answering[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 4508-4513.

[55] Mannem P, Prasad R, Joshi A. Question generation from paragraphs at UPenn: QGSTEC system description[C]//Proceedings of QG2010: The Third Workshop on Question Generation. 2010: 84-91.

[56] Kunichika H, Katayama T, Hirashima T, et al. Automated question generation methods for intelligent English learning systems and its evaluation[C]//Proc. of ICCE. 2004, 670.

[57] Lindberg D, Popowich F, Nesbit J, et al. Generating natural language questions to support learning on-line[C]//Proceedings of the 14th European Workshop on Natural Language Generation. 2013: 105-114.

[58] Mazidi K, Nielsen R. Linguistic considerations in automatic question generation[C]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2014: 321-326.

[59] Zhou W, Zhang M, Wu Y. Question-type Driven Question Generation[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 6032-6037.

[60] 易也难, 卞艺杰. 基于改进注意力机制的问题生成模型研究[J/OL]. 微电子学与计算机, 2022, 39(4): 49-57.

[61] 曾碧卿, 裴枫华, 徐马一, 等. 基于双注意力的段落级问题生成研究[J]. 中文信息学报, 2022, 36(8): 154-162+174.

[62] Wang Y, Zheng J, Liu Q, et al. Weak supervision enhanced generative network for question generation[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence. 2019: 3806-3812.

[63] 武恺莉, 朱朦朦, 朱鸿雨, 等. 结合问题类型及惩罚机制的问题生成[J]. 中文信息学报, 2021, 35(4): 110-119.

[64] Chan Y H, Fan Y C. BERT for question generation[C]//Proceedings of the 12th International Conference on Natural Language Generation. 2019: 173-177.

[65] Chan Y H, Fan Y C. A recurrent BERT-based model for question generation[C]//Proceedings of the 2nd workshop on machine reading for question answering. 2019: 154-162.

[66] Dong L, Yang N, Wang W, et al. Unified language model pre-training for natural language understanding and generation[J]. Advances in neural information processing systems, 2019, 32.

[67] Xiao D, Zhang H, Li Y, et al. ERNIE-GEN: an enhanced multi-flow pre-training and fine-tuning framework for natural language generation[C]//Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence. 2021: 3997-4003.

[68] Wang W, Wei F, Dong L, et al. Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers[J]. Advances in Neural Information Processing Systems, 2020, 33: 5776-5788.

[69] Qi W, Yan Y, Gong Y, et al. ProphetNet: Predicting Future N-gram for Sequence-to-SequencePre-

中国知网 https://www.cnki.net

training[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. 2020: 2401-2410.

[70] Lamba D, Hsu W H. Constraint-based Neural Question Generation using Sequence-to-Sequence and Transformer models for privacy policy documents[J]. International Journal of Knowledge Engineering, 2021, 7(2): 14-20.

[71] Chai Z, Wan X. Learning to ask more: Semi-autoregressive sequential question generation under dual-graph interaction[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 225-237.

[72] Huang Q, Fu M, Mo L, et al. Entity guided question generation with contextual structure and sequence information capturing[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(14): 13064-13072.

[73] Fei Z, Zhang Q, Zhou Y. Iterative GNN-based decoder for question generation[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 2573-2582.

[74] Kingma D P, Welling M. Auto-Encoding Variational Bayes.[C/OL]//2nd International Conference on Learning Representations, ICLR 2014, Banff, AB, Canada, April 14-16, 2014, Conference Track Proceedings. 2014. http://arxiv.org/abs/1312.6114.

[75] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.

[76] Wang W, Feng S, Wang D, et al. Answer-guided and semantic coherent question generation in open-domain conversation[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 5066-5076.

[77] Lee D B, Lee S, Jeong W T, et al. Generating Diverse and Consistent QA pairs from Contexts with Information-Maximizing Hierarchical Conditional VAEs[C]//58th Annual Meeting of the Association-for-Computational-Linguistics (ACL). ACL, 2020: 208-224.

[78] Li J, Qi P, Luo H. Generating consistent and diverse qa pairs from contexts with bn conditional vae[C]//2022 IEEE 25th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2022: 944-949.

[79] Bao J, Gong Y, Duan N, et al. Question generation with doubly adversarial nets[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2018, 26(11): 2230-2239.

[80] Hosking T, Riedel S. Evaluating Rewards for Question Generation Models[C]//Proceedings of NAACL-HLT. 2019: 2278-2283.

[81] Xie J, Fang W, Huang Q, et al. Enhancing Paraphrase Question Generation With Prior Knowledge[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022.

[82] Papineni K, Roukos S, Ward T, et al. Bleu: a method for automatic evaluation of machine translation[C]//Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002: 311-318.

[83] Banerjee S, Lavie A. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments[C]//Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization. 2005: 65-72.

[84] Lin C Y. Rouge: A package for automatic evaluation of summaries[C]//Text summarization branches out. 2004: 74-81.

[85] Li J, Galley M, Brockett C, et al. A Diversity-Promoting Objective Function for Neural

中国知网 https://www.cnki.net

Conversation Models[C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2016: 110-119.

[86] 乔振浩, 车万翔, 刘挺. 基于问题生成的知识图谱问答方法[J]. 智能计算机与应用, 2020, 10(5): 1-5.

[87] 陈锡, 陈奥博. 基于掩码矩阵-BERT 注意力机制的神经机器翻译[J/OL]. 现代电子技术, 2023, 46(21): 111-116. DOI:10.16652/j.issn.1004-373x.2023.21.021.

[88] 王灿宇, 孙晓海, 吴叶辉, 等. 基于 Deep Q-Learning 的抽取式摘要生成方法[J/OL]. 吉林大学学报(信息科学版), 2023, 41(2): 306-314.

[89] 陈佳玉, 王元龙, 张虎. 基于文本知识增强的问题生成模型[J/OL]. 计算机工程: 1-13.

[90] 徐坚. 语义图支持的阅读理解型问题的自动生成[J]. 智能系统学报: 1-9.

[91] 庞泽雄, 张奇. 基于佐证图神经网络的多跳问题生成[J]. 中文信息学报, 2022, 36(5): 94-101.

[92] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing. 2014: 1532-1543.

[93] Chung J, Gulcehre C, Cho K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[C]//NIPS 2014 Workshop on Deep Learning, December 2014. 2014.

[94] Kawakami K. Supervised sequence labelling with recurrent neural networks[D]. Technical University of Munich, 2008.

[95] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[96] Kingma D P, Salimans T, Welling M. Variational dropout and the local reparameterization trick[J]. Advances in neural information processing systems, 2015, 28.

[97] Su, Y., Lan, T., Wang, Y., Yogatama, D., Kong, L., & Collier, N. (2022). A contrastive framework for neural text generation. Advances in Neural Information Processing Systems, 35, 21548-21561.

[98] Kumar, A., Vembu, S., Menon, A. K., & Elkan, C. (2013). Beam search algorithms for multilabel learning. Machine learning, 92, 65-89.

[99] Atif, F., El Khatib, O., & Difallah, D. (2023, July). Beamqa: Multi-hop knowledge graph question answering with sequence-to-sequence prediction and beam search. In Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (pp. 781-790).

[100] Vijayakumar, A., Cogswell, M., Selvaraju, R., Sun, Q., Lee, S., Crandall, D., & Batra, D. (2018). Diverse beam search for improved description of complex scenes. In Proceedings of the AAAI Conference on Artificial Intelligence. 32, 1.

[101] Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2019). The Curious Case of Neural Text Degeneration. In International Conference on Learning Representations.

[102] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI blog, 1(8), 9.

[103] Fan, A., Lewis, M., & Dauphin, Y. (2018). Hierarchical Neural Story Generation. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. pp. 889-898.

[104] Romero-Medrano, L., Moreno-Muñoz, P., & Artés-Rodríguez, A. (2020). Multinomial sampling for hierarchical change-point detection. In 2020 IEEE 30th International Workshop

中国知网 https://www.cnki.net

on Machine Learning for Signal Processing. pp. 1-6.

[105] Grover, K., Kaur, K., Tiwari, K., Rupali, & Kumar, P. (2021). Deep learning based question generation using t5 transformer. In Advanced Computing: 10th International Conference, IACC 2020, Panaji, Goa, India, December 5–6, 2020, Revised Selected Papers, pp. 243-255.

[106] Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., ... & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. pp. 7871-7880.

[107] Ushio, A., Alva-Manchego, F., & Camacho-Collados, J. (2022). Generative Language Models for Paragraph-Level Question Generation. In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. pp. 670-688.

[108] Ushio, A., Alva-Manchego, F., & Camacho-Collados, J. (2023). An Empirical Comparison of LM-based Question and Answer Generation Methods. In Findings of the Association for Computational Linguistics: ACL 2023. pp. 14262–14272.

[109] Yuan X, Wang T, Gülçehre Ç, et al. Machine Comprehension by Text-to-Text Neural Question Generation[C]//Proceedings of the 2nd Workshop on Representation Learning for NLP. 2017: 15-25.

[110] Reimers N, Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Association for Computational Linguistics, 2019.

[111] Rao S, Daumé III H. Learning to Ask Good Questions: Ranking Clarification Questions using Neural Expected Value of Perfect Information[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. 2018: 2737-2746.

[112] Shen T, Ott M, Auli M, et al. Mixture models for diverse machine translation: Tricks of the trade[C]//International conference on machine learning. PMLR, 2019: 5719-5728.

中国知网 https://www.cnki.net